

华南理工大学
本科毕业设计（论文）

面向高效推理的大语言模型键值缓存行为对齐
量化框架

学 院： 吴贤铭智能工程学院
专 业： 智能制造工程
学生姓名： 陈梓浪
学生学号： 202264642457
指导教师： 曾子倩
提交日期： 2026 年 6 月

华南理工大学 学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

作者签名：_____ 日期：_____年____月____日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保存并向国家有关部门或机构送交论文的复印件和电子版，允许学位论文被查阅；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。本人电子文档的内容和纸质论文的内容相一致。

作者签名：_____ 日期：_____年____月____日

指导教师签名：_____ 日期：_____年____月____日

摘要

随着大语言模型长上下文推理窗口不断扩大，自回归推理过程中键值缓存的显存占用大幅增长。在真实部署场景中，解码瓶颈不仅仅出现在计算负载上，同时也转向持续增长的 KV Cache 存储与访存开销。降低缓存位宽能够直接减少显存占用，但因为 Key 侧扰动可能经 logits 与 softmax 改写注意力分布，Value 侧扰动通过加权聚合影响输出表示，现有量化路径常用的张量级重建误差校准并不一定能充分展示量化缓存进入注意力计算后的功能偏移。基于这一传播差异，本文提出一种面向高效推理的 KV Cache 行为对齐量化框架，将注意力分布、聚合输出与任务表现作为共同的校准和审计对象，连接量化参数选择、低比特恢复和层间预算分配三个决策环节。

本文先使用校准样本并行评估全精度参考配置与候选量化配置，记录 attention-distribution KL 与注意力聚合输出扰动两类保真读数，用于筛选量化校准参数，将下游任务读数作为任务层面的审计依据保留。校准阶段得到的逐层读数进一步汇总为层级行为敏感度，用于后续层间预算分配。在固定 k 预算下，本文将行为引导分配与位置启发式基线纳入同一比较口径。提出自动预算建议 AutoK，根据敏感度排序和覆盖率阈值生成模型级 k 候选。这样，同一套离线行为读数同时服务于保真校准、低比特行为恢复和预算候选生成，使量化路径与层间预算建议形成连续证据链。

实验覆盖 Qwen2.5、LLaMA-3.1 与 Mistral 三个模型族的六个开源指令模型，结果显示 KV Cache 量化和预算分配都具有明显的模型族、规模和任务依赖性。INT8 基准路径在 Qwen2.5-1.5B 的 task-core 协议中与 FP16 的三任务均值差约为 +0.02，说明行为引导校准在保守位宽下能够保持稳定保真。进入 INT4 后，对称量化在 Qwen 系列中出现检索阶跃崩塌，K/V 角色诊断进一步表明 Key 侧低比特噪声是更直接的失稳触发源。本文采用角色感知低比特路径将检索行为恢复到可用区间。跨模型预算实验显示，Mistral-7B 提供最清晰的 AutoK 单模型支持，Qwen2.5-3B 对应早层保护有效区间，LLaMA-3.1-8B 呈现中等规模共识区间，Qwen2.5-14B 则表现为高性能簇接近而无稳定最优。INT4 路径可带来约 73.4% 的 KV Cache 容量压缩，但融合解码的时间收益仍受 H_{kv} 、序列长度和后端实现共同影响。总体而言，本文验证了一条以注意力行为保持为核心、以 K/V 角色差异恢复为低比特路径、以 AutoK 和行为敏感度画像为预算接口的 KV Cache 行为对齐量化框架。

关键词：大语言模型；KV Cache 量化；注意力行为保持；低比特推理；行为引导校准；预算分配

Abstract

As long-context inference expands, the KV cache in autoregressive decoding grows linearly with sequence length, shifting the deployment bottleneck from computation toward cache storage and memory access. Reducing cache bit-width directly lowers memory footprint, but tensor-level reconstruction error is an incomplete proxy once the quantized cache enters attention. Key-side perturbations can reshape logits and softmax attention distributions, while Value-side perturbations mainly affect output representations through weighted aggregation. This thesis proposes a behavior-aligned KV-cache quantization framework for efficient inference, using attention distributions, aggregation outputs, and task behavior as shared calibration and auditing targets across quantization-parameter selection, low-bit recovery, and layer-wise budget allocation.

The framework first builds an INT8 baseline path calibrated by attention-distribution KL, which serves as a conservative fidelity anchor for behavior-guided calibration. It then introduces INT4-RoleAlign, an asymmetric per-channel Key and per-token Value format that separates Key-side attention-ranking shifts from Value-side output perturbations. The same offline calibration artifacts are summarized into layer-wise behavioral sensitivity profiles and reused by behavior-guided fixed- k allocation, positional heuristic comparisons, and AutoK coverage-based budget proposals. Calibration, low-bit recovery, and budget selection are therefore connected by one continuous evidence chain.

Experiments on six open-source instruction models from the Qwen2.5, LLaMA-3.1, and Mistral families show clear family-, scale-, and task-dependent behavior. The INT8 path keeps task readings close to FP16, supporting attention-distribution KL as a stable calibration proxy under conservative bit-width. In INT4 settings, symmetric quantization mainly fails through Key-side low-bit noise that enters the more sensitive attention-ranking path; with the role-aware Key/Value format, low-bit retrieval behavior returns to a usable regime. Cross-model allocation further shows that layer-wise sensitivity has no universal shape. AutoK translates sensitivity profiles into model-level budget candidates and works best when the profile structure is clear, while early-layer protection, positional heuristics, and uniform allocation each occupy different applicability regimes. System measurements show predictable INT4 cache-capacity gains, whereas fused-decode speedups depend on H_{kv} , sequence length, and backend implementation. Overall, this thesis provides a behavior-aligned KV-cache quantization framework centered on attention-behavior preservation, K/V role-aware low-bit recovery, and AutoK-based budget allocation.

Keywords: large language models, KV-cache quantization, attention-behavior preservation, low-bit inference, behavior-guided calibration, budget allocation

目录

摘要	i
Abstract	ii
目录	iii
第一章 绪论	1
1.1 研究背景	1
1.2 问题定义与研究动机	2
1.3 国内外研究现状概述	3
1.4 核心假设与研究问题	4
1.5 研究内容、技术路线与主要贡献	5
1.6 论文结构安排	6
第二章 相关工作与技术基础	7
2.1 Transformer 架构与自注意力机制	7
2.2 KV Cache 机制与显存分析	8
2.3 模型量化技术基础	9
2.4 KV Cache 量化与高效推理相关工作	11
2.5 研究空白与本文定位	14
2.6 本章小结	15
第三章 行为引导量化框架设计	16
3.1 注意力近似误差的代数分解与问题形式化	16
3.2 动机诊断: K/V 敏感性不对称及其设计启示	17
3.3 行为引导量化框架总览	19
3.4 行为引导校准目标与参数搜索策略	21
3.5 跨位宽量化路径的实例化设计	25
3.6 行为敏感度驱动的层间预算分配与 AutoK	30
3.7 系统级部署实现与开销分析	37
3.8 本章小结	42
第四章 实验评估与策略适用区间分析	44

4.1	实验设置与可信性声明	44
4.2	行为引导校准的保真度验证	47
4.3	低比特路径从对称失效到 RoleAlign 恢复	49
4.4	跨模型预算分配与策略适用区间	55
4.5	部署效率评估	61
4.6	实验结果讨论与效度威胁	65
4.7	本章小结	69
结论		71
5.1	研究结论	71
5.2	创新点与学术价值	72
5.3	研究局限性	73
5.4	未来工作展望	74
5.5	结语	74
参考文献		76
附录 A 补充材料		81
A.1	评测协议、环境与复现入口	81
A.2	量化路径与复现配置类别	82
A.3	校准产物与搜索空间审计	82
A.4	LongBench、统计检验与质量趋势补充材料	84
A.5	部署效率与批处理扩展补充	85
A.6	INT4 失稳机制与评估粒度边界补充	86
A.7	K/V 精度消融与 MixedKV 跨模型补充数据	91
A.8	逐头温度校正诊断与 7B 校准目标溯源	91
A.9	Triton 融合核函数变体说明	92
A.10	Prompt-Adaptive Selector 探索性补充 (future-work 起点)	93
致谢		95

第一章 绪论

1.1 研究背景

长上下文推理把大语言模型的部署压力集中到解码阶段。LLaMA 3^[1]、Qwen2.5^[2] 等模型已经能够处理更长输入,但在自回归生成中,每个新 token 都要访问此前累积的缓存。部署压力可以具体化为上下文长度和服务并发同步上升时,如何降低 Decode 阶段反复读取 KV Cache 所带来的访存开销。

Transformer^[3] 自回归解码的计算路径决定了这一压力。第 t 个生成步只新增当前位置的 Query、Key 和 Value,但注意力仍需访问前 S 个历史位置的 Key/Value。KV Cache 避免了重复执行历史 K/V 投影,却把缓存容量与访存带宽变成每个 decode step 都要面对的约束。也就是说,缓存不只在 prefill 后静态占用显存,还在后续 token 生成中持续参与注意力计算。

从存储结构上看, KV Cache 的显存占用与模型层数、每层 KV 头数、头维度、序列长度以及存储位宽近似成正比,可写为

$$M_{KV} = 2 \times L \times H_{kv} \times d_k \times S \times b \quad (1-1)$$

其中 L 、 H_{kv} 与 d_k 由模型结构给定, S 对应上下文长度, b 对应缓存元素的存储字节数,系数 2 来自 Key 与 Value 两部分。本文使用式 (1-1) 固定后续实验变量: 模型结构决定基础缓存形状,序列长度与 batch size 决定部署压力,量化位宽直接改变 b ,而预算分配方法则决定哪些层或角色保留更高精度。在长上下文和批量推理场景下,这一开销会随上下文长度与并发批次同步放大。vLLM^[4] 等推理框架通过分页注意力 (PagedAttention) 改善显存碎片和缓存管理效率,但这类方法并不直接减少 KV Cache 的绝对存储量。

因此, KV Cache 量化的系统价值首先来自它直接作用于存储位宽所对应的 b 。在只计算 Key/Value 缓存元素本体时, FP16 每个元素占 2 bytes, INT8 将其降为 1 byte,对应缓存容量约减半; INT4 进一步将单元素存储压到 4 bits,理想情况下只保留 FP16 的 1/4 缓存字节数。考虑 scale、zero-point、打包格式和运行接口后,第四章系统评估中 INT4 路径在代表性模型上仍实现约 73.4% 的 KV Cache 容量压缩。本文把 Decode 阶段缓存字节数、注意力行为稳定性和任务读数放在同一套实验口径下比较,区分存储位宽下降带来的容量收益与低比特扰动进入注意力计算后的功能后果。

1.2 问题定义与研究动机

在上述背景下，KV Cache 量化的价值首先来自直接的存储压缩。INT8 可以作为较保守的保真基线，更低位宽则能进一步释放显存空间，支持更长上下文或更高并发。但缓存压缩不能只按 bit 数下降来理解：位宽降低以后，Key 与 Value 的扰动会进入注意力计算，并可能改变检索、摘要和语言建模等任务行为。本文后续以 INT4 作为低比特压力点，正是因为这一设置会更清楚地暴露 Key/Value 角色差异和模型间敏感度差异；后文的 Qwen 与 LLaMA 对照会把这种差异落到 K4V8/K4V4 等布局上。

当前 KV Cache 量化的校准目标仍多落在数值重建误差上，常见做法包括 MSE 损失和基于分位数的裁剪。这类方法通常沿用一个工作前提，即张量越接近原值，模型行为也越接近全精度路径。进入注意力计算后，这一前提并不总是成立：softmax 的非线性可能把较小的 Key 扰动转化为注意力概率的明显变化，而某些数值上更大的误差也可能在归一化中被部分吸收。因此，张量误差大小很难与下游功能偏移建立稳定的一一对应关系；层、头和上下文位置带来的分布差异，也会进一步削弱静态阈值的解释力。

KV Cache 量化的困难并不只是继续调节超参数或降低重建误差。误差进入注意力计算以后，推理过程中实际暴露出来的是行为偏移，而不是孤立的张量差值。具体来看，这种偏移会体现为注意力分布是否被重排、聚合输出是否偏离，以及任务行为是否随之改变。长上下文和低比特设置会让这种差异更加突出；同一量级的数值扰动，出现在不同层、不同注意力头，或不同缓存角色中时，可能产生截然不同的后果。因此，单纯追求全局数值误差最小，不一定能保证模型在推理时保持稳定和可用。

这使本文把观察对象从单纯的张量近似扩展到推理行为本身：KV Cache 量化在保持重建精度之外，还需要尽量维持注意力分布、聚合输出和任务表现的稳定。我们认为量化后注意力分布是否发生重排、这种重排是否继续影响输出与任务结果，是更本质，更贴近推理可用性的观察依据。后续关于校准目标、量化路径和预算分配的讨论，也以这些行为读数作为共同依据。

为避免“行为”停留在抽象表述，本文将注意力行为操作化为三类可观测测量：其一是量化前后注意力分布的偏移，用于刻画检索和排序关系是否被扰动；其二是加权聚合输出的变化，用于刻画 Value 信息进入残差流后的表示偏移；其三是语言建模、检索和长文档任务上的表现变化，用于检验上述扰动是否传导到任务层面。进一步地，本文所说的行为敏感度画像，

是指由离线校准与诊断读数聚合得到的逐层相对敏感度，用于回答哪些层或角色应被优先保护；策略适用区间则指在特定模型家族、规模、任务和预算条件下，不同预算策略进入高性能区域的条件范围。

基于这一问题意识，下一节做必要的相关研究定位：已有工作分别回答低比特表示、缓存压缩格式和系统执行效率问题，而本文要探讨的问题是量化缓存进入注意力计算后如何保持推理行为。

1.3 国内外研究现状概述

围绕长上下文推理与 KV Cache 压缩，现有研究主要回答三个相邻但不同的问题。模型量化研究提供低比特表示、校准与误差控制的基础方法；KV Cache 专属量化直接处理缓存存储压力；高效推理系统则从注意力计算和缓存管理角度降低部署开销。三条路线的交集说明，长上下文部署由压缩精度、缓存组织和系统执行共同决定。

模型量化方向已有工作为低比特表示、训练后量化和校准策略提供了基础工具。SmoothQuant^[5] 通过迁移激活中的量化难点缓解推理部署压力，GPTQ^[6] 从近似误差补偿角度提高权重量化后的保真度，AWQ^[7] 则利用激活感知信息保护更关键的通道。它们的主要对象仍是模型权重与激活，而不是解码过程中持续增长的 KV Cache；不过，量化表示、误差控制和校准流程这些基本思想，仍构成本文处理缓存压缩问题时可以复用的方法背景。

KV Cache 专属量化的关注点从静态参数和前向过程中的瞬时激活转到解码过程中持续累积的缓存状态。长上下文推理 KV Cache 的显存占用随序列长度增长，缓存读写带来持续的带宽压力，Key 与 Value 的统计差异提示同质化压缩格式可能不足以覆盖二者差异。KIVI^[8] 以 K/V 分布差异和异构量化轴为设计依据，KVQuant^[9] 围绕极低比特缓存表示引入非均匀码本、Pre-RoPE Key 量化与异常值处理，ZipCache^[10] 则沿 token 重要性组织差异化缓存压缩。这些工作从不同角度表明，KV Cache 压缩需要引入区别于权重或激活量化的设计约束。本文进一步追问，Key 侧扰动经由 attention scores 和 softmax 改变权重分配、Value 侧扰动经由加权聚合影响输出表示后，校准目标与格式选择应由哪些行为信号来检验，又应受哪些边界条件约束。

相关系统优化也在缓解长上下文部署压力。FlashAttention^[11,12] 通过分块注意力计算减少中间结果访存，分页注意力^[4] 则借助缓存分页缓解显存碎片并提高缓存利用率。这些系统层优化与 KV Cache 量化并不冲突，而是

作用在不同层面。系统优化改善注意力执行和缓存管理，量化则降低缓存表示本身的存储成本。在 decode 阶段，低位宽 K/V 仍要参与注意力计算，并引入反量化、解包、GQA 头映射和后端实现开销。本文关注的是，压缩后的 KV Cache 在 decode 注意力执行路径中是否仍能保持可用的推理行为。

现有研究已经从模型量化、KV Cache 专属压缩与高效推理等角度推进了长上下文部署，但这些路线解决的层面并不相同。本文的切入点是 KV Cache 量化中的行为保持问题：量化后的缓存不仅要占用更少显存，还要在注意力计算中保持可用的推理行为。下面的研究问题从这一观察出发，而不是预设某一种量化格式或预算策略会在所有模型上占优。

1.4 核心假设与研究问题

KV Cache 量化的核心难点不只是继续提高压缩率，而是如何在压缩后保持模型的实际推理行为。本文把注意力行为作为分析起点，关注量化后注意力分布、聚合输出和任务表现是否仍与全精度路径保持一致。

核心假设：在 KV Cache 量化中，注意力行为比张量重建误差更接近模型实际功能损伤。本文关心量化后注意力分布是否保持稳定、加权聚合输出是否偏离，以及这些变化是否影响任务行为。基于这一假设，校准目标和预算分配可以共享同一个观察对象，而不必被拆成彼此孤立的局部问题。

研究问题 1：注意力行为能否作为 KV Cache 量化的统一对象？KV Cache 量化需要保持的，到底只是张量层面的重建精度，还是还包括注意力分布、聚合输出和任务行为的稳定性？如果后者能够成立，它应当同时支撑基准校准、低比特恢复和预算分配三类讨论，而不是只解释某一个局部设置。

研究问题 2：行为引导校准能否形成稳定的 INT8 基准路径？在 INT8 这一较保守、便于审计的位宽下，以注意力行为为导向的校准能否建立一条相对 FP16 任务行为偏差可控的基准路径？这一路径也为后续低比特探索和系统落地提供相对稳定的参照。

研究问题 3：行为敏感度画像能否支撑跨模型预算分配？校准链路产生的行为敏感度画像，能否在不同模型家族、不同规模和不同任务条件下读出可区分的策略适用区间？本文关注的是这些条件如何改变预算策略的有效范围，而不是给出一种脱离条件的单点配置。

研究问题 4：固定预算选择是否需要画像驱动自动建议？手工固定 k 的预算 sweep 在跨模型迁移中是否会暴露不稳定性？同源敏感度画像能否被转写为 AutoK 预算建议，从而减少手工选择带来的偶然性？本文把 AutoK

放在 allocation 的自动化扩展位置；它的经验作用由第四章的跨模型读数限定。

围绕上述核心假设与四个问题，下一节将进一步概述本文的研究内容、技术路线与主要贡献。

1.5 研究内容、技术路线与主要贡献

围绕前述核心假设与四个问题，本文将 KV Cache 量化组织为一条以注意力行为为主线的研究路径。校准层回答如何选择量化参数，低比特路径回答如何在更激进的压缩下保持可用，分配层回答有限预算应优先保护哪些层或角色，预算建议层回答固定 k 是否需要画像驱动自动建议。

本文从注意力行为视角重新组织 KV Cache 量化问题，用更贴近模型实际推理效果稳定性的校准对象连接不同层级的量化决策；在此基础上，围绕不同位宽形成可执行的方法实例，并通过跨模型比较提炼策略适用区间。本文据此追问：校准、低比特实例和预算分配能否被同一组行为读数解释，而不把贡献限定在某个局部设置的压缩收益上。

后续章节按问题链条展开。第二章梳理模型量化、KV Cache 压缩和高效推理系统中与本文直接相关的工作，说明本文与这些研究路线的承接关系。第三章进入方法设计，定义行为代理，并给出路径实例与预算分配机制。第四章通过实验结果考察 INT8 基准保真、低比特恢复、跨模型结构差异和 AutoK 预算建议。第五章收束全文，归纳贡献、适用范围与后续扩展空间。

以注意力行为保持重新界定 KV Cache 量化对象。本文把量化后的缓存视为注意力计算路径中的行为载体，关注它在行为层面呈现的三类可观测变化，包括注意力分布变化、Value 聚合后的输出表示偏移，以及任务表现波动。这组行为证据在校准层用于选择量化参数，在预算分配层用于判断哪些层或角色更需要保护。

建立从 INT8 基准路径到低比特恢复的可复核实例链。INT8 基准路径先在保守位宽下提供保真参照，检验行为引导校准能否在受控设置中维持接近全精度的任务表现。进入低比特位宽后，INT4-RoleAlign 把 Key 参与注意力排序、Value 参与输出聚合的角色差异纳入诊断过程，用 K/V 角色对照支撑失稳分析与路径实例。AutoK 复用同源行为敏感度画像，生成预算建议。Triton^[13] kernel、离线校准产物和在线推理管线属于系统支撑层，负责当前实验协议下的执行接口与复核入口。

识别跨模型预算策略的适用区间。第四章第 4.4 节把跨模型分配结果放在同量级 INT4 预算带内比较，表 4-9 使用 NarrativeQA、HotpotQA 与 GovReport 的三任务均值，图 4-5 用每行最高落点与达到该行最佳值 97% 以上的近簇标出各模型的高性能区间。相关结论只对应本文测试的模型族、参数规模和任务组合，不外推为统一策略排名。heuristic 在多个被测试组合中表现为强基线；当保护层集合偏离高敏感层时，本文剖面结果也观察到质量下降。AutoK 在这里承担模型级预算候选生成器角色，而不是跨模型统一最优规则。早层保护、高性能簇共存等现象，由表 4-10、表 4-11 和适用区间图共同限定其成立范围。

上述内容与四个问题对应：先确认注意力行为是否足以组织 KV Cache 量化，再建立 INT8 保真锚点；低比特恢复用于检验同一对象在更激进位宽下是否仍能指导路径实例，随后跨模型预算分配与 AutoK 建议共同回答画像读数能否进入预算决策。

1.6 论文结构安排

全文按上述问题展开。第一章界定 Decode 阶段 KV Cache 压力、行为保持假设和四个研究问题。第二章说明 Transformer、KV Cache、量化与高效推理中哪些已有结论可直接复用，哪些问题仍未覆盖缓存扰动后的注意力行为。第三章给出行为代理、INT8 基准路径、INT4-RoleAlign 和预算分配接口。第四章给出基准保真、低比特恢复、跨模型策略和 AutoK 预算建议的实验证据，并把部署效率读数作为系统边界而非单独的加速宣称。第五章收束贡献、适用范围和未覆盖的任务与部署条件。

第二章 相关工作与技术基础

本章梳理本文所依赖的模型结构、缓存机制、量化方法与高效推理研究，并据此界定后续工作的论证边界。第 2.2 节把 decoder-only Transformer、GQA/MQA 与 KV Cache 显存公式连接到本文后续控制的变量：序列长度、 H_{kv} 、bit-width 与 Decode 阶段访存压力。随后，本章讨论量化格式、校准代理、KV Cache 压缩与高效推理工作，并说明本文为何把注意力行为保持作为连接校准、低比特恢复和预算分配的对象。

2.1 Transformer 架构与自注意力机制

本文在 decoder-only Transformer 的因果自注意力设定下给出后文使用的基本公式。给定输入序列的隐藏状态矩阵 H ，Query、Key 和 Value 由三组线性投影得到：

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V \quad (2-1)$$

当前步注意力由缩放点积、softmax 与 Value 聚合组成：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \quad (2-2)$$

其中 d_k 为 Key 的头维度。因果掩码使当前位置只能访问历史 token；因此，后文需要跟踪的是历史 K/V 的存储规模、访问方式以及量化后对 softmax 排序和聚合输出的影响。

多头注意力（Multi-Head Attention, MHA）把 Q 、 K 和 V 沿头维度拆分后并行计算，再在输出端拼接：

$$\begin{aligned} \text{MHA}(Q, K, V) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h) W_O, \\ \text{head}_i &= \text{Attention}(Q_i, K_i, V_i) \end{aligned} \quad (2-3)$$

其中 W_O 为输出投影矩阵。这里保留 MHA 记号，是为了区分查询头数 H_q 与实际缓存的 KV 头数 H_{kv} 。

在标准 MHA 中， $H_q = H_{kv}$ 。多查询注意力（Multi-Query Attention, MQA）^[14] 令多个 Query 头共享单一 KV 头；分组查询注意力（Grouped Query Attention, GQA）^[15] 将 H_q 个查询头划分为若干组，每 H_q/H_{kv} 个 Query 头共享一组 K/V 头。因此，当 $H_{kv} < H_q$ 时，缓存字节数随实际 KV 头数下

降，而 Decode kernel 也需要处理 Q 头到 KV 头的映射关系。后文的显存公式、低比特格式和 TPOT 边界都使用这一变量。

2.2 KV Cache 机制与显存分析

2.2.1 KV Cache 的作用与工作原理

在 Decoder-only Transformer 的自回归推理过程中，当前步只新生成一个 Query，但这个 Query 仍要访问全部历史 Key，并用相应 Value 聚合上下文信息。若每一步都重新计算历史 Key/Value，重复投影会随历史长度累积；实际推理系统因此把各层历史词元对应的 Key 和 Value 保存在显存中，并在后续解码步直接读取，这一机制即为 KV Cache。

本文关心的瓶颈主要发生在 Decode 阶段。Prefill 一次性处理完整提示词序列，并行度较高；Decode 每步只处理一个新词元，却必须读取随上下文长度线性增长的历史 K/V 。因此，后文报告 TPOT、融合 Decode 路径和 H_{kv} 交叉边界时，本文具体追踪每个 Decode 步要搬运多少缓存字节，以及如何利用低比特格式减少这部分访存负担。

2.2.2 KV Cache 显存占用分析

对于包含 L 层的 Transformer 解码器，若每层保存 H_{kv} 个 Key/Value 头，每个头的维度为 d_k ，序列长度为 S ，单个缓存元素占用 b 字节，则 KV Cache 的总显存占用可写为

$$M_{KV} = 2 \times L \times H_{kv} \times d_k \times S \times b. \quad (2-4)$$

其中，系数 2 对应 Key 与 Value 各占一份缓存；这里默认每头满足 $d_v = d_k$ 。 L 表示层数， H_{kv} 表示每层实际参与缓存的 KV 头数， d_k 表示头维度， S 表示序列长度， b 表示单元字节数，例如 FP16、INT8 与 INT4 分别对应 2、1 和 0.5。结合上一节的 MHA、MQA 与 GQA 结构可知，缓存规模由共享后的 H_{kv} 决定，而不是由查询头数 H_q 决定：当模型从标准 MHA 过渡到 MQA 或 GQA 时， H_{kv} 的降低会直接减少缓存存储需求，这也是不同模型在长上下文部署成本上出现显著差异的重要结构原因之一。

以 Qwen2.5-7B-Instruct 为例，其可取 $L = 28$ 、 $H_{kv} = 4$ 、 $d_k = 128$ 。当序列长度 $S = 32768$ ，并采用 FP16 存储（即 $b = 2$ ）时，单个请求的 KV

Cache 显存占用为

$$M_{KV} = 2 \times 28 \times 4 \times 128 \times 32768 \times 2 \approx 1.75 \text{ GiB}. \quad (2-5)$$

这一数值仅对应 KV Cache 本身的存储，不包含模型权重、激活峰值与其他运行时开销；但在 32K 乃至更长上下文场景下，单请求缓存占用已经足以影响最大并发数与可服务长度。式 (2-4) 也给出后文实验变量的来源： H_{kv} 用于解释不同 GQA 结构的缓存压力， S 用于解释长上下文下的 Decode 访存放大， b 则是量化方法直接干预的字节数。下一节介绍本文使用的量化工具。

2.3 模型量化技术基础

量化将浮点张量映射为低比特整数表示，其直接效果是降低每个元素的存储字节数。本文重点讨论推理期不断增长的 KV Cache；因此，后文只保留三类会进入方法设计的概念：对称量化作为保守基准，非对称量化作为 K/V 角色差异的探究起点，校准代理作为离线选择量化参数的依据。

2.3.1 对称量化

对称量化将浮点数值映射到以零为中心的均匀整数网格上。给定浮点张量 x 与目标比特宽度 n ，其缩放因子 (scale) 可写为

$$s = \frac{\max(|x|)}{2^{n-1} - 1}. \quad (2-6)$$

在此基础上，量化映射与反量化过程分别为

$$x_q = \text{clamp}\left(\text{round}\left(\frac{x}{s}\right), -(2^{n-1} - 1), 2^{n-1} - 1\right), \quad \hat{x} = x_q \cdot s. \quad (2-7)$$

由此得到的近似值 $\hat{x}$ 与原始值 x 之间存在量化误差，记为 $\epsilon = x - \hat{x}$ 。本文把对称量化作为基线格式，它实现时不需要额外处理非零 zero-point，零点也自然落在原点上。后文使用 INT8 和对称 INT4 时，二者承担的检查任务不同。INT8 位宽较保守，用来检查行为校准、离线参数和在线执行路径能否稳定闭环；对称 INT4 提供更强的低比特压力，用来观察位宽继续压低后注意力行为最先在哪里失稳。二者的差别首先体现在整数网格。INT8 对称量化使用 $[-127, 127]$ 的整数范围，共有 255 个离散等级；对称 INT4 只保留

$[-7, 7]$, 对应 15 个离散等级, 离散等级数量约相差 17 倍。只按 K/V 主数据的 bit-packed 载荷计算时, INT4 可将两个 4 位整数写入同一个字节, 使 KV Cache 占用约为 FP16 的 $1/4$; 实际系统还会受到 scale、metadata 和对齐开销影响。这种存储占用降低只有在注意力分布、聚合输出和任务行为仍可保持时才有意义。若这些行为已经明显偏离, 低位宽缓存即使节省显存, 也难以作为有效的推理路径。因此, 后文先用 INT8 验证行为引导校准和执行路径的稳定性, 确定可行后, 再用对称 INT4 暴露 Key 侧位宽降低可能触发的功能断点, 把容量收益和行为可用性分开判断。

2.3.2 非对称量化

非对称量化通过引入零点偏移来处理非零中心的数值分布。给定浮点张量 x 与目标比特宽度 n , 其缩放因子与零点可定义为

$$s = \frac{\max(x) - \min(x)}{2^n - 1}, \quad z = \text{clamp}\left(\text{round}\left(-\frac{\min(x)}{s}\right), 0, 2^n - 1\right). \quad (2-8)$$

相应的量化映射与反量化过程为

$$x_q = \text{clamp}\left(\text{round}\left(\frac{x}{s}\right) + z, 0, 2^n - 1\right), \quad \hat{x} = (x_q - z) \cdot s. \quad (2-9)$$

当张量均值偏离零点, 或不同维度的统计特征差异较大时, 非对称量化通过零点调整实数值与整数编码之间的对齐关系, 使可表示区间更贴合非零中心分布。在同一校准和截断口径下, 这通常比对称量化更能利用有限整数范围。这一性质为后文的 K/V 角色诊断提供单独的参数化入口。本文关注的统计差异中, Key 侧更突出地表现为通道尺度差异, Value 侧更突出地表现为沿序列变化的动态范围; 二者可以在量化参数层面由独立的零点与缩放因子分别刻画, 而不必压进同一组共享参数。

量化轴会影响误差在不同维度上的分布方式。逐通道量化把缩放因子绑定到通道方向, 更适合吸收通道间尺度差异; 逐 token 量化把缩放因子绑定到时序方向, 更适合刻画位置相关的动态范围变化。对 KV Cache 而言, 这种轴向选择会影响误差进入不同计算角色的方式。Key 通过 $qK^\top$ 影响 attention logits 及其相对次序, 再经 softmax 转化为权重分布; Value 则在这些权重下被加权聚合。后续讨论不只报告使用多少 bit, 还会同时说明 bit 落在 K 还是 V 一侧、沿通道还是沿 token 分配。这样可以更清楚地呈现位宽、功能角色与量化粒度之间的关系。

2.3.3 校准方法综述

量化校准在本文中指离线确定缩放因子、裁剪阈值及相关参数的过程。它不重新训练模型，也不改变模型权重，而要解决的问题是，在部署前用少量样本选择一组上线后可复用的量化参数。

后文只需要区分两种校准视角。第一种直接看张量重建，例如用百分位裁剪抑制异常值，或用均方误差（MSE）衡量量化前后张量的逐元素差异。第二种把目标移到行为空间，例如用 KL 散度比较参考路径与量化路径诱导出的概率分布。二者的差别在于代理对象：MSE 约束“张量像不像”，KL 约束“softmax 后的注意力分布是否仍然把概率质量放在相近位置”。

这一点在 KV Cache 上尤其关键。量化后的 Key 和 Value 并不会被下游任务直接读取，而是先经过点积、softmax 与加权聚合，再影响最终输出。数值空间中的较小重建误差，不等价于注意力行为被保持；Key 侧的有限扰动也可能通过排序变化被 softmax 放大。下一节讨论已有 KV Cache 压缩工作中哪些工作已经处理了格式、异常值或缓存选择，哪些问题仍需要一个行为层代理来组织。

2.4 KV Cache 量化与高效推理相关工作

长上下文场景下，KV Cache 压缩研究已经不只回答“能否省显存”。相邻工作大致沿三条路径展开：低比特格式如何适配 K/V 的统计结构，量化失真如何在注意力行为层被发现和恢复，以及 bit-width 节省如何在 Decode 阶段转化为实际收益。更一般的量化理论综述可参见 Nagel 等人^[16]与 Hubara 等人^[17]。

量化压缩与校准方法。这组工作从不同侧面说明，KV Cache 量化不宜只按统一位宽或统一轴处理。KIVI^[8]采用 per-channel Key 与 per-token Value 的非对称格式，是本文低比特角色感知路径的直接参照；KVQuant^[9]通过非均匀码本与 Pre-RoPE Key 量化进一步处理 RoPE 后表示对量化网格的影响；AsymKV^[18]进一步显示 K/V 敏感性沿网络深度发生迁移，AQUA-KV^[19]则将这一观察扩展到时序相关性维度。这些格式与统计差异的判断在本文中保留下来，作为低比特路径的格式约束。本文进一步把校准参数的来源问题独立出来，关注量化参数由什么行为信号选出，以及这些读数能否继续支撑跨层预算分配。

低比特恢复与异常值处理。低比特恢复方向工作沿两条思路展开。一条

思路直接缓冲量化误差。QuaRot^[20] 用旋转把 Key 通道异常值打散到多维空间, GEAR^[21] 借助残差低秩近似补偿量化误差, QServe^[22] 把低比特格式整合到端到端系统路径中。另一类工作关注缓存内容的重要性差异, 并据此保留更高精度表示或采用更细粒度的量化处理。ZipCache^[10] 基于缓存内容的重要性差异组织混合精度保留, IntactKV^[23] 保留少量关键 token 的高精度表示, SKVQ^[24] 则利用缓存局部性或窗口化访问特征进行更细粒度的量化处理。Outlier Tokens Tracing^[25]、Atom^[26] 与 QJL^[27] 分别从异常 token 追踪、低比特表示和随机投影近似等方向扩展 KV Cache 压缩的边界, 本文将它们列入表 2-1 作为边界参考。总体来看, 这些研究提示低比特 KV Cache 的性能保持不能只看平均压缩率, 还需要判断哪些内容、模型层位置或访问局部性更可能在量化后引发失稳。本文沿着这一线索, 将离线校准链路产生的行为敏感度画像用于失稳诊断和预算分配, 使压缩目标与分配决策建立在一致的行为证据之上。

缓存管理与量化的正交关系。缓存管理工作回答的是另一类问题: 哪些历史缓存应被保留、驱逐或差异化处理。H2O^[28]、StreamingLLM^[29]、SnapKV^[30] 与 PyramidKV^[31] 主要依据注意力重要性或层级结构压缩保留集合; DuoAttention^[32]、HeadKV^[33] 与 ChunkKV^[34] 则从头级、逐头贡献或 chunk 结构组织缓存; CacheGen^[35] 与 ThinK^[36] 分别从流式编解码和查询驱动 Key 剪枝进入这一问题。它们与本文讨论的 bit-width 压缩不是替代关系: 缓存管理决定“哪些 token/head/chunk 还在”, 量化决定“留下来的缓存以多少 bit 和什么格式存”。系统性的 KV Cache 压缩 benchmark 可参见^[37]。因此, 本文在后续章节中只把这一路线作为可组合边界, 而不把缓存驱逐本身纳入当前方法贡献。

表 2-1 KV Cache 压缩相关代表工作比较

方法	对象/位宽	核心策略	备注
KIVI ^[8]	KV Cache 2-bit	per-channel Key + per-token Value 非对称量化	典型的 K/V 角色差异化格式
KVQuant ^[9]	KV Cache sub-4-bit	非均匀码本 + Pre-RoPE Key 量化	推进极低比特缓存压缩
AsymKV ^[18]	KV Cache —	分层 K>V 异质处理	强调深度相关的敏感性差异
AQUA-KV ^[19]	KV Cache —	利用时序相关性的自适应量化	面向动态分布的缓存压缩
ZipCache ^[10]	KV Cache mixed	token 显著性驱动的混合精度策略	压缩与恢复并重
GEAR ^[21]	KV Cache 2-bit	残差低秩补偿	低比特修复的代表路径
QServe ^[22]	W4A8KV4	端到端联合量化	突出系统协同
IntactKV ^[23]	KV Cache 4-bit	枢纽 token 高精度保留	保护关键内容
QJL ^[27]	KV Cache 1-bit	JL 随机投影压缩	极限压缩探索
SnapKV ^[30]	KV Cache —	注意力预测驱动的缓存驱逐	与量化正交
DuoAttention ^[32]	KV Cache mixed	头级差异化缓存策略	与量化正交
ThinK ^[36]	KV Cache —	查询驱动的 Key 剪枝	与量化正交

表 2-1 将上述路线压缩成对照表。角色差异化格式解释“如何量化 K/V”，内容保护和混合精度路线解释“哪里不应同等压缩”，系统工作解释“低 bit-width 如何进入运行时”。本文将讨论离线行为校准结果如何产生，并如何被整理为同源行为敏感度画像交给预算分配层。

量化对注意力行为的扰动。若只看压缩率，容易漏掉量化误差进入注意力计算后的形态变化。本文的锚点有两个：Key 误差可能经 logits 与 softmax 改写概率质量，输出侧误差则要回到聚合结果中评价。KV Tuner^[38] 分析了 Key 量化误差在注意力得分中的放大，并观察到高误差注意力头往往不再保持稀疏结构；Softmax Bias Correction^[39] 从 softmax 量化角度指出 SQNR 劣化和近零概率问题。QeRL^[40]、Softmax-Not-Enough^[41] 与 AhaKV^[42] 提供了概率平坦化、温度和缓存重要性的相邻证据。

高效注意力与系统协同。量化格式成立之后，还要经过系统路径检查。FlashAttention^[11] 及 FlashAttention-2^[12] 通过分块计算、在线 softmax 与更高效的并行组织降低注意力计算 IO；vLLM^[4] 的 PagedAttention 通过分页式 KV Cache 管理减少显存碎片；Triton^[13] 则为反量化与注意力计算融合提供 kernel 编写载体。这些工作共同说明，bit-width 降低后，若 nibble unpack、GQA head mapping 和 kernel 调度开销没有被 Decode 阶段的访存节省抵消，低比特缓存未必会转化为更低 TPOT。因此，第四章会把系统收益写成 H_{kv} 、

序列长度和后端路径共同决定的经验边界。

上述文献已经分别覆盖格式设计、低比特恢复、缓存选择与系统执行。本文沿三件事继续推进：用行为代理选择参数，用 K/V 角色差异解释低比特断点，用行为敏感度画像驱动预算分配和部署路径判断。

2.5 研究空白与本文定位

综合上述文献位置，本文将贡献边界收束为四个需要在后续方法与实验中串联验证的问题。

仅依赖张量重建的校准目标难以充分刻画下游功能偏移。MSE、百分位裁剪和运行时统计仍是有用工具，但 KV Cache 误差必须经过 logits、softmax 和 Value 聚合后才变成下游功能损伤。因此第三章把 attention-distribution KL 写成可执行的分布侧代理，并同时保留它与输出扰动代理的边界。

进入低比特路径后，本文不只报告某个 INT4 路径是否可用，还进一步追问失稳与 Key/Value 角色差异、量化轴选择和执行路径之间的关系。KIVI 等工作已经给出角色差异化格式，本文在此基础上把对称 INT4 的断点、K4V8/K8V4 的角色对照以及 INT4-RoleAlign 的非对称路径实例放入同一条诊断路径；第四章再检查这种解释在不同模型族、规模和 H_{kv} 下的边界。

预算分配层面还存在进一步衔接校准结果的问题。已有混合精度和缓存管理工作通常回答“哪里保留更多内容”或“哪里使用更高精度”，但这些决策常与校准参数选择分开组织。本文把同源行为敏感度画像从校准层传递到 allocation / AutoK 层，用来解释 family-/scale-/task-dependent regimes，而不是宣称单一固定策略跨模型成立。

最后，部署收益不能直接由 bit-width 推出。低 bit-width 给出的是缓存字节数下降，TPOT 是否下降还取决于反量化、nibble unpack、GQA head mapping 与 kernel 调度是否同向。第四章因此把显存收益与时间收益分开报告，并把融合 Decode 路径写成受 H_{kv} 和序列长度共同调制的条件性结果。

这四个问题决定了第三章的方法组织：本文以注意力行为保持为主线，分别定义离线校准代理、低比特角色感知路径、预算分配机制和系统执行边界。

2.6 本章小结

本章为后续方法设计保留了四组必要前置：自注意力与 MQA/GQA 给出缓存结构记号，KV Cache 公式给出 H_{kv} 、 S 与 bit-width 三个关键变量，对称/非对称量化说明 INT8 基准路径与 INT4 断点的格式差异，相关工作则限定了本文与格式设计、缓存管理和系统优化路线的关系。

第三章将在这些前置上转入方法定义：用注意力行为保持组织离线校准，用 K/V 角色差异解释低比特路径，用行为敏感度画像承接预算分配，并把这些产物落到可执行的推理机制中。

第三章 行为引导量化框架设计

3.1 注意力近似误差的代数分解与问题形式化

在模型生成最终输出之前，KV Cache 误差会通过注意力 logits、softmax 权重和 Value 聚合进入后续计算，并在该层注意力中体现为注意力分布 a 与注意力输出 o 的变化。 K, V 的逐元素重建距离仍可作为数值代理，但不足以单独刻画这种行为变化。基于这一观察，本文将 (a, o) 视为量化后需要共同保持的行为表征，并先在单头注意力设定下展开代数分解，以说明 Key 扰动经注意力分布影响输出、Value 扰动经加权聚合影响输出的两条耦合路径。

记当前查询为行向量 $q \in \mathbb{R}^{1 \times d_k}$ ，历史上下文长度为 S ， $K \in \mathbb{R}^{S \times d_k}$ 与 $V \in \mathbb{R}^{S \times d_v}$ 分别由行向量 k_i, v_i 拼接而成。本文实验涉及的 Qwen2.5、LLaMA-3.1 以及 Mistral-7B-Instruct-v0.3 均采用常见的 $d_v = d_k$ 设置，因此在下述单头注意力记法中 q 与 o 同维。标准单头注意力可写为

$$a = \text{softmax}\left(\frac{qK^\top}{\sqrt{d_k}}\right), \quad o = aV, \quad (3-1)$$

其中 $a \in \mathbb{R}^{1 \times S}$ 为注意力分布，其第 i 个分量记为 $a_i \in \mathbb{R}$ ； $o \in \mathbb{R}^{1 \times d_v}$ 为注意力输出。注意力行为记作联合表征

$$\mathcal{B}(q, K, V) := (a, o). \quad (3-2)$$

后文以 Δ_{beh} 刻画量化前后 (a, o) 的行为偏移。多层、多头情形可按层索引 ℓ 与头索引 h 逐一展开，记为 $q^{(\ell, h)}, K^{(\ell, h)}$ 等；GQA/MQA 下，多个 Query 头可共享同一 KV 头，本节分解可对应到每个 Query 头及其映射的 KV 头，具体映射关系已在第 2.2 节给出。

设 $Q_{\theta_K}(\cdot)$ 与 $Q_{\theta_V}(\cdot)$ 分别表示作用于 Key 与 Value 的量化映射；参数 θ_K, θ_V 的具体含义（scale、zero-point、bit-width 等）以及作用域（逐元素、逐通道或逐 token）由量化路径决定，详见第 3.5 节。量化后的 Key 与 Value 记为

$$\hat{K} = Q_{\theta_K}(K), \quad \hat{V} = Q_{\theta_V}(V), \quad (3-3)$$

对应的量化后注意力分布与输出为

$$\hat{a} = \text{softmax}\left(\frac{q\hat{K}^\top}{\sqrt{d_k}}\right), \quad \hat{o} = \hat{a}\hat{V}. \quad (3-4)$$

KV Cache 量化的目标即

$$\min_{\theta_K, \theta_V} \Delta_{\text{beh}}((a, o), (\hat{a}, \hat{o})), \quad (3-5)$$

其中 $\Delta_{\text{beh}} : (\mathbb{R}^{1 \times S} \times \mathbb{R}^{1 \times d_v})^2 \rightarrow \mathbb{R}_{\geq 0}$ 满足 $\Delta_{\text{beh}}(x, x) = 0$ ，刻画量化前后注意力行为的联合偏移；其作为损失函数使用，无需满足度量空间的对称性或三角不等式。 Δ_{beh} 的具体实例化由量化路径决定，并在层、头或路径粒度上聚合实例化（第 3.4 节）。

由 $\hat{o} = \hat{a}\hat{V}$ 与 $o = aV$ 的定义，输出误差可作如下精确代数展开：

$$\hat{o} - o = \sum_{i=1}^S \hat{a}_i \hat{v}_i - \sum_{i=1}^S a_i v_i \quad (3-6)$$

$$= \sum_{i=1}^S (\hat{a}_i \hat{v}_i - \hat{a}_i v_i) + \sum_{i=1}^S (\hat{a}_i v_i - a_i v_i) \quad (3-7)$$

$$= \sum_{i=1}^S \hat{a}_i (\hat{v}_i - v_i) + \sum_{i=1}^S (\hat{a}_i - a_i) v_i. \quad (3-8)$$

式 (3-8) 是恒等变形。右侧第一项（聚合侧/Value 通路）描述 Value 侧内容被量化后如何进入聚合结果；右侧第二项（分布侧/Key 通路）描述 Key 侧扰动经 logits 与 softmax 改变注意力分布后如何传到输出。两条通路同时进入输出，单独追踪 a 或 o 均会遗漏一侧。第一项的权重为量化后分布 $\hat{a}_i$ 而非参考分布 a_i ，因此聚合侧误差与 Key 侧扰动并非加性可分——Key 量化通过 $\hat{a}$ 同时改变第二项的分布偏移与第一项的聚合权重。张量重建误差并不刻画这种交叉依赖，可执行代理的具体形式由后续校准目标实例化（第 3.4 节）。两条耦合路径的可视化分解见图 3-1。

3.2 动机诊断：K/V 敏感性不对称及其设计启示

式 (3-8) 区分了两类误差作用于输出的路径。Key 侧扰动先改变注意力 logits，经 softmax 归一化后表现为注意力分布差异，并由分布项传到输出；




图 3-1 注意力误差的两条耦合传播路径及其精确代数分解。左侧为 FP16 attention flow，中部为量化扰动，右侧为由 Key 与 Value 误差分别触发的两条传播路径，底部标出输出误差对应的两类传播项。

Value 侧误差则以 $\hat{a}_i(\hat{v}_i - v_i)$ 的形式，在量化后权重下进入聚合。扰动对输出的影响大小取决于分布形态、logit 间隔以及权重集中程度，因此在低比特预算下，Key 与 Value 量化误差对输出的敏感性可能不同。后文通过 K/V 单侧诊断，并以对称低比特配置作为参照，检验这种不对称是否在实验中出现，为低比特路径的格式选择提供依据。

为统一后续图表记号，本节采用 $K \times V_y$ 表示 K/V 两侧位宽组合。K4V8 表示 4-bit Key 与 8-bit Value。单侧隔离配置中，K4V16 表示 Key 为 4-bit、Value 保持 FP16，K16V4 表示 Key 保持 FP16、Value 为 4-bit。在本文实验记号中，MixedKV 对应 K8V4。图 3-2 呈现压缩诊断视图，并按三组配置组织：K8V8 是高位宽量化参考，K8V4/K4V8 在相同 K/V 平均位宽设置下对照 K/V 角色，K4V4 作为对称低比特锚点。未量化 FP16 参考和单侧 PPL 隔离实验结果分别由第四章表 4-7 与表 4-6 给出。

Qwen2.5-1.5B 的单侧 PPL 诊断给出最直接的隔离读数。K4V16 将 PPL 相对 FP16 基线推高约两个数量级，K16V4 只带来基线邻域内的小幅变化，原始读数见表 4-6。同一方向也出现在 32K 任务诊断中。K4V8 下，Qwen2.5-1.5B 与 Qwen2.5-7B 的 RULER 通过率降为零；K8V4 没有出现归零式失稳。两组读数共同支持一个较窄判断，即在本文这些 Qwen2.5 低比特对照中，Key 侧低比特噪声是更直接的任务级失稳触发源；Value 侧压缩并非没有影响，但在 K16V4 与 K8V4 对照中没有触发同等强度的失稳。这个判断与式 (3-8) 对 Key/Value 两条误差路径的机制区分一致。

这种不对称的强弱还随模型族和头共享结构改变。Qwen 系列的 H_{kv} 为 2 或 4，重复因子 $N_{\text{rep}} = H_q/H_{kv}$ 落在 $\{6, 7\}$ ，在 K4V8 与 K4V4 下出现检索




图 3-2 K/V 位宽落点诊断与设计启示。左侧压缩展示 K8V8、K8V4/K4V8 与 K4V4 的代表性 Needle 观察，突出 Qwen 系列在 4bit K 下的崩塌风险及 LLaMA-3.1-8B 的不同表现；右侧将该观察收束为低比特路径约束。完整 Needle、RULER 与 LongBench 风格证据见第 4.3.2 节。

归零。LLaMA-3.1-8B 的 $H_{kv} = 8$ 、 $N_{rep} = 4$ ，在当前对照里失稳幅度较小。在 GQA 机制中，同一个 KV 头的量化误差会由映射到该头的一组 Query 头共同承受；在 H_q 可比的对照中，较小的 N_{rep} 意味着共享同一 KV 头误差的 Query 头更少，相关读数见表 4-7。更稳妥的解释还需要同时纳入模型规模、训练数据与 GQA 配置， H_{kv} 在本文中只作为组间差异的代理变量，用于描述严重程度与触发位宽的边界变化。

这些证据表明，Key 侧低比特退化是低比特路径设计中需要优先约束的风险点。主要隔离依据来自单侧 PPL 诊断，K4V16 单独使 PPL 出现数量级退化，K16V4 只带来小幅变化。任务读数提供外部一致性，K4V8/K4V4 在 Key 位宽降到 4 bit 后出现更强失稳，K8V4 未出现归零式失稳。由于 K4V8 与 K4V4 同时压低 K 与 V，它们仍只适合作为边界辅助证据，不能单独支撑 K 主导的隔离推断。PPL 原始读数见表 4-6；跨任务读数及统计协议，包括 Bootstrap 95% CI、sign-flip 置换检验与 BH-FDR 多重比较校正，见表 4-7 与第 4.3.2 节。

3.3 行为引导量化框架总览

第 3.1 节把量化质量评判从张量重建误差移至注意力行为差异 Δ_{beh} ，第 3.2 节把低比特退化定位为 Key 侧主导。框架以两个离线模块落实上述约束：校准模块按候选量化路径搜索行为代理最优的参数；预算分配模块在同一离线链路上读取逐层敏感度统计量，输出每层（或 Key/Value 角色）保留多少 bit。

逐层行为敏感度画像

$$\mathcal{S} = \{s^{(l)}\}_{l=1}^L, \quad s^{(l)} \in \mathbb{R}_{\geq 0}, \quad (3-9)$$

是离线校准链路在处理校准样本时作为副产物输出的逐层标量统计量；分配模块以只读方式读取它，不发起新的校准搜索。 $\mathcal{S}$ 不预设唯一计算公式，由具体量化路径对应的行为代理实例化（第 3.4 节详述）。本文取 $s^{(l)}$ 越大表示第 l 层在量化扰动下注意力行为越不稳定，并归纳地采用单调假设——读数越高的层在预算受限时保留更高位宽的边际收益越大；该假设的实验支撑见第 4.4 节。

校准层把“如何量化”组织为参数选择问题。设候选量化参数空间 Θ 为离散候选集合，如 per-layer scale 候选格点，校准层求解

$$\theta^* = \arg \min_{\theta \in \Theta} \Delta_{\text{beh}}^{\text{cal}}(\theta), \quad (3-10)$$

其中 $\Delta_{\text{beh}}^{\text{cal}}(\theta)$ 是 Δ_{beh} 在有限校准样本上的代理估计——把第 3.1 节联合行为目标限制到离线校准集，转化为可执行计算。给定一条路径及其候选参数家族，校准层输出 θ^* 供在线缓存写入直接读取；不同位宽与格式的差异由候选家族 Θ 与代理 $\Delta_{\text{beh}}^{\text{cal}}$ 的具体形式承担，框架不要求所有路径使用同一数值评分。

分配层负责决定各层保留的位宽预算。设平均 KV 位宽预算为 $\bar{b}$ ，分配映射

$$b^* = \mathcal{A}(\mathcal{S}; \bar{b}), \quad \frac{1}{L} \sum_{l=1}^L b_l^* \leq \bar{b}, \quad (3-11)$$

是一个确定性规则。它只读取共享画像 $\mathcal{S}$ ，把逐层敏感度转换为整数位宽向量 b^* ，在线推理时不重新优化，也不重复校准参数搜索。基础设置把 b^* 写成 L 维逐层预算， $b^* \in \{b_{\min}, \dots, b_{\max}\}^L$ ，本文使用 $b \in \{4, 8, 16\}$ 。当预算表达进一步区分 K/V 角色时， b^* 变为 $\{b_{\min}, \dots, b_{\max}\}^{L \times 2}$ 中的向量，对应第 3.2 节识别的 Key/Value 双角色；此时 $\mathcal{S}$ 也拆分为角色分量。第 3.6 节给出具体规则。

上述组织使校准链路和推理链路可以分开核验。离线阶段提取参考行为，完成路径参数搜索，写出冻结校准产物，并同步生成 $\mathcal{S}$ 。在线推理阶段只读取这些冻结产物，按照固定规则为当前缓存写入计算尺度或预算。推理阶段不重复离线搜索，这是框架的执行边界； θ^* 与 b^* 也相应作为离线交

付物保存，而不是在线决策变量。图 3-3 给出离线—在线协作关系，以及共享画像在校准、低比特恢复和预算分配三层之间的传递方式。




图 3-3 行为引导量化框架总览。离线校准链路读取校准样本、FP16 参考行为和候选量化路径，计算行为代理并完成稳健选择，输出冻结校准产物 θ^* 。校准链路同时沉淀逐层行为敏感度画像 S ，预算分配模块读取该画像，依据平均位宽预算 $\bar{b}$ 生成位宽向量 b^* 。在线推理阶段只读取 θ^* 与 b^* ，不重新搜索或更新离线产物，并据此执行缓存写入与解码。

3.4 行为引导校准目标与参数搜索策略

第 3.1 节把量化质量评判落到联合行为偏移 Δ_{beh} ，但该量在样本上无显式可执行形式。本节把代理 $\Delta_{\text{beh}}^{\text{cal}}$ 实例化为分布侧 KL 散度，作为对称路径与 INT4-RoleAlign 的 K-path 共用的可计算目标；V-path 使用独立的输出扰动代理，详见第 3.5 节。两类代理均在路径相关的候选参数家族上完成稳健选择。

对称路径与角色感知低比特路径在候选参数家族与代理形式上不必相同，但都在离线样本上计算行为读数，在可行域约束下控制尾部坏案例，并把最终选择写入固定校准产物。

3.4.1 注意力分布 KL 散度目标

设第 l 层、第 h 个注意力头、时间步 t 的 Query 与 Key 分别为 $q^{(l,h,t)} \in \mathbb{R}^{d_k}$ 与 $K^{(l,h,t)} \in \mathbb{R}^{N \times d_k}$ ，二者均在 input_layernorm 与 RoPE 处理后取出， N 为当前位置可见的上下文长度。FP16 参考路径下的注意力分布

$$p_{\text{ref}}^{(l,h,t)} = \text{softmax} \left(\frac{q^{(l,h,t)} K^{(l,h,t)\top}}{\sqrt{d_k}} \right) \in \Delta^{N-1}, \quad (3-12)$$

其中 Δ^{N-1} 为 N 维概率单纯形。对候选量化参数 θ ，记量化—反量化映射 $\tilde{K}_\theta^{(l,h,t)} = \text{dequant}(\text{quant}(K^{(l,h,t)}; \theta); \theta)$ ，对应分布

$$p_\theta^{(l,h,t)} = \text{softmax}\left(\frac{q^{(l,h,t)} \tilde{K}_\theta^{(l,h,t)\top}}{\sqrt{d_k}}\right) \in \Delta^{N-1}. \quad (3-13)$$

单位置分布偏移取前向 KL

$$d_{\text{KL}}^{(l,h,t)}(\theta) = D_{\text{KL}}\left(p_{\text{ref}}^{(l,h,t)} \parallel p_\theta^{(l,h,t)}\right), \quad (3-14)$$

将第 3.3 节引入的 $\Delta_{\text{beh}}^{\text{cal}}(\theta)$ 实例化为校准样本集合 T 上的均值

$$\Delta_{\text{beh}}^{\text{cal}}(\theta) = \frac{1}{|T_{\text{cal}}|} \sum_{(x,l,h,t) \in T_{\text{cal}}} d_{\text{KL}}^{(x,l,h,t)}(\theta), \quad (3-15)$$

其中 $T_{\text{cal}} = \{(x, l, h, t) : x \in \mathcal{D}_{\text{calib}}\}$ 是校准样本上 (x, l, h, t) 的索引集合。该代理作为离线参数搜索的优化目标，尾部稳健的选择准则与候选参数家族延至第 3.4.2 节给出。

MSE 仍停留在张量重建空间，只比较 K 或 V 的逐元素差异。Key 侧误差进入输出前，还要经过 $qK^\top$ 、softmax 排序和概率质量分配；因此，即便某个候选的 MSE 较小，关键 token 的注意力概率质量仍可能发生转移。式 (3-8) 给出对应的两条输出误差路径。分布项为 $\sum_i (\hat{a}_i - a_i) v_i$ ，聚合项为 $\sum_i \hat{a}_i (\hat{v}_i - v_i)$ 。这里 $a_i \equiv p_{\text{ref},i}^{(l,h,t)}$ 、 $\hat{a}_i \equiv p_{\theta,i}^{(l,h,t)}$ ， v_i 与 $\hat{v}_i$ 分别表示参考 Value 和量化 Value。KL 直接比较 a 与 $\hat{a}$ 的分布偏移，与分布项对应；聚合项则保留 Value 扰动经由量化后权重 $\hat{a}_i$ 进入输出的作用。这个分工使 KL 沿分布侧误差路径，比逐元素重建误差更贴近输出层面的注意力行为。

本文采用前向 KL $D_{\text{KL}}(p_{\text{ref}} \parallel p_\theta)$ ，因为当量化路径低估参考分布中的高概率位置时，该方向会给出更大的惩罚。这一取向对应长上下文检索中“不漏关键 token”的需求。反向 KL 更关注量化分布自身的高概率区域，JS 散度则更对称，二者保留为补充诊断。Value 路径不沿用这一分布代理，而使用独立的输出扰动代理，见第 3.5 节。

数值上对 p_{ref} 与 p_θ 均在 $[\varepsilon, 1]$ 上做 clamp 截断（取 $\varepsilon = 10^{-6}$ ）以避免极端尾部概率引起的不稳定。KL 与数值代理（如 MSE）的必要性边界——在哪些条件下 KL 更必要、在哪些条件下二者会趋同——见第四章。

3.4.2 参数搜索空间与稳健选择准则

第 3.4.1 节给出均值代理 $\Delta_{\text{beh}}^{\text{cal}}$ 后，对一条具体路径还需要确定有限离散候选网格 Θ_{path} 、该路径使用的行为代理 R_{path} ，以及写入在线推理系统的产物字段。图 3-4 给出参考行为提取、路径实例化、行为评分、稳健选择与产物冻结五步离线流程，表 3-1 列出 INT8、对称 INT4 与 INT4-RoleAlign 三条路径在这五步上各自的接口实例化。




图 3-4 行为引导离线校准的统一 workflow。校准样本先经过 FP16 前向得到参考行为；每条量化路径据此实例化候选网格 Θ_{path} ，并计算路径相关风险 $R_{\text{path}}(\theta)$ 。稳健选择阶段根据可行域、P95 尾部读数与裁剪率审计确定 θ_{path}^* ，同时保留行为读数 $\mathcal{S}$ 与在线接口。RoleAlign 中，K 侧使用注意力分布 KL，V 侧使用输出扰动代理。

表 3-1 统一离线校准 workflow 下的路径参数化接口

路径	校准接口	量化粒度	主代理 / 约束	输出产物
INT8 基准路径	(p_c, g, m)	对称 per-group	注意力分布 KL；P95；裁剪率约束	静态 scale + 保护元数据
对称 INT4 试探路径	(p_c, g)	对称 per-group	注意力分布 KL；P95；裁剪率约束	静态 scale
INT4-RoleAlign	K: p_K V: p_V	K: per-channel V: per-token	K: 注意力分布 KL / P95 V: 输出扰动代理 路径相关稳健约束	角色感知产物 K/V 参数与轴元数据

统一的是离线校准流程与稳健选择纪律，不同路径的差异体现在参数接口与行为代理上；在 INT4-RoleAlign 中，Key 路径由 attention-distribution KL 主导，Value 路径由独立的输出扰动代理主导。

给定候选网格 Θ_{path} 后，路径参数的离线选择写为

$$\theta_{\text{path}}^* = \arg \min_{\theta \in \Theta_{\text{path}}} R_{\text{path}}(\theta), \quad (3-16)$$

其中 $R_{\text{path}}(\theta)$ 是该路径上的稳健风险统计量；具体形式由路径决定，对称路径下下文式 (3-18) 给出的 attention-distribution KL 95% 分位数 $q_{0.95}(\theta)$ 为主序，并叠加裁剪率过滤与字典序回退（详见下文）。角色感知低比特路径在同一选择纪律下，把 K-path 与 V-path 的代理分开定义。

对称路径（包括 INT8 基准与对称 INT4 试探路径）使用同一组本地读数。设校准样本集合为 $\mathcal{D}_{\text{calib}}$ （来源、规模与序列长度见第 3.7 节）， K^{cal} 与

V^{cal} 分别为 $\mathcal{D}_{\text{calib}}$ 上抽取的 Key 与 Value 张量元素集合，定义

$$\mu(\theta) = \text{Mean}_{(x,l,h,t) \in T_{\text{cal}}} d_{\text{KL}}^{(x,l,h,t)}(\theta), \quad (3-17)$$

$$q_{0.95}(\theta) = \text{P95}_{(x,l,h,t) \in T_{\text{cal}}} d_{\text{KL}}^{(x,l,h,t)}(\theta), \quad (3-18)$$

$$c_K(\theta) = \frac{|\{x \in K^{\text{cal}} : |x/s_{\theta}(x)| > q_{\max}\}|}{|K^{\text{cal}}|}, \quad (3-19)$$

$$c_V(\theta) = \frac{|\{x \in V^{\text{cal}} : |x/s_{\theta}(x)| > q_{\max}\}|}{|V^{\text{cal}}|}. \quad (3-20)$$

这里的 $\mu(\theta)$ 是第 3.4.1 节均值代理对每个候选的取值， $q_{0.95}(\theta)$ 是同一逐位置 KL 分布的 95% 分位数。 $c_K(\theta)$ 与 $c_V(\theta)$ 分别记录 Key 与 Value 张量的裁剪率。对元素 x 以候选 θ 对应的分组尺度 $s_{\theta}(x)$ 缩放后，若 $|x/s_{\theta}(x)|$ 超过整数上界 $q_{\max}$ ，该元素计入对应裁剪率；INT8 取 $q_{\max} = 127$ ，INT4 取 $q_{\max} = 7$ 。可行域用裁剪率阈值 τ_K, τ_V 硬过滤候选，定义为

$$\Theta_{\text{feasible}} = \{\theta \in \Theta_{\text{path}} \mid c_K(\theta) \leq \tau_K, c_V(\theta) \leq \tau_V\}, \quad (3-21)$$

本文取 $\tau_K = \tau_V = 0.01$ 。若 $\Theta_{\text{feasible}} \neq \emptyset$ ，选择规则为

$$\theta^* = \arg \min_{\theta \in \Theta_{\text{feasible}}} q_{0.95}(\theta). \quad (3-22)$$

以尾部统计 $q_{0.95}$ 为主序； μ 不参与主选择规则的最小化目标，仅在并列或下文的回退规则中作为次级排序键。

若所有候选均违反裁剪率约束，回退规则按字典序选取：先最小化总裁剪负担 $c_K(\theta) + c_V(\theta)$ ；若总裁剪负担相同，再比较尾部统计 $q_{0.95}(\theta)$ ；若尾部统计仍相同，最后比较平均偏移 $\mu(\theta)$ 。排序第一的候选记为 θ^* ，并在产物字段中标记触发回退及其原因。

INT4-RoleAlign 仍使用上述五步流程，但 p_K 与 p_V 分别选择，不合并为单一注意力 KL 分数。K 路径的候选参数为 p_K ，对应逐通道 Key 非对称量化的百分位裁剪参数，具体路径见第 3.5 节；该路径使用注意力分布 KL 及其尾部统计完成选择。V 路径的候选参数为 p_V ，对应逐 token Value 非对称量化的百分位裁剪参数；该路径使用独立输出扰动代理 $R_V(\theta)$ 及其稳健统计，具体形式见第 3.5 节。两条路径共享可行域审计框架，包含裁剪率过滤、依据各自代理的尾部统计或稳健统计排序、用次级排序键处理并列与

回退；对应阈值、主排序统计和次级排序键在 K/V 两条路径中分别给出。

产物字段按用途分成两类。路径特定校准字段由在线缓存写入过程直接读取，逐层敏感度统计则供第 3.6 节的预算分配模块使用。逐头温度校正保留在附录诊断中，主线流程仅使用前两类产物。基于这一接口边界，后两节分别展开三条跨位宽路径的实例化设计，以及由敏感度统计支撑的预算分配机制。

3.5 跨位宽量化路径的实例化设计

第 3.4 节给出的离线校准流程与稳健选择纪律不规定唯一位宽或唯一量化格式。后文先用 INT8 基准路径检查校准闭环能否在保守位宽下稳定落地，再用对称 INT4 试探路径暴露直接降位宽后的结构困难，最后用 INT4-RoleAlign 把低比特路径改写为 K/V 角色分离的非对称格式，并在方法层面区分它与 KIVI-style^[8] 的参数来源。三条路径共享第 3.4 节的参考行为提取、可行域约束、尾部优先选择和固定产物输出，差异仅在参数接口、量化轴与行为代理；三条路径输出的逐层敏感度统计共同供第 3.6 节的 allocator 读取。三条路径在量化格式、参数接口与行为代理上的并列对照见表 3-2。

表 3-2 跨位宽路径的实例化关系与统一校准 workflow

路径	位宽 / 量化格式	主要接口	暴露问题 / 目标	统一流程中的定位
INT8 基准路径	8-bit 对称 per-group	(p_c, g, m)	形成稳定、便于复核的基准验证实例	基准验证路径；验证校准闭环
对称 INT4 试探路径	4-bit 对称 per-group	(p_c, g)	暴露 Key 排序脆弱性，以及量化级别骤降带来的结构困难	说明对称 INT4 不能机械继承 INT8 路径
INT4-RoleAlign	4-bit K: per-channel V: per-token	K-path: p_K V-path: p_V	在低比特下定义 K/V 角色分离的固定产物接口	角色感知低比特路径；统一流程下的实例

统一的是离线校准流程与稳健选择纪律；不同路径的差异体现在参数接口、量化格式与行为代理上。对 INT4-RoleAlign 而言，Key 路径由 attention-distribution KL 主导，Value 路径由独立的输出扰动代理主导。

3.5.1 INT8 基准路径下的静态 Scale 与自适应保护

INT8 的有效整数等级为 255 级，量化网格相对细，校准层写出的 scale 参数也能按组追溯。本文先在这一设置下检查离线选择与在线执行是否形成闭环，并在第四章将该路径记为 INT8-Canonical。INT8 还提供后续低比特路径的压缩率参照。

该路径对 Key 和 Value 使用相同的静态对称逐组量化。分组沿通道维度划分，每组包含 $g = 128$ 个元素并共享一个缩放参数。设第 l 层第 j 个分组的待量化张量为 $x_{l,j}$ ；给定校准百分位参数 p_c 和分组大小 g 后，静态缩放参数定义为

$$s_{l,j}^{\text{static}} = \frac{\text{Percentile}(|x_{l,j}|; p_c)}{q_{\max}}, \quad (3-23)$$

其中 $q_{\max}$ 表示对称量化网格的正端点（INT8 取 127）。令 $q \in \mathbb{Z}$ 为量化整数输出，量化—反量化写为

$$q = \text{clamp}\left(\text{round}\left(\frac{x}{s_{l,j}^{\text{static}}}\right), -q_{\max}, q_{\max}\right), \quad \hat{x} = q s_{l,j}^{\text{static}}. \quad (3-24)$$

候选网格 Θ_{path} 同时枚举 (p_c, g) ，并依据第 3.4.2 节给出的 KL 尾部统计与裁剪率约束选出最终组合。

运行时样本可能落到校准覆盖范围之外，因此该路径在静态缩放参数之外加入自适应保护。设当前写入张量为 $x_{l,j}^{\text{cur}}$ ，动态尺度定义为

$$s_{l,j}^{\text{dyn}} = \frac{\text{absmax}(x_{l,j}^{\text{cur}})}{q_{\max}}, \quad (3-25)$$

保护裕度 m 是固定超参数，本文取 $m = 1$ ，并将其保留为后续扩展参数。最终缩放参数取

$$s_{l,j}^{\text{final}} = \max\left(m \cdot s_{l,j}^{\text{static}}, s_{l,j}^{\text{dyn}}\right), \quad (3-26)$$

当前 token 仍处在校准覆盖范围内时，静态参数继续主导。若当前 token 的 absmax 超过 $m \cdot s_{l,j}^{\text{static}} \cdot q_{\max}$ 对应的覆盖，则改用动态尺度写入当前 token，使该 token 仍落在量化网格内，避免异常值被直接压到 $q_{\max}$ 。max 在每个写入步单独计算，K 与 V 的自适应保护开关也分别控制。极端漂移会抬高 $s_{l,j}^{\text{final}}$ ，进而扩大一定量化误差；这是为裁剪安全付出的工程代价。缓存写入时是否回写历史缓存的系统语义，见第 3.7 节。

3.5.2 对称 INT4 的局限与格式升级动因

直接把上述对称路径从 INT8 降到对称 INT4 后，量化网格首先变粗。INT8 提供 255 级有效等级，而对称 INT4 只剩 15 级（等级密度差约 17 倍）；原先可由细粒度缩放参数吸收的分布差异被压到这个粗网格内。

前文提供了理解这一现象的机制线索。第 3.1 节说明 Key 扰动先进入

logits 排序, 再经 softmax 改写注意力分布; 第 3.2 节与第 4.3.2 节的 Qwen 系列读数给出经验锚点。结合前述单侧诊断, Key 降到 4 bit 的配置更直接暴露风险; 任务对照中, K4V8 在 Qwen 系列出现断崖式失稳, 而 K8V4 未出现同等强度退化。K4V4 同时压低 K 与 V, 只作为同向辅助观察列出。跨模型判读仍以第四章表图为准, 其中 Qwen 系列的归零更明显, LLaMA-3.1-8B 在当前对照中失稳幅度较小, 具体边界还受模型规模、训练数据与 GQA 配置共同影响。

据此, 本文把对称 INT4 作为低比特格式选择的下界参照。单一对称 scale 需要同时覆盖 Key 通道间的幅值差异和 Value 沿 token 变化的动态范围; 当这两类差异由同一个参数覆盖时, 会在粗 INT4 网格内相互牵制。下一节转向 INT4-RoleAlign, 把两类差异交给分开的 K/V 量化路径处理。

3.5.3 INT4-RoleAlign 的角色感知非对称量化

INT4-RoleAlign 将第 3.5 节开头的两条诊断落实为 K/V 分路设计。Key 扰动会改变 $qK^\top$ 排序, 因此 Key 侧采用逐通道非对称量化, 用通道独立参数保留各特征方向的取值范围; Value 误差经注意力权重进入聚合, 因此 Value 侧采用逐 token 非对称量化, 围绕当前 token 的动态范围保留后续加权聚合所需的信息。两条分路仍沿用第 3.4 节的候选搜索、稳定性筛选与边界记录纪律。

下文公式只保留序列长度与通道维度, 记号中省略 batch 维度与 KV head 维度。实现中 K/V 张量形状为 $[B, H_{kv}, S, D]$, Key 的 scale 张量形状为 $[B, H_{kv}, D]$, Value 的 scale 张量形状为 $[B, H_{kv}, S]$ 。Key 侧采用逐通道非对称量化。设第 l 层 Key 矩阵为 $K^{(l)} \in \mathbb{R}^{S \times d_k}$; 对第 j 个通道, 分位数裁剪边界定义为

$$m_{l,j}^K = \text{Percentile}(K_{:,j}^{(l)}; 100 - p_K), \quad M_{l,j}^K = \text{Percentile}(K_{:,j}^{(l)}; p_K), \quad (3-27)$$

其中 $p_K \in (50, 100]$, 由此得到 Key 侧仿射缩放与偏移

$$s_{l,j}^K = \frac{M_{l,j}^K - m_{l,j}^K}{q_{\max} - q_{\min}}, \quad \zeta_{l,j}^K = m_{l,j}^K - q_{\min} s_{l,j}^K. \quad (3-28)$$

这些分位数沿序列维度统计, 因此每个通道各自得到一组 (s, ζ) 。这样做的目的不是改变 Key 的计算路径, 而是在粗 INT4 网格下保留不同特征方向的取值范围, 减少通道差异被同一尺度抹平后对 $qK^\top$ 排序造成的影响。该

设计承接第 3.2 节中关于 Key 侧低比特失稳的诊断。

Value 侧则按 token 建立非对称量化参数。设第 l 层 Value 矩阵为 $V^{(l)} \in \mathbb{R}^{S \times d_v}$ ；对第 t 个 token，分位数裁剪边界定义为

$$m_{l,t}^V = \text{Percentile}(V_{t,:}^{(l)}; 100 - p_V), \quad M_{l,t}^V = \text{Percentile}(V_{t,:}^{(l)}; p_V), \quad (3-29)$$

对应仿射参数

$$s_{l,t}^V = \frac{M_{l,t}^V - m_{l,t}^V}{q_{\max} - q_{\min}}, \quad \zeta_{l,t}^V = m_{l,t}^V - q_{\min} s_{l,t}^V. \quad (3-30)$$

分位数统计沿特征维度聚合，每个 token 独立量化。逐 token 参数吸收不同时间步的内容幅值变化。两条轴的配对直接绑定各自下游计算角色：K 侧影响 $qK^\top$ 排序，V 侧影响注意力权重下的聚合。

K/V 两侧统一的量化—反量化形式为

$$q = \text{clamp}\left(\text{round}\left(\frac{x - \zeta}{s}\right), q_{\min}, q_{\max}\right), \quad \hat{x} = qs + \zeta, \quad (3-31)$$

其中 INT4 非对称网格取 $q_{\min} = -8, q_{\max} = 7$ （共 16 个量化等级）。 ζ 为浮点仿射偏移（不同于第二章中常用整数 zero-point 符号 z ；本节用 ζ 强调其为浮点存储以避免与前文 attention output o 撞名），与整数 zero-point z 的关系为 $\zeta = -s \cdot z$ ；以浮点 ζ 存储可在反量化路径中省去额外整数偏移操作。 (p_K, p_V) 的来源按角色拆开： p_K 由 per-channel Key 路径的注意力分布 KL 搜索确定（参见第 3.4.1 节）， p_V 由 per-token Value 路径的输出扰动代理 $R_V(p_V)$ 确定，其形式为

$$R_V(p_V) = \mathbb{E}_{\mathcal{D}_{\text{calib}}} \sum_{h=1}^H \sum_{r=1}^S \left\| \sum_{t=1}^S a_{h,r,t} (V_{t,:} - \tilde{V}_{p_V,t,:}) \right\|^2, \quad (3-32)$$

其中 $a_{h,r,t}$ 是第 h 个注意力头从 query 位置 r 到 key 位置 t 的注意力权重，由 FP16 参考路径在校准样本上单独前向得到； $\tilde{V}_{p_V}$ 为按候选 p_V 反量化后的 Value。内层求和把 V 量化误差按 attention 加权聚合得到 query r 在头 h 上的输出扰动向量，外层在头与 query 位置上累加，期望在校准集 $\mathcal{D}_{\text{calib}}$ 与各层上取均值。该代理把 V 量化误差经注意力权重加权后聚合再取二范数平方，与第 3.5 节扰动分解中的 V 主导路径形式一致； $a_{h,r,t}$ 的快照来自 FP16 参考路径的独立前向，不与量化路径共享中间状态，保证代理的独立

性。 (p_K, p_V) 候选网格为 $\{95.0, 97.0, 99.0, 99.5, 99.9, 100.0\}$ ，由第 3.4.2 节的稳健选择规则筛选；K 侧以注意力分布 KL 为目标，V 侧以 R_V 为目标，两侧目标函数独立，仅在网格采样上保持一致。

由于 $\text{Percentile}(\cdot; 100) = \max$ 且 $\text{Percentile}(\cdot; 0) = \min$ ，端点

$$(p_K, p_V) = (100, 100) \quad (3-33)$$

正好对应 K 路径与 V 路径各自的 min-max 仿射端点。这也给出与 KIVI-style 对照的基准情形。KIVI-style 在运行时用 min/max 统计确定逐通道端点和逐 token 端点；INT4-RoleAlign 则先通过离线搜索选定百分位 (p_K, p_V) ，运行时仍针对当前张量统计对应百分位，并分别逐通道、逐 token 计算 (s, ζ) 。在该对照口径下，核心差异是端点参数来自运行时 min/max 统计，还是来自离线搜索得到的百分位；并不是一方运行时确定实际范围、另一方离线冻结实际范围。INT4-RoleAlign 在 $(50, 100]$ 内搜索可能相对 min-max 更稳健的百分位端点，受控比较见第 3.5.4 节。K 侧沿 token 维度聚合后按通道独立确定 (s_K, ζ_K) ，V 侧沿通道维度聚合后按 token 独立确定 (s_V, ζ_V) ；双轴非对称布局见图 3-5。

INT4-RoleAlign 的角色感知非对称量化轴




图 3-5 INT4-RoleAlign 的角色感知非对称量化轴。Key 侧沿 token 方向聚合、对每个 channel 单独确定非对称量化参数，以优先保持 attention ranking；Value 侧沿 channel 方向聚合、对每个 token 单独确定非对称量化参数，以适应内容侧的动态范围变化。

表 3-3 给出本路径进入第四章时的固定配置。Key 侧承担排序保持，Value 侧承担内容幅值适配。逐头温度校正非对称格式下未作主线收益来源，相关推导与溯源说明见附录第 A.8 节。

表 3-3 INT4-RoleAlign 的最终路径配置

路径	量化轴	参数	离线选择读数	运行时载荷
K-path	per-channel 非对称	p_K	注意力分布 KL 与尾部稳定性检查	冻结的 p_K ；运行时计算每通道 (s, ζ)
V-path	per-token 非对称	p_V	注意力权重加权 V 重建代理 R_V 与边界记录	冻结的 p_V ；运行时计算每 token (s, ζ)
补充诊断	per-head temperature	τ_h^{-1}	非对称格式下未作为主线收益来源	不进入默认运行时载荷

3.5.4 INT4-RoleAlign 与 KIVI-style 的设计差异

INT4-RoleAlign 与 KIVI-style 共享 per-channel Key + per-token Value 的低比特格式。第四章第 4.3.3 节的比较因此只关注参数来源与冻结时刻这两条变量，跨格式表现留给该节的格式族消融。

两者的分叉点在于量化端点的参数来源。KIVI-style 在运行时按 min/max 统计直接确定每通道与每 token 的端点，仅在初始化阶段固定 chunk 与 residual 缓冲长度等结构性超参数；INT4-RoleAlign 则在评测前以离线校准产物冻结 K/V 分路径的百分位参数 (p_K, p_V) 、轴元数据与边界记录，运行时按这组百分位逐通道、逐 token 重算 (s, ζ) 。Key 侧的百分位由注意力 KL 离线搜索确定，Value 侧引入独立的输出扰动代理，与 Key 校准流程解耦。为系统呈现这些设计选择，表 3-4 从格式、参数来源、行为代理、离线产物与分配读数五个维度展开。

表 3-4 INT4-RoleAlign 与 KIVI-style 在参数来源与冻结时刻上的设计差异

维度	KIVI-style	RoleAlign	边界读法
量化轴	per-channel K + per-token V	相同	共享低比特格式，比较聚焦于参数来源
参数来源	运行时 min/max 统计	离线 K/V 分路径搜索	比较锚定在参数来源与冻结时刻
行为代理	仅运行时统计驱动	K: 注意力分布 KL V: 输出扰动代理 R_V	两侧代理分开定义，校准逻辑可独立追溯
离线产物	结构超参数固定 (chunk size 等)，无固化校准文件	固化 K/V 校准产物	同一接口下可复核参数、轴与 percentile 边界
分配读数	设计上不输出共享画像	可输出共享读数	校准产物兼容第 3.6 节分配器接口；KIVI 路径下的画像化为后续工作

定量比较与跨模型表现见第四章第 4.3.3 节；本节只在方法层面厘清两者在 KV Cache 量化中的可控变量。

3.6 行为敏感度驱动中层间预算分配与 AutoK

第 3.4 节已经将行为引导原则落实为可执行的离线校准流程，第 3.5 节则给出了 INT8 基准路径与 INT4-RoleAlign 的跨位宽实例。在这一基础上，

本节把问题改写为预算选择问题——给定位宽约束下，由分配器决定哪些层或角色应被优先保护。校准层回答“如何量化”，分配层回答“哪里优先保护”；行为引导分配是校准产物的下游接口，不与校准路径竞争主轴。

为了统一记号，设共有 L 层，第 l 层的 Key 与 Value 位宽分别记为 $b_K^{(l)}$ 和 $b_V^{(l)}$ ，则平均 KV bit 预算可写为

$$\bar{b} = \frac{1}{2L} \sum_{l=1}^L (b_K^{(l)} + b_V^{(l)}). \quad (3-34)$$

在对称分配的特殊情形下，若 $b_K^{(l)} = b_V^{(l)} = b^{(l)}$ ，则有

$$\bar{b} = \frac{1}{L} \sum_{l=1}^L b^{(l)}. \quad (3-35)$$

后续分配器的任务，就是在给定 $\bar{b}$ 的前提下，为各层或各角色生成满足预算约束的位宽决策向量。

3.6.1 逐层敏感度构建与分配策略

本节推导主线 BA- k 分配器：以离线校准产物为输入，由逐层 K 侧角色尺度生成保护层集合。以 INT4-RoleAlign 为主实例，校准产物中存有逐层 K 侧 per-channel scale 范围张量

$$\sigma_K^{(l)} \in \mathbb{R}^{H_{kv} \times d_k}, \quad (3-36)$$

其中 H_{kv} 为 KV head 数， d_k 为 Key 通道数（沿用第 3.5.3 节 per-channel 非对称量化的通道分组）。该读数与第 3.4 节产出的角色尺度统计同源，与表 3-4 ”分配读数” 行描述的接口一致；整个分配阶段以离线读数驱动，不再对样本逐 token / 逐 head 计算注意力 KL。校准产物同时存有 V 侧读数 $\sigma_V^{(l)} \in \mathbb{R}^{H_{kv} \times S_{\text{cal}}}$ (S_{cal} 为校准集对齐后的 token 序列长度)，由 V 侧 per-token 范围在校准 token 维上排列得到（与第 3.5.3 节 per-token 量化轴一致），将在第 3.6.2 节角色感知扩展中使用。

第 3.2 节的 K-cliff 诊断给出本节代理的物理来源：在 Qwen 与 LLaMA 系列对称 INT4 场景中，K 位宽下降是触发分配崩塌的主导方向，因此本节以 K 侧角色尺度构建逐层画像，V 侧读数留作角色感知扩展使用。机制依据来自 Qwen 与 LLaMA 系列的单侧诊断；跨家族适用区间由第四章在

Qwen2.5、LLaMA-3.1 与 Mistral 三个模型族上分别读取。给定聚合模式 α ，第 l 层的逐层敏感度记为

$$s_\alpha^{(l)} = \text{Agg}_\alpha(\sigma_K^{(l)}), \quad l = 1, \dots, L, \quad (3-37)$$

其中 $\text{Agg}_\alpha : \mathbb{R}^{H_{kv} \times d_k} \rightarrow \mathbb{R}$ 在 head 与通道两轴上做一次性 max 或 mean 聚合。主线分配器固定 $\alpha = \text{max}$ ，对应”最脆弱读数主导”的保守口径，因此后文实验统一以 BA- k 命名； $\alpha = \text{mean}$ 作为聚合鲁棒性消融，留待第 3.6.3 节单独评估。整层画像记为有序序列

$$S_\alpha = (s_\alpha^{(1)}, s_\alpha^{(2)}, \dots, s_\alpha^{(L)}), \quad (3-38)$$

序列保留层索引位置，使下文 TopK 可以稳定返回层索引集合。

给定固定保护层数 k ，BA- k 分配器先选出保护层集合

$$\mathcal{P}_k^{(\alpha)} = \text{TopK}(S_\alpha, k) \subseteq \{1, \dots, L\}, \quad (3-39)$$

TopK 在敏感度并列时按层索引升序打破平局，使保护集合在复现中唯一确定。再把位宽决策写成两级向量

$$b^{(l)} = b_{\text{lo}} + (b_{\text{hi}} - b_{\text{lo}}) \mathbf{1}[l \in \mathcal{P}_k^{(\alpha)}], \quad (b_{\text{lo}}, b_{\text{hi}}) = (4, 8), \quad (3-40)$$

即未保护层落到 INT4，保护层升至 INT8。由 $|\mathcal{P}_k^{(\alpha)}| = k$ 与 $\sum_{l=1}^L b^{(l)} = (L - k)b_{\text{lo}} + k b_{\text{hi}}$ ，平均预算

$$\bar{b} = \frac{1}{L} \sum_{l=1}^L b^{(l)} = b_{\text{lo}} + \frac{k}{L} (b_{\text{hi}} - b_{\text{lo}}), \quad (3-41)$$

k 直接控制平均位宽 $\bar{b}$ 在 $[b_{\text{lo}}, b_{\text{hi}}]$ 上的位置。BA- k 在预算受限时保护行为代理最高的若干层；固定 k 网格由本节定义，跨模型 best- k 读数由第四章第 4.3.3 节报告。从离线读数 $\sigma_K^{(l)}$ 经聚合、覆盖度与 TopK 写入逐层位宽向量的整体流程，以及 K/V 角色接口的预留位置见图 3-6。

3.6.2 K/V 角色感知的预算扩展

第 3.2 节的 K-cliff 诊断揭示了 K 与 V 在低比特下的扰动不对称：K 侧主导排序崩塌，V 侧扰动经注意力权重稀释后影响较弱。BA- k 主线分配器

行为敏感度画像到预算分配

逐层分配给出主线, K/V 角色预算保留为接口扩展




图 3-6 行为敏感度画像到预算分配的图示。左侧主线从离线读数出发, 经层级聚合得到逐层敏感度画像, 并由 BA- k 、Heuristic- k 与 AutoK 三类策略写入逐层位宽向量。右侧给出 K/V 角色预算接口, 后续扩展可分别读取 $s_K^{(l)}$ 与 $s_V^{(l)}$, 形成角色保护集合与角色位宽对。

在保护层与未保护层各自统一两级位宽 $(b_{lo}, b_{hi}) = (4, 8)$, 未对 K/V 两侧的差异做进一步区分。本节把分配器扩展为 K/V 两侧独立的两级版本, 第 l 层的位宽决策从单值 $b^{(l)}$ 升为角色对

$$\mathbf{b}^{(l)} = (b_K^{(l)}, b_V^{(l)}). \quad (3-42)$$

沿用第 3.6.1 节的聚合记号, K/V 两侧的逐层敏感度读数分别由各自的角色尺度张量聚合得到

$$s_K^{(l)} = \text{Agg}_\alpha(\sigma_K^{(l)}), \quad s_V^{(l)} = \text{Agg}_\alpha(\sigma_V^{(l)}), \quad (3-43)$$

对应的整层画像写为有序序列 $S_{K,\alpha} = (s_K^{(l)})_{l=1}^L$ 与 $S_{V,\alpha} = (s_V^{(l)})_{l=1}^L$ 。此时 $S_{K,\alpha}$ 等同于第 3.6.1 节中由 $\sigma_K^{(l)}$ 主导的 BA- k 主线画像, $S_{V,\alpha}$ 是 V 侧并行扩展。

在固定保护层数 (k_K, k_V) 后, K/V 两侧分别按各自的画像选取保护集合

$$\mathcal{P}_K^{(\alpha)} = \text{TopK}(S_{K,\alpha}, k_K), \quad \mathcal{P}_V^{(\alpha)} = \text{TopK}(S_{V,\alpha}, k_V), \quad (3-44)$$

位宽决策仍取统一两级 $(b_{lo}, b_{hi}) = (4, 8)$

$$b_K^{(l)} = b_{lo} + (b_{hi} - b_{lo}) \mathbf{1}[l \in \mathcal{P}_K^{(\alpha)}], \quad b_V^{(l)} = b_{lo} + (b_{hi} - b_{lo}) \mathbf{1}[l \in \mathcal{P}_V^{(\alpha)}]. \quad (3-45)$$

由 $|\mathcal{P}_K^{(\alpha)}| = k_K$ 与 $|\mathcal{P}_V^{(\alpha)}| = k_V$ ，全局平均预算

$$\bar{b} = \frac{1}{2L} \sum_{l=1}^L (b_K^{(l)} + b_V^{(l)}) = b_{lo} + \frac{k_K + k_V}{2L} (b_{hi} - b_{lo}), \quad (3-46)$$

即角色感知扩展用 $(k_K + k_V)$ 替代 BA- k 中的单一保护层数 k 。当 $k_K = k_V = k$ 时退化为 BA- k 主线分配器；当 $k_K \neq k_V$ 时分配器可在不增加平均预算的前提下，把保护名额按 K/V 角色重新分配。

INT4-RoleAlign 的离线校准产物中已同时记录 $\sigma_K^{(l)}$ 与 $\sigma_V^{(l)}$ ，因此本节的角色感知预算可直接由现有产物驱动，无需额外校准开销。第四章的主线实验固定 $k_K = k_V = k$ 与 BA- k 一致，角色感知扩展作为接口预留进入第 3.7.1 节的产物清单；K/V 独立保护数的实证比较留待后续工作展开。

3.6.3 敏感度聚合与覆盖度准则

前两小节给出了由校准产物到逐层/角色感知预算的基本接口。本节把“画像形状”这一定性描述转写为可计算的覆盖度函数 $\Gamma(k)$ ，作为 AutoK 的输入。第 3.6.1 节定义的聚合算子 $\text{Agg}_\alpha : \mathbb{R}^{H_{kv} \times d_k} \rightarrow \mathbb{R}$ 在两轴上一次性归约（flat 聚合），即第 l 层敏感度

$$s^{(l)} = \text{Agg}_\alpha(\sigma_K^{(l)}) = \begin{cases} \max_{u \in \mathcal{U}_l} \sigma_{K,u}^{(l)}, & \alpha = \max, \\ \frac{1}{|\mathcal{U}_l|} \sum_{u \in \mathcal{U}_l} \sigma_{K,u}^{(l)}, & \alpha = \text{mean}, \end{cases} \quad (3-47)$$

其中 $\mathcal{U}_l = \{(h, j) : h \in \{1, \dots, H_{kv}\}, j \in \{1, \dots, d_k\}\}$ 。INT4-RoleAlign 校准产物中存储的 $\sigma_K^{(l)}$ 由非对称量化在 p_K 下确定的百分位端点区间 $[m_{l,j}^K, M_{l,j}^K]$ 各通道独立计算得到（跨通道聚合发生在后续 Agg_α 算子上），逐元素非负，因此 $s^{(l)} \geq 0$ 。BA- k 主线固定 $\alpha = \max$ ， $\alpha = \text{mean}$ 留作聚合敏感性的备用读数。

将 $\{s^{(l)}\}_{l=1}^L$ 归一化为概率分布

$$\tilde{s}^{(l)} = \frac{s^{(l)}}{\sum_{j=1}^L s^{(j)}}, \quad \sum_{l=1}^L \tilde{s}^{(l)} = 1, \quad (3-48)$$

当 $\sum_j s^{(j)} = 0$ （极端退化情形）时改取均匀分布 $\tilde{s}^{(l)} = 1/L$ 。把 $\{\tilde{s}^{(l)}\}$ 按值

降序映射为序数索引序列

$$\tilde{s}_{(1)} \geq \tilde{s}_{(2)} \geq \cdots \geq \tilde{s}_{(L)}, \quad \tilde{s}_{(i)} \equiv \tilde{s}^{(\pi(i))}, \quad (3-49)$$

其中 π 是把序数 i 映回原层索引的排列；并列值的内部排序按层索引升序确定，与第 3.6.1 节的 TopK 平局规则一致。累计覆盖度函数定义在 $k \in \{0, 1, \dots, L\}$ 上：

$$\Gamma(k) = \sum_{i=1}^k \tilde{s}_{(i)}, \quad \Gamma(0) = 0, \Gamma(L) = 1, \quad (3-50)$$

约定空和 $\sum_{i=1}^0 = 0$ 。 $\Gamma(k)$ 把画像形状直接转写为预算覆盖：敏感度集中在少数层的模型， $\Gamma(k)$ 在较小 k 处即接近 1；敏感度在层间更弥散的模型，达到同一覆盖阈值所需的 k 显著增大。集中型与弥散型画像在相同覆盖阈值 ρ 下推出不同最小保护层数 k^* 的直观对照见图 3-7。




图 3-7 敏感度覆盖度曲线示意，图中以保护层数 k 为横轴，以排序后前 k 层累计敏感度 $\Gamma(k)$ 为纵轴。给定相同覆盖阈值，集中型画像用较小的 k 即可达到目标覆盖度；弥散型画像则需要覆盖更多层。该示意说明 AutoK 依据画像形态生成预算建议的方式。

第 3.6.4 节随后给出 AutoK 的具体规则。该规则以 $\Gamma(k)$ 为依据，给出达到覆盖阈值所需的最小保护层数建议；覆盖度准则与 BA- k 方案因此读取同一份敏感度画像。

3.6.4 AutoK 的预算自动建议机制

BA- k 把人工选定的整数 k 作为保护层数，但不同模型的敏感度画像形状不一致，相同的 k 在画像集中模型与画像弥散模型上对应的行为覆盖差异显著。AutoK 直接读取第 3.6.3 节给出的覆盖度函数 $\Gamma(k)$ ，把“覆盖阈值”

作为外部超参数取代逐 k 网格扫描，从而把人工选 k 的环节折叠到画像曲线本身。AutoK 不是完全无超参的自动决策，而是把整数 k sweep 转换为覆盖率阈值 ρ 下的候选生成器——决策粒度从「逐模型逐 k 跑实验」转移到「按画像曲线一次写入 ρ 」，但 ρ 仍由设计者按部署目标在 $(0, 1)$ 内取值。

给定覆盖阈值 $\rho \in (0, 1)$ ，定义满足覆盖的最小保护层数

$$k^*(\rho) = \min\{k \in \{1, \dots, L\} : \Gamma(k) \geq \rho\}. \quad (3-51)$$

由 $\Gamma(0) = 0$ 与 $\Gamma(L) = 1$ ，集合非空， $k^*(\rho)$ 在 $\{1, \dots, L\}$ 上唯一存在；由于 Γ 是单调阶梯函数， $k^*(\rho)$ 满足 $\Gamma(k^*) \geq \rho > \Gamma(k^* - 1)$ ，即 ρ 不要求被等号命中。 $\rho = 1$ 退化为全层保护 $k^* = L$ ， $\rho \rightarrow 0^+$ 退化为单层保护 $k^* = 1$ ，故实践中 ρ 取自 $(0, 1)$ 的开区间，并在每个模型上按校准画像单独选定。AutoK 对应的保护集合写为

$$\mathcal{P}_{\text{AutoK}}^{(\alpha, \rho)} = \text{TopK}(S_{K, \alpha}, k^*(\rho)), \quad (3-52)$$

即在 BA- k 主线的 $S_{K, \alpha}$ 上把 k 替换为 $k^*(\rho)$ 。两级位宽向量沿用 $(b_{\text{lo}}, b_{\text{hi}}) = (4, 8)$

$$b_{\text{AutoK}}^{(l)} = b_{\text{lo}} + (b_{\text{hi}} - b_{\text{lo}}) \mathbf{1}[l \in \mathcal{P}_{\text{AutoK}}^{(\alpha, \rho)}]. \quad (3-53)$$

AutoK 与 BA- k 共享同一离线画像入口与同一保护规则；二者只在 k 的来源上不同，BA- k 取人工指定的整数，AutoK 取由 ρ 与 Γ 反推的最小整数。第四章主线实验取 $\rho \in \{0.80, 0.90\}$ ，每个模型按画像选定单值（具体读数见第 4.3.3 节）。

表 3-5 分配层策略的输入、选择规则与对应记号

策略	输入	保护规则	需扫整数 k ?	输出	实验记号	方法定位
Uniform	无	所有层统一默认低位宽	否	统一位宽向量	Uniform	低预算参考
BA- k	$(S_{K, \alpha}, k)$	保护敏感度最高的 k 层	是	分层位宽向量	BA- k	分层分配器主体
Heuristic- k	(L, k)	固定位置规则保护 k 层	是	分层位宽向量	Heuristic- k	位置先验基线
BA-AutoK	$(S_{K, \alpha}, \rho)$	取满足 $\Gamma(k) \geq \rho$ 的最小 k^*	否（仅 ρ 一次设定）	分层位宽向量	BA-AutoK	覆盖度预算建议

表 3-5 中 $S_{K, \alpha} = (s^{(l)})_{l=1}^L$ 为第 3.6.1 节定义的逐层 K 侧敏感度序列；Heuristic- k 作为 BA- k 的强基线对照在第 4.3.3 节定义具体位置规则。AutoK 的”无需扫描整数 k ”与 BA- k 的”按 k 网格扫描”在工程粒度上有数量级差

异：BA- k 在第四章按 $k \in \{1, 3, 5, 7, 11\}$ 等离散采样点逐点跑实验，AutoK 仅在校准期一次写入 ρ ， $k^*(\rho)$ 由画像曲线确定。该粒度差异不等同于完全无超参；AutoK 仍以 ρ 作为部署侧外部超参，整体定位为画像驱动的候选生成器，而非端到端自动决策。

3.7 系统级部署实现与开销分析

前述各节已经分别给出了行为引导校准目标、跨位宽路径实例以及预算分配接口。本节回答实现层问题：离线定义好的量化规则与预算决策如何进入推理系统。本节只定义离线校准产物、在线缓存写入语义、融合解码核函数数据流和理论开销；TPOT、性能交叉边界、不同模型之间速度优劣与部署建议，留到第四章的部署效率小节讨论。

3.7.1 离线校准产物与在线推理管线

行为引导框架沿用量化系统中常见的”离线校准、在线执行”两阶段分工：离线阶段以少量校准样本执行第 3.4 节定义的搜索与选择纪律，写出路径特定的校准产物；在线阶段直接载入这些产物并按既定规则执行量化写入。本节的增量在于把”行为代理驱动的参数搜索”对应的离线产物字段、缓存写入语义与解码路径接口梳理清楚，使后续融合核函数设计与第四章实验都能稳定挂接。

记路径相关的离线校准产物为

$$\mathcal{A}_{\text{path}} = \{\theta_{\text{path}}^{(l)}, m_{\text{path}}^{(l)}\}_{l=1}^L, \quad (3-54)$$

其中 $\theta_{\text{path}}^{(l)} \in \mathbb{R}^{n_l}$ 是第 l 层进入量化算子 Q 的参数向量（如逐通道 scale、percentile 选择记录、保护裕度）， $m_{\text{path}}^{(l)}$ 为不进入 Q 的工程元数据（如量化轴布局、group size、诊断读数），仅用于路由与复核。表 3-6 把字段拆成四类。

三条路径写入 $\mathcal{A}_{\text{path}}$ 的字段并不相同，具体对照见表 3-7。INT8 基准路径保存逐组静态 scale 与分组元数据，inv_tau 字段保留在产物中，但主线运行时将 use_attn_temperature 设为 false。对称 INT4 沿用这一字段组织，只把量化网格降为 4-bit。INT4-RoleAlign 则在量化参数字段中增加 K/V 两侧的 percentile 选择记录与轴向元数据。运行时再按 K/V 角色生成仿射参数。K 侧在预填充阶段依据冻结 percentile，用逐通道数据一次性计算 (s_K, ζ_K) ，

表 3-6 离线校准产物的运行时字段表

字段组	典型字段	读取模块	边界说明
路径索引	model id、layer id、K/V role	路径选择	决定缓存写入与解码路径的路由
量化参数	逐组 scale、percentile 选择记录（保护裕度由运行时配置提供）	缓存写入	评测前冻结离线规则；INT4-RoleAlign 的 K 侧 per-channel scale/zero-point 在 prefill 阶段一次性按数据现场计算后冻结复用，V 侧 per-token scale/zero-point 随每个新 token 写入时按 per-token 数据现场计算并写入缓存
轴元数据	group size、per-channel/per-token 标记、KV head 数	参考/融合后端	定义布局与 GQA 头数关系，作为接口契约存在
诊断记录	候选网格、保护触发标记、画像读数 $\sigma_K^{(l)}/\sigma_V^{(l)}$	复核脚本、第 3.6 节分配器	分配器仅读敏感度统计行；其余字段供溯源使用

之后保持不变并复用；V 侧在每个新 token 写入时，用逐 token 数据即时计算 (s_V, ζ_V) 。

在线推理接收第 t 个新 token 时，第 l 层的量化写入统一记作

$$\hat{x}_t^{(l)} = Q_{\theta_t^{(l)}}(x_t^{(l)}), \quad \theta_t^{(l)} = \begin{cases} \theta_{\text{path}}^{(l)}, & \text{对称路径，无自适应保护} \\ g_t(\theta_{\text{path}}^{(l)}, x_t^{(l)}), & \text{INT8 自适应保护} \\ h^{K/V}(\theta_{\text{path}}^{(l)}, x_t^{(l)}), & \text{INT4-RoleAlign} \end{cases} \quad (3-55)$$

这里， $\theta_{\text{path}}^{(l)}$ 是离线冻结的路径参数集合。对称路径对应静态尺度 scale，INT4-RoleAlign 对应冻结的 percentile 参数 (p_K, p_V) 、量化轴标记和边界元数据。 g_t 只读取当前 token 在该层待写入的张量与离线参数，并依据第 3.5.1 节的逐 token 最大值触发规则，通过自适应保护逻辑确定当前组 scale。 $h^{K/V}$ 描述 INT4-RoleAlign 在 K 和 V 两侧的运行时映射。K 侧在预填充阶段依据冻结 percentile，用逐通道数据一次性计算 (s_K, ζ_K) ，之后保持不变并复用；V 侧在每个新 token 写入时，用逐 token 数据即时计算 (s_V, ζ_V) 。

对任意 $t' < t$ ，第 t 步不会改写历史缓存项 $\hat{x}_{t'}^{(l)}$ ，缓存只按时间追加。多随机种子复现中的逐位一致结果，为写入过程确定且历史缓存封闭的语义提供了间接核验；第四章第 4.2.1 节给出固定协议得到的 INT8-Canonical 主线读数。自适应保护只在主线实验的 INT8-Canonical 路径中开启；其余对称路径使用常量 $\theta_{\text{path}}^{(l)}$ 。INT4-RoleAlign 按照 $h^{K/V}$ 给出的 K/V 两侧规则生成仿射参数，其中 K 侧在预填充后复用，V 侧随新 token 写入即时计算，不依赖自适应保护机制。

预填充时，当前块的 K/V 先按路径规则量化并写入缓存；解码阶段开始后，系统从历史量化缓存读取 K/V，并送入相应的注意力后端。这样的数据流把 Decode 路径的输入限定为固定产物和已经写入的历史缓存，也为

后续融合解码核直接消费量化缓存、避免反量化后的中间张量物化提供接口边界。

表 3-7 不同量化路径的离线产物、运行时缓存载荷与默认执行后端

路径	离线产物	追加写入	解码后端	边界说明
INT8	scale、保护裕度、轴元数据	INT8 K/V 与 scale	Triton 融合后端	主部署路径
对称 INT4	scale、轴元数据	packed INT4 K/V	参考实现或 Triton 试探	压力测试；解包计入成本
RoleAlign	(p_K, p_V) 、K/V 轴头数	K per-channel；V per-token	参考实现；融合扩展	质量核对优先；速度见第四章

3.7.2 Triton 融合解码核函数设计

自回归解码每前进一步只新增一个查询 token，但注意力仍需访问全部历史 KV Cache，主要瓶颈来自访存。朴素实现会先从低比特缓存取出 K/V，将其完整反量化为 FP16 中间张量，再交给标准注意力计算；这条路径功能正确，代价是中间张量物化和显存读写会随序列长度线性增长。INT8 路径采用基于 Triton^[13] 的融合解码核，把反量化、点积、online softmax 和输出累加放入同一条片上流水线，减少往返全局内存的数据量。

融合核按序列维度分块推进。每个块从量化缓存读取低比特 K_B, V_B 以及对应的缩放参数和元数据，在 SRAM 和寄存器等片上存储中完成解包和反量化，并直接计算当前查询向量与该块 Key 的点积 $z_i = qk_i^\top / \sqrt{d_k}$ ，其中 k_i 表示反量化后的第 i 个 Key 行向量。随后，核函数用在线 softmax 维护跨块递推状态^[11]。设第 r 个块的状态包含行最大值 $m^{(r)}$ 、归一化因子 $\ell^{(r)}$ 和归一化输出累加器 $o^{(r)}$ ，并令

$$m_B = \max_{i \in B} z_i, \quad B = \{\text{第 } r+1 \text{ 个块中的 token 索引}\}, \quad (3-56)$$

跨块更新写为

$$m^{(r+1)} = \max(m^{(r)}, m_B), \quad (3-57)$$

$$\ell^{(r+1)} = e^{m^{(r)} - m^{(r+1)}} \ell^{(r)} + \sum_{i \in B} e^{z_i - m^{(r+1)}}, \quad (3-58)$$

$$o^{(r+1)} = \frac{\ell^{(r)} e^{m^{(r)} - m^{(r+1)}} o^{(r)} + \sum_{i \in B} e^{z_i - m^{(r+1)}} v_i}{\ell^{(r+1)}}, \quad (3-59)$$

这里 v_i 表示反量化后的第 i 个 Value 行向量。上述递推与 FlashAttention 的 online softmax 等价；实现中保留非归一化累加器 $\tilde{o}^{(r+1)} = \ell^{(r+1)} o^{(r+1)}$ ，待全部块处理完后再除以 $\ell^{(\text{final})}$ ，从而避免逐步重复除法。

INT4 的表示形式减少了存储字节数，但解包开销也进入运行路径。nibble packing 将两个 4-bit 整数放入一个 8-bit 字节。写入 packed 缓存时，整数码值先平移到无符号 $[0, 15]$ 域再存入 nibble；非对称 INT4 使用 $[-8, 7]$ 的 16 级码本，对称诊断路径仍按前文 $q_{\max} = 7$ 的 $[-7, 7]$ 网格产生码值。读取时，核函数用位移和掩码拆出半字节，再还原为路径对应的有符号整数，并按对应参数反量化；对称路径使用 scale，INT4-RoleAlign 使用 (s, ζ) 。本文把执行路径分为两类。对称 INT4 诊断路径采用 wrapper 封装，先将 nibble 缓存批量反打包为 INT8 张量，再复用 INT8 融合核完成片上反量化、点积、online softmax 和输出累加。INT4-RoleAlign 的非对称融合扩展采用核内解包，核函数直接读取 K 侧逐通道与 V 侧逐 token 的 (s, ζ) ，在片上存储中完成 nibble 解包和非对称反量化，避免显式 INT8 中间张量物化。4-bit 载荷减少全局读取字节数，反打包和寄存器压力则会重新体现在每输出 token 的时间 TPOT 中。相关变体命名与角色见附录第 A.9 节，端到端 TPOT 数字见第四章第 4.5.1 节。

为兼容 GQA^[15]，融合核需要把 Query 头映射到共享的 KV 头。记 Query 头数为 H_q 、KV 头数为 H_{kv} ；本文涉及的 GQA 模型均满足 $H_{kv} \mid H_q$ 。重复因子定义为

$$N_{\text{rep}} = \frac{H_q}{H_{kv}}, \quad h_{kv} = \lfloor h_q / N_{\text{rep}} \rfloor. \quad (3-60)$$

核函数按 (B, H_q) 网格组织并行。每个 Query 头直接访问对应的 h_{kv} 切片，因此不需要把 KV 头显式复制成 H_q 个副本。这个寻址方式会影响块内访存合并、元数据广播和寄存器占用，并与反打包开销一起反映到 TPOT 中。

系统落地保留三类路径，各自承担不同验证目标。INT8-Canonical 基准路径由 INT8 融合核支撑，用来检验行为引导校准能否在保守位宽设置中形成稳定闭环。INT4-RoleAlign 的质量评估主线采用参考解码实现进行语义一致性核验；第四章 TPOT 表中的参考路径 INT4 列对应该类参考后端的时间口径。用于系统边界测量的 INT4 扩展区分格式对照和后端实现，并覆盖 KIVI-style 对照以及 Triton 融合后端读数。下一节转向三条路径在访存、存储和算力维度的开销分析。

3.7.3 复杂度、访存与存储开销分析

离线开销主要来自候选参数扫描。记候选集合规模为 $|\Theta_{\text{path}}|$ 、校准样本数为 N 、模型层数为 L 、Query 头数为 H_q 、每个样本的校准长度为 n ，头

维度为 d_k 。路径级离线搜索复杂度可记为

$$T_{\text{calib}}^{\text{path}} = \mathcal{O}(|\Theta_{\text{path}}| N L H_q n d_k), \quad (3-61)$$

式中采用 H_q 而非 H_{kv} ，是因为这一阶次描述注意力分布 KL 代理的主要计算；该代理逐 Query 头比较参考分布与量化分布。INT8 基准路径、对称 INT4 与 INT4-RoleAlign 使用同一搜索流程，但各路径的代理实例化并不完全相同。K 路径沿 KL 统计计算，V 路径按输出扰动代理统计；在主导阶次表示中，路径差异主要体现为候选集合规模差异，以及代理实现带来的常数项差异。

KV Cache 显存按“数据载荷 + 元数据载荷”分解。设 S 为当前缓存的序列长度，每元素数据字节为 b_{data} （FP16 取 2，INT8 取 1，INT4 packed 取 1/2），每组 scale 占 4 字节（FP32），group size 为 g （本文 INT8 路径取 $g = 128$ ，对称 INT4 路径取 $g = 32$ ，与第 3.5.1 节给出的实现默认一致）。FP16 参考开销

$$M_{\text{FP16}} = \underbrace{2}_{\text{K+V}} \cdot \underbrace{2}_{2 \text{ bytes/element}} \cdot L H_{kv} S d_k = 4 L H_{kv} S d_k. \quad (3-62)$$

对称 INT8 路径

$$M_{\text{INT8}} = 2 L H_{kv} S d_k \left(\underbrace{1}_{1 \text{ byte/element}} + \underbrace{\frac{4}{g}}_{\text{scale 摊销}} \right), \quad (3-63)$$

对称 INT4 路径

$$M_{\text{INT4}} = 2 L H_{kv} S d_k \left(\frac{1}{2} + \frac{4}{g} \right). \quad (3-64)$$

INT4-RoleAlign 不采用 per-group 元数据，K 侧 scale/zero-point 形状为 $[L, H_{kv}, d_k]$ ，V 侧 scale/zero-point 形状为 $[L, H_{kv}, S]$ ，因此其显存口径写为

$$M_{\text{RoleAlign}} \approx \underbrace{L H_{kv} S d_k}_{\text{packed K+V payload}} + \underbrace{8 L H_{kv} d_k}_{\text{K per-channel scale/zp}} + \underbrace{8 L H_{kv} S}_{\text{V per-token scale/zp}}, \quad (3-65)$$

其中 packed payload 由 K 与 V 各一份的 nibble 化字节构成（每元素 0.5 字节、合计 $L H_{kv} S d_k$ 字节）；K 侧 scale 与 zero-point 各占 4 字节、独立于 S ；V 侧 scale 与 zero-point 各占 4 字节、随 S 线性增长。该公式按实现口径给出方法层面的近似估计，第四章表 4-14 给出端到端实测显存读数。

decode 阶段的访存收益按 block 级字节量解释。设 block 大小为 B_s ，每个 block 的访存量在对称 INT8 与 INT4 路径下分别近似为

$$\text{Bytes}_{\text{INT8}} \approx 2B_s d_k \left(1 + \frac{4}{g}\right), \quad \text{Bytes}_{\text{INT4}} \approx 2B_s d_k \left(\frac{1}{2} + \frac{4}{g}\right), \quad (3-66)$$

块级浮点计算量按 $4B_s d_k$ 估计 ($qK^\top$ 与权重—Value 加和各贡献 $2B_s d_k$ 次乘加)，相应算术强度

$$AI_{\text{INT8}} \approx \frac{2}{1 + 4/g}, \quad AI_{\text{INT4}} \approx \frac{2}{1/2 + 4/g}. \quad (3-67)$$

代入 $g = 128$ 时 $AI_{\text{INT8}} \approx 1.94$ ， $g = 32$ 时 $AI_{\text{INT4}} \approx 3.20$ ，低比特融合路径在相同浮点计算下减少全局内存传输，从而缓解 decode 阶段的访存压力、提升 arithmetic intensity；与此同时，nibble 反 pack、调度与寄存器占用成为新的条件性开销，端到端 TPOT 边界由第四章第 4.5.1 节实测给出。

离线校准产物的存储相对运行时 KV Cache 与模型权重可忽略。对称 INT8 基准路径的产物规模为

$$\mathcal{O}(LH_{kv}d_k/g), \quad (3-68)$$

INT4-RoleAlign 产物由层级分位数参数与量化轴元数据构成；K 侧 per-channel scale/zero-point 在 prefill 阶段由数据现场计算后冻结复用，V 侧 per-token scale/zero-point 随追加 token 现场计算后入缓存，二者均不持久化到校准文件，因此离线产物规模量级与对称 INT8 同阶。第四章在上述公式基础上给出部署效率边界与跨硬件读数。

3.8 本章小结

本章先说明注意力误差怎样进入输出。第 3.1 节通过代数分解，把注意力近似误差写成分布侧扰动与聚合侧扰动；第 3.2 节再借助 K/V 对照诊断给出较窄的经验判断，Key 侧低比特扰动更容易触发断崖式失稳，Value 侧在本文对照中没有出现同等强度的退化。后续校准目标与分配规则，主要围绕这两条机制线索展开。

第 3.4 节把行为对齐具体化为注意力分布 KL 代理，并在候选参数搜索中加入稳健选择与回退规则。第 3.5 节继续把同一校准规则落实到三条跨位宽路径中。INT8 基准路径提供可信参考，对称 INT4 用来暴露低比特崩

塌方向，INT4-RoleAlign 则以逐通道 Key 与逐 token Value 的非对称量化缓解低比特失稳。该路径把离线百分位参数与轴元数据写入产物，运行时再按 K/V 两侧规则生成仿射参数；其退化幅度受模型族、规模与 GQA 配置共同调制，相关边界见第 4.3.3 节。与 KIVI-style 的对比限定在相同 K/V 轴布局与非对称仿射口径内，核心差异是端点统计规则。KIVI-style 在运行时用 min/max 统计确定端点，INT4-RoleAlign 使用离线选定并在评测前冻结的百分位参数，运行时仍按当前张量计算仿射参数，从而把校准来源差异与格式差异分开。

分配部分接着把校准产物转化为层级预算。第 3.6 节从逐层 K 侧角色尺度得到敏感度画像 $S_{K,\alpha}$ ，并据此定义 BA- k 主线分配器；归一化覆盖度函数 $\Gamma(k)$ 描述前 k 个保护层对敏感度画像的累计覆盖程度。给定覆盖阈值 ρ 后，AutoK 据此生成最小保护层数候选。第 3.7 节说明系统接口，列出离线校准产物字段、融合解码核接口，以及三条路径的访存和算术强度分解。第四章将基于这些固定接口报告质量保真、低比特路径的缓解效果与边界证据、跨模型策略的适用区间，并比较融合解码路径相对参考解码的 TPOT 等系统读数。

第四章 实验评估与策略适用区间分析

4.1 实验设置与可信性声明

本节只固定后文读数的可比口径。第四章随后报告的质量、长上下文和系统效率结果，都在这里列出的模型集合、任务协议、比较路径和数据溯源规则下解释；本节本身不报告实验结果。

具体设置按四个依赖项展开：第 4.1.1 节说明模型族、规模、GQA 配置与运行环境；第 4.1.2 节说明每个评测指标负责捕捉哪类失败模式；第 4.1.3 节固定后文比较对象及其控制变量；第 4.1.4 节说明哪些读数进入正文主证据，哪些读数只作为补充审计或协议一致性检查。

4.1.1 模型、硬件与实现环境

本文实验覆盖 Qwen2.5^[2]、LLaMA-3.1^[1] 与 Mistral^[43] 三个模型族，共六个开源指令模型，参数规模从 1.5B 延伸至 14B，同时覆盖 $H_{kv} = 2$ 、4 与 8 三种 GQA 配置。这个矩阵的作用是给后文三类变量留下观察空间：模型族差异、规模差异和 GQA 头数差异。所有模型的头维度统一为 128。

表 4-1 本章实验所用 6 个模型与 GQA 配置

模型	模型族	参数规模	GQA (H_q, H_{kv})	Layers	头维度	实验角色
Qwen2.5-1.5B-Instruct	Qwen2.5	1.5B	(12, 2)	28	128	INT8 基准路径与官方数据对照锚点
Qwen2.5-3B-Instruct	Qwen2.5	3B	(16, 2)	36	128	小模型分配策略剖面
Qwen2.5-7B-Instruct	Qwen2.5	7B	(28, 4)	28	128	同族补充对照
Qwen2.5-14B-Instruct	Qwen2.5	14B	(40, 8)	48	128	大模型分配策略剖面
LLaMA-3.1-8B-Instruct	LLaMA-3.1	8B	(32, 8)	32	128	中等规模与 $H_{kv} = 8$ 对照
Mistral-7B-Instruct-v0.3	Mistral	7B	(32, 8)	32	128	Mistral 家族分配策略剖面

表 4-1 只固定模型角色，不预告结果。Qwen2.5-1.5B-Instruct 用于基准路径和官方数据对照；Qwen2.5-3B-Instruct、Mistral-7B-Instruct-v0.3、LLaMA-3.1-8B-Instruct 与 Qwen2.5-14B-Instruct 分别承担后文典型剖面；Qwen2.5-7B-Instruct 提供同族补充对照。

所有实验均在单张 NVIDIA H20 GPU (98 GB HBM) 上完成。软件环境为 Python 3.12、PyTorch 2.8.0 (CUDA 12.8)、Transformers 与 Triton；完整依赖清单随复现材料发布。除特别说明外，生成式质量评测与吞吐量测试采用贪婪解码¹。PPL 使用固定输入序列上的 likelihood 累计，不涉及采

¹除特别说明外，生成式任务采用贪婪解码：temperature=0.0、top_p=1.0、top_k=0。

样解码。

4.1.2 评测任务、数据与指标

本章的指标按失败模式组织。PPL 观察固定窗口内语言建模概率质量的整体漂移, Needle-in-a-Haystack^[44] 以精确匹配通过率检查长距离目标片段能否取回, LongBench 风格合成任务用于比较任务级输出在同一评分管线内的相对变化, RULER^[45] 提供更高压力的长上下文组合能力检查; TPOT、KV Cache 占用与峰值显存则对应部署层代价。官方 LongBench 真实数据对照另置于第 4.2.2 节, 主要承担评测协议一致性检验与外部真实数据方向核验; 本节主评测矩阵仍以 LongBench 风格合成任务为核心。

PPL 用来观察固定窗口内的整体语言建模似然是否退化。本文统一采用 32K 上下文评测协议, 并将 `chunk_size` 固定为 128; 交叉熵累计时, 每个位置可访问的历史窗口受该设置约束。显存充足的模型按完整测试集协议报告 PPL; 14B 模型受 H20 显存约束, 只使用测试集固定前缀评测, 因此其绝对值仅用于该模型内部对照, 跨模型比较仍以同协议读数为准。

Needle-in-a-Haystack 关注目标片段能否被精确取回。评测覆盖 4K、8K、16K 与 32K 四个上下文长度, 并在各长度内按统一的 `needle` 深度设置扫描; 正文以精确匹配通过率作为主读数, 将其作为长距离目标片段取回能力的代理读数。

任务级主矩阵使用 LongBench 风格合成任务。正文主表聚焦 `task-core` 子集, 覆盖单文档问答、多文档问答和摘要三类功能; 问答任务采用 F1, 摘要任务采用 Rouge-L, 少量扩展任务采用 Edit Similarity 等文本相似度指标。这个协议用于在同一数据生成与评分管线内比较方法差异, 绝对分数只按本文协议解释, 不与社区官方榜单做直接对齐。

RULER 用宏平均通过率观察模型在组合式长上下文任务中的稳定性。与 Needle 的单点检索探针不同, RULER 更接近高压任务组, 两者在正文中承担互补角色。Needle 用于暴露检索功能临界点, RULER 则检查多个子任务中的长上下文能力是否同步退化。

系统效率部分保留三项读数。TPOT 对应解码阶段生成单个 token 的时间, KV Cache 占用对应缓存压缩收益, 峰值显存对应整体运行压力。第 4.5 节的部署结论限定在这三项指标与当前 H20 环境内解释。

4.1.3 比较方法与配置

表 4-2 中的每一类比较对象都承担一个控制问题。FP16 提供质量参考上界；percentile INT8/INT4 baseline 回答“只做数值截断会怎样”；INT8-Canonical 与对称 INT4 回答同一行为引导纪律在不同位宽下是否还能成立；INT4-RoleAlign 与 KIVI-style^[8] 固定在 per-channel K + per-token V 的同一非对称格式内，用于分离格式升级与离线校准来源的影响；MixedKV 只进入 K/V 角色诊断。

表 4-2 比较方法与配置总表

量化模式	校准理念	量化轴	Key bit	Value bit	默认后端
FP16	—	—	FP16	FP16	FP16
INT8 baseline	percentile	对称 per-group	8	8	参考实现 / Triton
INT8-Canonical	KL-guided	对称 per-group + 自适应保护	8	8	Triton
INT4 percentile baseline	percentile	对称 per-group	4	4	参考实现
对称 INT4 (behavior-guided)	KL-guided	对称 per-group	4	4	参考实现
INT4-RoleAlign	role-aware offline calibration	per-channel K + per-token V	4	4	参考实现
KIVI-style	runtime min/max	per-channel K + per-token V	4	4	参考实现
MixedKV	diagnostic	K8V4	8	4	参考实现

表 4-2 同时固定三个控制变量。校准理念区分 percentile、KL-guided、role-aware offline calibration 与 runtime min/max；量化轴区分对称 per-group 与非对称 per-channel K + per-token V；scale 时间语义区分离线固化与逐 token 更新；K/V 位宽混合作为单独的诊断维度，由 MixedKV 在 K/V 角色诊断中承担。后文的每个比较只在这些变量中读取其负责的问题，不把所有路径写成同一张胜负表。

两条边界在此固定。MixedKV 仅用于第 4.3.2 节的 K/V 角色敏感性诊断，不参与主线方法比较。逐头温度校正仅作为附录中的补充诊断变体，本章主线配置不使用该组件。

分配策略的比较不放入表 4-2。Uniform、BA-k、Heuristic-k 与 BA-AutoK 将在第 4.4 节按同量级预算带单独报告；其中 Heuristic-k 是位置先验基线，BA-AutoK 是画像驱动预算建议器，二者均按各自比较角色读取，不在设置节预设优劣。

4.1.4 统计检验、显著性与数据溯源

第四章的证据分三层读取。第一层是正文主结果：它们来自同一实验矩阵、同一解码设置和同一统计规则下重新执行并核验的读数。第二层是协议一致性或补充审计材料，例如第 4.2.2 节的官方 LongBench 小范围对照，以及附录中的完整 LongBench-style 聚合和上下文长度趋势。第三层是较早批次或回溯整理的补充读数；这类读数若进入正文，只在对应表注中说明来源和用途，不替代主结果承担结论权重。

随机性控制采用统一的固定种子与统一生成策略。生成式质量评测统一使用 5 个固定 seeds，吞吐量测试统一使用 8 个固定 seeds；生成式任务采用贪婪解码，从而将采样噪声从比较中剥离出去。PPL 评测采用固定输入序列上的确定性 likelihood 累计；seed 只用于实现路径一致性核验，不构成独立统计重复。在此基础上，质量指标的区间估计采用基于 10,000 次重采样的 95% Bootstrap 置信区间，配对比较采用符号翻转置换检验，多重比较则使用 Benjamini–Hochberg 控制假发现率。在小样本下，Bootstrap 区间稳定性与 sign-flip 检验 power 都有限，因此正文中的“未显著”应优先理解为当前样本下不可分辨，而不是正面证明“方法无差异”。

PPL 的读法需要单独说明：在固定输入序列、固定 tokenization、固定窗口与固定 loss mask 下，它是确定性 likelihood 指标，因此可靠性主要由协议一致性与效应量承担，而不是由 p 值承担。PPL 读数值幅度，不读统计显著性。任务级分数、吞吐量等会随种子或系统噪声波动的指标，才配合 Bootstrap、sign-flip 与 BH-FDR 一并解释。

后文所有主表、主图与典型剖面都按上述层级解释：不同协议之间的绝对分数不做直接横向比较；官方 LongBench 真实数据对照只承担第 4.2.2 节的一致性检验职责；完整 LongBench-style 聚合、统计检验汇总与上下文长度质量趋势保留在附录第 A.4 节，只作补充审计；部署效率结论限定于当前 H20 硬件、固定软件栈与当前后端组合。正文主结论只由统一协议下的主结果承担。

4.2 行为引导校准的保真度验证

第 4.1 节固定了实验口径，本节只回答一个较窄的问题：在最保守的 INT8 位宽上，离线行为引导校准是否会改变模型的任务行为。这里控制的变量是位宽和校准产物本身；低比特格式、预算分配和后端效率都留到后

续小节。

证据按两张表读取。表 4-3 比较 FP16 与 INT8 基准路径；表 4-4 检查三个官方 LongBench 任务上的方向。两者共同限定结论范围：本节验证基准位宽下的保真度，不把 INT8 结果用作低比特恢复或部署收益证据。

4.2.1 INT8 基准路径保真度

本小节只比较两条路径：未量化的 FP16 参考，以及使用离线行为引导校准产物的 INT8-Canonical。这张表不引入 INT4-RoleAlign 或 KIVI-style，因为它们会把低比特格式变量提前带入第一章研究问题 2 所对应的基准位宽验证。

表 4-3 INT8 基准路径保真度 (Qwen2.5-1.5B-Instruct)

任务	FP16	INT8-Canonical	Δ
NarrativeQA (F1)	7.07	7.16	+0.09
HotpotQA (F1)	4.90	4.88	-0.02
GovReport (Rouge-L)	9.21	9.20	-0.01
Mean	7.06	7.08	+0.02

注：本表聚焦 FP16 与 INT8-Canonical 两条基准路径，用于回答第 4.2 节的保真度问题；低比特路径的比较留待第 4.3 节在对应实验语境下讨论。

表 4-3 汇总了 Qwen2.5-1.5B-Instruct 在三个 task-core LongBench 风格合成基准任务上的基准路径读数。INT8-Canonical 相对 FP16 的平均差异仅为 +0.02，且差异方向并不一致：NarrativeQA 上为 +0.09，HotpotQA 上为 -0.02，GovReport 上为 -0.01。这种幅度很小、方向不一致的模式，更接近量化噪声下的微小波动，而不是系统性的行为偏移。

表 4-3 支持的最小结论是：在 Qwen2.5-1.5B-Instruct 的 task-core 协议内，INT8-Canonical 没有表现出相对 FP16 的系统性任务偏移。

这个结论只归属于校准产物本身，不归属于任何解码后端。Triton 融合核的系统收益只在第 4.5 节讨论。

4.2.2 评测协议一致性检验：官方 LongBench 真实数据对照

前文主矩阵中的 LongBench 评测均建立在 LongBench 风格合成基准任务之上。这样的主协议适合做 controlled comparison，但其绝对值不与社区官方榜单直接对齐。因此，在基准路径已经通过第 4.2.1 节立住之后，还需要一块范围受控的官方真实数据对照，检查本文主评测协议的方向性结论是否会被系统性带偏。

为此，本文从官方 LongBench^[46] 数据集中选取三个代表性子任务进行对照实验：NarrativeQA（单文档问答，F1）、HotpotQA（多文档问答，F1）与 GovReport（摘要，Rouge-L）。实验模型固定为 Qwen2.5-1.5B-Instruct，上下文截断至 4K，生成长度为 64，随机种子固定为 1234，每个任务最多采样 50 个官方样本；量化配置固定为 INT8-Canonical 主线配置。上述设定的作用，是对主文合成协议做一块最小但可信的一致性检查，而不是替代整章跨模型主实验。

表 4-4 官方 LongBench 真实数据对照（评测协议一致性检验）

官方任务	FP16	INT8-Canonical	Δ (pp)
NarrativeQA (F1)	7.07	7.13	+0.06
HotpotQA (F1)	4.90	5.27	+0.37
GovReport (Rouge-L)	9.21	9.25	+0.04
宏平均	7.06	7.22	+0.16

注：Qwen2.5-1.5B-Instruct，4K 上下文截断，seed=1234，生成长度为 64，每任务最多 50 个样本；数字取自 phase1_summary.csv（与第 4.2.1 节 task-core 合成基准属于不同评测数据集，不可与表 4-3 做绝对值并列读取）。本表仅用于评测协议一致性检验，不构成全面统计检验，也不进入主评测矩阵。

表 4-4 表明，官方真实数据上的单任务差异均控制在 0.4 pp 以内：NarrativeQA 为 +0.06 pp，HotpotQA 为 +0.37 pp，GovReport 为 +0.04 pp，宏平均相差 +0.16 pp。三者方向均为正，但绝对幅度仍处于 task-core 协议中观察到的量化噪声范围内。INT8-Canonical 在三个官方任务上未出现相对 FP16 的系统性退化；这一结果与第 4.2.1 节方向一致，更适合作为评测协议一致性检验，而不是官方真实分布上的显著性结论。

表 4-4 的作用是排除一个具体风险：主文合成协议没有在这三个官方任务上把 INT8-Canonical 的方向性结论反转。它不证明真实数据分布上的全面泛化，也不替代跨模型主矩阵。关于为何校准层采用 KL 而非 MSE，以及该选择在不同规模上的必要性差异，将在第 4.6.1 节中讨论。

本节的两张表把第一章研究问题 2 限定在基准位宽：INT8-Canonical 在主协议和小范围官方真实数据对照中都没有出现方向性偏移。下一节再讨论 INT4 下的失效与恢复。

4.3 低比特路径从对称失效到 RoleAlign 恢复

第 4.2 节只验证了 INT8 基准位宽。本节把控制变量切换到低比特路径：同一行为引导原则被压到 INT4 后，先看对称格式是否仍可用，再定位 K/V 哪一侧触发失效，最后在同一非对称格式内比较离线校准与运行时统计。

本节的证据锚点依次是表 4-5、表 4-6、表 4-7 与表 4-8。它们分别承担四个判断：对称 INT4 在部分架构上跨过功能临界点；Key 侧低比特噪声是更直接的触发源；K/V 角色差异能在任务指标上复现；共享格式下的 INT4-RoleAlign 与 KIVI-style 应按校准来源而非格式差异来读。

4.3.1 对称 INT4 的架构依附性失效与阶跃崩塌

INT8 基准路径的读数表明，行为引导校准可以在较保守位宽上保持任务行为；但当位宽继续压低到 INT4 时，同一对称量化思路并不会自动延伸成一条可用的低比特路径。当前证据更支持一种更强也更窄的判断：当有效量化等级从 INT8 的 255 个骤降到对称 INT4 的 15 个时，退化不再表现为温和的连续滑落，而会在部分模型上直接跨过功能临界点，出现检索能力从“可用”到“不可用”的阶跃式崩塌。与此同时，这种崩塌又并非对所有架构强度相同，因此本节将其表述为**架构依附性失效**。

表 4-5 对称 INT4 的阶跃崩塌摘要

模型	H_{kv}	FP16 Needle	对称 INT4 Needle	诊断标签
Qwen2.5-1.5B	2	100%	0%	阶跃崩塌；PPL 8.93 $\rightarrow$ 19.54
Qwen2.5-7B	4	100%	0%	阶跃崩塌；PPL 6.71 $\rightarrow$ 85.49
LLaMA-3.1-8B	8	100%	98%	架构例外；PPL 6.92 $\rightarrow$ 6.97

注：本表只汇总对称 INT4 的最小现象锚点。Needle 百分比为第 4.1.2 节定义的 exact-match 通过率，按 4K–32K 上下文与统一 depth sweep 汇总；生成式质量协议使用 5 个固定 seeds。PPL 列采用 phase5v2 主线统一协议 (WikiText-2, seq_len=32K, kv_cache 模式, chunk_size=128, 每条配置 ≥ 20 runs)，与表 4-8 所用的 hf-mode 长序列 likelihood 协议不同；两者各自内部自洽，不做跨表绝对值比较。Qwen2.5-1.5B/7B 出现“100% $\rightarrow$ 0%”的检索阶跃；LLaMA-3.1-8B ($H_{kv} = 8$) 作为架构例外保留 98% Needle。

表 4-5 给出了这一阶跃崩塌的最小证据。Qwen2.5-1.5B 与 Qwen2.5-7B 使用对称 INT4 时，Needle 由 100% 直接降至 0%，语言建模读数也同步出现明显退化；LLaMA-3.1-8B 仍保留 98% Needle。基于这一组对照，第 4.3.1 节给出的结论限定为**对称 INT4 会使一类模型出现架构依附性的阶跃崩塌**。这个读数将后续分析推向更结构化的问题，即量化格式如何匹配误差传播路径，而不仅是继续调整校准参数。

阶跃退化而非平滑退化，可以从 softmax 对 $QK^\top$ 分数的指数敏感性理解。在 Key 侧路径中，若量化噪声把目标 token 的分数推出 top- k 区域，softmax 会把概率质量快速转移到错误位置，检索结果便更容易形成从 100% 到 0% 的临界跳变，而不是 50%/30%/10% 这类线性衰减。LLaMA-3.1-8B 保留 98% Needle，这一读数与 $H_{kv} = 8$ 和较小 H_q/H_{kv} 重复因子对应的 GQA 噪声稀释条件相符；同时，模型族、规模和训练数据差异仍可能共同影响结果。更稳妥的读法是，LLaMA-3.1-8B 作为架构例外，极低比特 Key 噪声尚

未完全越过经验触发边界。接下来需要区分的是，这一崩塌首先由 Key 侧还是 Value 侧触发。

4.3.2 K/V 角色敏感性与 MixedKV 完整诊断

第三章第 3.2 节使用的是压缩诊断视图：K8V4 与 K4V8 对照同平均 bit 预算下的 K/V 角色，K4V4 提供对称低比特坍塌锚点。本小节回到完整证据，先用表 4-6 隔离 Key 与 Value 的单侧 PPL 影响，再用表 4-7 和图 4-1 检查同一方向是否出现在检索压测与任务级指标上。

表 4-6 的四个干预项分别回答两个问题：高精度 Key 或 Value 是否已经足够安全，极低精度 Key 或 Value 哪一侧会单独触发 cliff。后续任务级矩阵切换为 K-only / V-only / K4V8 / MixedKV；其中，第三章压缩视图中的 K8V4 与本节恢复性配置 MixedKV 对应，因此两处共享设计结论，但不要求图面逐项同构。

表 4-6 Key/Value 单侧干预的 PPL 诊断表 (Qwen2.5-1.5B-Instruct, WikiText-2, chunk_size=128)

消融配置	PPL ↓	相对 FP16 变化
FP16 (参考)	9.31	—
K8V16	9.33	+0.2%
K16V8	9.31	+0.0%
K4V16	1290.9	+13,774%
K16V4	9.35	+0.4%

注：PPL 为固定输入序列上的确定性 likelihood 指标，固定 seed=1234 报告；追加种子的数值与 1234 逐位一致，因此本表不适用 Bootstrap CI 或符号翻转检验。

表 4-6 先从语言建模层面给出最直接的诊断证据。在 Qwen2.5-1.5B 上，仅将 Key 压到 INT4 (K4V16) 就会把 PPL 从 9.31 推高到 1290.9，相对 FP16 达到 +13,774%；相比之下，仅将 Value 压到 INT4 (K16V4) 时，PPL 为 9.35，相对 FP16 仅增加 0.4%，而 K8V16 也只增加 0.2%。这说明对当前 low-bit path 而言，决定“是否越过功能临界点”的主要变量是 Key 侧位宽是否已经低到足以扰动 attention ranking 的区域。Key-first protection 的依据来自这组单侧干预证据。

表 4-7 K/V 消融多任务结果

Panel A. RULER 通过率 (%，32K，上下文)					
模型	FP16	K-only	V-only	K4V8	MixedKV
Qwen2.5-1.5B	24.38	24.61 ± 0.00	23.83 ± 0.39	0.00 ± 0.00	24.87 ± 0.20
Qwen2.5-7B	24.92	25.39 ± 0.68	25.13 ± 0.45	0.00 ± 0.00	25.16 ± 0.45
LLaMA-3.1-8B	31.48	29.82 ± 1.26	36.72 ± 1.56	31.12 ± 0.90	33.28 ± 0.75
Panel B. LongBench 风格合成基准任务综合评分 (×100，32K)					
模型	FP16	K-only	V-only	K4V8	MixedKV
Qwen2.5-1.5B	4.82	4.57 ± 0.01	4.54 ± 0.04	2.58 ± 0.08	4.47 ± 0.05
Qwen2.5-7B	3.78	4.10 ± 0.11	3.85 ± 0.02	0.80 ± 0.05	4.27 ± 0.06
LLaMA-3.1-8B	7.92	7.31 ± 0.43	6.21 ± 0.66	8.92 ± 0.79	7.42 ± 0.83

注：Panel A 为 RULER 宏平均通过率，Panel B 为 LongBench 风格 task-core 综合评分。Mistral-7B 的 LongBench 消融因合成数据源全部为 1.0、不具跨模型可比性，相关说明见附录第 A.7 节。本表用于同时呈现检索压测与任务级指标下的 K/V 角色诊断证据。

表 4-7 把同一诊断放到检索压测和任务级指标中。第一，K-only 的 RULER 贴近各自 FP16 基线，说明 INT8 Key 在该协议下不是主要风险源。第二，V-only 总体保持可用，说明单独压低 Value 不会触发表 4-6 中那类 PPL cliff。第三，K4V8 在 Qwen2.5-1.5B 与 Qwen2.5-7B 上把 RULER 打到 0%，而 LLaMA-3.1-8B 仍保留 31.12 的 RULER 与 8.92 的 LongBench-style 综合分；因此，Key 主导退化是共同方向，退化强度仍受模型族、规模与 H_{kv} 调制。

图 4-1 将 Needle、RULER 与 LongBench-style 放到同一位宽布局矩阵中。Qwen2.5-1.5B 与 Qwen2.5-7B 的共同模式是：K8V8 与 K8V4 大体保持可用，而 K4V8 和 K4V4 在 Needle 与 RULER 上直接跌入 cliff，LongBench-style 也同步下降。LLaMA-3.1-8B 则不表现出同强度 cliff：K4V8 在三类指标上仍接近高精度路径，K4V4 在 Needle 与 RULER 上也未出现同幅度坍塌；其 LongBench-style 高读数作为 synthetic task-core 的格式敏感结果保留在图中，但不用于支持“K4V4 优于 FP16”这一判断。由此，本图只支持一个受限结论：4bit Key 扰动在 Qwen 系列上会触发行为崩塌，但其强度受到模型族、规模与 H_{kv} 等架构因素调制。

图 4-2 从误差结构侧补充了这种架构依附性。配对热力图显示，在 MixedKV 配置下，Qwen2.5-1.5B 的高误差层段更早、更分散，而 LLaMA-3.1-8B 的误差峰值则更集中于后部层段，整体量级也更低。这张图不是 attention-KL 主指标的替代物，但它支持了与表 4-7 同方向的解释：在更高 H_{kv} 与更平滑的架构条件下，Key 量化噪声更不容易被放大成检索崩塌。

14B 补充对比只承担外推边界的提示作用。在 Qwen2.5-14B 上，保持 Key 为高精度的 K16V4 可将 PPL 从 full INT4 的 5.040 恢复到 4.709，约恢




图 4-1 K/V 角色敏感性的跨指标诊断图。子图 (a) – (c) 分别在 Needle、RULER 与 LongBench-style 指标上比较主要位宽布局；横轴为模型，折线表示不同位宽布局的原始分数。为避免完全重叠，部分标记做微小纵向避让，但折线仍连接原始读数。子图 (d) 汇总 K4V8 相对 K8V4 的下降幅度。Qwen 系列在 K4V8/K4V4 下出现 cliff，LLaMA-3.1-8B 不呈现同强度坍塌，因此该现象应理解为受架构调制的 Key-side low-bit 敏感性，并非所有模型同强度规律。

复 93% 的退化；保持 Value 为高精度的 K4V16 恢复到 4.813，约恢复 64%。这条补充读数与表 4-6 和表 4-7 同向，但不替代前三个模型上的主诊断。

本小节支持的最小结论是：在本文考察的 low-bit 场景中，首先越过功能临界点的是 Key 侧低比特噪声；MixedKV 的恢复说明低比特路径需要优先保护 Key，并在此基础上升级量化格式。

4.3.3 INT4-RoleAlign 与 KIVI-style 的跨模型对比

表 4-6 与表 4-7 已经把低比特失效定位到 Key 侧，因此本小节不再在对称 INT4 参数空间里继续比较。这里进入 per-channel K + per-token V 的同一非对称格式，并只比较两种实例化来源：离线 role-aware calibration 的 INT4-RoleAlign，以及运行时 min/max 的 KIVI-style。二者的设计差异已在第三章第 3.5.4 节固定，本小节只读取表 4-8 的同格式结果。




图 4-2 Qwen2.5-1.5B 与 LLaMA-3.1-8B 的配对 K/V 重建误差热力图 (MixedKV, K8V4, 32K 上下文)。上排为 Qwen2.5-1.5B, 下排为 LLaMA-3.1-8B; 左两列分别为 Key 与 Value 的逐层逐头重建误差, 右列为逐层平均误差曲线。统一色标显示: 相较于 Qwen2.5-1.5B, LLaMA-3.1-8B 的高误差层段更集中、整体误差更低, 与其更强的噪声稀释能力一致。

表 4-8 INT4-RoleAlign 与 KIVI-style 的跨模型主对比

模型	H_{kv}	FP16 PPL	KIVI-style PPL	RoleAlign PPL	Δ PPL	KIVI Needle	RoleAlign Needle
Qwen2.5-1.5B	2	9.31	10.43	10.58	+0.15	100/100%	100/100%
Qwen2.5-7B	4	7.14	7.53	7.58	+0.05	100/100%	100/100%
LLaMA-3.1-8B	8	6.73	6.90	6.90	+0.00	100/100%	100/100%
Qwen2.5-14B	8	4.68	—	5.04	—	—	100/100%

注 100/100% 表示 Needle-single-retrieval 与 MK-NIAH-2 两类检索任务均达到 100% 通过率; 生成式质量协议使用 5 个固定 seeds。Qwen2.5-14B 当前仅有 RoleAlign 结果, 因此不纳入配对差异判断。

表 4-8 的配对比较只覆盖 1.5B、7B 与 8B 三个模型, 14B 行用于标明当前 RoleAlign 覆盖范围。配对模型中, RoleAlign 相对 KIVI-style 的 PPL 差距分别为 +0.15、+0.05 和 +0.00, 两类 Needle 任务均恢复到 100%。这些读数支持的判断较窄。从对称逐组格式升级为 per-channel K + per-token V 后, 低比特检索由崩塌状态恢复到可用状态; 同一格式内, 不同校准来源对应的质量读数保持接近。

校准来源的差异仍然有方法层价值, 但表 4-8 未显示稳定、可外推的质

量分化。KIVI-style 在运行时根据 min/max 更新 scale; RoleAlign 则把 K-path 与 V-path 的分路校准结果固化为离线产物，并把同一产物继续交给第 4.4 节的行为引导分配器。因此，本小节读取的是“同格式恢复 + 离线产物组织”的组合，不将其读成跨模型无条件优越。

第 4.3 节支持的最小结论是三条。第一，表 4-5 显示对称 INT4 在 Qwen 系列上出现阶跃崩塌，但 LLaMA-3.1-8B 构成架构例外。第二，表 4-6、表 4-7 与图 4-1 将崩塌主因定位到 Key 侧低比特噪声。第三，表 4-8 表明共享非对称格式能够恢复检索可用性，而 RoleAlign 的独立价值主要在离线产物和后续分配接口。下一节据此转向一个新的问题：恢复后的行为敏感度画像能否支撑跨模型预算分配。

4.4 跨模型预算分配与策略适用区间

第 4.3 节已经确认，低比特路径可以在角色感知非对称格式下被恢复。本节进一步回答跨模型预算分配问题：由行为引导校准产出的敏感度画像，是否能够支撑跨模型预算分配，并读出稳定的策略适用区间结构。后文将分配器结果从若干跑分表整理为可命名的结构类型，同时避免把它们解释成跨模型单一策略排名。

为避免将 allocator 结果误读为单一策略排名，本节首先在同量级 INT4 预算带内给出跨模型主表，再通过四个典型剖面概括不同模型上的结构落点。这里所谓“策略适用区间”，指的是在给定模型族、规模与任务组合下，某类 allocator 策略更容易落在该模型的高性能区间；严格同预算优势判定留给后续协议。

4.4.1 同量级预算下的跨模型主表

本节先明确比较口径。表 4-9 报告的是同量级 INT4 预算带内的结构读数，不是严格同显存的 $\pm 3\%$ 对照。当前各 allocator 策略的平均位宽大致落在 4.5–5.0 bit 带内，而 uniform INT4 对应 $\bar{b} = 4.0$ bit，因此这里回答的是“在同一数量级预算内，不同分配风格会在不同模型上落到哪里”。严格同预算胜负判定属于后续比较协议，这也是本节与未来工作的分界线。

表 4-9 同量级 INT4 预算带内的跨模型主表

模型	任务/汇总	Uniform INT4	BA-k	Heuristic-k	BA-AutoK
Qwen2.5-3B ($H_{kv} = 2$)	NarrativeQA (F1)	4.33	7.17	3.08	6.48
	HotpotQA (F1)	2.38	4.73	1.39	4.89
	GovReport (Rouge-L)	5.77	8.81	5.96	8.90
	Mean	4.16	6.90	3.48	6.75
LLaMA-3.1-8B ($H_{kv} = 8$)	NarrativeQA (F1)	10.24	11.14	10.47	10.74
	HotpotQA (F1)	6.73	7.88	5.68	7.57
	GovReport (Rouge-L)	9.24	9.54	9.47	9.75
	Mean	8.74	9.52	8.54	9.35
Qwen2.5-14B ($H_{kv} = 8$)	NarrativeQA (F1)	7.05	6.67	6.83	6.80
	HotpotQA (F1)	5.57	5.49	5.40	5.39
	GovReport (Rouge-L)	9.09	8.95	9.03	9.27
	Mean	7.23	7.04	7.09	7.15
Mistral-7B-v0.3 ($H_{kv} = 8$)	NarrativeQA (F1)	15.55	15.71	17.11	16.26
	HotpotQA (F1)	17.81	17.78	17.84	19.08
	GovReport (Rouge-L)	8.70	8.66	8.86	8.96
	Mean	14.02	14.05	14.60	14.76

注：本表报告的是同量级 INT4 预算带内的跨模型读数，而不是严格同预算比较。各模型的 best- k 动态选择为：Qwen2.5-3B 用 $k = 1$ ，LLaMA-3.1-8B 用 $k = 11$ ，Qwen2.5-14B 用 $k = 7$ ，Mistral-7B 用 $k = 3$ ；AutoK 的覆盖阈值在 14B 上为 90%，其余模型为 80%。Uniform 指所有层 K/V 统一采用 INT4；BA-k 指 behavior-guided allocator 保护 top- k 高敏感层；Heuristic-k 指等距位置启发式保护；BA-AutoK 指根据覆盖率准则自动确定保护层数的 behavior-guided allocator。

表 4-9 的核心信息是四个模型的最佳策略家族并不一致：Qwen2.5-3B 的三任务均值最优落在 BA-k1，LLaMA-3.1-8B 的三任务均值最优落在 BA-k11，Qwen2.5-14B 的最高均值落在 Uniform，而 Mistral-7B 的三任务均值最优则落在 BA-AutoK。这些差异不能只靠敏感度画像的对应关系单独成立；它们还需要与图 4-3 中的保护层结构相互印证，而图 4-5 则把这种异质性整理为后续四个模型剖面的阅读路线。

图 4-3 把这种结构差异直接可视化。Qwen2.5-3B 的保护层明显前移并集中于最早层，说明其 sensitivity profile 呈现典型的 early-layer bottleneck；LLaMA-3.1-8B 与 Mistral-7B 则呈现中层簇集，说明在中等规模与特定家族上，关键层从单一首层扩展为一簇相邻高敏感层；Qwen2.5-14B 则近乎铺满全深度，表现为广泛铺展的 profile，说明大模型的行为敏感度已经弥散化。于是，“不同模型最优项不同”与 sensitivity structure 的差异相互印证。

图 4-4 与图 4-5 进一步把主表读成适用区间。Pareto 图说明同量级预算带内存在清晰的质量-预算局部几何：Mistral-7B 上 AutoK 区域最为突出，LLaMA-3.1-8B 上几种高性能策略形成近 Pareto 的局部簇；Qwen2.5-7B 的补充结果只作为 uniform policy 质量断崖的旁证，不进入后文四个模型剖面节。合并后的适用区间图承担两层作用：左图把四模型压缩成“每行一个高性能落点”的速览图，右图按 Mistral-7B、Qwen2.5-3B、LLaMA-3.1-8B 与




图 4-3 Behavior-guided AutoK 的逐层保护决策。四个子图分别对应 Qwen2.5-3B、LLaMA-3.1-8B、Qwen2.5-14B 与 Mistral-7B，展示覆盖率准则下各模型的保护层结构（覆盖阈值 14B 为 90%，其余模型为 80%，与表 4-9 注一致）。该图将跨模型主表背后的 sensitivity shape 直接可视化。




图 4-4 质量-预算 Pareto 视图。三个子图分别对应 Qwen2.5-7B、LLaMA-3.1-8B 与 Mistral-7B；横轴为平均 KV bit budget，纵轴为任务核心平均质量。该图用于可视化同量级 INT4 预算带下不同策略家族的局部几何关系，而不是严格的同预算比较。

Qwen2.5-14B 的后文顺序提示四个待展开结构类型，本小节只建立阅读顺序。position-based heuristic 在多个区间内与 behavior-guided 选中集合发生重合；这一强基线现象的结构性含义，将在第 4.6.3 节中进一步讨论。

4.4.2 Mistral-7B：AutoK 的单模型支持证据

Mistral-7B 被单独列出，是因为它提供了当前最清晰的 AutoK 单模型支持证据。该剖面回答一个较窄的问题：当敏感度画像本身具有可压缩的中层簇集结构时，覆盖度预算建议能否读出层间结构。




图 4-5 跨模型策略适用区间与模型适用区间速览。左图展示各模型在四类策略家族下的任务核心平均质量; 同一模型所在行内, 某一列颜色越深表示该策略越接近该模型的高性能区间, 但颜色不表示跨模型绝对质量可比。BA-AutoK 列虽然并非每行最深, 但整体处于相对深色区间, 因此可视效果较好的自动预算候选。实线边框标出每行最高落点, 虚线边框标出达到该行最高三任务均值 97% 以上的近簇。右图按后文模型分析顺序列出四类待展开结构类型, 作为第 4.4.2–4.4.5 节的阅读路线图。

表 4-10 典型剖面表 A: Mistral-7B 与 Qwen2.5-3B

Panel A. Mistral-7B: AutoK 的单模型支持证据						
任务	Uniform	BA-k3	Heuristic-k3	BA-AutoK (80%)	最优项	备注
NarrativeQA (F1)	15.55	15.71	17.11	16.26	Heur-k3	
HotpotQA (F1)	17.81	17.78	17.84	19.08	AutoK	
GovReport (Rouge-L)	8.70	8.66	8.86	8.96	AutoK	
DuReader (Rouge-L)	7.35	8.64	7.97	11.62	AutoK	增益最大
LCC (EditSim)	21.38	22.10	20.30	19.77	BA-k3	
Mean	14.16	14.58	14.42	15.14	AutoK	5-task mean
Panel B. Qwen2.5-3B: 早层保护有效区间						
任务	Uniform	BA-k1	Heuristic-k1	BA-AutoK (80%)	Quality Δ	备注
NarrativeQA (F1)	4.33	7.17	3.08	6.48	+4.09	提升
HotpotQA (F1)	2.38	4.73	1.39	4.89	+3.33	提升
GovReport (Rouge-L)	5.77	8.81	5.96	8.90	+2.85	提升
Mean	4.16	6.90	3.48	6.75	+3.42	差距最大

注: Panel A 来自 Mistral-7B-v0.3 的 5-task 扩展剖面; 摘要中使用的 core mean 为前三个 task-core 的 BA-AutoK 均值 14.76, extend mean 为 DuReader 与 LCC 两个扩展任务的 BA-AutoK 均值 15.69, 五任务均值为 15.14。Panel B 来自 Qwen2.5-3B 的 3-task task-core 剖面。Mistral 的 AutoK 覆盖阈值为 80%; Qwen2.5-3B 的 behavior-guided best-k 为 $k = 1$ 。本表由第 4.4.2 节与第 4.4.3 节共用, 并以双剖面块形式组织。

表 4-10 的 Panel A 显示, BA-AutoK 在 Mistral-7B 的五个任务中有三个任务给出最高读数, 并取得最高平均值。最明显的差异来自 DuReader: BA-AutoK 达到 11.62, 而 Heuristic-k3 为 7.97, 差距达到 3.6 分; 同时, 它在 HotpotQA 与 GovReport 上也给出最优读数。由于这些增益分散在多个任务上, 而不是由单一异常任务造成, 因此它们支持一种基于覆盖率的正向

解释，而不只是单个数据集上的偶然波动。

这一优势与图 4-3 中的敏感度画像是一致的。Mistral-7B 的重点保护层落在中前层簇集，且 80% 覆盖阈值选出的保护范围与这种簇集结构相吻合，因此 AutoK 在这里与覆盖率预算建议器所捕捉到的层间结构保持一致。于是，Mistral-7B 在本文中承担的是一个单模型实例：当画像具有可压缩簇集结构时，覆盖率预算建议器可以给出清晰正向信号。

4.4.3 Qwen2.5-3B：早层保护有效区间

Qwen2.5-3B 则承担了全文最清晰的行为引导策略与位置启发式差距剖面。它揭示了一类更窄但更重要的适用区间：当行为敏感度高度集中于最早几层时，保护正确的第一层会产生质量提升，而位置启发式若把预算投向“看起来更居中”的层，可能难以覆盖关键瓶颈位置。

表 4-10 的 Panel B 给出了这一点的主要数字支撑。对 BA-k1 与 Heuristic-k1 的直接比较表明，BA-k1 在 NarrativeQA 上高出 4.09 分，在 HotpotQA 上高出 3.33 分，在 GovReport 上高出 2.85 分，平均差距达到 3.42 分。这些差距对应于从低质量区间进入可用区间，因此应被读作早层保护带来的质量提升。

这一恢复性收益与图 4-3 的 3B 结构读数一致。Qwen2.5-3B 的敏感度画像明显前移，top protected layers 集中在最早层；BA-k1 保护的是 layer 0，而 Heuristic-k1 的单层保护则落在中层，因而偏离瓶颈层。3B 定义了一种更精确的适用区间：当行为敏感度在最早几层高度集中时，位置启发式可能偏离关键层，而行为引导保护可以产生恢复性收益。

4.4.4 LLaMA-3.1-8B：中等规模共识区间

LLaMA-3.1-8B 是当前主线中的一个重要模型案例。跨模型主表已经显示出足够清晰的结构信号：最佳平均值落在 BA-k11，同时 BA-AutoK 与其它高性能策略距离并不远。因此，本节将这行结果展开为一个可单独讨论的结构区间。

表 4-11 典型剖面表 B: LLaMA-3.1-8B 与 Qwen2.5-14B

Panel A. LLaMA-3.1-8B: 中等规模共识区间						
任务	Uniform	BA-k11	Heuristic-k11	BA-AutoK (80%)	最优项	备注
NarrativeQA (F1)	10.24	11.14	10.47	10.74	BA-k11	
HotpotQA (F1)	6.73	7.88	5.68	7.57	BA-k11	
GovReport (Rouge-L)	9.24	9.54	9.47	9.75	AutoK	
Mean	8.74	9.52	8.54	9.35	BA-k11	共识高性能区间
Panel B. Qwen2.5-14B: 高性能簇共存而无稳定最优						
任务	Uniform	BA-k7	Heuristic-k7	BA-AutoK (90%)	gap_{rel}	备注
NarrativeQA (F1)	7.05	6.67	6.83	6.80	3.55%	top-3 聚簇
HotpotQA (F1)	5.57	5.49	5.40	5.39	3.05%	top-3 聚簇
GovReport (Rouge-L)	9.09	8.95	9.03	9.27	2.59%	top-3 聚簇
Mean	7.23	7.04	7.09	7.15	3.06%	max $\approx$ 3.5%

注: Panel A 展示 LLaMA-3.1-8B 的中等规模共识区间; Panel B 展示 Qwen2.5-14B 的高性能策略簇。Qwen2.5-14B 的 $gap_{rel}(t) = (top1(t) - top3(t))/top1(t)$ 最大约 3.5%, 平均约 3.0%。在当前统计功效下, 14B 的高性能策略更适合解释为近似不可分辨的策略簇, 而不是稳定单一最优。

表 4-11 的 Panel A 表明, LLaMA-3.1-8B 的确存在一个较明确的 BA-k11 结构落点: NarrativeQA 与 HotpotQA 上 BA-k11 都给出最优读数, GovReport 上则由 BA-AutoK 略占优势, 最终平均值由 BA-k11 取得最优。它与 BA-AutoK 之间的差距非常有限; 再结合图 4-4 中近 Pareto 的局部几何关系, 更合理的读法是: LLaMA-3.1-8B 所代表的, 是一个 共识高性能区间, 而不是单点独占。

这一命名与其敏感度画像形状也是一致的。与 Qwen2.5-3B 的尖锐前层集中不同, LLaMA-3.1-8B 的最佳保护范围已经扩展到更广的中层簇集, $best-k = 11$ 本身就意味着“单点保护”不再是合理抽象; 但与此同时, 它又不像 Qwen2.5-14B 那样弥散到几乎全深度广泛铺展。因此, LLaMA-3.1-8B 最适合被命名为 中等规模共识区间: 存在一个相对稳定的 BA-k 结构落点, 但其它高性能策略并未远离。它在本文中还承担一个更克制的对照角色: 其 $H_{kv} = 8$ 设置与较平滑的分配器响应同时出现, 可作为 GQA 架构稳健性的补充剖面, 但不能升级为“更高 H_{kv} 必然导向更优策略”的强结论。

4.4.5 Qwen2.5-14B: 高性能簇共存而无稳定最优

Qwen2.5-14B 提供的是第 4.4 节的边界剖面: 并非每个模型都会给出清晰最优项。它在跨模型主表中的最高均值落在 Uniform, 但这一读数如果被直接概括为“Uniform 最优”, 就会弱化 14B 的结构形状。对于这个模型, 更关键的事实在于几类高性能策略彼此接近, 以至于在当前证据下更适合被读成近似持平的策略簇。

表 4-11 的 Panel B 直接支持这一点。三个任务上四类策略的数值都非常接近，按照 $gap_{rel}(t) = (top1(t) - top3(t))/top1(t)$ 的定义，NarrativeQA、HotpotQA 与 GovReport 的 top-3 相对 top-1 gap 分别约为 3.55%、3.05% 与 2.59%，平均值约为 3.06%。这意味着 14B 的 top-3 策略全部位于 top-1 的 3.5% 相对距离内。基于这些相对差距，更稳的解释应写成：**14B 当前呈现出一个高性能策略彼此接近的簇，尚未形成稳定单一最优。**

这种近似持平的格局与图 4-3 的广泛铺展画像是一致的。Qwen2.5-14B 的敏感度画像已经近乎铺满全深度，AutoK 在 48 层中标出 42 个受保护层，说明少数关键层不足以解释该模型的分配结果。正因为画像本身已经高度弥散，分配器在当前预算区间中的选择顺序只会带来有限边际影响。于是，14B 留下的结构结论应写成：**高性能簇共存而无稳定最优。**

回到图 4-5 的右图，第 4.4 节的四个模型剖面最终对应四类结构类型：Mistral-7B 提供 AutoK 的单模型支持证据，Qwen2.5-3B 是早层保护有效区间，LLaMA-3.1-8B 是中等规模共识区间，Qwen2.5-14B 则表现为高性能簇共存而无单一最优。这个读数把跨模型预算分配问题收束到更具体的判断：行为敏感度画像可以在同量级预算带内组织预算选择，并把不同模型的结构落点区分出来。下一节将不再继续讨论质量适用区间，而转向这些路径在真实推理系统中的时间与显存边界。

4.5 部署效率评估

第 4.2–4.4 节已经分别回答了基准保真、low-bit 恢复与跨模型策略适用区间。本节转向部署层，考察这些路径在真实推理系统中的时间与显存代价。本节不再重复第三章关于 kernel 设计与离线校准产物的实现细节，而是聚焦一个更务实的问题：**在什么条件下，当前低比特部署路径能够带来部署收益；在什么条件下，其收益会受到限制。**

为此，本节按“入口读数 → 长序列放大 → 经验边界 → 部署建议”的顺序组织。首先，第 4.5.1 节给出 4K 序列下的后端路径入口读数，避免把任何后续加速误读为无条件现象；随后，第 4.5.2 节展示长序列下融合路径收益如何随上下文增长而放大；在此基础上，第 4.5.3 节将这些单点与单模型结果整理为一条可读出的性能交叉边界；最后，第 4.5.4 节用 KV Cache 显存压缩率与当前硬件约束将系统层结论收束为当前平台上的部署建议。

4.5.1 4K 序列下的 TPOT 对比

短上下文入口层的读数是部署判断的起点。4K 序列既是常见的部署长度点，也是判断固定 kernel 开销是否已经值得付出的最低长度点。因此，本小节只给出各后端路径在当前硬件与 batch 设定下的入口层读数：哪些模型上 Triton 融合路径仍受固定调度开销影响，哪些模型上它已经开始逼近甚至略微越过参考路径。

表 4-12 4K 序列下的 TPOT 对比（生成长度 128，batch size 为 1，NVIDIA H20；单位：ms）

模型	H_{kv}	FP16	参考路径 (INT4)	KIVI(INT4)	Triton 融合路径 (INT4)	FlashInfer(INT4)	最快项
Qwen2.5-1.5B	2	24.36	36.35	36.39	38.68	43.73	参考路径
Qwen2.5-7B	4	24.82	37.61	37.41	38.76	47.07	KIVI
LLaMA-3.1-8B	8	28.55	44.88	44.70	44.49	51.50	Triton 融合路径
Qwen2.5-14B	8	42.58	68.07	68.46	67.67	85.07	Triton 融合路径

注：粗体标注同模型 INT4 后端路径中的最快项。所有 TPOT 读数按第 4.1.4 节的吞吐量协议使用 8 个固定 seeds，表中不单独报告 CI；该表作为第 4.5.1 节的入口层对照，不用于宣称 4K 已形成加速收益；收益边界需结合后续长序列读数与性能交叉边界共同解释。

表 4-12 给出三类清楚但应被克制解释的现象：

- 在 $H_{kv} = 2$ 的 Qwen2.5-1.5B 上，Triton 融合路径录得 38.68 ms，高于参考路径的 36.35 ms。
- 在 $H_{kv} = 4$ 的 Qwen2.5-7B 上，Triton 融合路径录得 38.76 ms，也高于参考路径的 37.61 ms。
- 只有在 $H_{kv} = 8$ 的两种模型上，Triton 融合路径才开始成为该模型下最快的 INT4 后端路径。对 LLaMA-3.1-8B 与 Qwen2.5-14B，其 TPOT 分别为 44.49 ms 与 67.67 ms。

4K 入口层的读数不应被写成“融合路径已经普适占优”；它只是一个前置信号：当 H_{kv} 较小、Grid 规模不足时，Triton 的固定调度开销仍然可见，而在 $H_{kv} = 8$ 上，融合路径已开始逼近甚至轻微越过参考路径，但清晰优势仍要到长序列下才能被放大。

4.5.2 长序列 TPOT 扩展规律

如果 4K 入口层只是一个“优势可能开始出现”的信号，那么长序列读数才适合判断融合路径是否具备部署价值。这里选择 Qwen2.5-14B 作为主要观察对象，原因在于它在 $H_{kv} = 8$ 下已经显现出明确的正向趋势，同时长上下文下 memory traffic 足够重，适合观察融合路径是否会随着历史 KV 的增长而放大收益。

表 4-13 部署边界综合表

Panel A. 14B 长序列 TPOT (生成长度 64, 10 次运行, H20; ms)						
执行路径	4K	8K	16K	32K	Δ vs. 参考路径	备注
FP16	42.28	42.81	42.64	43.13	–	baseline
参考路径 (INT4)	68.17	86.08	119.83	190.23	–	reference
KIVI (INT4)	68.07	86.02	121.49	187.82	–	runtime baseline
Triton 融合路径 (INT4)	67.73	71.53	86.56	113.16	4K: -0.44 8K: -14.54 16K: -33.26 32K: -77.08	fused path
Panel B. 跨模型性能交叉边界 ($\Delta T = T_{\text{Triton}} - T_{\text{ref}}$; ms)						
模型	H_{kv}	ΔT 4K	ΔT 8K	ΔT 16K	ΔT 32K	备注
Qwen2.5-1.5B	2	+1.67 n.s.	+4.23	+9.78	+15.92	始终更慢
Qwen2.5-7B	4	+1.03 n.s.	+1.56 n.s.	+0.55 n.s.	-4.90	32K 交叉
Qwen2.5-14B	8	-0.44 n.s.	-14.54	-33.26	-77.08	8K 起加速

注 Panel A 与 Panel B 共享生成长度 64 协议 (10 次运行), 与表 4-12 的入口层 (生成长度 128) 不同, 因此同模型 4K 处的 ΔT 与从表 4-12 推出的差值略有不同。Panel A 与 Panel B 分别对应第 4.5.2 节与第 4.5.3 节。这里的“性能交叉边界”是经验读数, 并非理论闭式模型; 8B vs 14B 的同 $H_{kv} = 8$ 控制对比不单独列成表, 而在第 4.5.3 节正文作为补充段落报告。所有长度点上 $|\Delta T| < 2 \text{ ms}$ 的读数统一标记为 n.s., 不作为交叉点读取。

表 4-13 中 Panel A 的读数表明, 融合路径的部署价值主要随序列长度拉长显现, 4K 单点仅能作为噪声范围内的参照。Qwen2.5-14B 采用 Triton 融合路径时, 相对参考路径的时间差在 4K 仅为 -0.44 ms; 序列长度增至 8K 后, 时间差扩大为 -14.54 ms, 16K 为 -33.26 ms, 32K 为 -77.08 ms, 对应约 -17%、-28% 和 -40% 的相对降幅。这个趋势在本组长度点保持单调。8K 之后, 历史 KV 越长, 融合路径相对参考路径的时间优势越明显。据此, 第 4.5.2 节只支持一个有边界的最小结论, 即在 Qwen2.5-14B、H20、batch=1 与当前后端组合这一适用条件内, 访存流量上升后, 融合路径的带宽节省能够逐步压过固定调度开销。

4.5.3 性能交叉边界与 GQA 影响

第 4.5.1 节给出入口层读数, 第 4.5.2 节给出单模型的扩展证据; 本节把这些读数整理成一条可命名的经验边界。这里的“性能交叉边界”严格指经验量 $\Delta T = T_{\text{Triton}} - T_{\text{ref}}$ 的符号变化, 并非理论闭式模型或严格因果识别。对所有长度点上 $|\Delta T| < 2 \text{ ms}$ 的情况, 本文统一视为 n.s.; 因此本节关心的是融合路径何时进入可读出的加速区间, 以及这条边界如何随 H_{kv} 与序列长度共同移动。

表 4-13 的 Panel B 给出三条边界路径。对于 Qwen2.5-1.5B ($H_{kv} = 2$),

ΔT 在 4K/8K/16K/32K 上分别为 +1.67 / +4.23 / +9.78 / +15.92 ms，说明融合路径在全长度下都不划算；对于 Qwen2.5-7B ($H_{kv} = 4$)， ΔT 在 4K/8K/16K 仍为正或近似零，直到 32K 才降为 -4.90 ms，说明交叉点被推迟到更长序列；而对于 Qwen2.5-14B ($H_{kv} = 8$)， ΔT 从 8K 起越过 n.s. 区间，并在更长上下文下继续扩大。由这三条路径可读出的经验边界是：在当前硬件与后端组合下， H_{kv} 越高，交叉点越早；序列越长，融合路径越容易进入收益区间。

同 $H_{kv} = 8$ 的 8B 与 14B 对照仍然是本节的重要补充证据。LLaMA-3.1-8B 与 Qwen2.5-14B 虽然参数规模相差约 1.75 倍，却共享相同的 $H_{kv} = 8$ ；以表 4-12 的入口层读数（生成长度 128）为统一协议，两者在 4K 处的交叉幅度高度一致，分别为 -0.39 ms 与 -0.40 ms。这支持一种更稳的结构性读法：相较于参数量， H_{kv} 更接近当前交叉边界的主导相关变量。但由于当前模型集合中 H_{kv} 与规模并未被完全独立控制，这里仍只能写成相关性支持，而不能上升为严格的因果结论。

因此，第 4.5.3 节保留下来的系统读数是一条经验边界： $H_{kv} = 2$ 基本落在融合路径不划算区， $H_{kv} = 4$ 只有到很长序列才越过边界， $H_{kv} = 8$ 则在较早长度点进入收益区间。部署路径的选择因而不应按模型名字决定，而应按 H_{kv} 与序列长度是否已经越过性能交叉边界决定。

4.5.4 KV Cache 显存压缩率与部署建议

速度边界只给出了一半答案。对于长上下文部署而言，低比特路径是否值得采用，还取决于它在缓存存储上的直接收益是否可预期。为此，本节最后报告 KV Cache 显存压缩率，并在时间边界与硬件约束共同作用下，将系统层结论转写成当前平台上的经验部署建议。本小节只保留一张正式表，部署建议不再单独成表。

表 4-14 KV Cache 显存压缩率对比（4K 序列，batch size 为 1，仅统计 KV Cache，占用单位：MB）

模型	H_{kv}	FP16 KV Cache	INT4 KV Cache	压缩率	备注
Qwen2.5-1.5B	2	115.5	30.7	73.4%	
Qwen2.5-7B	4	230.9	61.5	73.4%	
LLaMA-3.1-8B	8	527.9	140.5	73.4%	
Qwen2.5-14B	8	791.8	210.8	73.4%	

注：本表只统计 KV Cache，占用不包含模型权重与激活峰值；因此它服务于缓存压缩率判断，而不适用于替代完整的运行时峰值显存分析。相应部署建议见第 4.5.4 节正文结尾。

表 4-14 表明，INT4 路径在四个代表性模型上都实现了近乎相同的缓存压缩率：Qwen2.5-1.5B 从 115.5 MB 压缩到 30.7 MB，Qwen2.5-7B 从

230.9 MB 压缩到 61.5 MB, LLaMA-3.1-8B 从 527.9 MB 压缩到 140.5 MB, 而 Qwen2.5-14B 从 791.8 MB 压缩到 210.8 MB, 压缩率均约为 73.4%。这说明在当前 INT4 路径下, KV Cache 的显存收益是稳定且可预估的; 它不是只对某个模型成立的偶然现象。

把这一点与前文的时间边界合起来, 就得到一个关键部署判断: INT4 路径带来的显存节省是可预期的容量收益, 而融合 decode 路径的速度收益是条件性收益。部署选择应在既定压缩前提下判断何时切到融合后端路径更划算。在当前 NVIDIA H20 (sm_90, 130 SM, 98 GB HBM) 平台上, 更稳的经验规则是: 当 $H_{kv} = 8$ 且序列长度达到 8K 及以上时, 优先选择 Triton 融合路径; 对于 $H_{kv} = 4$ 的模型, 只有在很长的序列区间 (如 32K 附近) 才值得切换; 当 $H_{kv} = 2$ 或序列长度短于 8K 时, 优先使用参考路径。这些建议严格限定于当前硬件、当前软件栈与当前后端组合; 跨硬件、跨 batch 或更换 backend 后, 性能交叉边界需要重新测量。

附录第 A.5 节进一步给出 Qwen2.5-1.5B 设置下的 batch 维度容量边界、吞吐与显存扩展读数, 用于补充审计本节部署建议的适用范围。

本节由此限定了第四章的系统层边界: INT4 的 KV Cache 显存收益是可预期的容量收益, 而 Triton 融合路径的时间收益取决于 H_{kv} 与序列长度是否已经越过性能交叉边界。下一节转入对这些结果为何呈现出当前形状的机制辨析。

4.6 实验结果讨论与效度威胁

第 4.2–4.5 节已经分别回答了基准路径保真、低比特恢复、跨模型策略适用区间与部署效率边界。本节据此讨论这些结果的机制含义及适用边界。下文依次讨论 KL 与 MSE 校准目标、INT4 结果的分层机制、heuristic 强基线以及效度威胁。

4.6.1 KL 与 MSE 校准目标的规模依赖性机制辨析

在 INT8 基准路径已经通过第 4.2.1 节与第 4.2.2 节立住之后, 读者自然会追问: 既然当前主线校准目标写成 KL, 为什么这里不是更常见的 MSE 或其它数值重建代理? 这个问题不属于第三章的方法定义层, 而属于第四章的必要性边界层。第三章第 3.4 节负责回答“为什么 KL 可作为行为代理”; 本节要回答的则是: 在什么条件下, 这个代理更必要; 又在什么条件下, 它会与数值代理趋同。

表 4-15 7B 上 KL 与 MSE 校准目标的趋同验证

设置 / path	KL-selected params	MSE-selected params	参数是 否趋同	KL 结果 (PPL)	MSE 结 果 (PPL)	Δ
Qwen2.5-7B-Instruct, INT4-RoleAlign	(100.0, 99.9)	(100.0, 99.9)	是	7.1121	7.1121	0.00

注：本表由附录第 A.8.2 节的 7B KL/MSE 溯源结果提炼而来。FP16 基线 PPL 为 6.7097。KL 目标与 MSE 目标分别来自两组冻结的离线校准产物。两者在固定输入序列上的 likelihood 累计结果用 3 个 seeds 验证逐位一致；该表的职责是支撑“规模依赖性边界”，而不是承担新的主结果宣称。

就本章直接展示的证据而言，更稳的判断是：KL 的必要性会随位宽压缩强度与模型鲁棒性而变化。当量化扰动足以改变 attention ranking 时，分布侧代理更重要；当量化扰动已经被模型冗余度、位宽与架构平滑性共同吸收时，KL 与数值代理会趋同。KL 在本文中的角色应理解为更贴近行为损伤的可操作代理，而非跨所有 setting 的统一胜利者。

表 4-15 提供了这一问题的最小实证支撑。Qwen2.5-7B-Instruct 的 KL 与 MSE 目标最终搜索到同一组参数，即 $k_{\text{pct}} = 100.0$ 、 $v_{\text{pct}} = 99.9$ ；对应的 INT4-RoleAlign PPL 完全一致，均为 7.1121。7B 结果的关键读数是，**该设定中 KL 与 MSE 已经高度趋同**。结合附录第 A.8.2 节的补充对照，这一结果提示模型规模与鲁棒性可能调节二者差异；当前正文证据主要支持“趋同已经出现”这一判断。

这种解释可以作为机制层面的读法。较敏感的小模型或更激进的低比特设置中，softmax 排序对 Key 误差更脆弱，注意力分布错位可能先于张量范数恶化出现，KL 这类分布代理因而更有诊断价值；模型更大、位宽更高或架构更平滑时，量化噪声未必足以把排序推离原本稳定区域，KL 与 MSE 搜索到的参数也就更容易收敛。上述判断仍属于解释性推断，尚未构成机制定理。

因此，本文对 KL 的主张更适理解解为：在 attention ranking 容易被量化噪声改写的场景中，KL 是更贴近行为损伤的可操作代理；而在较稳的规模与较缓和的 setting 下，它可能与 MSE 逐步趋同，而不是始终制造同样大的经验优势。这一表述保留了 behavior-guided 主线，同时避免把校准目标写成普适性 overclaim。

4.6.2 INT4 结果的分层机制辨析

INT4 相关结果在前文已经成立；本节讨论的是它们在机制上能被解释到哪一步，而不是重新比较 INT4-RoleAlign 与 KIVI-style 的主表相对表现。这里沿事实层、解释层与开放问题三个层次展开。

从事实层看，在当前主结果覆盖范围内，INT4-RoleAlign 与 KIVI-style

的质量、PPL 与 Needle 差距总体很小。二者共享的角色感知非对称格式是 per-channel K + per-token V。前文表 4-8 已经显示，三组完整配对模型上的 PPL 差距都被压在 $|\Delta\text{PPL}| \leq 0.15$ 范围内，而 Needle 检索共同恢复到 100/100%。这组事实首先支持的是：**low-bit 恢复的一阶条件是 role-aware 非对称格式本身**。一旦从对称 per-group 升级到这一格式，检索行为就已经从“崩塌”回到“可用”；校准理念并未先制造出一边倒的巨大缺口。

从解释层看，当前证据更支持“格式是一阶、校准是二阶组织增益”的判断。所谓“二阶”，指的是离线行为引导校准的独立价值主要体现为：它把角色感知格式背后的架构选择解释化、把参数来源固定为可复核的离线产物，并为后续分配器留出统一接口。也正因为如此，RoleAlign 在同格式对比中的意义，不应被理解为“在 KIVI-style 之上取得约 0.1 PPL 的相对差异”，而应被理解为“把低比特路径组织成一条可延伸的实例化路径”。这里还必须显式锁定口径，避免旧说法回流：更准确地说，K-path 以 attention-distribution KL 为主代理，并在离线搜索纪律下确定参数，V-path 由独立输出扰动代理主导，两者共享的是校准流程、结果接口与稳健选择纪律。

进一步地，前文 4.3.1–4.3.2 的结果还表明，low-bit cliff 的强度并不只由位宽决定，还受模型族、规模与 H_{kv} 调制。LLaMA-3.1-8B 在对称 INT4 下表现为架构例外，Qwen 系列在 K4V8 下更容易完全坍塌；这说明当前面对的是一类架构依附的误差传播现象，而非单一位宽规律。于是，当前章节能够支持的更稳结论是：INT4 的恢复是分层成立的，格式层面强成立，校准层面条件性成立，而跨模型族 / 规模 / GQA 的强机制仍应保持克制语气。

附录第 A.8 节中的逐头温度校正 τ^{-1} 也应放回补充诊断位置来理解。它提供了量化平坦化的动机与 Q 预缩放等价实现，但第三章主线已经明确：RoleAlign 默认不使用逐头温度校正，该组件只保留为诊断性变体。因此，在第四章讨论里，逐头温度校正与 GQA 的关系只能被写成一种架构依附性的提示性诊断线索，而不能重新抬成正文主方法。它可以提示我们在更高 H_{kv} 或更平滑 profile 上是否存在额外温度平坦化收益，但当前证据不足以把它写成主线组件。

仍待进一步检验的问题是：在什么更极端的设定下，校准理念会重新变成一阶因素。例如，更小的 chunk_size、更接近 streaming 的 decode 粒度、更大的官方任务覆盖、乃至更强的 role-aware allocator 反馈，都可能重新放大 behavior proxy 与 numerical proxy 的差异。当前同格式对比已经说明，RoleAlign 的价值不在一边倒的跑分差，而在方法组织层；但在哪些更极端条件下这种“二阶组织增益”会重新升级为“一阶经验差异”，仍是后续值得追

间的问题。

4.6.3 Heuristic 强基线的结构性含义

如果把第 4.4 节的 allocator 结果理解成“本文方法需要在所有区间持续高于 heuristic”，就会误读这组适用区间结果。更准确的观察是：在多个模型与预算带内，position-based heuristic 与 behavior-guided 策略的结果非常接近，甚至在选中层集上出现局部重合。这一观察本身已经构成本文结论的一部分：heuristic 是**强基线**，而且这一点需要正面承认。

heuristic 的强来自结构本身：在某些适用区间下，关键层集中在一个很窄的位置区间，因此“保护哪几层”更接近窄选择空间，而非高自由度优化问题。此时位置启发式能够逼近行为引导策略，说明结构本身已经把可行解压窄了。强启发式基线提示某些适用区间具有狭窄而稳定的可行层集。

这种重合也存在边界。Qwen2.5-3B 的早层保护剖面提供了清晰对照：当敏感层高度集中于最早层，而位置启发式的假设偏离到中层时，差距会放大到质量提升级别。因此，启发式基线的强表现与 3B 上的明显失配并不矛盾；有些模型的可行层集本来就很窄，但一旦该窄区间被位置假设错过，启发式表现会明显下降。它们共同构成了适用区间结构的两端。

行为引导分配器的价值在于区分位置启发式已经足够的区间和它会偏离关键层的区间。正是这种区分能力，使 allocator 结果不只停留在跑分比较上。强启发式基线并非本文贡献的反证；它说明某些适用区间的可行层集本来就很窄，而本文的贡献在于识别这种窄区间何时存在、何时出现偏离。

4.6.4 威胁效度与外推边界

本节最后收束第四章结论的适用范围。最重要的边界来自评测协议：正文主矩阵统一使用 LongBench 风格合成基准任务，而官方 LongBench 真实数据对照只在第 4.2.2 节以“Qwen2.5-1.5B + 3 个任务 + 单种子”的有限范围出现。因此，第四章在这一边界内支持的结论是：主协议给出的方向性判断与有限范围的官方真实数据对照保持一致。这一点必须再次重申，因为它是全章最容易被误读成 overclaim 的位置。

第二个边界来自比较口径。第四章的 cross-model allocator 结果统一建立在同量级 INT4 预算带上，而非严格的同预算比较。于是，第 4.4 节可以支持“存在适用区间结构”“存在 per-model 结构落点”这类结构结论，但尚不

足以外推出“某单一策略已在严格同预算下完成形式化优势验证”。这条边界是维持全文可信度的必要条件。

第三个边界来自系统与硬件环境。前文第 4.5 节的部署结论严格绑定于当前 NVIDIA H20、固定软件栈、batch=1 与贪婪解码设定；性能交叉边界的具体位置在其它 GPU、其它 batch、其它 runtime 上都可能移动。因此，第 4.5 节支持的是经验边界。相应地，本章给出的部署建议应理解为当前平台上的经验决策规则。

第四个边界来自数据来源。正文主结论以统一协议下重新核验的主结果为准；若个别补充行或外部效度参考来自较早批次或回溯整理的数据，均在表注中显式说明，且不得用于替代主表结论。前文在 RoleAlign vs KIVI-style 对比中对 Qwen2.5-14B 明确标示其比较范围，正是这一写法的具体体现。

在这些边界之内，第四章的结论已经足够成立；而在这些边界之外，更完整的官方数据集验证、更严格的同预算比较、更广的硬件矩阵，以及更成熟的 role-aware allocator 与 prompt 级自适应路由，都构成自然的后续工作。但这些后续方向应被理解为扩大当前结论的适用域，而不是修补当前结论本身失效。本章据此将结论限定在当前协议、预算口径、硬件环境与数据溯源边界之内。

4.7 本章小结

本章的结果按第一章研究问题 2、低比特恢复线、第一章研究问题 3 与研究问题 4、系统边界四条线读取。每条线都保留其证据锚点和适用范围，而不把第四章压缩成一段总括性摘要。

第一章研究问题 2 的最小结论来自表 4-3 与表 4-4：在 Qwen2.5-1.5B 的 task-core 协议内，INT8-Canonical 相对 FP16 的三任务平均差异为 $\text{mean } \Delta = +0.02$ ；三个官方 LongBench 子任务的小范围对照没有反转这一方向。该结论限定为基准位宽下的保真度检查，不承担低比特恢复或部署收益判断。

低比特恢复线的最小结论来自表 4-5、表 4-6、表 4-7、图 4-1 与表 4-8：对称 INT4 在 Qwen 系列上出现阶跃崩塌，LLaMA-3.1-8B 构成架构例外；Key 侧低比特噪声是更直接的触发源；升级到 per-channel K + per-token V 后，低比特检索恢复到可用状态。与 KIVI-style 的同格式比较说明，RoleAlign 的独立价值主要在离线产物组织和后续分配接口。该证据线支撑第一章研究

问题 1 中“注意力行为作为统一对象”的判断，也为第一章研究问题 2 之后的低比特路径提供压力测试。

第一章研究问题 3 与研究问题 4 的最小结论来自表 4-9、图 4-3、图 4-5 以及两个典型剖面表：行为敏感度画像能够在同量级 INT4 预算带内组织跨模型预算分配，但不同模型落入不同结构区间。Mistral-7B 提供 AutoK 的单模型支持证据，Qwen2.5-3B 显示早层保护有效区间，LLaMA-3.1-8B 对应中等规模共识区间，Qwen2.5-14B 则表现为高性能簇共存而无稳定最优。heuristic 是强基线；这一点说明部分区间的可行层集本来很窄。

系统线的最小结论来自表 4-12、表 4-13 与表 4-14：KV Cache 容量收益在当前 INT4 路径下可预期，而融合 decode 的时间收益取决于 H_{kv} 、序列长度、H20、batch=1 与当前 backend 组合。KL 的价值、INT4 的恢复、heuristic 强基线和部署建议都应按这些条件读取。第五章将在这些已限定的证据基础上归总全文结论。

结论

本章回扣第一章提出的四个问题。前四章已经完成问题界定、方法实例化与实证验证；本章归总这些结论的学术价值、适用边界和后续方向。

5.1 研究结论

本节不逐项复述第四章图表，而是概括本文对四个研究问题的回答。

注意力行为可以作为 KV Cache 量化的统一对象，但这一回答建立在两条证据上。第三章给出误差传播与可执行代理，说明缓存扰动进入 logits、softmax 和 Value 聚合后才会被模型读取；第四章的 K/V 角色诊断则表明，同等 bit-width 下 Key 与 Value 的扰动后果并不对称。基准校准、低比特恢复和预算分配因此可以围绕同一组行为量组织。研究问题 1 的回答是肯定的：本文需要保持的是经过注意力计算后被实际感知的行为，而不是孤立的张量近似。

在 INT8 基准路径上，行为引导校准给出一条基础保真路径。第四章表明，在 Qwen2.5-1.5B 的 task-core 协议内，INT8-Canonical 相对 FP16 的三任务平均差异为 $\text{mean } \Delta = +0.02$ ，且三个官方 LongBench 子任务的小范围对照没有反转这一方向。这个结论只限定在基准位宽和当前评测协议内：1.5B、三任务、每任务最多 50 个官方样本与单一种子，不能外推为更广真实应用分布的通用保真宣告。研究问题 2 的回答是基础保真路径成立，而不是全任务通用保证。

校准链路产出的行为敏感度画像可以作为跨模型预算分配的组织依据。第四章在同量级 INT4 预算带内没有支持脱离条件的统一最优：Qwen2.5-3B 的三任务 core mean 中，BA-k1 为 6.90，而中层 Heuristic-k1 为 3.48，说明 early-layer bottleneck 下位置先验可能错过关键层；LLaMA-3.1-8B 表现为中等规模共识区间；Qwen2.5-14B 上 Uniform 的 7.23 与 BA-AutoK 90% 覆盖率的 7.15 接近，说明高性能簇共存而无稳定最优。heuristic 在多个区间仍是强基线，说明可行层集有时本来很窄。研究问题 3 的回答因此是：画像能组织和命名适用区间，但不能导出跨模型固定策略。

固定预算选择上，画像驱动的自动建议有助于减少手工 sweep 的偶然性，但在本文中应限定为模型级候选生成器。AutoK 在 Mistral-7B 上给出最清晰的单模型支持：BA-AutoK 80% 覆盖率的 core mean 为 14.76，extend mean 为 15.69，五任务均值为 15.14；在 Qwen2.5-14B 这类高性能簇接近的

设置中，它只支持候选区间接近的阅读法。研究问题 4 的回答因此是有限肯定：画像驱动建议有助于组织固定预算选择，其有效性仍受模型家族、规模、任务和预算带共同限定。

这四个回答共同指向一个更高层的判断：注意力行为可以作为贯通校准与分配的组织对象。它先在 INT8 基准路径上建立基础保真路径，随后在低比特场景下具体化为一条承认 K/V 角色差异的恢复路径，并进一步扩展成能够读出跨模型策略适用区间、生成预算候选的结构化工具。第五章后续不再重复第四章的证据，而转向说明这些研究结论的创新点、学术价值与适用边界。

5.2 创新点与学术价值

本节说明这些结论的学术价值。

从问题建模看，本文把注意力行为引入 KV Cache 量化的校准与分配过程。第三章的误差传播分析说明，缓存量化误差进入下游时不再只是张量数值偏差，而是会经注意力分布和聚合输出表现为行为扰动。这样，基准验证、低比特实例和预算扩展可以在同一组行为变量下讨论，而不必为每类决策另立互不相连的目标。

方法上，本文把这一原则落实为三个相互衔接的环节：INT8 基准用于建立保守位宽下的保真参照，INT4-RoleAlign 在与 KIVI-style 共享非对称格式的条件下用于分析低比特失稳中的 K/V 角色差异，分配器与 AutoK 则将敏感度信息用于预算选择。这里 INT4-RoleAlign 的价值不在于经验结果上的全面占优，而在于离线参数、角色格式和运行接口能够被同一实验协议复核。

跨模型实验进一步说明，预算策略的有效性需要结合模型家族、规模和任务条件来判断。第四章的结果不支持脱离条件的统一最优；更稳定的事实是，模型家族、参数规模与任务共同塑造高性能区间。heuristic 多次作为强基线出现，提示某些模型条件下可行层集可能天然较窄；行为引导框架的经验价值，在于把“强基线何时成立、何时偏离”整理为可复核的结构证据。

这些结果共同支持本文的核心判断：注意力行为可以把基准校准、低比特诊断和跨模型预算分析纳入同一解释框架。本文回答的不只是缓存如何压缩，还包括压缩后的行为如何被观测、诊断和分配预算；这也是后续实验扩展和部署复核可以继续沿用的组织方式。

5.3 研究局限性

本节界定上述价值成立的范围。这里不撤回前述结论，只说明这些结论目前绑定在哪些评测协议、比较口径、系统环境和时间条件上。

评测协议给出第一层边界。正文主矩阵使用统一生成规则下的 LongBench 风格合成基准任务；官方 LongBench 真实数据对照只覆盖 Qwen2.5-1.5B、NarrativeQA/HotpotQA/GovReport 三个任务、每任务最多 50 个样本和单一随机种子。这个设置可以检查少数官方任务是否反转主协议方向，但它还不能代表更开放的真实应用分布，包括多轮问答、工具调用、代码仓库级检索、超长报告摘要和领域文档问答。PPL、Needle、RULER 与任务级指标共同降低了单一度量偏差；长上下文质量仍需要更多观察维度继续补充。

比较口径给出第二层边界。逐层预算分配结果来自同量级 INT4 预算带，而不是严格预算匹配比较。第 4.4 节能够支持的结论是，不同模型存在不同结构落点，模型族、规模和任务共同塑造高性能区间，heuristic 在部分区间中是强基线。当前结果尚未完成某一单一策略在严格同预算口径内的形式化胜负判定，也尚未完成分配器相对 KIVI-style 的预算匹配正式比较。因此，分配器方向的当前贡献应理解为识别和组织跨模型适用区间，严格预算可比性问题仍保留为后续任务。

机制解耦构成第三层边界。本文模型集合以 decoder-only GQA 模型为主，MHA、MQA、滑动窗口注意力、MoE 和新的长上下文注意力变体尚未纳入验证。INT4-RoleAlign 与 KIVI-style 的比较限定在 per-channel K + per-token V 同格式条件内，这有助于减少格式差异干扰；格式贡献、校准贡献与架构因素仍需要进一步正交拆分。当前证据更适合支持一条已验证设定中的低比特恢复路径，以及一组受模型族、规模和任务共同影响的结构读数；更广模型族与更细粒度机制因果仍需单独验证。

系统层和动态决策层也有清楚边界。部署效率、性能交叉边界和显存读数绑定于当前 NVIDIA H20、固定软件栈、batch=1、贪婪解码以及当前 Triton/FlashInfer 后端组合；A100/H100、消费级 GPU、多 batch serving、speculative decoding、连续批处理调度或 streaming decode 都可能移动交叉点。AutoK 目前主要是模型级静态 proposer，prompt 级自适应路由只呈现弱改善或混合信号，尚不足以写成正式结论。结果溯源链保证的是当前版本可追溯，未来架构或部署栈仍需重新复核。

因此，本节讨论的局限性应理解为适用域说明：当前关于基准路径保真、低比特恢复与跨模型策略适用区间的结论，已经在评测协议、比较口

径、模型条件、系统环境和时间外推上被限定。下一节只沿其中可直接转写为研究路线的三类方法性边界展开未来工作。

5.4 未来工作展望

基于上述适用边界，后续最值得推进的三个方向是 prompt 级策略选择、角色感知预算机制，以及严格预算可比性比较。三者分别处理调用粒度、预算表达力和比较口径的当前限制。

后续可以先推进 prompt 级条件化策略选择，使预算建议不再只停留在模型级粒度。现阶段的 AutoK 主要根据离线行为敏感度画像给出模型级建议；prompt 级自适应方案只呈现弱改善或混合信号，尚不足以进入正式结论。后续需要检验输入提示的结构表征能否与高性能区间稳定对应，并据此把策略调用从“按模型给建议”推进到“按输入做选择”。

另一条方向是继续完善角色感知预算机制。当前角色感知预算扩展仍主要停留在接口形态，已经具备“可表达、可试验、局部可受益”的证据，但还不能写成稳定跨模型占优的成熟机制。后续应进一步整合 Key 与 Value 两侧的预算描述、耦合关系和画像读数，检验能否形成更一致的联合分配机制。只有当角色差异进入分配器的核心决策，行为引导框架在分配层的解释力才可能继续增强。

比较协议也需要进一步收紧，尤其是补全分配器与基线之间的严格 matched-budget 对照。第四章已经显示，不同模型在同量级 INT4 预算带内会落入不同策略适用区间，但这还不是严格同预算条件下的形式化胜负判定。后续应设计更严格的预算可比性协议，补全分配器相对现有基线的正式证据链。比较口径收紧以后，策略适用区间的判读才能从经验组织推进到更可比较的结构主张。

总之，未来工作不应转向寻找脱离条件的固定策略，而应沿行为引导主线继续扩大框架的可解释性、可比较性与适用域：在调用粒度上检验 prompt 级路由，在预算机制上发展角色感知分配器，在比较口径上补齐严格同预算实验。

5.5 结语

长上下文高效推理对 KV Cache 量化的要求，已经无法只用 bit-width 选择回答。本文以注意力行为作为校准层与分配层共用的观察对象，在 INT8

基准实例、INT4 恢复路径与跨模型预算扩展之间，建立了可相互校验的证据链。

跨模型实验给出的不是脱离条件的固定策略，而是不同模型家族、参数规模与任务条件下的结构差异及其适用区间。本文进一步标注这些结论的协议边界、比较口径与系统适用域。在长上下文推理的部署需求下，本研究提供的是一条以注意力行为为中心、可被后续实验扩展与部署复核的研究路径。

参考文献

- [1] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The Llama 3 herd of models[A]. 2024.
- [2] YANG A, YANG B, ZHANG B, et al. Qwen2.5 technical report[A]. 2024.
- [3] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]//Advances in Neural Information Processing Systems: Vol. 30. 2017.
- [4] KWON W, LI Z, ZHUANG S, et al. Efficient memory management for large language model serving with PagedAttention[C]//Proceedings of the ACM SIGOPS 29th Symposium on Operating Systems Principles. 2023.
- [5] XIAO G, LIN J, SEZNEC M, et al. SmoothQuant: Accurate and efficient post-training quantization for large language models[C]//Proceedings of Machine Learning Research: Vol. 202 Proceedings of the 40th International Conference on Machine Learning. PMLR, 2023: 38087-38099.
- [6] FRANTAR E, ASHKBOOS S, HOEFLER T, et al. GPTQ: Accurate post-training quantization for generative pre-trained transformers[C]//International Conference on Learning Representations. 2023.
- [7] LIN J, TANG J, TANG H, et al. AWQ: Activation-aware weight quantization for on-device LLM compression and acceleration[C]//Proceedings of Machine Learning and Systems: Vol. 6. 2024.
- [8] LIU Z, YUAN J, JIN H, et al. KIVI: A tuning-free asymmetric 2bit quantization for KV cache[C]//Proceedings of Machine Learning Research: Vol. 235 Proceedings of the 41st International Conference on Machine Learning. PMLR, 2024: 32332-32344.
- [9] HOOPER C, KIM S, MOHAMMADZADEH H, et al. KVQuant: Towards 10 million context length LLM inference with KV cache quantization[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024.
- [10] HE Y, ZHANG L, WU W, et al. ZipCache: Accurate and efficient KV cache quantization with salient token identification[J]. Advances in Neural Information Processing Systems, 2024, 37.

- [11] DAO T, FU D, ERMON S, et al. FlashAttention: Fast and memory-efficient exact attention with IO-awareness[C]//Advances in Neural Information Processing Systems: Vol. 35. 2022.
- [12] DAO T. FlashAttention-2: Faster attention with better parallelism and work partitioning[C]//International Conference on Learning Representations. 2024.
- [13] TILLET P, KUNG H T, COX D. Triton: An intermediate language and compiler for tiled neural network computations[C]//Proceedings of the 3rd ACM SIGPLAN International Workshop on Machine Learning and Programming Languages. 2019.
- [14] SHAZEER N. Fast transformer decoding: One write-head is all you need [A]. 2019.
- [15] AINSLIE J, LEE-THORP J, DE JONG M, et al. GQA: Training generalized multi-query transformer models from multi-head checkpoints[C/OL]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 4895-4901. DOI: [10.18653/v1/2023.emnlp-main.298](https://doi.org/10.18653/v1/2023.emnlp-main.298).
- [16] NAGEL M, FOURNARAKIS M, AMJAD R A, et al. A white paper on neural network quantization[A]. 2021.
- [17] HUBARA I, COURBARIAUX M, SOUDRY D, et al. Quantized neural networks: Training neural networks with low precision weights and activations [J]. Journal of Machine Learning Research, 2018, 18(187): 1-30.
- [18] TAO Q, YU W, ZHOU J. AsymKV: Enabling 1-bit quantization of KV cache with layer-wise asymmetric quantization configurations[C/OL]//Proceedings of the 31st International Conference on Computational Linguistics (COLING). Association for Computational Linguistics, 2025: 2316-2328. DOI: [10.18653/v1/2025.coling-main.158](https://doi.org/10.18653/v1/2025.coling-main.158).
- [19] SHUTOVA A, MALINOVSKII V, EGIАЗARIAN V, et al. Cache me if you must: Adaptive key-value quantization for large language models[C]//International Conference on Machine Learning (ICML). 2025.

- [20] ASHKBOOS S, MOHTASHAMI A, CROCI M L, et al. QuaRot: Outlier-free 4-bit inference in rotated LLMs[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024.
- [21] KANG H, ZHANG Q, KUNDU S, et al. GEAR: An efficient KV cache compression recipe for near-lossless generative inference of LLM[J]. International Conference on Learning Representations, 2025.
- [22] LIN Y, TANG H, YANG S, et al. QServe: W4A8KV4 quantization and system co-design for efficient LLM serving[C]//Proceedings of Machine Learning and Systems (MLSys): Vol. 7. 2025.
- [23] LIU R, BAI H, LIN H, et al. IntactKV: Improving large language model quantization by keeping pivot tokens intact[C/OL]//Findings of the Association for Computational Linguistics: ACL 2024. Association for Computational Linguistics, 2024: 7716-7741. DOI: [10.18653/v1/2024.findings-acl.460](https://doi.org/10.18653/v1/2024.findings-acl.460).
- [24] DUANMU H, ZHONG Z, WEI W, et al. SKVQ: Sliding-window key and value cache quantization for large language models[A]. 2024.
- [25] SU Y, ZHOU Y, QIU Q, et al. Accurate KV cache quantization with outlier tokens tracing[C/OL]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2025: 12895-12915. DOI: [10.18653/v1/2025.acl-long.631](https://doi.org/10.18653/v1/2025.acl-long.631).
- [26] ZHAO Y, LIN C Y, ZHU K, et al. Atom: Low-bit quantization for efficient and accurate LLM serving[J]. Proceedings of Machine Learning and Systems, 2024, 6.
- [27] ZANDIEH A, DALIRI M, HAN I. QJL: 1-bit quantized JL transform for KV cache quantization with zero overhead[A]. 2024.
- [28] ZHANG Z, SHENG Y, ZHOU T, et al. H2O: Heavy-hitter oracle for efficient generative inference of large language models[J]. Advances in Neural Information Processing Systems, 2023, 36.

- [29] XIAO G, TIAN Y, CHEN B, et al. Efficient streaming language models with attention sinks[C]//International Conference on Learning Representations. 2024.
- [30] LI Y, HUANG Y, YANG B, et al. SnapKV: LLM knows what you are looking for before generation[J]. Advances in Neural Information Processing Systems, 2024, 37.
- [31] CAI Z, ZHANG Y, GAO B, et al. PyramidKV: Dynamic KV cache compression based on pyramidal information funneling[A]. 2024.
- [32] XIAO G, TANG J, ZUO J, et al. DuoAttention: Efficient long-context LLM inference with retrieval and streaming heads[C]//International Conference on Learning Representations (ICLR). 2025.
- [33] FU Y, CAI Z, ASI A, et al. Not all heads matter: A head-level KV cache compression method with integrated retrieval and reasoning[C]//International Conference on Learning Representations (ICLR). 2025.
- [34] LIU X, TANG Z, DONG P, et al. ChunkKV: Semantic-preserving KV cache compression for efficient long-context LLM inference[C]//Advances in Neural Information Processing Systems: Vol. 38. 2025.
- [35] LIU Y, LI H, CHENG Y, et al. CacheGen: KV cache compression and streaming for fast large language model serving[J/OL]. Proceedings of the ACM SIGCOMM Conference, 2024: 38-56. DOI: [10.1145/3651890.3672274](https://doi.org/10.1145/3651890.3672274).
- [36] XU Y, JIE Z, DONG H, et al. ThinK: Thinner key cache by query-driven pruning[C]//International Conference on Learning Representations. 2025.
- [37] YUAN J, LIU H, ZHONG S, et al. KV cache compression, but what must we give in return? A comprehensive benchmark of long context capable approaches[C/OL]//Findings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP Findings). Association for Computational Linguistics, 2024: 4623-4648. DOI: [10.18653/v1/2024.findings-emnlp.266](https://doi.org/10.18653/v1/2024.findings-emnlp.266).

- [38] LI X, XING Z, LI Y, et al. KVTuner: Sensitivity-aware layer-wise mixed precision KV cache quantization for efficient and nearly lossless LLM inference[C]//International Conference on Machine Learning (ICML). 2025.
- [39] BONDARENKO Y, NAGEL M, BLANKEVOORT T. Quantizable transformers: Removing outliers by helping attention heads do nothing[J]. Advances in Neural Information Processing Systems, 2023, 36.
- [40] HUANG W, GE Y, YANG S, et al. QeRL: Beyond efficiency – quantization-enhanced reinforcement learning for LLMs[C]//International Conference on Learning Representations. 2026.
- [41] VELIČKOVIĆ P, PERIVOLAROPOULOS C, BARBERO F, et al. softmax is not enough (for sharp out-of-distribution)[C]//NeurIPS Workshop on Scientific Methods for Understanding Deep Learning. 2024.
- [42] GU Y, JIANG Z, JIN J, et al. AhaKV: Adaptive holistic attention-driven kv cache eviction for efficient inference of large language models[A]. 2025.
- [43] JIANG A Q, SABLAYROLLES A, MENSCH A, et al. Mistral 7B[A]. 2023.
- [44] KAMRADT G. Needle in a haystack — pressure testing LLMs[EB/OL]. 2023. https://github.com/gkamradt/LLMTest_NeedleInAHaystack.
- [45] HSIEH C P, SUN S, KRIMAN S, et al. RULER: What’s the real context size of your long-context language models?[C]//Conference on Language Modeling (COLM). 2024.
- [46] BAI Y, LV X, ZHANG J, et al. LongBench: A bilingual, multitask benchmark for long context understanding[C/OL]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Bangkok, Thailand: Association for Computational Linguistics, 2024: 3119-3137. DOI: [10.18653/v1/2024.acl-long.172](https://doi.org/10.18653/v1/2024.acl-long.172).

附录 A 补充材料

A.1 评测协议、环境与复现入口

本节汇总三类复现审计材料：PPL 评测协议与 FP16 基线、软硬件环境，以及主线实验的复现入口与覆盖范围。这些信息用于解释正文表格的协议边界与复现条件，不承担新的实验结论。

PPL 协议与基线。本文 PPL 评测在不同章节使用了三种略有差异的协议，表 A-1 统一列出各模型 FP16 PPL 基线与对应协议，供读者在交叉比较时参照。同一模型同一精度在不同协议下可能出现 $\sim 0.1\text{--}0.5$ PPL 差异，各表的绝对数字不可直接跨表比较；各退化率（相对同表内 FP16 基线）方可在表内对比。

表 A-1 FP16 PPL 基线 $\times$ 评测协议汇总。

模型	协议	max_length / stride	chunk_size	FP16 PPL
Qwen2.5-1.5B	32K 上下文短窗	1024 / 512	128	8.93
Qwen2.5-1.5B	完整 test split	32K / 32K	128	9.31
Qwen2.5-7B	32K 上下文短窗	1024 / 512	128	6.71
Qwen2.5-7B	完整 test split	32K / 32K	128	7.14
Qwen2.5-7B	KL/MSE 配对诊断子集	32K / 32K	128	6.7097 [†]
LLaMA-3.1-8B	32K 上下文短窗	1024 / 512	128	6.92
LLaMA-3.1-8B	完整 test split	32K / 32K	128	6.73
Qwen2.5-14B	32K prefix	32K / —	128	4.685 [*]

[†] 附录表 A-11 的 7B FP16 基线 PPL 精确到四位小数为 6.7097，来自 KL/MSE 校准目标对比使用的配对诊断子集；本表第四行的 7.14 对应完整 test split 汇总口径。两者采用相同的 PPL 定义、窗口长度与 chunk_size，但样本覆盖与聚合人口不同，因此只允许在各自协议内部进行配对比较，不作为跨表绝对值比较对象。该表对比 INT4 KL/MSE 校准在 7B 上产生的逐位一致 PPL（7.1121，属 INT4 侧观察，非 FP16 基线）。

^{*} 14B 因 H20 显存限制仅在 test split 前 32767 tokens 上评测，与其他模型的完整 $\sim 302\text{K}$ test split 不可直接比较。

注：表 4-9 与附录第 A.7 节使用 32K 上下文短窗协议；表 4-8 使用完整 test split。

实验环境。表 A-2 列出了本文所有实验所使用的软硬件环境配置。

生成式质量评测采用固定随机种子（主实验 1234–1238）与贪心解码策略（temperature=0.0, top_p=1.0, top_k=0），吞吐实验采用固定随机种子 1234–1241，以确保结果的可复现性。PPL 采用固定输入序列上的 likelihood 累计，seed 仅用于实现路径一致性核验，不作为统计重复，也不绑定上述生成式解码设置。

表 A-2 实验软硬件环境

项目	配置
GPU	NVIDIA H20, 98 GB HBM
CPU	Intel Xeon
操作系统	Ubuntu 22.04 LTS
Python	3.12
PyTorch	2.8.0 (CUDA 12.8)
Transformers	4.48+
Triton	3.2+
NumPy	2.x
pandas	2.x
Matplotlib	3.x

复现入口与覆盖范围。本文主线实验保留了一套公开复现配置与 artifact 清单。对应条目覆盖第四章的基准路径验证、低比特恢复、跨模型预算分配与第 4.5 节的部署效率评估，并补充附录 A.8.2 的 7B KL/MSE 趋同溯源。BitDecoding 案例与官方 LongBench v2 数据作为补充参考材料保留，但不在主线复现保证范围内。

关于校准样本数量：表 A-4 中的 $N = 128$ 表示正文口径下的标准规模，复现配置实际使用 $N \in \{16, 32\}$ 来复现同一已选参数配置。校准样本数量敏感性检查（覆盖 $s \in \{16, 64, 256\}$ ）确认 PPL/Needle/RULER/LongBench 四类指标均已进入平坦收敛域。

A.2 量化路径与复现配置类别

本节只承担复现审计的论文侧说明。表 A-3 给出正文量化路径名称与复现配置类别之间的对应关系；具体配置键值保留在公开 artifact manifest 中，正文论证只使用左列名称。

A.3 校准产物与搜索空间审计

离线校准阶段产出一份小型结构化校准记录 (<10 KB)，其中包含路径特定的逐层 Key/Value scale、zero point、分位数参数、分组元数据，以及模型标识、校准样本数、seed、目标函数与量化格式等审计字段。对称路径主要消费静态 scale 与分组参数；INT4-RoleAlign 额外记录 per-channel Key 与 per-token Value 的角色感知分位数参数。逐头温度校正字段若出现在早期诊断记录中，仅用于附录第 A.8 节的诊断复现；第三章与第四章主线配置不

表 A-3 正文量化路径与复现配置类别的对应关系

正文名称	复现配置类别	K/V 位宽	默认执行路径	说明
FP16	full-precision reference	16/16	FP16	全精度基线
INT8 baseline	percentile symmetric baseline	8/8	参考实现 / Triton	percentile 对称基线
INT8-Canonical	behavior-guided symmetric INT8	8/8	Triton	KL-guided 对称基准路径
INT4 percentile baseline	percentile symmetric INT4	4/4	参考实现	percentile 对称低比特基线
对称 INT4 (behavior-guided)	behavior-guided symmetric INT4	4/4	参考实现	KL-guided 对称 INT4
融合 INT4 诊断变体	symmetric INT4 fused-kernel diagnostic	4/4	Triton	同校准参数的融合路径诊断，非 Ch4 主表项
INT4-RoleAlign	role-aware asymmetric INT4	4/4	参考实现*	per-channel K + per-token V
KIVI-style	runtime-statistic asymmetric INT4	4/4	参考实现	同格式 runtime 统计基线
MixedKV	mixed-precision diagnostic	8/4	参考实现	K8V4 诊断路径

注：第四章主表使用左列正文名称；中列仅说明公开复现材料中的配置类别，不作为正文方法命名。INT4-RoleAlign 与 KIVI-style 共享 per-channel K + per-token V 缓存格式，二者差异限定在离线行为校准与运行时统计更新的参数来源上。

* INT4-RoleAlign 的非对称 Triton 变体只作为实现可行性验证；正文质量评测默认使用参考解码实现，系统讨论见第 4.5 节。

使用该组件。推理时一次性加载相应产物到 GPU 显存，不引入运行时校准开销。

校准超参数搜索空间。表 A-4 汇总主线校准搜索空间；对称量化数据结构只保留复现所需常量。

表 A-4 校准超参数搜索空间

超参数	符号	候选值集合 / 默认配置
对称格式常量		
位宽 / 范围	$n, q_{\max}$	INT8: 8 / 127; INT4: 4 / 7
Scale / 量化轴	—	float32 scale, 对称 per-group (沿 d_k 分组)
INT8 对称量化路径 (主线校准搜索)		
Clip percentile	$\mathcal{P}_c$	{99.0, 99.5, 99.9, 100.0} (默认 99.5)
Group size	$\mathcal{G}$	{16, 32, 64, 128} (默认 16)
Outlier rescue ratio	—	{0, 0.0025, 0.005, 0.01}
补充诊断分支		
温度因子	$\mathcal{T}$	{0.5, 0.7, 0.85, 1.0, 1.2, 1.5, 2.0} (不计入主线搜索规模)
INT4-RoleAlign 非对称量化路径		
K percentile	$\mathcal{P}_K$	{95.0, 97.0, 99.0, 99.5, 99.9, 100.0}
V percentile	$\mathcal{P}_V$	{95.0, 97.0, 99.0, 99.5, 99.9, 100.0}
共用参数	$N, \text{len}, \text{data}$	128 (标准规模); 512 tokens; WikiText-2 (test split)

其中 $N = 128$ 表示正文口径下的标准校准规模；复现配置使用 $N \in \{16, 32\}$ 复现同一已选参数配置，见附录第 A.1 节说明。INT8 基准路径主

线搜索为 $|\mathcal{P}_c| \times |\mathcal{G}| = 16$ 组；温度因子只属补充诊断，不计入搜索规模，也不改变主线默认配置。INT4-RoleAlign 可枚举 $|\mathcal{P}_K| \times |\mathcal{P}_V| = 36$ 组用于审计，但 K-path 与 V-path 的代理需分别解释。

A.4 LongBench、统计检验与质量趋势补充材料

本节合并三类质量补充材料：LongBench-style 合成评测的完整审计表、官方 LongBench 小范围协议一致性检查、以及统计检验与上下文长度趋势图。这些材料共同服务于第四章的可信性边界，而不替代正文主表或扩大主结论适用范围。

LongBench-style 补充聚合表。表 A-5 列出了三种模型在 32K 上下文长度下、七种实验路径的 LongBench-style 聚合结果，包含 F1 宏平均、包含匹配宏平均以及综合评分。数值后的“ $\pm$ ”表示 Bootstrap 95% 置信区间半宽。本表只作为正文基准保真与低比特恢复证据的补充审计材料；其中 8B 的 INT4 读数不应被反向概括为低比特路径普遍安全。

表 A-5 LongBench-style 补充聚合结果（32K 上下文，三模型 $\times$ 七实验路径）

模型	实验路径	F1 宏平均	包含匹配率 (%)	综合评分
1.5B	FP16	5.53 ± 0.05	99.9 ± 0.2	0.0482 ± 0.0004
	INT8-Baseline	5.50 ± 0.02	99.9 ± 0.2	0.0478 ± 0.0002
	INT8-Canonical	5.54 ± 0.04	99.9 ± 0.1	0.0482 ± 0.0004
	INT4 percentile	2.91 ± 0.26	45.9 ± 2.0	0.0298 ± 0.0024
	Fused INT4	0.00 ± 0.00	0.0 ± 0.0	0.0515 ± 0.0068
	Behavior-guided INT4	0.00 ± 0.00	0.0 ± 0.0	0.0241 ± 0.0025
	KIVI-style	5.58 ± 0.07	99.9 ± 0.1	0.0481 ± 0.0005
7B	FP16	4.29 ± 0.15	100.0 ± 0.0	0.0378 ± 0.0008
	INT8-Baseline	4.38 ± 0.14	100.0 ± 0.0	0.0383 ± 0.0007
	INT8-Canonical	4.44 ± 0.14	100.0 ± 0.0	0.0383 ± 0.0009
	INT4 percentile	0.00 ± 0.00	0.0 ± 0.0	0.0172 ± 0.0024
	Fused INT4	0.45 ± 0.13	4.2 ± 0.9	0.0183 ± 0.0020
	Behavior-guided INT4	0.00 ± 0.01	0.4 ± 0.5	0.0027 ± 0.0011
	KIVI-style	4.28 ± 0.14	99.9 ± 0.1	0.0378 ± 0.0011
8B	FP16	10.29 ± 0.76	99.7 ± 0.5	0.0792 ± 0.0066
	INT8-Baseline	10.71 ± 0.85	99.7 ± 0.5	0.0817 ± 0.0092
	INT8-Canonical	10.72 ± 0.85	99.6 ± 0.7	0.0817 ± 0.0092
	INT4 percentile	12.95 ± 1.02	99.7 ± 0.5	0.1037 ± 0.0087
	Fused INT4	15.89 ± 1.37	99.8 ± 0.3	0.1505 ± 0.0138
	Behavior-guided INT4	19.88 ± 1.34	99.4 ± 0.5	0.1908 ± 0.0111
	KIVI-style	8.72 ± 0.98	99.6 ± 0.3	0.0682 ± 0.0069

注：1.5B = Qwen2.5-1.5B-Instruct, 7B = Qwen2.5-7B-Instruct, 8B = LLaMA-3.1-8B-Instruct。合成 LongBench (7 类子任务), 5 seeds 均值。8B INT4 的较高 F1 可能反映合成任务、评分器或该模型/路径组合下的协议特异性，不作为 INT4 优于 FP16 或 KIVI-style 的主证据。

官方数据一致性检查。前述 LongBench-style 评测使用确定性合成数据源，绝对值不可与社区官方榜单直接对齐。为检查主评测协议是否存在方向性误判，本文在 LongBench^[46] 官方数据集上使用 Qwen2.5-1.5B-Instruct、32K 截断、seed=1234 和每任务最多 50 个样本，选取 NarrativeQA、HotpotQA 与 GovReport 三个任务做小范围对照。在 INT8-Canonical 相对 FP16 的比较中，三项差异分别为 -0.43 、 $+0.31$ 、 $+0.08$ pp，宏平均为 FP16=7.06、INT8-Canonical=7.05。这一小范围官方对照与合成协议对 INT8 基准路径保真方向的判断保持一致，其作用限定在协议一致性检查层面。

统计检验设置与结果。表 A-6 合并列出了 INT8 路径在固定序列 PPL、生成式质量指标 (Needle/LongBench/RULER, $n = 5$ 种子) 与推理延迟 (TPOT, $n = 8$ 种子) 上的审计结果。PPL 行对应固定输入序列上的 likelihood 累计，只报告效应量，不进入显著性检验；Needle 行对应主配置，LongBench 与 RULER 行使用主配置及补充配置的合并读数，因此只用于稳定性审计，不作为正文主路径 claim。生成式质量指标与延迟指标的检验均基于配对种子的 sign-flip 置换检验，多重比较校正采用 Benjamini-Hochberg FDR 控制 ($\alpha = 0.05$)。

上下文长度质量趋势表。表 A-7 汇总了 Qwen2.5-1.5B-Instruct 上 RULER 与 LongBench-style 综合评分在不同上下文长度下的关键读数。该表只保留 FP16 与 INT8-Canonical 两条主线参照，用于确认补充质量指标没有改变正文主结论；低比特长上下文边界则由图 A-3 和附录第 A.6 节补充。

A.5 部署效率与批处理扩展补充

本节汇总 Qwen2.5-1.5B-Instruct 上的系统补充读数，包括单序列 TPOT 边界说明、吞吐/显存扩展图，以及 batch 维度的容量边界。这些材料只服务于第 4.5 节的部署边界审计；硬件、后端路径、batch size 与序列长度条件均不应外推为通用速度结论。

单序列 TPOT 边界与资源扩展图。单序列 TPOT 读数在下文以文字说明；图 A-1 和图 A-2 分别补充展示吞吐与显存扩展读数。

单序列 TPOT 的补充读数显示，在 Qwen2.5-1.5B-Instruct、NVIDIA H20、batch=1 的设置下，量化路径仍受到固定开销约束，适合作为部署边界条件

表 A-6 INT8 固定序列 PPL、质量与延迟审计统计 (32K 上下文)

模型	指标	INT8-Baseline	审计对象	变化 (%)	<i>p</i> 值	<i>q</i> 值	显著
固定序列 PPL (不做显著性检验)							
1.5B	PPL↓	8.9316	8.9497	−0.20	N/A	N/A	N/A
7B	PPL↓	6.7145	6.7322	−0.26	N/A	N/A	N/A
8B	PPL↓	6.9193	6.9252	−0.09	N/A	N/A	N/A
生成式质量指标 ($n = 5$ 种子 1234–1238)							
1.5B	Needle pass rate↑	100.00	100.00	+0.00	1.0000	1.0000	否
	LongBench score↑	0.0478	0.0486	+1.77	0.0909	0.1435	否
	RULER pass rate↑	24.45	23.81	−2.64	0.0909	0.7273	否
7B	Needle pass rate↑	100.00	100.00	+0.00	1.0000	1.0000	否
	LongBench score↑	0.0383	0.0383	+0.17	0.9394	0.9553	否
	RULER pass rate↑	24.92	24.84	−0.31	1.0000	1.0000	否
8B	Needle pass rate↑	100.00	100.00	+0.00	1.0000	1.0000	否
	LongBench score↑	0.0817	0.0817	+0.09	0.8788	0.9416	否
	RULER pass rate↑	32.58	31.25	−4.05	0.0909	0.7273	否
解码延迟 TPOT ($n = 8$ 种子 1234–1241, batch size 为 1, 生成长度为 64 tokens)							
1.5B	TPOT (ms)↓	51.42	47.14	+8.32	0.0117	0.0159	是
7B	TPOT (ms)↓	60.52	50.07	+17.26	0.0117	0.0159	是
8B	TPOT (ms)↓	91.77	57.23	+37.64	0.0117	0.0159	是

注: PPL 为固定输入序列上的确定性 likelihood 指标, seed 只用于实现路径一致性核验, 因此不进入生成式指标的显著性检验流程。生成式质量指标差异均未达到 BH-FDR 校正后的统计显著性; 三种模型上的 TPOT 降低均达到显著性 ($q < 0.05$)。1.5B Needle 行报告主配置 (5 种子均 100%); LongBench/RULER 行为主配置与补充配置的合并审计读数, 其中 RULER 退化主要受补充配置影响。

表 A-7 补充质量指标随上下文长度的关键读数 (Qwen2.5-1.5B-Instruct)。

上下文长度	RULER FP16	RULER INT8-Canonical	LongBench FP16	LongBench INT8-Canonical
4K	24.84	24.87	4.37	4.51
8K	24.92	24.92	4.82	5.00
16K	24.77	24.84	4.82	5.00
32K	24.38	23.88	4.82	4.92

注: RULER 为通过率 (%); LongBench-style 综合评分按 $\times 100$ 报告。

的说明。第 4.5 节的部署结论仍以正文表 4-12–4-14 以及本节的吞吐、显存补充读数为准。

批处理容量与 INT4-RoleAlign 扩展轨迹。表 A-8 合并呈现 batch 维度的容量边界与扩展轨迹: (a) 各模式在序列长度 8192 条件下的已测最大可行 batch; (b) INT4-RoleAlign 在不同 batch 下的 TPOT 与 KV Cache 显存。

A.6 INT4 失稳机制与评估粒度边界补充

本节按四层组织 INT4 相关补充材料: 首先用 Needle 深度–位置热力图给出 long-context cliff 的可视化背景; 随后用 scale 精度敏感性读数排除




图 A-1 吞吐扩展性三联图 (Qwen2.5-1.5B-Instruct, NVIDIA H20, 序列长度 8192, 生成长度 128)。面板 (a) 展示总吞吐量, 面板 (b) 展示单序列吞吐量, 面板 (c) 展示 prefill 吞吐量。统一图例和坐标轴用于观察当前后端组合下 batch 扩展中的并发收益与单序列代价。




图 A-2 显存扩展性双联图 (Qwen2.5-1.5B-Instruct, NVIDIA H20, 序列长度 8192)。面板 (a) 展示 KV Cache 显存随 batch size 的线性增长, 面板 (b) 展示总峰值显存; 两者共同说明量化节省如何改变当前扫描范围内的可容纳 batch。

“scale dtype 单点失误”解释; 第三部分保留噪声-长度交互的近似推导, 给出 32K 场景下 INT4 阶跃退化的机制直觉; 最后用 chunk size 消融界定评估粒度和流式近似协议边界。最后一部分只限定协议适用范围, 不引入新的主机结论。

Needle 深度-位置热力图补充。图 A-3 补充展示 Needle 任务的深度位置热力图。该图服务于正文第 4.3.1 节的阶跃崩塌模式: 它说明在当前热力图覆盖设置下, 对称 INT4 的退化主要在长上下文与深层 needle 位置上被放大, 并为下文噪声-长度推导提供可视化背景。

精确匹配率 (exact match) 采用比通过率更严格的 Needle 判据, 其趋势

表 A-8 批处理扩展综合数据 (Qwen2.5-1.5B-Instruct, NVIDIA H20, 序列长度 8192, 独占 GPU)

(a) 各量化模式已测最大可行 batch (1-32 扫描)

量化模式	已测最大可行 batch	扫描范围	容量结论
FP16	16	1-16	范围内可行; 未扩展至 32
INT8-Baseline	24	1-32	batch=32 显存不足
INT8-Canonical	32	1-32	范围内可行
INT4-Baseline	16	1-16	范围内可行; 未扩展至 32
INT4-Fused	32	1-32	范围内可行
INT4-RoleAlign	32	1-32	范围内可行

(b) INT4-RoleAlign 批处理扩展轨迹 (FP16 vs INT4-RA 对照)

Batch	TPOT FP16 / INT4-RA (ms)	KV FP16 / INT4-RA (MB)	KV 压缩比
1	24.78 / 60.18	227 / 60	3.78×
4	24.65 / 73.17	910 / 242	3.76×
8	24.21 / 93.07	1820 / 484	3.76×
16	24.23 / 134.46	3640 / 968	3.76×

注: (a) 在序列长度 8192、NVIDIA H20 与当前后端组合下, INT8-Canonical 与 INT4 融合模式均可支持已测 batch=32; INT8-Baseline 在 batch=32 时出现中间张量显存不足, 因此容量边界从 24 移至 32 只相对于该 baseline 解释。(b) KV 压缩比约 3.76× 恒定; INT4-RoleAlign 的 TPOT 随 batch 增长, 说明该实现仍有并发反量化摊销开销。batch=16 时其 KV Cache 为 968 MB (FP16 为 3640 MB), 主要收益体现在容量边界而非速度主结论。




图 A-3 Needle-in-a-Haystack 深度-位置热力图总览。四个面板分别对应 4K、8K、16K 和 32K, 并共享同一色标。该图用于定位 INT4 退化在上下文长度和 needle 深度上的放大位置, 不替代正文的主表结论。

与图 A-3 一致：FP16 在 4K–32K 均保持 100%，INT8-Canonical 在 4K–16K 保持 100%，并在 32K 端点给出约 70.3% 的长上下文边界读数；对称 INT4 则在 4K 已显露边界，并在 8K 及以上区间构成长上下文边界对照。这些 exact-match 读数作为严格判据补充图 A-3，不再作为独立视觉证据展开。

Scale 精度敏感性诊断。表 A-9 是一组补充诊断读数，用于确认对称 INT4 失稳并非仅由 scale 存储精度不足造成。所有 scale 参数均以 float32 精度维护。本节中的 behavior-guided 对称 INT4 不等同于正文主线的 INT4-RoleAlign 非对称路径。

表 A-9 INT4 量化 scale 精度敏感性实验（32K 序列；PPL 为固定序列 likelihood，Needle 使用三个固定种子的贪婪生成）

模型	模式	PPL	Needle (%)	校准	Scale dtype
Qwen2.5-1.5B	Symmetric INT4 baseline	19.65	0	percentile	float32
	Symmetric INT4 behavior-guided	22.80	0	KL proxy	float32
Qwen2.5-7B	Symmetric INT4 baseline	86.56	—	percentile	float32
	Symmetric INT4 behavior-guided	52.19	—	KL proxy	float32
LLaMA-3.1-8B	Symmetric INT4 baseline	6.97	100	percentile	float32
	Symmetric INT4 behavior-guided	7.64	100	KL proxy	float32

注：7B Needle 未包含在该诊断消融中（标记 —）。1.5B Needle 0% 反映该模型在 32K 对称 INT4 下的边界；7B 基线 PPL=86.56 与正文同量级结果一致，说明该敏感性不是 scale dtype 单点造成。

补充读数。在同一 float32 scale 条件下，7B 的 behavior-guided 对称 INT4 PPL 低于 percentile baseline，但 1.5B 的 Needle 仍为 0%，LLaMA-3.1-8B 则在两种对称 INT4 配置下保持 100%。因此本节只支撑第 4.6.2 节的边界判断：scale 精度是必要的数值卫生条件，但对称 INT4 cliff 还会受到模型结构与上下文长度调节。

量化噪声与序列长度交互效应。本段提供正文第 4.6.2 节中量化步长与序列长度交互效应的近似分析。

Needle-in-a-Haystack 任务的检索成功条件可形式化为：目标位置 t 的 attention logit 与最强干扰位置的差值 $\delta = z_t - \max_{i \neq t} z_i$ （其中 $z_i = \mathbf{q}^\top \mathbf{k}_i / \sqrt{d_k}$ ）需在量化后仍保持正值，使 softmax 将最大概率分配给目标位置。

当 Key 矩阵经 INT4 量化后，每个 logit z_i 受到量化噪声扰动 ϵ_i ，其方差约为：

$$\text{Var}(\epsilon_i) \approx \|\mathbf{q}\|^2 \cdot \sigma_{q,4}^2 / d_k \quad (\text{A-1})$$

其中 $\sigma_{q,4}^2 = \Delta_4^2 / 12$ 为 INT4 量化的逐元素噪声方差。

随序列长度 n 增大, $\max_{i \neq t}(z_i + \epsilon_i)$ 的期望值以 $O(\sqrt{2 \ln n} \cdot \sigma_\epsilon)$ 的速率增长 (极值统计理论), 而目标信号 δ 不随 n 增大。在这一近似模型下, 可以定义一个临界序列长度 n^* , 满足:

$$\delta \approx \sqrt{2 \ln n^*} \cdot \sigma_\epsilon \quad (\text{A-2})$$

当 $n > n^*$ 时, 量化噪声超过目标 margin 的风险快速上升, 检索失败概率随之增大。

在同一对称裁剪范围下, INT8 与 INT4 的 $q_{\max}$ 分别为 127 与 7, 因此 INT4 相对 INT8 的逐元素噪声方差比约为 $\sigma_{q,4}^2 / \sigma_{q,8}^2 = (127/7)^2 \approx 3.29 \times 10^2$ 。INT4 的 n^* 远小于 INT8。该近似模型为 1.5B 模型上从短上下文到 32K 的 Needle 通过率下降提供了理论直觉; 实际退化强度仍受模型结构、校准格式和注意力分布共同调节。

评估粒度鲁棒性。本段验证量化粒度变化对低比特路径的影响。前述各节采用 128-token chunk 协议; $cs=1$ 则更接近每步都读写量化历史 KV 的 streaming decode。表 A-10 给出 Qwen2.5-1.5B-Instruct 上三种粒度下 FP16、INT4-RoleAlign 和 KIVI-style INT4 的 PPL 对比。

表 A-10 量化评估粒度敏感性 (Qwen2.5-1.5B-Instruct, PPL, seed=1234)

配置	cs=128	cs=8	cs=1
FP16	9.31	9.31	9.31
INT8-Canonical	8.95	9.34 (+0.3% [†])	9.27 (-0.4% [†])
INT4-RoleAlign	10.58 (+13.7%)	62.10 (+567%)	>10,000*
KIVI-style INT4	10.43 (+12.0%)	60.54 (+550%)	10,332 (+110,900%)*

表注与边界。括号内为相对 FP16 的 PPL 变化率, $cs = \text{chunk_size}$ 。[†] INT8-Canonical 的 $cs=128$ PPL 低于 FP16, 主要反映评测切分口径差异; $cs=1$ 相对 FP16 仍基本持平, 说明更高量化级别提供了更大的 range 容错。* $cs=1$ 下的极端 PPL 失效来自不含 FP16 Residual Buffer 的 per-channel K + per-token V 格式: 当每步都以单 token 建立 per-channel K scale 时, 后续 token 极易超出 clamp 范围。KIVI 原论文为 streaming decode 设计了 Residual Buffer ($R = 128$) 和 residual-group-scale 更新; 因此表中 KIVI-style 的 $cs=1$ 数字只刻画本文简化基线与 INT4-RoleAlign 在无 residual buffer 条件下的共同边界, 不代表 KIVI 原论文方法在 streaming 设置下的性能上界。该边界仅在 Qwen2.5-1.5B 单模型单种子条件下验证, 并受上述实现范围限定。

A.7 K/V 精度消融与 MixedKV 跨模型补充数据

本节补充正文第 4.3.2 节中未展开的两类材料：Mistral-7B 的 LongBench 数据源说明，以及 MixedKV 的逐模型边界读数。

Mistral-7B LongBench 数据说明。 Mistral-7B-Instruct-v0.3 在本组 K/V 消融与 MixedKV 补充评测中的 LongBench 结果均为 1.0，包括 K/V 消融的三种配置 (K-only, V-only, K4V8) 和 MixedKV 对比的三种方法 (FP16, KIVI-style, MixedKV)。该结果源于这组补充评测使用的 Mistral LongBench 合成数据源，评分不反映模型的实际长文本理解能力，因此在正文第 4.3.2 节的 K/V 跨模型 LongBench 对比中排除了 Mistral 的数据。需强调的是，这一数据源异常影响的仅是 LongBench 评测本身，而非量化方法。Mistral-7B 在 PPL、Needle 和 RULER 上的评测均正常有效。

K/V 角色敏感性补充读数。 在正文表 4-7 的 LongBench 宏平均 F1 ($\times 100$) 上, K-only 与 V-only 两个诊断列分别为: Qwen2.5-1.5B 的 4.57 ± 0.01 与 4.54 ± 0.04 , Qwen2.5-7B 的 4.10 ± 0.11 与 3.85 ± 0.02 , LLaMA-3.1-8B 的 7.31 ± 0.43 与 6.21 ± 0.66 。Qwen 两个模型上的 K4V8 读数分别为 2.58 ± 0.08 与 0.80 ± 0.05 ，支持正文关于 Key 侧低精度更容易触发退化的判断；LLaMA-3.1-8B 的 K4V8 LongBench 为 8.92 ± 0.79 ，说明任务级指标还会受到模型结构和数据协议共同调节。因此本节只作为正文多指标诊断的补充，不把单一 LongBench 读数升级为独立结论。

MixedKV 跨模型细节。 MixedKV 的逐模型表现进一步说明恢复强度具有架构依附性。LLaMA-3.1-8B ($H_{kv} = 8$) 的 PPL 为 6.75 (FP16 为 6.92), Needle 为 100%, RULER 为 33.28% (FP16 为 31.48%), LongBench 为 7.42% (FP16 为 7.92%); Qwen2.5-1.5B ($H_{kv} = 2$) PPL 有轻度退化 (9.37 vs 8.93), Needle 保持 100%, RULER 为 24.87% (FP16 为 24.38%); Qwen2.5-7B ($H_{kv} = 4$) 是当前 MixedKV 诊断中唯一出现 Needle 退化的模型 (72.4% vs FP16 100%)。Mistral-7B 的 PPL 5.20 (FP16 为 5.19) 和 RULER 53.67% (FP16 为 53.98%) 均接近未量化基线，但其 LongBench 读数因上述数据源问题不参与跨模型任务比较。

A.8 逐头温度校正诊断与 7B 校准目标溯源

本节只承担两个附录功能：记录逐头温度校正 τ^{-1} 的补充诊断动机，并给出正文表 4-15 的 7B KL/MSE 数据溯源。第三章与第四章的主线配置均

不使用该组件，本节内容不构成默认组件。

A.8.1 诊断性温度校正

量化误差会扰动 logits $\mathbf{q}\hat{\mathbf{K}}^T/\sqrt{d_k}$ 并平坦化 softmax 分布；逐头温度校正的诊断动机，是用层/头级缩放因子 $\tau_{l,h}^{-1}$ 观察这种平坦化是否存在可补偿的架构依附性：

$$\mathbf{p}_{\text{corrected}} = \text{softmax}\left(\frac{\mathbf{q}\hat{\mathbf{K}}^T \cdot \tau_{l,h}^{-1}}{\sqrt{d_k}}\right) \quad (\text{A-3})$$

其中 $\tau^{-1} = 1$ 退化为标准注意力。实现上，该缩放可等价写成 Query 预缩放：

$$\text{Attn}(\mathbf{Q} \cdot \tau^{-1}, \hat{\mathbf{K}}, \hat{\mathbf{V}}) = \text{softmax}\left(\frac{\mathbf{Q}\hat{\mathbf{K}}^T \cdot \tau^{-1}}{\sqrt{d_k}}\right) \hat{\mathbf{V}} \quad (\text{A-4})$$

这一等价性说明 τ^{-1} 可作为诊断开关接入现有 attention kernel。但在非对称 RoleAlign 格式下，它没有形成稳定收益，因此只保留为补充诊断变体。

A.8.2 7B KL vs MSE 校准目标趋同溯源

表 A-11 是正文表 4-15 的溯源表。它只说明 Qwen2.5-7B-Instruct 上 KL 与 MSE 目标已经趋同，不承担新的主结果宣称。PPL 评测采用固定输入序列上的确定性 likelihood 累计，多 seed 只验证实现路径逐位一致性；规模依赖解释以正文讨论为准。

表 A-11 7B KL vs MSE 校准对比数据溯源

校准目标	k_{pct}	v_{pct}	PPL	Seeds
KL-selected	100.0	99.9	7.1121	3
MSE-selected	100.0	99.9	7.1121	3
FP16 (基线)	—	—	6.7097	1

A.9 Triton 融合核函数变体说明

本节仅对正文第 3.7 节提及的 Triton 融合解码路径做实现变体说明，其职责是给出不同变体的语义边界与复现角色，而不在附录中额外引入新的速度结论。当前实现变体包括五类：INT8 融合解码主线实现、INT4 非对称融合核原型、带自动调优的 INT4 迭代变体、显式兼容 GQA 头映射的 INT4

变体，以及外部推理库适配层。这里按语义角色区分实现变体，不暴露具体文件名或实现代号。

这些变体在论文主线中的地位需要分层读取。正文默认的系统落地主线是 INT8 融合核；对 INT4-RoleAlign 而言，默认质量评测路径仍为参考解码实现，非对称 Triton 变体仅承担实现可行性验证与后端扩展接口的角色。因此，本附录补足“变体命名 / 实现角色 / 语义边界”的复核说明，不把这些实现变体提升为正文主结果的直接来源。

A.10 Prompt-Adaptive Selector 探索性补充（future-work 起点）

本节汇总 prompt-adaptive selector 的探索性读数，作为第 5.4 节所列 per-prompt routing 方向的具体起点。所有读数均使用同一 5-task 任务集，每个任务 50 个样本；其中 8B 为正式探索矩阵，Qwen2.5-1.5B/7B 为同任务集下的补充读数。

A.10.1 LLaMA-3.1-8B 五任务结果

8B 读数显示，prompt-adaptive selector 在 LCC 任务上取得局部正向信号：其分数为 11.36，高于 auto- k 的 10.96。这一任务域信号提示，代码补全类输入可能为更细粒度的 prompt 级路由提供有价值的切入点。

A.10.2 Qwen2.5-1.5B/7B 补充结果

表 A-12 将三个模型上的 5-task mean 与局部信号并列展示。该汇总不重新定义第四章主结果，只为 future work 中的 selector 设计空间提供模型规模与任务类型上的参照。

Model	fixed- k mean	auto- k mean	prompt-adaptive mean	局部读数
LLaMA-3.1-8B	10.03	9.85	9.73	LCC: prompt-adaptive 11.36 vs auto- k 10.96
Qwen2.5-1.5B	8.72	9.40	9.04	auto- k 与 prompt-adaptive 在 GovReport / DuReader 上读数一致
Qwen2.5-7B	9.28	9.72	9.41	auto- k 与 prompt-adaptive 在 HotpotQA / GovReport / DuReader 上读数一致

表 A-12 Prompt-adaptive selector 的探索性 5-task 汇总。数值为各任务原生指标下的 mean；加粗表示该模型上的最高 mean。

这些读数共同指向一个正向的后续设计问题：prompt 级策略选择的收益可能集中在特定任务域与输入结构上，而三组 5-task mean 的最高项仍分别落在 fixed- k 或 auto- k 上；这说明当前 prompt-adaptive selector 更适合作为任务域线索的观察入口，后续仍有空间进一步吸收任务类型、模型规模与 prompt 表征。因此，本节将第 5.4 节的 future-work 方向落到具体可检验现象上，不新增正文主结果。

致 谢

本论文的完成离不开诸多师长、同学和亲友的关心与帮助，在此谨致以最诚挚的谢意。

首先，衷心感谢我的指导教师在本科毕业设计全过程的悉心指导与严格要求。从选题确立、方案设计到论文撰写，老师始终给予了富有启发性的建议和耐心细致的修改意见，使我在科研方法与学术写作方面受益匪浅。

感谢实验室各位同学在日常学习与研究中的交流与协助。他们在实验方案讨论、代码调试和结果分析等方面提供的宝贵意见，对本文的完善起到了重要作用。

感谢华南理工大学提供的优良学术环境和计算资源支持，为本研究的顺利开展提供了坚实的基础保障。

最后，特别感谢我的家人多年来的无私支持与默默付出。他们的理解与鼓励是我坚持学业、完成论文的最大动力。