

华南理工大学  
本科毕业设计（论文）

面向高效推理的大语言模型键值缓存行为对齐  
量化框架

学    院： 吴贤铭智能工程学院  
专    业： 智能制造工程  
学生姓名： 陈梓浪  
学生学号： 202264642457  
指导教师： 曾子倩  
提交日期： 2026 年 6 月

# 华南理工大学 学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

作者签名：\_\_\_\_\_ 日期：\_\_\_\_\_年\_\_\_\_月\_\_\_\_日

## 学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保存并向国家有关部门或机构送交论文的复印件和电子版，允许学位论文被查阅；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。本人电子文档的内容和纸质论文的内容相一致。

作者签名：\_\_\_\_\_ 日期：\_\_\_\_\_年\_\_\_\_月\_\_\_\_日

指导教师签名：\_\_\_\_\_ 日期：\_\_\_\_\_年\_\_\_\_月\_\_\_\_日

# 摘要

长上下文推理窗口扩大后，自回归解码需要持续保留越来越长的 K/V 历史，KV Cache 的显存占用和读取开销随序列长度同步增长。降低缓存存储位宽可以直接减少容量压力，但量化后的缓存并不是停在张量空间中被使用。Key 侧扰动会先进入 logits 与 softmax，并可能改变注意力质量的分配，Value 侧扰动则在注意力权重下进入输出表示。仅用张量级重建误差选择量化参数，难以完整描述这两条传播路径带来的功能偏移。围绕这一问题，本文构建面向高效推理的 KV Cache 行为对齐量化框架，以注意力分布、聚合输出和任务表现作为校准与审计读数，贯通量化参数选择、低比特恢复和层间预算分配。

方法设计从一组校准样本开始。全精度参考配置与候选量化配置并行前向，系统记录 attention-distribution KL 和注意力聚合输出扰动，并把下游任务读数保留为任务层审计信号。这些读数先用于筛选校准参数，随后按层汇总为行为敏感度画像，用来观察不同模型的关键层分布。围绕这组画像，本文比较 behavior-guided fixed- $k$  分配、位置启发式基线和 uniform 策略，并用 AutoK 按敏感度排序与覆盖率阈值生成模型级  $k$  候选。由此，离线行为读数不再只停留在校准阶段，而是继续进入低比特恢复、跨模型结构判读和预算候选生成。

在 Qwen2.5、LLaMA-3.1 与 Mistral 三个模型族的六个开源指令模型中，KV Cache 量化和预算分配呈现出清楚的模型族、规模和任务依赖性。Qwen2.5-1.5B 的 task-core 协议中，INT8 基准路径相对 FP16 的三任务均值差约为 +0.02，表明行为引导校准在保守位宽下可以形成稳定参照。位宽进入 INT4 后，对称量化在 Qwen 系列中触发检索阶跃崩塌，K/V 角色诊断显示 Key 侧低比特噪声是更直接的失稳来源。角色感知低比特路径 INT4-RoleAlign 将检索行为恢复到可用区间。跨模型预算实验进一步读出四类结构，Mistral-7B 给出最清晰的 AutoK 单模型支持，Qwen2.5-3B 对应早层保护有效区间，LLaMA-3.1-8B 呈现中等规模共识区间，Qwen2.5-14B 则表现为高性能簇接近而无稳定最优。INT4 路径带来约 73.4% 的 KV Cache 容量压缩，融合解码的时间收益还需要结合  $H_{kv}$ 、序列长度和后端实现判断。上述结果说明，以注意力行为保持为核心、以 K/V 角色差异恢复为低比特路径、以 AutoK 和行为敏感度画像为预算接口的框架，可以把 KV Cache 量化从单纯降位宽推进到可审计的行为对齐问题。

关键词：大语言模型；KV Cache 量化；注意力行为保持；低比特推理；行为引导校准；预算分配

# Abstract

Long-context autoregressive decoding keeps an increasingly long history of keys and values, so KV-cache capacity and memory traffic grow with sequence length. Lowering cache bit-width directly reduces this pressure, but the quantized cache is eventually consumed by attention rather than evaluated only as a tensor reconstruction problem. Key-side perturbations pass through logits and softmax before changing attention mass, whereas Value-side perturbations enter the output through weighted aggregation. The thesis builds a behavior-aligned KV-cache quantization framework around these two propagation paths, using attention distributions, aggregated outputs, and task behavior to guide calibration, low-bit recovery, and layer-wise budget allocation.

The method first runs full-precision reference and candidate quantized configurations on the same calibration samples. Attention-distribution KL and aggregation-output perturbation provide the main fidelity readings, while downstream task scores remain as task-level audit signals. The layer-wise readings are then summarized into behavioral sensitivity profiles and compared across models as a sensitivity-profile map. This map supports fixed- $k$  comparisons between behavior-guided allocation, positional heuristics, and uniform allocation, and AutoK uses the same rankings with coverage thresholds to produce model-level  $k$  candidates. The offline readings therefore continue beyond calibration and become the interface for low-bit recovery, cross-model interpretation, and budget selection.

Experiments on six open-source instruction models from Qwen2.5, LLaMA-3.1, and Mistral show strong family, scale, and task dependence. On Qwen2.5-1.5B, the INT8 baseline differs from FP16 by about +0.02 in the task-core three-task mean, giving a stable conservative-bit-width reference. Under INT4, symmetric quantization triggers stepwise retrieval collapse on Qwen models, and K/V diagnostics point to Key-side low-bit noise as the more direct instability source. INT4-RoleAlign restores retrieval to a usable range. Cross-model allocation further separates four regimes, with the clearest AutoK case on Mistral-7B, early-layer protection on Qwen2.5-3B, a medium-scale consensus regime on LLaMA-3.1-8B, and nearby high-performance clusters without a stable winner on Qwen2.5-14B. The INT4 path reduces KV-cache capacity by about 73.4%, while fused-decode time gains depend on  $H_{kv}$ , sequence length, and backend implementation. These results move KV-cache quantization from uniform bit-width reduction toward an auditable behavior-alignment problem.

**Keywords:** large language models, KV-cache quantization, attention-behavior preservation, low-bit inference, behavior-guided calibration, budget allocation

# 目录

|                                      |     |
|--------------------------------------|-----|
| 摘要 . . . . .                         | i   |
| Abstract . . . . .                   | ii  |
| 目录 . . . . .                         | iii |
| 第一章 绪论 . . . . .                     | 1   |
| 1.1 研究背景 . . . . .                   | 1   |
| 1.2 问题定义与研究动机 . . . . .              | 2   |
| 1.3 国内外研究现状概述 . . . . .              | 3   |
| 1.4 核心假设与研究问题 . . . . .              | 4   |
| 1.5 研究内容、技术路线与主要贡献 . . . . .         | 5   |
| 1.6 论文结构安排 . . . . .                 | 5   |
| 第二章 相关工作与技术基础 . . . . .              | 7   |
| 2.1 Transformer 架构与自注意力机制 . . . . .  | 7   |
| 2.2 KV Cache 机制与显存分析 . . . . .       | 8   |
| 2.3 模型量化技术基础 . . . . .               | 9   |
| 2.4 KV Cache 量化与高效推理相关工作 . . . . .   | 11  |
| 2.5 研究空白与本文定位 . . . . .              | 14  |
| 2.6 本章小结 . . . . .                   | 15  |
| 第三章 行为引导量化框架设计 . . . . .             | 16  |
| 3.1 注意力近似误差的代数分解与问题形式化 . . . . .     | 16  |
| 3.2 动机诊断: K/V 敏感性不对称及其设计启示 . . . . . | 17  |
| 3.3 行为引导量化框架总览 . . . . .             | 19  |
| 3.4 行为引导校准目标与参数搜索策略 . . . . .        | 20  |
| 3.5 跨位宽量化路径的实例化设计 . . . . .          | 25  |
| 3.6 行为敏感度驱动的层间预算分配与 AutoK . . . . .  | 30  |
| 3.7 系统级部署实现与开销分析 . . . . .           | 36  |
| 3.8 本章小结 . . . . .                   | 42  |
| 第四章 实验评估与策略适用区间分析 . . . . .          | 43  |

|                     |                                                           |    |
|---------------------|-----------------------------------------------------------|----|
| 4.1                 | 实验设置与可信性声明 . . . . .                                      | 43 |
| 4.2                 | 行为引导校准的保真度验证 . . . . .                                    | 46 |
| 4.3                 | 低比特路径从对称失效到 RoleAlign 恢复 . . . . .                        | 47 |
| 4.4                 | 跨模型预算分配与策略适用区间 . . . . .                                  | 52 |
| 4.5                 | 部署效率评估 . . . . .                                          | 57 |
| 4.6                 | 实验结果讨论与效度威胁 . . . . .                                     | 61 |
| 4.7                 | 本章小结 . . . . .                                            | 63 |
| 结论 . . . . .        |                                                           | 65 |
| 5.1                 | 研究结论 . . . . .                                            | 65 |
| 5.2                 | 创新点与学术价值 . . . . .                                        | 66 |
| 5.3                 | 研究局限性 . . . . .                                           | 67 |
| 5.4                 | 未来工作展望 . . . . .                                          | 68 |
| 5.5                 | 结语 . . . . .                                              | 69 |
| 参考文献 . . . . .      |                                                           | 70 |
| 附录 A 补充材料 . . . . . |                                                           | 75 |
| A.1                 | 评测协议、环境与复现入口 . . . . .                                    | 75 |
| A.2                 | 量化路径与复现配置类别 . . . . .                                     | 76 |
| A.3                 | 校准产物与搜索空间审计 . . . . .                                     | 76 |
| A.4                 | LongBench、统计检验与质量趋势补充材料 . . . . .                         | 78 |
| A.5                 | 部署效率与批处理扩展补充 . . . . .                                    | 79 |
| A.6                 | INT4 失稳机制与评估粒度边界补充 . . . . .                              | 80 |
| A.7                 | K/V 精度消融与 MixedKV 跨模型补充数据 . . . . .                       | 85 |
| A.8                 | 逐头温度校正诊断与 7B 校准目标溯源 . . . . .                             | 86 |
| A.9                 | Triton 融合核函数变体说明 . . . . .                                | 86 |
| A.10                | Prompt-Adaptive Selector 探索性补充 (future-work 起点) . . . . . | 87 |
| 致谢 . . . . .        |                                                           | 89 |

# 第一章 绪论

## 1.1 研究背景

长上下文推理把大语言模型的部署压力集中到解码阶段。LLaMA 3<sup>[1]</sup>、Qwen2.5<sup>[2]</sup> 等模型已经能够处理更长输入,但在自回归生成中,每个新 token 都要访问此前累积的缓存。部署压力可以具体化为上下文长度和服务并发同步上升时,如何降低 Decode 阶段反复读取 KV Cache 所带来的访存开销。

Transformer<sup>[3]</sup> 自回归解码的计算路径决定了这一压力。第  $t$  个生成步只新增当前位置的 Query、Key 和 Value,但注意力仍需访问前  $S$  个历史位置的 Key/Value。KV Cache 避免了重复执行历史 K/V 投影,却把缓存容量与访存带宽变成每个 decode step 都要面对的约束。也就是说,缓存不只在 prefill 后静态占用显存,还在后续 token 生成中持续参与注意力计算。

从存储结构上看, KV Cache 的显存占用与模型层数、每层 KV 头数、头维度、序列长度以及存储位宽近似成正比,可写为

$$M_{KV} = 2 \times L \times H_{kv} \times d_k \times S \times b \quad (1-1)$$

其中  $L$ 、 $H_{kv}$  与  $d_k$  由模型结构给定,  $S$  对应上下文长度,  $b$  对应缓存元素的存储字节数,系数 2 来自 Key 与 Value 两部分。本文使用式 (1-1) 固定后续实验变量: 模型结构决定基础缓存形状,序列长度与 batch size 决定部署压力,量化位宽直接改变  $b$ ,而预算分配方法则决定哪些层或角色保留更高精度。在长上下文和批量推理场景下,这一开销会随上下文长度与并发批次同步放大。vLLM<sup>[4]</sup> 等推理框架通过分页注意力 (PagedAttention) 改善显存碎片和缓存管理效率,但这类方法并不直接减少 KV Cache 的绝对存储量。

因此, KV Cache 量化的系统价值首先来自它直接作用于存储位宽所对应的  $b$ 。在只计算 Key/Value 缓存元素本体时, FP16 每个元素占 2 bytes, INT8 将其降为 1 byte,对应缓存容量约减半; INT4 进一步将单元素存储压到 4 bits,理想情况下只保留 FP16 的 1/4 缓存字节数。考虑 scale、zero-point、打包格式和运行接口后,第四章系统评估中 INT4 路径在代表性模型上仍实现约 73.4% 的 KV Cache 容量压缩。本文把 Decode 阶段缓存字节数、注意力行为稳定性和任务读数放在同一套实验口径下比较,区分存储位宽下降带来的容量收益与低比特扰动进入注意力计算后的功能后果。

## 1.2 问题定义与研究动机

在上述背景下，KV Cache 量化的价值首先来自直接的存储压缩。INT8 可以作为较保守的保真基线，更低位宽则能进一步释放显存空间，支持更长上下文或更高并发。但缓存压缩不能只按 bit 数下降来理解：位宽降低以后，Key 与 Value 的扰动会进入注意力计算，并可能改变检索、摘要和语言建模等任务行为。本文后续以 INT4 作为低比特压力点，正是因为这一设置会更清楚地暴露 Key/Value 角色差异和模型间敏感度差异。后文的 Qwen 与 LLaMA 对照会把这种差异落到 K4V8/K4V4 等布局上。

当前 KV Cache 量化的校准目标仍多落在数值重建误差上，常见做法包括 MSE 损失和基于分位数的裁剪。这类方法通常沿用个工作前提，即张量越接近原值，模型行为也越接近全精度路径。进入注意力计算后，这一前提并不总是成立：softmax 的非线性可能把较小的 Key 扰动转化为注意力概率的明显变化，而某些数值上更大的误差也可能在归一化中被部分吸收。因此，张量误差大小很难与下游功能偏移建立稳定的一一对应关系。层、头和上下文位置带来的分布差异，也会进一步削弱静态阈值的解释力。

KV Cache 量化的困难并不只是继续调节超参数或降低重建误差。误差进入注意力计算以后，推理过程中实际暴露出来的是行为偏移，而不是孤立的张量差值。具体来看，这种偏移会体现为注意力分布是否被重排、聚合输出是否偏离，以及任务行为是否随之改变。长上下文和低比特设置会让这种差异更加突出。同一量级的数值扰动，出现在不同层、不同注意力头，或不同缓存角色中时，可能产生截然不同的后果。因此，单纯追求全局数值误差最小，不一定能保证模型在推理时保持稳定和可用。

这使本文把观察对象从单纯的张量近似扩展到推理行为本身：KV Cache 量化在保持重建精度之外，还需要尽量维持注意力分布、聚合输出和任务表现的稳定。我们认为量化后注意力分布是否发生重排、这种重排是否继续影响输出与任务结果，是更本质，更贴近推理可用性的观察依据。后续关于校准目标、量化路径和预算分配的讨论，也以这些行为读数作为共同依据。

为避免“行为”停留在抽象表述，本文将注意力行为操作化为三类可观测测量。量化前后注意力分布的偏移用于刻画检索和排序关系是否被扰动，加权聚合输出的变化用于刻画 Value 信息进入残差流后的表示偏移，语言建模、检索和长文档任务上的表现变化则用于检验上述扰动是否传导到任务层面。进一步地，本文所说的行为敏感度画像，是指由离线校准与诊断读



数聚合得到的逐层相对敏感度，用于回答哪些层或角色应被优先保护。策略适用区间则指在特定模型家族、规模、任务和预算条件下，不同预算策略进入高性能区域的条件范围。

基于这一问题意识，下一节做必要的相关研究定位：已有工作分别回答低比特表示、缓存压缩格式和系统执行效率问题，而本文要探讨的问题是量化缓存进入注意力计算后如何保持推理行为。

### 1.3 国内外研究现状概述

围绕长上下文推理与 KV Cache 压缩，现有研究分别从量化表示、缓存格式和注意力后端进入同一个部署瓶颈。模型量化提供了低比特表示和校准工具，KV Cache 专属量化把对象转向解码阶段持续累积的缓存，高效推理系统则处理注意力计算与缓存管理中的访存开销。三条路线已经说明，长上下文部署不仅取决于存储位宽，还取决于缓存如何进入真实 Decode 路径。

模型量化工作作为本文提供了方法背景。SmoothQuant<sup>[5]</sup> 将激活中的量化难点迁移到权重侧，GPTQ<sup>[6]</sup> 用近似误差补偿提高权重量化后的保真度，AWQ<sup>[7]</sup> 根据激活读数保护更关键的通道。这些方法主要处理权重与瞬时激活，目标并不是随序列长度不断增长的 KV Cache，但其中关于量化表示、误差控制和离线校准的做法，仍可作为缓存压缩的起点。

KV Cache 专属量化把问题推到解码缓存本身。长上下文场景中，缓存读写随序列长度增长，Key 与 Value 的统计差异又使同质化格式难以覆盖两侧角色。KIVI<sup>[8]</sup> 以 K/V 分布差异和异构量化轴为设计依据，KVQuant<sup>[9]</sup> 引入非均匀码本、Pre-RoPE Key 量化与异常值处理，ZipCache<sup>[10]</sup> 则沿 token 重要性组织差异化压缩。这些路线已经把压缩对象从参数推到缓存状态。本文继续追问缓存扰动进入 attention scores、softmax 和 Value 聚合之后，校准目标与格式选择应由哪些行为信号来检验。

系统侧工作提供了另一条参照。FlashAttention<sup>[11,12]</sup> 用分块注意力减少中间结果访存，分页注意力<sup>[4]</sup> 通过缓存分页改善显存碎片和缓存利用率。KV Cache 量化与这些后端优化作用于不同层面。低位宽 K/V 在 decode 阶段仍要经过反量化、解包、GQA 头映射和 kernel 调度，容量下降能否转化为可用推理路径，还需要在注意力执行语义中检验。

现有研究已经从模型量化、KV Cache 专属压缩与高效推理等角度推进了长上下文部署，但这些路线解决的层面并不相同。本文的切入点是 KV

Cache 量化中的行为保持问题：量化后的缓存不仅要占用更少显存，还要在注意力计算中保持可用的推理行为。下面的研究问题从这一观察出发，而不是预设某一种量化格式或预算策略会在所有模型上占优。

## 1.4 核心假设与研究问题

KV Cache 量化的核心难点不只是继续提高压缩率，而是如何在压缩后保持模型的实际推理行为。本文把注意力行为作为分析起点，关注量化后注意力分布、聚合输出和任务表现是否仍与全精度路径保持一致。

**核心假设：**在 KV Cache 量化中，注意力行为比张量重建误差更接近模型实际功能损伤。本文关心量化后注意力分布是否保持稳定、加权聚合输出是否偏离，以及这些变化是否影响任务行为。基于这一假设，校准目标和预算分配可以共享同一个观察对象，而不必被拆成彼此孤立的局部问题。

**研究问题 1：注意力行为能否作为 KV Cache 量化的统一对象？** KV Cache 量化需要保持的，到底只是张量层面的重建精度，还是还包括注意力分布、聚合输出和任务行为的稳定性？如果后者能够成立，它应当同时支撑基准校准、低比特恢复和预算分配三类讨论，而不是只解释某一个局部设置。

**研究问题 2：行为引导校准能否形成稳定的 INT8 基准路径？** 在 INT8 这一较保守、便于审计的位宽下，以注意力行为为导向的校准能否建立一条相对 FP16 任务行为偏差可控的基准路径？这一路径也为后续低比特探索和系统落地提供相对稳定的参照。

**研究问题 3：行为敏感度画像能否支撑跨模型预算分配？** 校准链路产生的行为敏感度画像，能否在不同模型家族、不同规模和不同任务条件下读出可区分的策略适用区间？本文关注的是这些条件如何改变预算策略的有效范围，而不是给出一种脱离条件的单点配置。

**研究问题 4：敏感度画像能否自动生成量化预算候选？** 手工固定  $k$  的预算 sweep 在跨模型迁移中是否会暴露不稳定性？同源敏感度画像能否被转化为 AutoK 预算建议，从而减少手工选择带来的偶然性？本文把 AutoK 放在量化参数自动建议的探索位置，尝试生成模型级预算候选。

围绕上述核心假设与四个问题，下一节将进一步概述本文的研究内容、技术路线与主要贡献。

## 1.5 研究内容、技术路线与主要贡献

围绕前述核心假设与四个问题，本文把 KV Cache 量化组织为一条由注意力行为读数贯穿的研究路径。校准阶段选择量化参数，低比特路径检查更激进存储位宽下的可用性，分配阶段判断有限预算应优先保护哪些层或角色，并进一步探索敏感度画像能否自动生成量化预算候选。三类决策共享同一组行为证据，因而可以在同一条实验主线上被比较和复核。

校准层把量化后的缓存视为注意力计算路径中的行为载体，关注它在行为层面呈现的三类可观测变化，包括注意力分布变化、Value 聚合后的输出表示偏移，以及任务表现波动。这组行为证据在校准层用于选择量化参数，在预算分配层用于判断哪些层或角色更需要保护。

低比特路径层先用 INT8 基准路径提供保真参照，检验行为引导校准能否在受控设置中维持接近全精度的任务表现。进入更低存储位宽后，INT4-RoleAlign 将 Key 参与注意力排序、Value 参与输出聚合的角色差异纳入路径设计，并通过 K/V 角色对照定位对称量化 INT4 的失稳来源。系统实现方面，本文进一步实现面向低比特 KV Cache 的 Triton<sup>[13]</sup> Decode kernel，把离线校准产物、低比特缓存格式和在线推理管线接到同一条执行路径中，为容量压缩、反量化开销、nibble unpack、GQA head mapping 和 TPOT 读数提供固定复核接口。

分配层把校准链路产生的逐层行为敏感度画像继续用于预算决策。给定低比特预算后，问题不再只是选择统一位宽，而是判断哪些层或角色在行为扰动下更值得保留更高位宽。本文先构造 behavior-guided fixed- $k$  分配器，将高敏感层保护、位置启发式基线和 uniform 策略放入同量级 INT4 预算带比较。随后提出 AutoK，根据敏感度排序和覆盖率阈值生成模型级  $k$  候选，把手工 sweep 的选择过程转化为画像驱动的预算建议。进一步地，本文把不同模型的敏感度画像整理为跨模型结构读数，用于识别早层保护、中等规模共识区间、高性能簇接近和 AutoK 单模型支持等适用区间。这样，分配层既延续校准层的行为证据，又把低比特恢复后的读数转化为可复核的预算候选和跨模型策略解释。

## 1.6 论文结构安排

全文按上述问题展开。第一章界定 Decode 阶段 KV Cache 压力、行为保持假设和四个研究问题。第二章说明 Transformer、KV Cache、量化与高

效推理中哪些已有结论可直接复用，哪些问题仍未覆盖缓存扰动后的注意力行为。第三章给出行为代理、INT8 基准路径、INT4-RoleAlign 和预算分配接口。第四章给出基准保真、低比特恢复、跨模型策略和 AutoK 预算建议的实验证据，并把部署效率读数作为系统边界而非单独的加速宣称。第五章收束贡献、适用范围和未覆盖的任务与部署条件。

## 第二章 相关工作与技术基础

本章梳理本文所依赖的模型结构、缓存机制、量化方法与高效推理研究，并据此界定后续工作的论证边界。KV Cache 压缩不是一个孤立的位宽选择问题，而是同时受 decoder-only Transformer 的注意力路径、GQA/MQA 的 KV 头共享方式、缓存显存公式和 Decode 阶段访存压力共同约束。第 2.2 节把 decoder-only Transformer、GQA/MQA 与 KV Cache 显存公式连接到本文后续控制的变量：序列长度、 $H_{kv}$ 、bit-width 与 Decode 阶段访存压力。随后讨论量化格式、校准代理、KV Cache 压缩与高效推理工作，并说明本文为何把注意力行为保持作为连接校准、低比特恢复和预算分配的对象。

### 2.1 Transformer 架构与自注意力机制

本节在 decoder-only Transformer 的因果自注意力设定下给出后文使用的基本公式。给定输入序列的隐藏状态矩阵  $H$ ，Query、Key 和 Value 由三组线性投影得到：

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V \quad (2-1)$$

当前步注意力由缩放点积、softmax 与 Value 聚合组成：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \quad (2-2)$$

其中  $d_k$  为 Key 的头维度。因果掩码使当前位置只能访问历史 token。因此，后文需要跟踪的是历史  $K/V$  的存储规模、访问方式以及量化后对 softmax 排序和聚合输出的影响。

多头注意力（Multi-Head Attention, MHA）把  $Q$ 、 $K$  和  $V$  沿头维度拆分后并行计算，再在输出端拼接：

$$\begin{aligned} \text{MHA}(Q, K, V) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h) W_O, \\ \text{head}_i &= \text{Attention}(Q_i, K_i, V_i) \end{aligned} \quad (2-3)$$

其中  $W_O$  为输出投影矩阵。这里保留 MHA 记号，是为了区分查询头数  $H_q$  与实际缓存的 KV 头数  $H_{kv}$ 。

在标准 MHA 中， $H_q = H_{kv}$ 。多查询注意力<sup>[14]</sup>令多个 Query 头共享单一 KV 头。分组查询注意力<sup>[15]</sup>将  $H_q$  个查询头划分为若干组，每  $H_q/H_{kv}$

个 Query 头共享一组  $K/V$  头。因此，当  $H_{kv} < H_q$  时，缓存字节数随实际 KV 头数下降，而 Decode kernel 也需要处理 Q 头到 KV 头的映射关系。后文的显存公式、低比特格式和 TPOT 边界都使用这一变量。

## 2.2 KV Cache 机制与显存分析

### 2.2.1 KV Cache 的作用与工作原理

在 Decoder-only Transformer 的自回归推理过程中，当前步只新生成一个 Query，但这个 Query 仍要访问全部历史 Key，并用相应 Value 聚合上下文信息。若每一步都重新计算历史 Key/Value，重复投影会随历史长度累积。实际推理系统因此把各层历史词元对应的 Key 和 Value 保存在显存中，并在后续解码步直接读取，这一机制即为 KV Cache。

本文关心的瓶颈主要发生在 Decode 阶段。Prefill 一次性处理完整提示词序列，并行度较高。Decode 每步只处理一个新词元，却必须读取随上下文长度线性增长的历史  $K/V$ 。因此，后文报告 TPOT、融合 Decode 路径和  $H_{kv}$  交叉边界时，本文具体追踪每个 Decode 步要搬运多少缓存字节，以及如何利用低比特格式减少这部分访存负担。

### 2.2.2 KV Cache 显存占用分析

对于包含  $L$  层的 Transformer 解码器，若每层保存  $H_{kv}$  个 Key/Value 头，每个头的维度为  $d_k$ ，序列长度为  $S$ ，单个缓存元素占用  $b$  字节，则 KV Cache 的总显存占用可写为

$$M_{KV} = 2 \times L \times H_{kv} \times d_k \times S \times b. \quad (2-4)$$

其中，系数 2 对应 Key 与 Value 各占一份缓存。这里默认每头满足  $d_v = d_k$ 。 $L$  表示层数， $H_{kv}$  表示每层实际参与缓存的 KV 头数， $d_k$  表示头维度， $S$  表示序列长度， $b$  表示单元字节数，例如 FP16、INT8 与 INT4 分别对应 2、1 和 0.5。结合上一节的 MHA、MQA 与 GQA 结构可知，缓存规模由共享后的  $H_{kv}$  决定，而不是由查询头数  $H_q$  决定：当模型从标准 MHA 过渡到 MQA 或 GQA 时， $H_{kv}$  的降低会直接减少缓存存储需求，这也是不同模型在长上下文部署成本上出现显著差异的重要结构原因之一。

以 Qwen2.5-7B-Instruct 为例，其可取  $L = 28$ 、 $H_{kv} = 4$ 、 $d_k = 128$ 。当序列长度  $S = 32768$ ，并采用 FP16 存储（即  $b = 2$ ）时，单个请求的 KV

Cache 显存占用为

$$M_{KV} = 2 \times 28 \times 4 \times 128 \times 32768 \times 2 \approx 1.75 \text{ GiB}. \quad (2-5)$$

这一数值仅对应 KV Cache 本身的存储，不包含模型权重、激活峰值与其他运行时开销。但在 32K 乃至更长上下文场景下，单请求缓存占用已经足以影响最大并发数与可服务长度。式 (2-4) 也给出后文实验变量的来源： $H_{kv}$  用于解释不同 GQA 结构的缓存压力， $S$  用于解释长上下文下的 Decode 访存放大， $b$  则是量化方法直接干预的字节数。下一节介绍本文使用的量化工具。

## 2.3 模型量化技术基础

量化将浮点张量映射为低比特整数表示，降低每个元素的存储字节数。本文重点讨论推理期不断增长的 KV Cache，重点在三类会进入方法设计的概念：对称量化作为保守基准，非对称量化作为 K/V 角色差异的探究起点，校准代理作为离线选择量化参数的依据。

### 2.3.1 对称量化

对称量化将浮点数值映射到以零为中心的均匀整数网格上。给定浮点张量  $x$  与目标比特宽度  $n$ ，其缩放因子 (scale) 可写为

$$s = \frac{\max(|x|)}{2^{n-1} - 1}. \quad (2-6)$$

在此基础上，量化映射与反量化过程分别为

$$x_q = \text{clamp}\left(\text{round}\left(\frac{x}{s}\right), -(2^{n-1} - 1), 2^{n-1} - 1\right), \quad \hat{x} = x_q \cdot s. \quad (2-7)$$

由此得到的近似值  $\hat{x}$  与原始值  $x$  之间存在量化误差，记为  $\epsilon = x - \hat{x}$ 。本文把对称量化作为基线格式，它实现时不需要额外处理非零 zero-point，零点也自然落在原点上。INT8 和对称 INT4 的定位不同。INT8 位宽相对保守，用来确认行为校准、离线参数和在线执行路径能否稳定衔接。对称 INT4 提供更强的低比特压力，用来观察继续压低位宽后，注意力行为会先在哪一侧出现失稳。INT8 对称量化使用  $[-127, 127]$  的整数范围，共有 255 个离散等级；对称 INT4 只保留  $[-7, 7]$ ，对应 15 个离散等级，离散等级数量相差

17 倍。只计算 K/V 主数据的 bit-packed 载荷时, INT4 可以把两个 4 位整数写入同一个字节, 使 KV Cache 占用为 FP16 的 1/4。实际系统中的 scale、metadata 和对齐方式会继续改变最终占用。本文关心的不是低位宽本身, 而是这种存储压缩进入注意力计算后是否仍能保持可用的推理行为。若注意力分布、聚合输出和任务读数已经明显偏离, 缓存字节数下降并不能单独说明量化路径有效。基于这一点, 后文先用 INT8 检查行为引导校准和执行路径的稳定性, 再用对称 INT4 暴露 Key 侧位宽降低可能触发的功能断点, 从而把容量收益和行为可用性分开判断。

### 2.3.2 非对称量化

非对称量化通过引入零点偏移来处理非零中心的数值分布。给定浮点张量  $x$  与目标比特宽度  $n$ , 其缩放因子与零点可定义为

$$s = \frac{\max(x) - \min(x)}{2^n - 1}, \quad z = \text{clamp}\left(\text{round}\left(-\frac{\min(x)}{s}\right), 0, 2^n - 1\right). \quad (2-8)$$

相应的量化映射与反量化过程为

$$x_q = \text{clamp}\left(\text{round}\left(\frac{x}{s}\right) + z, 0, 2^n - 1\right), \quad \hat{x} = (x_q - z) \cdot s. \quad (2-9)$$

当张量均值偏离零点, 或不同维度的统计差异较大时, 对称网格会把一部分整数等级花在样本很少落入的区间。非对称量化通过 zero-point 移动实数值与整数编码的对齐位置, 使可表示区间贴近非零中心分布, 在相同存储位宽下减少单侧范围浪费。这个参数入口也对应后文的 K/V 角色诊断。Key 侧主要暴露通道尺度差异, Value 侧主要暴露沿序列变化的动态范围, 两类差异可以分别由独立的零点与缩放因子刻画。

量化轴决定缩放因子绑定在哪个维度。逐通道量化沿通道方向设置参数, 更适合吸收通道间尺度差异。逐 token 量化沿时序方向设置参数, 更适合刻画位置相关的动态范围变化。

对 KV Cache 来说, 轴向选择会进入功能角色。Key 参与  $qK^\top$ , 先影响 attention logits 及其相对次序, 再经 softmax 转为权重分布。Value 在这些权重下被加权聚合。后文讨论存储位宽时, 会同时说明 bit 落在 K 还是 V 一侧, 以及它沿通道还是沿 token 分配。



### 2.3.3 校准方法综述

量化校准在本文中指离线确定缩放因子、裁剪阈值及相关参数的过程。不重新训练模型，也不改变模型权重，而是在部署前用少量样本选择一组上线后可复用的量化参数。

后文只需要区分两种校准视角。第一种直接看张量重建，例如用百分位裁剪抑制异常值，或用均方误差（MSE）衡量量化前后张量的逐元素差异。第二种把目标移到行为空间，例如用 KL 散度比较参考路径与量化路径诱导出的概率分布。二者的差别在于代理对象：MSE 约束“张量像不像”，KL 约束“softmax 后的注意力分布是否仍然把概率质量放在相近位置”。

这一点在 KV Cache 上尤其关键。量化后的 Key 和 Value 并不会被下游任务直接读取，而是先经过点积、softmax 与加权聚合，再影响最终输出。数值空间中的较小重建误差，不等价于注意力行为被保持。Key 侧的有限扰动也可能通过排序变化被 softmax 放大。下一节讨论已有 KV Cache 压缩工作中哪些工作已经处理了格式、异常值或缓存选择，哪些问题仍需要一个行为层代理来组织。

## 2.4 KV Cache 量化与高效推理相关工作

长上下文场景下，KV Cache 压缩研究已经不只回答“能否省显存”。相邻工作大致沿三条路径展开：低比特格式如何适配 K/V 的统计结构，量化失真如何在注意力行为层被发现和恢复，以及 bit-width 节省如何在 Decode 阶段转化为实际收益。更一般的量化理论综述可参见 Nagel 等人<sup>[16]</sup>与 Hubara 等人<sup>[17]</sup>。

以下工作从不同侧面说明，KV Cache 量化不宜只按统一位宽或统一轴处理。KIVI<sup>[8]</sup>采用 per-channel Key 与 per-token Value 的非对称格式，是本文低比特角色感知路径的直接参照。KVQuant<sup>[9]</sup>通过非均匀码本与 Pre-RoPE Key 量化进一步处理 RoPE 后表示对量化网格的影响。AsymKV<sup>[18]</sup>进一步显示 K/V 敏感性沿网络深度发生迁移，AQUA-KV<sup>[19]</sup>则将这一观察扩展到时序相关性维度。这些格式与统计差异的判断在本文中保留下来，作为低比特路径的格式约束。本文进一步把校准参数的来源问题独立出来，关注量化参数由什么行为信号选出，以及这些读数能否继续支撑跨层预算分配。

低比特恢复相关工作大致可以分处理量化误差本身与从缓存内容的重要性出发，决定哪些位置或 token 值得保留更高位宽。QuaRot<sup>[20]</sup>通过旋

转变换分散 Key 通道异常值, GEAR<sup>[21]</sup> 用残差低秩近似补偿量化误差, QServe<sup>[22]</sup> 则把低比特格式接入端到端推理系统。ZipCache<sup>[10]</sup> 按缓存重要性组织混合精度保留, IntactKV<sup>[23]</sup> 保留少量枢纽 token 的高精度表示, SKVQ<sup>[24]</sup> 利用局部窗口访问特征进行细粒度量化处理。Outlier Tokens Tracing<sup>[25]</sup>、Atom<sup>[26]</sup> 与 QJL<sup>[27]</sup> 分别从异常 token 追踪、低比特表示和随机投影近似等方向扩展 KV Cache 压缩的边界, 本文将它们列入表 2-1 作为边界参考。总体来看, 这些研究提示低比特 KV Cache 的性能保持不能只看平均压缩率, 还需要判断哪些内容、模型层位置或访问局部性更可能在量化后引发失稳。本文沿着这一线索, 将离线校准链路产生的行为敏感度画像用于失稳诊断和预算分配, 使压缩目标与分配决策建立在一致的行为证据之上。

缓存管理工作回答的是另一类问题: 哪些历史缓存应被保留、驱逐或差异化处理。H2O<sup>[28]</sup>、StreamingLLM<sup>[29]</sup>、SnapKV<sup>[30]</sup> 与 PyramidKV<sup>[31]</sup> 主要依据注意力重要性或层级结构压缩保留集合。DuoAttention<sup>[32]</sup>、HeadKV<sup>[33]</sup> 与 ChunkKV<sup>[34]</sup> 则从头级、逐头贡献或 chunk 结构组织缓存。CacheGen<sup>[35]</sup> 与 ThinK<sup>[36]</sup> 分别从流式编解码和查询驱动 Key 剪枝进入这一问题。它们与本文讨论的 bit-width 压缩不是替代关系: 缓存管理决定“哪些 token/head/chunk 还在”, 量化决定“留下来的缓存以多少 bit 和什么格式存”。系统性的 KV Cache 压缩 benchmark 可参见<sup>[37]</sup>。因此, 本文在后续章节中只把这一路线作为可组合边界, 而不把缓存驱逐本身纳入当前方法贡献。

表 2-1 KV Cache 压缩相关代表工作比较

| 方法                           | 对象/位宽                 | 核心策略                                       | 备注              |
|------------------------------|-----------------------|--------------------------------------------|-----------------|
| KIVI <sup>[8]</sup>          | KV Cache<br>2-bit     | per-channel Key +<br>per-token Value 非对称量化 | 典型的 K/V 角色差异化格式 |
| KVQuant <sup>[9]</sup>       | KV Cache<br>sub-4-bit | 非均匀码本 +<br>Pre-RoPE Key 量化                 | 推进极低比特缓存压缩      |
| AsymKV <sup>[18]</sup>       | KV Cache<br>—         | 分层 K>V 异质处理                                | 强调深度相关的敏感性差异    |
| AQUA-KV <sup>[19]</sup>      | KV Cache<br>—         | 利用时序相关性的自适应量化                              | 面向动态分布的缓存压缩     |
| ZipCache <sup>[10]</sup>     | KV Cache<br>mixed     | token 显著性驱动的混合精度策略                         | 压缩与恢复并重         |
| GEAR <sup>[21]</sup>         | KV Cache<br>2-bit     | 残差低秩补偿                                     | 低比特修复的代表路径      |
| QServe <sup>[22]</sup>       | W4A8KV4               | 端到端联合量化                                    | 突出系统协同          |
| IntactKV <sup>[23]</sup>     | KV Cache<br>4-bit     | 枢纽 token 高精度保留                             | 保护关键内容          |
| QJL <sup>[27]</sup>          | KV Cache<br>1-bit     | JL 随机投影压缩                                  | 极限压缩探索          |
| SnapKV <sup>[30]</sup>       | KV Cache<br>—         | 注意力预测驱动的缓存驱逐                               | 与量化正交           |
| DuoAttention <sup>[32]</sup> | KV Cache<br>mixed     | 头级差异化缓存策略                                  | 与量化正交           |
| ThinK <sup>[36]</sup>        | KV Cache<br>—         | 查询驱动的 Key 剪枝                               | 与量化正交           |

角色差异化格式解释“如何量化 K/V”，内容保护和混合精度路线解释“哪里不应同等压缩”，系统工作解释“低 bit-width 如何进入运行时”。本文将讨论离线行为校准结果如何产生，并如何被整理为同源行为敏感度画像交给预算分配层。

**量化对注意力行为的扰动。**若只看压缩率，容易漏掉量化误差进入注意力计算后的形态变化。本文的锚点有两个：Key 误差可能经 logits 与 softmax 改写概率质量，输出侧误差则要回到聚合结果中评价。KV Tuner<sup>[38]</sup> 分析了 Key 量化误差在注意力得分中的放大，并观察到高误差注意力头往往不再保持稀疏结构。Softmax Bias Correction<sup>[39]</sup> 从 softmax 量化角度指出 SQNR 劣化和近零概率问题。QeRL<sup>[40]</sup>、Softmax-Not-Enough<sup>[41]</sup> 与 AhaKV<sup>[42]</sup> 提供了概率平坦化、温度和缓存重要性的相邻证据。

**高效注意力与系统协同。**量化格式成立之后，还要经过系统路径检查。FlashAttention<sup>[11]</sup> 及 FlashAttention-2<sup>[12]</sup> 通过分块计算、在线 softmax 与更高效的并行组织降低注意力计算 IO。vLLM<sup>[4]</sup> 的 PagedAttention 通过分页式 KV Cache 管理减少显存碎片。Triton<sup>[13]</sup> 则为反量化与注意力计算融合提供 kernel 编写载体。这些工作共同说明，bit-width 降低后，若 nibble unpack、GQA head mapping 和 kernel 调度开销没有被 Decode 阶段的访存节省抵消，低比特缓存未必会转化为更低 TPOT。因此，第四章会把系统收益写成  $H_{kv}$ 、

序列长度和后端路径共同决定的经验边界。

上述文献已经分别覆盖格式设计、低比特恢复、缓存选择与系统执行。本文沿三件事继续推进：用行为代理选择参数，用 K/V 角色差异解释低比特断点，用行为敏感度画像驱动预算分配和部署路径判断。

## 2.5 研究空白与本文定位

综合上述文献位置，本文将贡献边界收束为四个需要在后续方法与实验中串联验证的问题。

仅依赖张量重建的校准目标难以充分刻画下游功能偏移。MSE、百分位裁剪和运行时统计仍是有用工具，但 KV Cache 误差必须经过 logits、softmax 和 Value 聚合后才变成下游功能损伤。因此第三章把 attention-distribution KL 写成可执行的分布侧代理，并同时保留它与输出扰动代理的边界。

进入低比特路径后，本文不只报告某个 INT4 路径是否可用，还进一步追问失稳与 Key/Value 角色差异、量化轴选择和执行路径之间的关系。KIVI 等工作已经给出角色差异化格式，本文在此基础上把对称 INT4 的断点、K4V8/K8V4 的角色对照以及 INT4-RoleAlign 的非对称路径实例放入同一条诊断路径。第四章再检查这种解释在不同模型族、规模和  $H_{kv}$  下的边界。

预算分配层面还存在进一步衔接校准结果的问题。已有混合精度和缓存管理工作通常回答“哪里保留更多内容”或“哪里使用更高精度”，但这些决策常与校准参数选择分开组织。本文把同源行为敏感度画像从校准层传递到 allocation / AutoK 层，用来解释 family-/scale-/task-dependent regimes，而不是宣称单一固定策略跨模型成立。

最后，部署收益不能直接由 bit-width 推出。低 bit-width 给出的是缓存字节数下降，TPOT 是否下降还取决于反量化、nibble unpack、GQA head mapping 与 kernel 调度是否同向。第四章因此把显存收益与时间收益分开报告，并把融合 Decode 路径写成受  $H_{kv}$  和序列长度共同调制的条件性结果。

这四个问题决定了第三章的方法组织：本文以注意力行为保持为主线，分别定义离线校准代理、低比特角色感知路径、预算分配机制和系统执行边界。

## 2.6 本章小结

本章为后续方法设计保留了四组必要前置：自注意力与 MQA/GQA 给出缓存结构记号，KV Cache 公式给出  $H_{kv}$ 、 $S$  与 bit-width 三个关键变量，对称/非对称量化说明 INT8 基准路径与 INT4 断点的格式差异，相关工作则限定了本文与格式设计、缓存管理和系统优化路线的关系。

第三章将在这些前置上转入方法定义：用注意力行为保持组织离线校准，用 K/V 角色差异解释低比特路径，用行为敏感度画像承接预算分配，并把这些产物落到可执行的推理机制中。

### 第三章 行为引导量化框架设计

#### 3.1 注意力近似误差的代数分解与问题形式化

在模型生成最终输出之前, KV Cache 误差会通过注意力 logits、softmax 权重和 Value 聚合进入后续计算, 并在该层注意力中体现为注意力分布  $a$  与注意力输出  $o$  的变化。本文提出  $K, V$  的逐元素重建距离不足以单独刻画这种行为变化, 将  $(a, o)$  视为量化后需要共同保持的行为表征, 并先在单头注意力设定下展开代数分解, 以说明 Key 扰动经注意力分布影响输出、Value 扰动经加权聚合影响输出的两条耦合路径。

记当前查询为行向量  $q \in \mathbb{R}^{1 \times d_k}$ , 历史上下文长度为  $S$ ,  $K \in \mathbb{R}^{S \times d_k}$  与  $V \in \mathbb{R}^{S \times d_v}$  分别由行向量  $k_i, v_i$  拼接而成。本文实验涉及的 Qwen2.5、LLaMA-3.1 以及 Mistral-7B-Instruct-v0.3 均采用常见的  $d_v = d_k$  设置, 因此在下述单头注意力记法中  $q$  与  $o$  同维。标准单头注意力可写为

$$a = \text{softmax}\left(\frac{qK^\top}{\sqrt{d_k}}\right), \quad o = aV, \quad (3-1)$$

其中  $a \in \mathbb{R}^{1 \times S}$  为注意力分布, 其第  $i$  个分量记为  $a_i \in \mathbb{R}$ ,  $o \in \mathbb{R}^{1 \times d_v}$  为注意力输出。注意力行为记作联合表征

$$\mathcal{B}(q, K, V) := (a, o). \quad (3-2)$$

后文以  $\Delta_{\text{beh}}$  刻画量化前后  $(a, o)$  的行为偏移。多层、多头情形可按层索引  $\ell$  与头索引  $h$  逐一展开, 记为  $q^{(\ell, h)}, K^{(\ell, h)}$  等。GQA/MQA 下, 多个 Query 头可共享同一 KV 头, 本节分解可对应到每个 Query 头及其映射的 KV 头, 具体映射关系已在第 2.2 节给出。

设  $Q_{\theta_K}(\cdot)$  与  $Q_{\theta_V}(\cdot)$  分别表示作用于 Key 与 Value 的量化映射。参数  $\theta_K, \theta_V$  的具体含义 (scale、zero-point、bit-width 等) 以及作用域 (逐元素、逐通道或逐 token) 由量化路径决定, 详见第 3.5 节。量化后的 Key 与 Value 记为

$$\hat{K} = Q_{\theta_K}(K), \quad \hat{V} = Q_{\theta_V}(V), \quad (3-3)$$

对应的量化后注意力分布与输出为

$$\hat{a} = \text{softmax}\left(\frac{q\hat{K}^\top}{\sqrt{d_k}}\right), \quad \hat{o} = \hat{a}\hat{V}. \quad (3-4)$$

KV Cache 量化的目标即

$$\min_{\theta_K, \theta_V} \Delta_{\text{beh}}((a, o), (\hat{a}, \hat{o})), \quad (3-5)$$

其中  $\Delta_{\text{beh}} : (\mathbb{R}^{1 \times S} \times \mathbb{R}^{1 \times d_v})^2 \rightarrow \mathbb{R}_{\geq 0}$  满足  $\Delta_{\text{beh}}(x, x) = 0$ ，刻画量化前后注意力行为的联合偏移。其作为损失函数使用，无需满足度量空间的对称性或三角不等式。 $\Delta_{\text{beh}}$  的具体实例化由量化路径决定，并在层、头或路径粒度上聚合实例化（第 3.4 节）。

由  $\hat{o} = \hat{a}\hat{V}$  与  $o = aV$  的定义，输出误差可作如下精确代数展开：

$$\hat{o} - o = \sum_{i=1}^S \hat{a}_i \hat{v}_i - \sum_{i=1}^S a_i v_i \quad (3-6)$$

$$= \sum_{i=1}^S (\hat{a}_i \hat{v}_i - \hat{a}_i v_i) + \sum_{i=1}^S (\hat{a}_i v_i - a_i v_i) \quad (3-7)$$

$$= \sum_{i=1}^S \hat{a}_i (\hat{v}_i - v_i) + \sum_{i=1}^S (\hat{a}_i - a_i) v_i. \quad (3-8)$$

式 (3-8) 是恒等变形。右侧第一项（聚合侧/Value 通路）描述 Value 侧内容被量化后如何进入聚合结果；右侧第二项（分布侧/Key 通路）描述 Key 侧扰动经 logits 与 softmax 改变注意力分布后如何传到输出。两条通路同时进入输出，单独追踪  $a$  或  $o$  均会遗漏一侧。第一项的权重为量化后分布  $\hat{a}_i$  而非参考分布  $a_i$ ，因此聚合侧误差与 Key 侧扰动并非加性可分——Key 量化通过  $\hat{a}$  同时改变第二项的分布偏移与第一项的聚合权重。张量重建误差并不刻画这种交叉依赖，可执行代理的具体形式由后续校准目标实例化（第 3.4 节）。两条耦合路径的可视化分解见图 3-1。

### 3.2 动机诊断：K/V 敏感性不对称及其设计启示

式 (3-8) 区分了两类误差作用于输出的路径。Key 侧扰动先改变注意力 logits，经 softmax 归一化后表现为注意力分布差异，并由分布项传到输出；Value 侧误差则以  $\hat{a}_i(\hat{v}_i - v_i)$  的形式，在量化后权重下进入聚合。扰动对输出的影响大小取决于分布形态、logit 间隔以及权重集中程度，因此在低比特预算下，Key 与 Value 量化误差对输出的敏感性可能不同。后文通过 K/V 单侧诊断，并以对称低比特配置作为参照，检验这种不对称是否在实验中




图 3-1 注意力误差的两条传播路径及其代数分解。FP16 attention 给出参考分布  $a$  与输出  $o$ ，量化后的 Key 误差经 logits 与 softmax 改变注意力分布，Value 误差在量化后权重下进入加权聚合。底部公式给出式 (3-8) 的最终分解形式。

出现，为低比特路径的格式选择提供依据。

本节采用  $K \times V_y$  表示 K/V 两侧位宽组合。K4V8 表示 4-bit Key 与 8-bit Value。K4V16 表示 Key 为 4-bit、Value 保持 FP16，K16V4 表示 Key 保持 FP16、Value 为 4-bit，MixedKV 对应 K8V4。图 3-2 呈现压缩诊断视图，并按三组配置组织：K8V8 是高位宽量化参考，K8V4/K4V8 在相同 K/V 平均位宽设置下对照 K/V 角色，K4V4 作为对称低比特锚点。未量化 FP16 参考和单侧 PPL 隔离实验结果分别由第四章表 4-7 与表 4-6 给出。




图 3-2 K/V 位宽落点诊断与设计启示。左侧压缩展示 K8V8、K8V4/K4V8 与 K4V4 的代表性 Needle 观察，突出 Qwen 系列在 4bit K 下的崩塌风险及 LLaMA-3.1-8B 的不同表现。右侧将该观察收束为低比特路径约束。完整 Needle、RULER 与 LongBench 风格证据见第 4.3.2 节。

Qwen2.5-1.5B 的单侧 PPL 诊断给出最直接的隔离读数。K4V16 将 PPL 相对 FP16 基线推高约两个数量级，K16V4 只带来基线邻域内的小幅变化，原始读数见表 4-6。同一方向也出现在 32K 任务诊断中，K4V8 下 Qwen2.5-1.5B 与 Qwen2.5-7B 的 RULER 通过率降为零，而 K8V4 没有出现归零式失



稳。两组读数共同支持一个较窄判断，即在本文这些 Qwen2.5 低比特对照中，Key 侧低比特噪声是更直接的任务级失稳触发源。Value 侧压缩并非没有影响，但在 K16V4 与 K8V4 对照中没有触发同等强度的失稳。这个判断与式 (3-8) 对 Key/Value 两条误差路径的机制区分一致。

这种不对称的强弱还随模型族和头共享结构改变。Qwen 系列的  $H_{kv}$  为 2 或 4，重复因子  $N_{\text{rep}} = H_q/H_{kv}$  落在  $\{6, 7\}$ ，在 K4V8 与 K4V4 下出现检索归零。LLaMA-3.1-8B 的  $H_{kv} = 8$ 、 $N_{\text{rep}} = 4$ ，在当前对照里失稳幅度较小。在 GQA 机制中，同一个 KV 头的量化误差会由映射到该头的一组 Query 头共同承受。在  $H_q$  可比的对照中，较小的  $N_{\text{rep}}$  意味着共享同一 KV 头误差的 Query 头更少，相关读数见表 4-7。模型规模、训练数据与 GQA 配置也同样会影响效果， $H_{kv}$  在本文中作为组间差异的代理变量，用于描述严重程度与触发位宽的边界变化。

这些证据表明，Key 侧低比特退化是低比特路径设计中需要优先约束的风险点。主要隔离依据来自单侧 PPL 诊断，K4V16 单独使 PPL 出现数量级退化，K16V4 只带来小幅变化。任务读数提供外部一致性，K4V8/K4V4 在 Key 位宽降到 4 bit 后出现更强失稳，K8V4 未出现归零式失稳。由于 K4V8 与 K4V4 同时压低 K 与 V，它们仍只适合作为边界辅助证据，不能单独支撑 K 主导的隔离推断。PPL 原始读数见表 4-6。跨任务读数及统计协议，包括 Bootstrap 95% CI、sign-flip 置换检验与 BH-FDR 多重比较校正，见表 4-7 与第 4.3.2 节。

### 3.3 行为引导量化框架总览

第 3.1 节把量化质量评判从张量重建误差移至注意力行为差异  $\Delta_{\text{beh}}$ ，第 3.2 节把低比特退化定位为 Key 侧主导。框架以两个离线模块落实上述约束：校准模块按候选量化路径搜索行为代理最优的参数。预算分配模块在同一离线链路上读取逐层敏感度统计量，输出每层（或 Key/Value 角色）保留多少 bit。

逐层行为敏感度画像

$$\mathcal{S} = \{s^{(l)}\}_{l=1}^L, \quad s^{(l)} \in \mathbb{R}_{\geq 0}, \quad (3-9)$$

是离线校准链路在处理校准样本时作为副产物输出的逐层标量统计量。分配模块以只读方式读取它，不发起新的校准搜索。 $\mathcal{S}$  不预设唯一计算公式，由具体量化路径对应的行为代理实例化（第 3.4 节详述）。本文取  $s^{(l)}$  越大表

示第  $l$  层在量化扰动下注意力行为越不稳定，并归纳地采用单调假设——读数越高的层在预算受限时保留更高位宽的边际收益越大。该假设的实验支撑见第 4.4 节。

校准层把“如何量化”组织为参数选择问题。设候选量化参数空间  $\Theta$  为离散候选集合，如 per-layer scale 候选格点，校准层求解

$$\theta^* = \arg \min_{\theta \in \Theta} \Delta_{\text{beh}}^{\text{cal}}(\theta), \quad (3-10)$$

其中  $\Delta_{\text{beh}}^{\text{cal}}(\theta)$  是  $\Delta_{\text{beh}}$  在有限校准样本上的代理估计——把第 3.1 节联合行为目标限制到离线校准集，转化为可执行计算。给定一条路径及其候选参数家族，校准层输出  $\theta^*$  供在线缓存写入直接读取。不同位宽与格式的差异由候选家族  $\Theta$  与代理  $\Delta_{\text{beh}}^{\text{cal}}$  的具体形式承担，框架不要求所有路径使用同一数值评分。

分配层负责决定各层保留的位宽预算。设平均 KV 位宽预算为  $\bar{b}$ ，分配映射

$$b^* = \mathcal{A}(\mathcal{S}; \bar{b}), \quad \frac{1}{L} \sum_{l=1}^L b_l^* \leq \bar{b}, \quad (3-11)$$

是一个确定性规则。它读取共享画像  $\mathcal{S}$ ，把逐层敏感度转换为整数位宽向量  $b^*$ ，在线推理时不重新优化，也不重复校准参数搜索。基础设置把  $b^*$  写成  $L$  维逐层预算， $b^* \in \{b_{\min}, \dots, b_{\max}\}^L$ ，本文使用  $b \in \{4, 8, 16\}$ 。当预算表达进一步区分 K/V 角色时， $b^*$  变为  $\{b_{\min}, \dots, b_{\max}\}^{L \times 2}$  中的向量，对应第 3.2 节识别的 Key/Value 双角色。此时  $\mathcal{S}$  也拆分为角色分量。第 3.6 节给出具体规则。

上述组织使校准链路和推理链路可以分开核验。离线阶段提取参考行为，完成路径参数搜索，写出冻结校准产物，并同步生成  $\mathcal{S}$ 。在线推理阶段只读取这些冻结产物，按照固定规则为当前缓存写入计算尺度或预算。推理阶段不重复离线搜索，这是框架的执行边界。 $\theta^*$  与  $b^*$  也相应作为离线交付物保存，而不是在线决策变量。图 3-3 给出离线—在线协作关系，以及共享画像在校准、低比特恢复和预算分配三层之间的传递方式。

### 3.4 行为引导校准目标与参数搜索策略

第 3.1 节把量化质量评判落到联合行为偏移  $\Delta_{\text{beh}}$ ，但该量在样本上无显式可执行形式。本节把代理  $\Delta_{\text{beh}}^{\text{cal}}$  实例化为分布侧 KL 散度，作为对称路




图 3-3 行为引导量化框架总览。离线校准链路读取校准样本、FP16 参考行为和候选量化路径，计算行为代理并完成稳健选择，输出冻结校准产物  $\theta^*$ 。校准链路同时沉淀逐层行为敏感度画像  $\mathcal{S}$ ，预算分配模块读取该画像，依据平均位宽预算  $\bar{b}$  生成位宽向量  $b^*$ 。在线推理阶段只读取  $\theta^*$  与  $b^*$ ，不重新搜索或更新离线产物，并据此执行缓存写入与解码。

径与 INT4-RoleAlign 的 K-path 共用的可计算目标。V-path 使用独立的输出扰动代理，详见第 3.5 节。两类代理均在路径相关的候选参数家族上完成稳健选择。

对称路径与角色感知低比特路径在候选参数家族与代理形式上不必相同，但都在离线样本上计算行为读数，在可行域约束下控制尾部坏案例，并把最终选择写入固定校准产物。

### 3.4.1 注意力分布 KL 散度目标

设第  $l$  层、第  $h$  个注意力头、时间步  $t$  的 Query 与 Key 分别为  $q^{(l,h,t)} \in \mathbb{R}^{d_k}$  与  $K^{(l,h,t)} \in \mathbb{R}^{N \times d_k}$ ，二者均在 input\_layernorm 与 RoPE 处理后取出， $N$  为当前位置可见的上下文长度。FP16 参考路径下的注意力分布

$$p_{\text{ref}}^{(l,h,t)} = \text{softmax} \left( \frac{q^{(l,h,t)} K^{(l,h,t)\top}}{\sqrt{d_k}} \right) \in \Delta^{N-1}, \quad (3-12)$$

其中  $\Delta^{N-1}$  为  $N$  维概率单纯形。对候选量化参数  $\theta$ ，记量化—反量化映射  $\tilde{K}_{\theta}^{(l,h,t)} = \text{dequant}(\text{quant}(K^{(l,h,t)}; \theta); \theta)$ ，对应分布

$$p_{\theta}^{(l,h,t)} = \text{softmax} \left( \frac{q^{(l,h,t)} \tilde{K}_{\theta}^{(l,h,t)\top}}{\sqrt{d_k}} \right) \in \Delta^{N-1}. \quad (3-13)$$

单位置分布偏移取前向 KL

$$d_{\text{KL}}^{(l,h,t)}(\theta) = D_{\text{KL}} \left( p_{\text{ref}}^{(l,h,t)} \parallel p_{\theta}^{(l,h,t)} \right), \quad (3-14)$$

将第 3.3 节引入的  $\Delta_{\text{beh}}^{\text{cal}}(\theta)$  实例化为校准样本集合  $T$  上的均值

$$\Delta_{\text{beh}}^{\text{cal}}(\theta) = \frac{1}{|T_{\text{cal}}|} \sum_{(x,l,h,t) \in T_{\text{cal}}} d_{\text{KL}}^{(x,l,h,t)}(\theta), \quad (3-15)$$

其中  $T_{\text{cal}} = \{(x, l, h, t) : x \in \mathcal{D}_{\text{calib}}\}$  收集校准样本中的位置、层和头索引。后续离线搜索直接以该代理作为候选参数的评分函数。候选家族、尾部读数和稳健选择规则在第 3.4.2 节展开。

用 MSE 选择量化参数时，比较对象仍是  $K$  或  $V$  的逐元素重建差异。对 Key 来说，这个差异进入输出之前还会经过  $qK^\top$ 、softmax 排序和概率质量重新分配。于是，某个候选即使在逐元素误差上较小，也可能把关键 token 的注意力质量转移到其它位置。式 (3-8) 正好给出这种差异进入输出的两条路径，

$$\sum_i (\hat{a}_i - a_i) v_i \quad \text{与} \quad \sum_i \hat{a}_i (\hat{v}_i - v_i).$$

前一项对应分布侧偏移，后一项对应 Value 聚合侧扰动。这里  $a_i \equiv p_{\text{ref},i}^{(l,h,t)}$ ， $\hat{a}_i \equiv p_{\theta,i}^{(l,h,t)}$ ， $v_i$  与  $\hat{v}_i$  分别表示参考 Value 和量化 Value。KL 直接比较  $a$  与  $\hat{a}$ ，因此读取的是分布侧误差。Value 侧扰动则通过量化后权重  $\hat{a}_i$  进入聚合项。这个对应关系说明，attention-distribution KL 更贴近 Key 误差影响输出的路径，而不是只停留在逐元素重建距离。


本文使用前向 KL  $D_{\text{KL}}(p_{\text{ref}} \| p_\theta)$ 。在长上下文检索中，高概率参考位置通常对应需要保留的关键信息。若量化候选低估这些位置，前向 KL 会给出更直接的惩罚。反向 KL 更偏向量化分布自身的高概率区域，JS 散度则提供对称读数，二者在本文中保留为补充诊断。Value 路径不复用该分布代理，而采用独立的输出扰动代理，见第 3.5 节。

数值上对  $p_{\text{ref}}$  与  $p_\theta$  均在  $[\varepsilon, 1]$  上做 clamp 截断（取  $\varepsilon = 10^{-6}$ ）以避免极端尾部概率引起的不稳定。KL 与数值代理（如 MSE）的必要性边界——在哪些条件下 KL 更必要、在哪些条件下二者会趋同——见第四章。

### 3.4.2 参数搜索空间与稳健选择准则

第 3.4.1 节给出均值代理  $\Delta_{\text{beh}}^{\text{cal}}$  后，对一条具体路径还需要确定有限离散候选网格  $\Theta_{\text{path}}$ 、该路径使用的行为代理  $R_{\text{path}}$ ，以及写入在线推理系统的产物字段。图 3-4 给出参考行为提取、路径实例化、行为评分、稳健选择与产物冻结五步离线流程，表 3-1 列出 INT8、对称 INT4 与 INT4-RoleAlign 三

条路径在这五步上各自的接口实例化。



**图 3-4** 行为引导离线校准的统一 workflow。校准样本先经过 FP16 前向得到参考行为。每条量化路径据此实例化候选网格  $\Theta_{\text{path}}$ ，并计算路径相关风险  $R_{\text{path}}(\theta)$ 。稳健选择阶段根据可行域、P95 尾部读数与裁剪率审计确定  $\theta_{\text{path}}^*$ ，同时保留行为读数  $\mathcal{S}$  与在线接口。RoleAlign 中，K 侧使用注意力分布 KL，V 侧使用输出扰动代理。

**表 3-1** 统一离线校准 workflow 下的路径参数化接口

| 路径             | 校准接口                 | 量化粒度                           | 主代理 / 约束                                   | 输出产物                  |
|----------------|----------------------|--------------------------------|--------------------------------------------|-----------------------|
| INT8 基准路径      | $(p_c, g, m)$        | 对称 per-group                   | 注意力分布 KL；P95；裁剪率约束                         | 静态 scale + 保护元数据      |
| 对称 INT4 试探路径   | $(p_c, g)$           | 对称 per-group                   | 注意力分布 KL；P95；裁剪率约束                         | 静态 scale              |
| INT4-RoleAlign | K: $p_K$<br>V: $p_V$ | K: per-channel<br>V: per-token | K: 注意力分布 KL / P95<br>V: 输出扰动代理<br>路径相关稳健约束 | 角色感知产物<br>K/V 参数与轴元数据 |

统一的是离线校准流程与稳健选择纪律，不同路径的差异体现在参数接口与行为代理上。在 INT4-RoleAlign 中，Key 路径由 attention-distribution KL 主导，Value 路径由独立的输出扰动代理主导。

给定候选网格  $\Theta_{\text{path}}$  后，路径参数的离线选择写为

$$\theta_{\text{path}}^* = \arg \min_{\theta \in \Theta_{\text{path}}} R_{\text{path}}(\theta), \quad (3-16)$$

其中  $R_{\text{path}}(\theta)$  是该路径上的稳健风险统计量。具体形式由路径决定，对称路径下下文式 (3-18) 给出的 attention-distribution KL 95% 分位数  $q_{0.95}(\theta)$  为主序，并叠加载剪率过滤与字典序回退（详见下文）。角色感知低比特路径在同一选择纪律下，把 K-path 与 V-path 的代理分开定义。

对称路径（包括 INT8 基准与对称 INT4 试探路径）使用同一组本地读数。设校准样本集合为  $\mathcal{D}_{\text{calib}}$ （来源、规模与序列长度见第 3.7 节）， $K^{\text{cal}}$  与  $V^{\text{cal}}$  分别为  $\mathcal{D}_{\text{calib}}$  上抽取的 Key 与 Value 张量元素集合，定义

$$\mu(\theta) = \text{Mean}_{(x,l,h,t) \in T_{\text{cal}}} d_{\text{KL}}^{(x,l,h,t)}(\theta), \quad (3-17)$$

$$q_{0.95}(\theta) = \text{P95}_{(x,l,h,t) \in T_{\text{cal}}} d_{\text{KL}}^{(x,l,h,t)}(\theta), \quad (3-18)$$

$$c_K(\theta) = \frac{|\{x \in K^{\text{cal}} : |x/s_\theta(x)| > q_{\max}\}|}{|K^{\text{cal}}|}, \quad (3-19)$$

$$c_V(\theta) = \frac{|\{x \in V^{\text{cal}} : |x/s_\theta(x)| > q_{\max}\}|}{|V^{\text{cal}}|}. \quad (3-20)$$

这里的  $\mu(\theta)$  是第 3.4.1 节均值代理对每个候选的取值,  $q_{0.95}(\theta)$  是同一逐位置 KL 分布的 95% 分位数。  $c_K(\theta)$  与  $c_V(\theta)$  分别记录 Key 与 Value 张量的裁剪率。对元素  $x$  以候选  $\theta$  对应的分组尺度  $s_\theta(x)$  缩放后, 若  $|x/s_\theta(x)|$  超过整数上界  $q_{\max}$ , 该元素计入对应裁剪率。INT8 取  $q_{\max} = 127$ , INT4 取  $q_{\max} = 7$ 。可行域用裁剪率阈值  $\tau_K, \tau_V$  硬过滤候选, 定义为

$$\Theta_{\text{feasible}} = \{\theta \in \Theta_{\text{path}} \mid c_K(\theta) \leq \tau_K, c_V(\theta) \leq \tau_V\}, \quad (3-21)$$

本文取  $\tau_K = \tau_V = 0.01$ 。若  $\Theta_{\text{feasible}} \neq \emptyset$ , 选择规则为

$$\theta^* = \arg \min_{\theta \in \Theta_{\text{feasible}}} q_{0.95}(\theta). \quad (3-22)$$

以尾部统计  $q_{0.95}$  为主序。  $\mu$  不参与主选择规则的最小化目标, 仅在并列或下文的回退规则中作为次级排序键。

若所有候选均违反裁剪率约束, 回退规则按字典序选取: 先最小化总裁剪负担  $c_K(\theta) + c_V(\theta)$ 。若总裁剪负担相同, 再比较尾部统计  $q_{0.95}(\theta)$ 。若尾部统计仍相同, 最后比较平均偏移  $\mu(\theta)$ 。排序第一的候选记为  $\theta^*$ , 并在产物字段中标记触发回退及其原因。

INT4-RoleAlign 沿用上述五步校准流程, 但不再把 Key 与 Value 合成一个统一的 KL 分数来选择参数。Key 路径只搜索  $p_K$ , 它对应逐通道 Key 非对称量化中的百分位裁剪参数, 读取 attention-distribution KL 及其尾部统计, 用来约束 Key 侧排序扰动。Value 路径只搜索  $p_V$ , 它对应逐 token Value 非对称量化中的百分位裁剪参数, 读取独立的输出扰动代理  $R_V(\theta)$  及其稳健统计, 用来约束聚合内容侧的偏移。两条路径的具体量化形式见第 3.5 节。

两条分路仍共用同一套可行域审计纪律。候选参数先经过裁剪率过滤, 再按各自代理的尾部统计或稳健统计排序, 若候选之间出现并列或需要回退, 则使用次级排序键处理。这样, K/V 两侧共享的是审计流程和选择纪律, 分开的则是候选参数、行为代理和主排序读数。对应阈值、主排序统计和次级排序键在 K/V 两条路径中分别给出。

离线产物按用途分成两类。路径特定校准字段由在线缓存写入过程直

接读取，逐层敏感度统计则交给第 3.6 节的预算分配模块。逐头温度校正只保留为附录诊断项，不进入主线流程。基于这个接口边界，后两节分别展开三条跨位宽路径的实例化设计，以及由敏感度统计支撑的预算分配机制。

### 3.5 跨位宽量化路径的实例化设计

第 3.4 节给出的离线校准流程与稳健选择纪律不规定唯一位宽或唯一量化格式。后文先用 INT8 基准路径检查校准闭环能否在保守位宽下稳定落地，再用对称 INT4 试探路径暴露直接降位宽后的结构困难，最后用 INT4-RoleAlign 把低比特路径改写为 K/V 角色分离的非对称格式，并在方法层面区分它与 KIVI-style<sup>[8]</sup> 的参数来源。三条路径共享第 3.4 节的参考行为提取、可行域约束、尾部优先选择和固定产物输出，差异仅在参数接口、量化轴与行为代理。三条路径输出的逐层敏感度统计共同供第 3.6 节的 allocator 读取。三条路径在量化格式、参数接口与行为代理上的并列对照见表 3-2。

表 3-2 跨位宽路径的实例化关系与统一校准 workflow

| 路径             | 位宽 / 量化格式                               | 主要接口                           | 暴露问题 / 目标                    | 统一流程中的定位                    |
|----------------|-----------------------------------------|--------------------------------|------------------------------|-----------------------------|
| INT8 基准路径      | 8-bit 对称 per-group                      | $(p_c, g, m)$                  | 形成稳定、便于复核的基准验证实例             | 基准验证路径<br>验证校准闭环            |
| 对称 INT4 试探路径   | 4-bit 对称 per-group                      | $(p_c, g)$                     | 暴露 Key 排序脆弱性，以及量化级别骤降带来的结构困难 | 说明对称 INT4<br>不能机械继承 INT8 路径 |
| INT4-RoleAlign | 4-bit<br>K: per-channel<br>V: per-token | K-path: $p_K$<br>V-path: $p_V$ | 在低比特下定义 K/V 角色分离的固定产物接口      | 角色感知低比特路径<br>统一流程下的实例       |

统一的是离线校准流程与稳健选择纪律。不同路径的差异体现在参数接口、量化格式与行为代理上。对 INT4-RoleAlign 而言，Key 路由 attention-distribution KL 主导，Value 路由独立的输出扰动代理主导。

#### 3.5.1 INT8 基准路径下的静态 Scale 与自适应保护

INT8 的有效整数等级为 255 级，量化网格相对细，校准层写出的 scale 参数也能按组追溯。本文先在这一设置下检查离线选择与在线执行是否形成闭环，并在第四章将该路径记为 INT8-Canonical。INT8 还提供后续低比特路径的压缩率参照。

该路径对 Key 和 Value 使用相同的静态对称逐组量化。分组沿通道维度划分，每组包含  $g = 128$  个元素并共享一个缩放参数。设第  $l$  层第  $j$  个分组的待量化张量为  $x_{l,j}$ 。给定校准百分位参数  $p_c$  和分组大小  $g$  后，静态缩

放参数定义为

$$s_{l,j}^{\text{static}} = \frac{\text{Percentile}(|x_{l,j}|; p_c)}{q_{\max}}, \quad (3-23)$$

其中  $q_{\max}$  表示对称量化网格的正端点 (INT8 取 127)。令  $q \in \mathbb{Z}$  为量化整数输出, 量化—反量化写为

$$q = \text{clamp}\left(\text{round}\left(\frac{x}{s_{l,j}^{\text{static}}}\right), -q_{\max}, q_{\max}\right), \quad \hat{x} = q s_{l,j}^{\text{static}}. \quad (3-24)$$

候选网格  $\Theta_{\text{path}}$  同时枚举  $(p_c, g)$ , 并依据第 3.4.2 节给出的 KL 尾部统计与裁剪率约束选出最终组合。

运行时样本可能落到校准覆盖范围之外, 因此该路径在静态缩放参数之外加入自适应保护。设当前写入张量为  $x_{l,j}^{\text{cur}}$ , 动态尺度定义为

$$s_{l,j}^{\text{dyn}} = \frac{\text{absmax}(x_{l,j}^{\text{cur}})}{q_{\max}}, \quad (3-25)$$

保护裕度  $m$  是固定超参数, 本文取  $m = 1$ , 并将其保留为后续扩展参数。最终缩放参数取

$$s_{l,j}^{\text{final}} = \max\left(m \cdot s_{l,j}^{\text{static}}, s_{l,j}^{\text{dyn}}\right), \quad (3-26)$$

当前 token 仍处在校准覆盖范围内时, 静态参数继续主导。若当前 token 的  $\text{absmax}$  超过  $m \cdot s_{l,j}^{\text{static}} \cdot q_{\max}$  对应的覆盖, 则改用动态尺度写入当前 token, 使该 token 仍落在量化网格内, 避免异常值被直接压到  $q_{\max}$ 。max 在每个写入步单独计算, K 与 V 的自适应保护开关也分别控制。极端漂移会抬高  $s_{l,j}^{\text{final}}$ , 进而扩大一定量化误差。这是为裁剪安全付出的工程代价。缓存写入时是否回写历史缓存的系统语义, 见第 3.7 节。

### 3.5.2 对称 INT4 的局限与格式升级动因

将第 3.5.1 节的对称路径改为对称 INT4 后, 最先改变的是整数网格。INT8 有 255 个有效离散等级, 对称 INT4 只保留 15 个, 离散等级数量约相差 17 倍。原本可以由 INT8 scale 细调吸收的通道幅值差异和 token 动态范围变化, 在 INT4 中会被映射到更稀疏的整数等级里, 量化扰动也更容易进入注意力计算。

这类扰动的主要风险落在 Key 侧。第 3.1 节已经把 Key 误差的传播路径写成 logits 排序变化和 softmax 分布偏移。第 3.2 节以及第 4.3.2 节中的



Qwen 系列读数给出对应的实验参照。单侧诊断与任务诊断方向一致，Key 降到 4 bit 后更容易触发功能断点。K4V8 在 Qwen 系列出现断崖式失稳，K8V4 没有出现同等强度退化。K4V4 同时降低 K 与 V 的位宽，因此只作为同向辅助观察。第四章的跨模型表图进一步限定了这一判断的范围。Qwen 系列的归零现象更明显，LLaMA-3.1-8B 在当前对照中失稳幅度较小。

据此，本文把对称 INT4 作为低比特格式选择的下界参照。单一对称 scale 需要同时覆盖 Key 通道间的幅值差异和 Value 沿 token 变化的动态范围。当这两类差异由同一个参数覆盖时，会在粗 INT4 网格内相互牵制。下一节转向 INT4-RoleAlign，把两类差异交给分开的 K/V 量化路径处理。

### 3.5.3 INT4-RoleAlign 的角色感知非对称量化

INT4-RoleAlign 从 K/V 两条传播路径出发改写低比特格式。Key 先参与  $qK^\top$ ，并影响 logits 的相对次序，粗 INT4 网格中的通道尺度误差容易被带入注意力排序。因此 Key 侧采用逐通道非对称量化，让每个特征方向保留独立的取值范围。Value 不直接决定排序，而是在注意力权重下进入加权聚合。Value 侧采用逐 token 非对称量化，用当前 token 的动态范围描述后续聚合所需的内容幅值。两条分路使用第 3.4 节的候选搜索、稳定性筛选与边界记录流程，差别只体现在量化轴、参数接口和代理读数。

实际实现中的 K/V 张量形状为  $[B, H_{kv}, S, D]$ ，Key 的 scale 张量形状为  $[B, H_{kv}, D]$ ，Value 的 scale 张量形状为  $[B, H_{kv}, S]$ 。先看 Key 侧的逐通道非对称量化。设第  $l$  层 Key 矩阵为  $K^{(l)} \in \mathbb{R}^{S \times d_k}$ 。对第  $j$  个通道，分位数裁剪边界定义为

$$m_{l,j}^K = \text{Percentile}(K_{:,j}^{(l)}; 100 - p_K), \quad M_{l,j}^K = \text{Percentile}(K_{:,j}^{(l)}; p_K), \quad (3-27)$$

其中  $p_K \in (50, 100]$ ，由此得到 Key 侧仿射缩放与偏移

$$s_{l,j}^K = \frac{M_{l,j}^K - m_{l,j}^K}{q_{\max} - q_{\min}}, \quad \zeta_{l,j}^K = m_{l,j}^K - q_{\min} s_{l,j}^K. \quad (3-28)$$

分位数沿序列维度统计，每个通道各有一组  $(s, \zeta)$ ，在粗 INT4 网格下保留不同特征方向的取值范围，减少通道差异被同一尺度抹平后对  $qK^\top$  排序的影响。

Value 侧逐 token 建立非对称量化参数。设第  $l$  层 Value 矩阵为  $V^{(l)} \in$

$\mathbb{R}^{S \times d_v}$ 。对第  $t$  个 token，分位数裁剪边界定义为

$$m_{l,t}^V = \text{Percentile}(V_{t,:}^{(l)}; 100 - p_V), \quad M_{l,t}^V = \text{Percentile}(V_{t,:}^{(l)}; p_V), \quad (3-29)$$

对应仿射参数

$$s_{l,t}^V = \frac{M_{l,t}^V - m_{l,t}^V}{q_{\max} - q_{\min}}, \quad \zeta_{l,t}^V = m_{l,t}^V - q_{\min} s_{l,t}^V. \quad (3-30)$$

分位数统计沿特征维度聚合，每个 token 独立量化。逐 token 参数吸收不同时间步的内容幅值变化。两条轴的配对直接绑定各自下游计算角色：K 侧影响  $qK^\top$  排序，V 侧影响注意力权重下的聚合。

K/V 两侧统一的量化—反量化形式为

$$q = \text{clamp}\left(\text{round}\left(\frac{x - \zeta}{s}\right), q_{\min}, q_{\max}\right), \quad \hat{x} = q s + \zeta, \quad (3-31)$$

其中 INT4 非对称网格取  $q_{\min} = -8, q_{\max} = 7$ （共 16 个量化等级）。 $\zeta$  为浮点仿射偏移，与整数 zero-point  $z$  的关系为  $\zeta = -s \cdot z$ 。以浮点  $\zeta$  存储可在反量化路径中省去额外整数偏移操作。 $(p_K, p_V)$  的来源按角色拆开： $p_K$  由 per-channel Key 路径的注意力分布 KL 搜索确定， $p_V$  由 per-token Value 路径的输出扰动代理  $R_V(p_V)$  确定，其形式为

$$R_V(p_V) = \mathbb{E}_{\mathcal{D}_{\text{calib}}} \sum_{h=1}^H \sum_{r=1}^S \left\| \sum_{t=1}^S a_{h,r,t} (V_{t,:} - \tilde{V}_{p_V,t,:}) \right\|^2, \quad (3-32)$$

其中  $a_{h,r,t}$  是第  $h$  个注意力头从 query 位置  $r$  到 key 位置  $t$  的注意力权重，由 FP16 参考路径在校准样本上单独前向得到。 $\tilde{V}_{p_V}$  为按候选  $p_V$  反量化后的 Value。内层求和把 V 量化误差按 attention 加权聚合得到 query  $r$  在头  $h$  上的输出扰动向量，外层在头与 query 位置上累加，期望在校准集  $\mathcal{D}_{\text{calib}}$  与各层上取均值。该代理把 V 量化误差经注意力权重加权后聚合再取二范数平方，与第 3.5 节扰动分解中的 V 主导路径形式一致。 $a_{h,r,t}$  的快照来自 FP16 参考路径的独立前向，不与量化路径共享中间状态，保证代理的独立性。 $(p_K, p_V)$  候选网格为  $\{95.0, 97.0, 99.0, 99.5, 99.9, 100.0\}$ ，由第 3.4.2 节的稳健选择规则筛选。K 侧以注意力分布 KL 为目标，V 侧以  $R_V$  为目标，两侧目标函数独立，仅在网格采样上保持一致。

由于  $\text{Percentile}(\cdot; 100) = \max$  且  $\text{Percentile}(\cdot; 0) = \min$ ，当

$$(p_K, p_V) = (100, 100) \quad (3-33)$$

时，K 路径与 V 路径退化为各自的 min-max 仿射端点。这一设置可以作为 KIVI-style 对照的参照点。KIVI-style 运行时直接用 min/max 统计确定逐通道 Key 端点和逐 token Value 端点。INT4-RoleAlign 则先在离线校准中选出百分位参数  $(p_K, p_V)$ ，运行时再按这组百分位读取当前张量的端点，并分别沿 K 的通道方向和 V 的 token 方向计算  $(s, \zeta)$ 。RoleAlign 固定的是端点统计口径，而不是每次写入时的实际数值范围。两者的可控差异因此落在端点规则上，前者使用运行时 min/max，后者使用离线搜索得到的百分位。

在  $(50, 100]$  的候选区间内，INT4-RoleAlign 搜索相对 min-max 更稳健的百分位端点，受控比较见第 3.5.4 节。K 侧沿 token 维度聚合，再按通道独立确定  $(s_K, \zeta_K)$ ；V 侧沿通道维度聚合，再按 token 独立确定  $(s_V, \zeta_V)$ 。双轴非对称布局见图 3-5。

INT4-RoleAlign 的角色感知非对称量化轴




图 3-5 INT4-RoleAlign 的角色感知非对称量化轴。Key 侧沿 token 方向聚合、对每个 channel 单独确定非对称量化参数，以优先保持 attention ranking；Value 侧沿 channel 方向聚合、对每个 token 单独确定非对称量化参数，以适应内容侧的动态范围变化。

表 3-3 给出本路径进入第四章时的固定配置。Key 侧承担排序保持，Value 侧承担内容幅值适配。逐头温度校正非对称格式下未作主线收益来源，相关推导与溯源说明见附录第 A.8 节。

表 3-3 INT4-RoleAlign 的最终路径配置

| 路径     | 量化轴                  | 参数            | 离线选择读数                     | 运行时载荷                                |
|--------|----------------------|---------------|----------------------------|--------------------------------------|
| K-path | per-channel 非对称      | $p_K$         | 注意力分布 KL 与尾部稳定性检查          | 冻结的 $p_K$ 。运行时计算每通道 $(s, \zeta)$     |
| V-path | per-token 非对称        | $p_V$         | 注意力权重加权 V 重建代理 $R_V$ 与边界记录 | 冻结的 $p_V$ 。运行时计算每 token $(s, \zeta)$ |
| 补充诊断   | per-head temperature | $\tau_h^{-1}$ | 非对称格式下未作为主线收益来源            | 不进入默认运行时载荷                           |

### 3.5.4 INT4-RoleAlign 与 KIVI-style 的设计差异

INT4-RoleAlign 与 KIVI-style 采用相同的低比特轴布局，即 per-channel Key 与 per-token Value。KIVI-style 运行时根据 min/max 统计直接生成每个 Key 通道和每个 Value token 的仿射端点，初始化阶段只固定 chunk、residual 缓冲长度等结构性超参数。INT4-RoleAlign 则在评测前写入离线校准产物，其中包括 K/V 分路径选出的百分位参数  $(p_K, p_V)$ 、轴元数据和边界记录，运行时仍读取当前张量，只是按这些百分位而不是 min/max 重新计算  $(s, \zeta)$ 。Key 侧百分位来自 attention-distribution KL 搜索，Value 侧百分位来自独立的输出扰动代理  $R_V$ ，两条路径的校准目标不合并。表 3-4 从格式、参数来源、行为代理、离线产物与分配读数五个维度列出差异。

表 3-4 INT4-RoleAlign 与 KIVI-style 在参数来源与冻结时刻上的设计差异

| 维度   | KIVI-style                     | RoleAlign                      | 边界读法                                 |
|------|--------------------------------|--------------------------------|--------------------------------------|
| 量化轴  | per-channel K + per-token V    | 相同                             | 共享低比特格式，比较聚焦于参数来源                    |
| 参数来源 | 运行时 min/max 统计                 | 离线 K/V 分路径搜索                   | 比较锚定在参数来源与冻结时刻                       |
| 行为代理 | 仅运行时统计驱动                       | K: 注意力分布 KL<br>V: 输出扰动代理 $R_V$ | 两侧代理分开定义，校准逻辑可独立追溯                   |
| 离线产物 | 结构超参数固定 (chunk size 等)，无固化校准文件 | 固化 K/V 校准产物                    | 同一接口下可复核参数、轴与 percentile 边界          |
| 分配读数 | 设计上不输出共享画像                     | 可输出共享读数                        | 校准产物兼容第 3.6 节分配器接口。KIVI 路径下的画像化为后续工作 |

定量比较与跨模型表现见第四章第 4.3.3 节。本节只在方法层面厘清两者在 KV Cache 量化中的可控变量。

## 3.6 行为敏感度驱动的层间预算分配与 AutoK

本节讨论预算选择问题——给定位宽约束下，由分配器决定哪些层或角色应被优先保护。校准层回答“如何量化”，分配层回答“哪里优先保护”。行为引导分配是校准产物的下游接口，不与校准路径竞争主轴。

为了统一记号，设共有  $L$  层，第  $l$  层的 Key 与 Value 位宽分别记为  $b_K^{(l)}$

和  $b_V^{(l)}$ ，则平均 KV bit 预算可写为

$$\bar{b} = \frac{1}{2L} \sum_{l=1}^L (b_K^{(l)} + b_V^{(l)}). \quad (3-34)$$

在对称分配的特殊情形下，若  $b_K^{(l)} = b_V^{(l)} = b^{(l)}$ ，则有

$$\bar{b} = \frac{1}{L} \sum_{l=1}^L b^{(l)}. \quad (3-35)$$

后续分配器的任务，就是在给定  $\bar{b}$  的前提下，为各层或各角色生成满足预算约束的位宽决策向量。

### 3.6.1 逐层敏感度构建与分配策略

本节推导主线 BA- $k$  分配器。以离线校准产物为输入，由逐层 K 侧角色尺度生成保护层集合。以 INT4-RoleAlign 为主实例，校准产物中存有逐层 K 侧 per-channel scale 范围张量

$$\sigma_K^{(l)} \in \mathbb{R}^{H_{kv} \times d_k}, \quad (3-36)$$

其中  $H_{kv}$  为 KV head 数， $d_k$  为 Key 通道数（沿用第 3.5.3 节 per-channel 非对称量化的通道分组）。该读数与第 3.4 节产出的角色尺度统计同源，与表 3-4 ”分配读数” 行描述的接口一致。整个分配阶段以离线读数驱动，不再对样本逐 token / 逐 head 计算注意力 KL。校准产物同时存有 V 侧读数  $\sigma_V^{(l)} \in \mathbb{R}^{H_{kv} \times S_{\text{cal}}}$  ( $S_{\text{cal}}$  为校准集对齐后的 token 序列长度)，由 V 侧 per-token 范围在校准 token 维上排列得到，将在第 3.6.2 节角色感知扩展中使用。

第 3.2 节的 K-cliff 诊断给出本节代理的物理来源。在 Qwen 与 LLaMA 系列对称 INT4 场景中，K 位宽下降是触发分配崩塌的主导方向，因此本节以 K 侧角色尺度构建逐层画像，V 侧读数留作角色感知扩展使用。机制依据来自 Qwen 与 LLaMA 系列的单侧诊断。给定聚合模式  $\alpha$ ，第  $l$  层的逐层敏感度记为

$$s_\alpha^{(l)} = \text{Agg}_\alpha(\sigma_K^{(l)}), \quad l = 1, \dots, L, \quad (3-37)$$

其中  $\text{Agg}_\alpha : \mathbb{R}^{H_{kv} \times d_k} \rightarrow \mathbb{R}$  在 head 与通道两轴上做一次性 max 或 mean 聚合。主线分配器固定  $\alpha = \text{max}$ ，对应”最脆弱读数主导”的保守口径，因此

后文实验统一以 BA- $k$  命名。整层画像记为有序序列

$$S_\alpha = (s_\alpha^{(1)}, s_\alpha^{(2)}, \dots, s_\alpha^{(L)}), \quad (3-38)$$

序列保留层索引位置，使下文 TopK 可以稳定返回层索引集合。

给定固定保护层数  $k$ ，BA- $k$  分配器先选出保护层集合

$$\mathcal{P}_k^{(\alpha)} = \text{TopK}(S_\alpha, k) \subseteq \{1, \dots, L\}, \quad (3-39)$$

TopK 在敏感度并列时按层索引升序打破平局，使保护集合在复现中唯一确定。再把位宽决策写成两级向量

$$b^{(l)} = b_{\text{lo}} + (b_{\text{hi}} - b_{\text{lo}}) \mathbf{1}[l \in \mathcal{P}_k^{(\alpha)}], \quad (b_{\text{lo}}, b_{\text{hi}}) = (4, 8), \quad (3-40)$$

即未保护层落到 INT4，保护层升至 INT8。由  $|\mathcal{P}_k^{(\alpha)}| = k$  与  $\sum_{l=1}^L b^{(l)} = (L - k)b_{\text{lo}} + k b_{\text{hi}}$ ，平均预算

$$\bar{b} = \frac{1}{L} \sum_{l=1}^L b^{(l)} = b_{\text{lo}} + \frac{k}{L} (b_{\text{hi}} - b_{\text{lo}}), \quad (3-41)$$

$k$  直接控制平均位宽  $\bar{b}$  在  $[b_{\text{lo}}, b_{\text{hi}}]$  上的位置。BA- $k$  在预算受限时保护行为代理最高的若干层。固定  $k$  网格由本节定义，跨模型 best- $k$  读数由第四章第 4.3.3 节报告。从离线读数  $\sigma_K^{(l)}$  经聚合、覆盖度与 TopK 写入逐层位宽向量的整体流程，以及 K/V 角色接口的预留位置见图 3-6。

### 3.6.2 K/V 角色感知的预算扩展

BA- $k$  主线分配器在保护层与未保护层各自统一两级位宽  $(b_{\text{lo}}, b_{\text{hi}}) = (4, 8)$ ，未对 K/V 两侧的差异做进一步区分。本节把分配器扩展为 K/V 两侧独立的两级版本，第  $l$  层的位宽决策从单值  $b^{(l)}$  升为角色对

$$\mathbf{b}^{(l)} = (b_K^{(l)}, b_V^{(l)}). \quad (3-42)$$

沿用第 3.6.1 节的聚合记号，K/V 两侧的逐层敏感度读数分别由各自的角色尺度张量聚合得到

$$s_K^{(l)} = \text{Agg}_\alpha(\sigma_K^{(l)}), \quad s_V^{(l)} = \text{Agg}_\alpha(\sigma_V^{(l)}), \quad (3-43)$$

### 行为敏感度画像到预算分配

逐层分配给出主线, K/V 角色预算保留为接口扩展




图 3-6 行为敏感度画像到预算分配的图示。左侧主线从离线读数出发, 经层级聚合得到逐层敏感度画像, 并由 BA-k、Heuristic-k 与 AutoK 三类策略写入逐层位宽向量。右侧给出 K/V 角色预算接口, 后续扩展可分别读取  $s_K^{(l)}$  与  $s_V^{(l)}$ , 形成角色保护集合与角色位宽对。

对应的整层画像写为有序序列  $S_{K,\alpha} = (s_K^{(l)})_{l=1}^L$  与  $S_{V,\alpha} = (s_V^{(l)})_{l=1}^L$ 。此时  $S_{K,\alpha}$  等同于第 3.6.1 节中由  $\sigma_K^{(l)}$  主导的 BA-k 主线画像,  $S_{V,\alpha}$  是 V 侧并行扩展。

在固定保护层数  $(k_K, k_V)$  后, K/V 两侧分别按各自的画像选取保护集合

$$\mathcal{P}_K^{(\alpha)} = \text{TopK}(S_{K,\alpha}, k_K), \quad \mathcal{P}_V^{(\alpha)} = \text{TopK}(S_{V,\alpha}, k_V), \quad (3-44)$$

位宽决策仍取统一两级  $(b_{\text{lo}}, b_{\text{hi}}) = (4, 8)$

$$b_K^{(l)} = b_{\text{lo}} + (b_{\text{hi}} - b_{\text{lo}}) \mathbf{1}[l \in \mathcal{P}_K^{(\alpha)}], \quad b_V^{(l)} = b_{\text{lo}} + (b_{\text{hi}} - b_{\text{lo}}) \mathbf{1}[l \in \mathcal{P}_V^{(\alpha)}]. \quad (3-45)$$

由  $|\mathcal{P}_K^{(\alpha)}| = k_K$  与  $|\mathcal{P}_V^{(\alpha)}| = k_V$ , 全局平均预算

$$\bar{b} = \frac{1}{2L} \sum_{l=1}^L (b_K^{(l)} + b_V^{(l)}) = b_{\text{lo}} + \frac{k_K + k_V}{2L} (b_{\text{hi}} - b_{\text{lo}}), \quad (3-46)$$

即角色感知扩展用  $(k_K + k_V)$  替代 BA-k 中的单一保护层数  $k$ 。当  $k_K = k_V = k$  时退化为 BA-k 主线分配器。当  $k_K \neq k_V$  时分配器可在不增加平均预算的前提下, 把保护名额按 K/V 角色重新分配。

INT4-RoleAlign 的离线校准产物中已同时记录  $\sigma_K^{(l)}$  与  $\sigma_V^{(l)}$ , 因此本节的角色感知预算可直接由现有产物驱动, 无需额外校准开销。第四章的主线实验固定  $k_K = k_V = k$  与 BA-k 一致, 角色感知扩展作为接口预留进入第 3.7.1 节的产物清单。

### 3.6.3 敏感度聚合与覆盖度准则

前两小节给出了由校准产物到逐层/角色感知预算的基本接口。本节把”画像形状”这一定性描述转写为可计算的覆盖度函数  $\Gamma(k)$ ，作为 AutoK 的输入。第 3.6.1 节定义的聚合算子  $\text{Agg}_\alpha : \mathbb{R}^{H_{kv} \times d_k} \rightarrow \mathbb{R}$  在两轴上一次性归约 (flat 聚合)，即第  $l$  层敏感度

$$s^{(l)} = \text{Agg}_\alpha(\sigma_K^{(l)}) = \begin{cases} \max_{u \in \mathcal{U}_l} \sigma_{K,u}^{(l)}, & \alpha = \max, \\ \frac{1}{|\mathcal{U}_l|} \sum_{u \in \mathcal{U}_l} \sigma_{K,u}^{(l)}, & \alpha = \text{mean}, \end{cases} \quad (3-47)$$

其中  $\mathcal{U}_l = \{(h, j) : h \in \{1, \dots, H_{kv}\}, j \in \{1, \dots, d_k\}\}$ 。INT4-RoleAlign 校准产物中存储的  $\sigma_K^{(l)}$  由非对称量化在  $p_K$  下确定的百分位端点区间  $[m_{l,j}^K, M_{l,j}^K]$  各通道独立计算得到 (跨通道聚合发生在后续  $\text{Agg}_\alpha$  算子上)，逐元素非负，因此  $s^{(l)} \geq 0$ 。BA- $k$  主线固定  $\alpha = \max$ ， $\alpha = \text{mean}$  留作聚合敏感性的备用读数。

将  $\{s^{(l)}\}_{l=1}^L$  归一化为概率分布

$$\tilde{s}^{(l)} = \frac{s^{(l)}}{\sum_{j=1}^L s^{(j)}}, \quad \sum_{l=1}^L \tilde{s}^{(l)} = 1, \quad (3-48)$$

当  $\sum_j s^{(j)} = 0$  (极端退化情形) 时改取均匀分布  $\tilde{s}^{(l)} = 1/L$ 。把  $\{\tilde{s}^{(l)}\}$  按值降序映射为序数索引序列

$$\tilde{s}_{(1)} \geq \tilde{s}_{(2)} \geq \dots \geq \tilde{s}_{(L)}, \quad \tilde{s}_{(i)} \equiv \tilde{s}^{(\pi(i))}, \quad (3-49)$$

其中  $\pi$  是把序数  $i$  映回原层索引的排列。并列值的内部排序按层索引升序确定，与第 3.6.1 节的 TopK 平局规则一致。累计覆盖度函数定义在  $k \in \{0, 1, \dots, L\}$  上：

$$\Gamma(k) = \sum_{i=1}^k \tilde{s}_{(i)}, \quad \Gamma(0) = 0, \Gamma(L) = 1, \quad (3-50)$$

约定空和  $\sum_{i=1}^0 = 0$ 。 $\Gamma(k)$  把画像形状直接转写为预算覆盖。敏感度集中在少数层的模型， $\Gamma(k)$  在较小  $k$  处即接近 1，敏感度在层间更弥散的模型，达到同一覆盖阈值所需的  $k$  显著增大。集中型与弥散型画像在相同覆盖阈值



$\rho$  下推出不同最小保护层数  $k^*$  的直观对照见图 3-7。




图 3-7 敏感度覆盖度曲线示意，图中以保护层数  $k$  为横轴，以排序后前  $k$  层累计敏感度  $\Gamma(k)$  为纵轴。给定相同覆盖阈值，集中型画像用较小的  $k$  即可达到目标覆盖度；弥散型画像则需要覆盖更多层。该示意说明 AutoK 依据画像形态生成预算建议的方式。

### 3.6.4 AutoK 的预算自动建议机制

BA- $k$  把人工选定的整数  $k$  作为保护层数，但不同模型的敏感度画像形状不一致，相同的  $k$  在画像集中模型与画像弥散模型上对应的行为覆盖差异显著。AutoK 直接读取第 3.6.3 节给出的覆盖度函数  $\Gamma(k)$ ，把“覆盖阈值”作为外部超参数取代逐  $k$  网格扫描，从而把人工选  $k$  的环节折叠到画像曲线本身。AutoK 不是完全无超参的自动决策，而是把整数  $k$  sweep 转换为覆盖率阈值  $\rho$  下的候选生成器——决策粒度从「逐模型逐  $k$  跑实验」转移到「按画像曲线一次写入  $\rho$ 」，但  $\rho$  仍由设计者按部署目标在  $(0, 1)$  内取值。

给定覆盖阈值  $\rho \in (0, 1)$ ，定义满足覆盖的最小保护层数

$$k^*(\rho) = \min\{k \in \{1, \dots, L\} : \Gamma(k) \geq \rho\}. \quad (3-51)$$

由  $\Gamma(0) = 0$  与  $\Gamma(L) = 1$ ，集合非空， $k^*(\rho)$  在  $\{1, \dots, L\}$  上唯一存在。由于  $\Gamma$  是单调阶梯函数， $k^*(\rho)$  满足  $\Gamma(k^*) \geq \rho > \Gamma(k^* - 1)$ ，即  $\rho$  不要求被等号命中。 $\rho = 1$  退化为全层保护  $k^* = L$ ， $\rho \rightarrow 0^+$  退化为单层保护  $k^* = 1$ ，故实践中  $\rho$  取自  $(0, 1)$  的开区间，并在每个模型上按校准画像单独选定。AutoK 对应的保护集合写为

$$\mathcal{P}_{\text{AutoK}}^{(\alpha, \rho)} = \text{TopK}(S_{K, \alpha}, k^*(\rho)), \quad (3-52)$$

即在 BA- $k$  主线的  $S_{K, \alpha}$  上把  $k$  替换为  $k^*(\rho)$ 。两级位宽向量沿用  $(b_{\text{lo}}, b_{\text{hi}}) =$

(4, 8)

$$b_{\text{AutoK}}^{(l)} = b_{\text{lo}} + (b_{\text{hi}} - b_{\text{lo}}) \mathbf{1}[l \in \mathcal{P}_{\text{AutoK}}^{(\alpha, \rho)}]. \quad (3-53)$$

AutoK 与 BA- $k$  共享同一离线画像入口与同一保护规则。二者只在  $k$  的来源上不同，BA- $k$  取人工指定的整数，AutoK 取由  $\rho$  与  $\Gamma$  反推的最小整数。第四章主线实验取  $\rho \in \{0.80, 0.90\}$ ，每个模型按画像选定单值。

表 3-5 分配层策略的输入、选择规则与对应记号

| 策略             | 输入                     | 保护规则                                | 需扫整数<br>$k$ ?            | 输出         | 实验记号        | 方法定位    |
|----------------|------------------------|-------------------------------------|--------------------------|------------|-------------|---------|
| Uniform        | 无                      | 所有层统一默认低位宽                          | 否                        | 统一位宽<br>向量 | Uniform     | 低预算参考   |
| BA- $k$        | $(S_{K,\alpha}, k)$    | 保护敏感度最高的 $k$ 层                      | 是                        | 分层位宽<br>向量 | BA-k        | 分层分配器主体 |
| Heuristic- $k$ | $(L, k)$               | 固定位置规则保护 $k$ 层                      | 是                        | 分层位宽<br>向量 | Heuristic-k | 位置先验基线  |
| BA-AutoK       | $(S_{K,\alpha}, \rho)$ | 取满足 $\Gamma(k) \geq \rho$ 的最小 $k^*$ | 否 (仅 $\rho$<br>一次设<br>定) | 分层位宽<br>向量 | BA-AutoK    | 覆盖度预算建议 |

表 3-5 中  $S_{K,\alpha} = (s^{(l)})_{l=1}^L$  为第 3.6.1 节定义的逐层 K 侧敏感度序列。Heuristic- $k$  作为 BA- $k$  的强基线对照在第 4.3.3 节定义具体位置规则。AutoK 的”无需扫描整数  $k$ ”与 BA- $k$  的”按  $k$  网格扫描”在工程粒度上有数量级差异：BA- $k$  在第四章按  $k \in \{1, 3, 5, 7, 11\}$  等离散采样点逐点跑实验，AutoK 仅在校准期一次写入  $\rho$ ， $k^*(\rho)$  由画像曲线确定。该粒度差异不等同于完全无超参。AutoK 仍以  $\rho$  作为部署侧外部超参，整体定位为画像驱动的候选生成器，而非端到端自动决策。

### 3.7 系统级部署实现与开销分析

前述各节分别给出了行为引导校准目标、跨位宽路径实例以及预算分配接口。本节回答实现层问题：离线定义好的量化规则与预算决策如何进入推理系统，定义离线校准产物、在线缓存写入语义、融合解码核函数数据流和理论开销。

#### 3.7.1 离线校准产物与在线推理管线

行为引导框架沿用量化系统中常见的”离线校准、在线执行”两阶段分工。离线阶段以少量校准样本执行第 3.4 节定义的搜索与选择纪律，写出路径特定的校准产物，在线阶段直接载入这些产物并按既定规则执行量化写入。本节把”行为代理驱动的参数搜索”对应的离线产物字段、缓存写入语

义与解码路径接口梳理清楚，使后续融合核函数设计与第四章实验都能稳定挂接。

记路径相关的离线校准产物为

$$\mathcal{A}_{\text{path}} = \{\theta_{\text{path}}^{(l)}, m_{\text{path}}^{(l)}\}_{l=1}^L, \quad (3-54)$$

其中  $\theta_{\text{path}}^{(l)} \in \mathbb{R}^{n_l}$  是第  $l$  层进入量化算子  $Q$  的参数向量（如逐通道 scale、percentile 选择记录、保护裕度）， $m_{\text{path}}^{(l)}$  为不进入  $Q$  的工程元数据（如量化轴布局、group size、诊断读数），仅用于路由与复核。表 3-6 把字段拆成四类。

表 3-6 离线校准产物的运行时字段表

| 字段组  | 典型字段                                             | 读取模块            | 边界说明                                                                                                                                                       |
|------|--------------------------------------------------|-----------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 路径索引 | model id、layer id、K/V role                       | 路径选择            | 决定缓存写入与解码路径的路由                                                                                                                                             |
| 量化参数 | 逐组 scale、percentile 选择记录（保护裕度由运行时配置提供）           | 缓存写入            | 评测前冻结离线规则。INT4-RoleAlign 的 K 侧 per-channel scale/zero-point 在 prefill 阶段一次性按数据现场计算后冻结复用，V 侧 per-token scale/zero-point 随每个新 token 写入时按 per-token 数据现场计算并缓存 |
| 轴元数据 | group size、per-channel/per-token 标记、KV head 数    | 参考/融合后端         | 定义布局与 GQA 头数关系，作为接口契约存在                                                                                                                                    |
| 诊断记录 | 候选网格、保护触发标记、画像读数 $\sigma_K^{(l)}/\sigma_V^{(l)}$ | 复核脚本、第 3.6 节分配器 | 分配器仅读敏感度统计行。其余字段供溯源使用                                                                                                                                      |

三条路径写入  $\mathcal{A}_{\text{path}}$  的字段并不相同，具体对照见表 3-7。INT8 基准路径保存逐组静态 scale 与分组元数据，inv\_tau 字段保留在产物中，但主线运行时将 use\_attn\_temperature 设为 false。对称 INT4 沿用这一组织，只把量化网格降为 4-bit。INT4-RoleAlign 则在量化参数字段中增加 K/V 两侧的 percentile 选择记录与轴向元数据。运行时再按 K/V 角色生成仿射参数。K 侧在预填充阶段依据冻结 percentile，用逐通道数据一次性计算  $(s_K, \zeta_K)$ ，之后保持不变并复用。V 侧在每个新 token 写入时，用逐 token 数据即时计算  $(s_V, \zeta_V)$ 。

在线推理接收第  $t$  个新 token 时，第  $l$  层的量化写入统一记作

$$\hat{x}_t^{(l)} = Q_{\theta_t^{(l)}}(x_t^{(l)}), \quad \theta_t^{(l)} = \begin{cases} \theta_{\text{path}}^{(l)}, & \text{对称路径，无自适应保护} \\ g_t(\theta_{\text{path}}^{(l)}, x_t^{(l)}), & \text{INT8 自适应保护} \\ h^{K/V}(\theta_{\text{path}}^{(l)}, x_t^{(l)}), & \text{INT4-RoleAlign} \end{cases} \quad (3-55)$$

其中  $\theta_{\text{path}}^{(l)}$  表示评测前固化的路径参数。对称路径读取逐组静态 scale，INT4-RoleAlign 读取已选定的 percentile 参数  $(p_K, p_V)$ 、K/V 轴标记与边界

记录。 $g_t$  对应 INT8-Canonical 的写入保护逻辑，只查看第  $l$  层当前 token 待写入的张量和离线参数，并按第 3.5.1 节的逐 token 最大值触发规则决定当前组是否改用动态 scale。 $h^{K/V}$  则对应 INT4-RoleAlign 的 K/V 分路映射。K 侧在预填充阶段依据冻结 percentile 计算逐通道  $(s_K, \zeta_K)$ ，解码时复用这组参数。V 侧随每个新 token 写入，根据该 token 的内容即时计算逐 token  $(s_V, \zeta_V)$ 。

缓存写入保持按时间追加的语义。对任意  $t' < t$ ，第  $t$  步只追加当前缓存项  $\hat{x}_t^{(l)}$ ，不回写已经存在的历史缓存  $\hat{x}_{t'}^{(l)}$ 。多随机种子复现中的逐位一致结果，间接核验了这一写入过程的确性和历史缓存封闭性。第四章第 4.2 节给出固定协议下的 INT8-Canonical 主线读数。自适应保护只在主线实验的 INT8-Canonical 路径中开启，其余对称路径沿用常量  $\theta_{\text{path}}^{(l)}$ 。INT4-RoleAlign 按  $h^{K/V}$  生成仿射参数，K 侧预填充后复用，V 侧随新 token 写入即时计算，不依赖自适应保护。

预填充阶段，当前块的 K/V 按各自路径规则量化后写入缓存。进入解码阶段后，注意力后端只从已经写入的量化历史缓存中读取 K/V。Decode 路径的输入被限制为离线产物和历史缓存两类对象。后续融合解码核也可以直接消费量化缓存，在接口层面避开反量化后中间张量的显式物化。

表 3-7 不同量化路径的离线产物、运行时缓存载荷与默认执行后端

| 路径        | 离线产物                  | 追加写入                       | 解码后端            | 边界说明          |
|-----------|-----------------------|----------------------------|-----------------|---------------|
| INT8      | scale、保护裕度、轴元数据       | INT8 K/V 与 scale           | Triton 融合后端     | 主部署路径         |
| 对称 INT4   | scale、轴元数据            | packed INT4 K/V            | 参考实现或 Triton 试探 | 压力测试，解包计入成本   |
| RoleAlign | $(p_K, p_V)$ 、K/V 轴头数 | K per-channel; V per-token | 参考实现；融合扩展       | 质量核对优先，速度见第四章 |

### 3.7.2 Triton 融合解码核函数设计

自回归解码每生成一步，只新增一个 query token，历史 K/V 却要被完整访问一次。序列变长后，瓶颈自然落到 KV Cache 的读取和反量化路径。最直接的做法是从低比特缓存读出 K/V，先完整反量化成 FP16 中间张量，再交给标准注意力实现。这条路径语义清楚，但会额外产生一份随序列长度增长的中间张量，显存读写也随之放大。INT8 路径采用 Triton<sup>[13]</sup> 融合解码核，把反量化、点积、online softmax 和输出累加放入同一条片上流水线，减少低比特缓存与全局内存之间的往返。

融合核沿序列维度分块处理历史缓存。每个块从量化缓存中读取低比特  $K_B, V_B$  及其缩放参数和元数据，在 SRAM 与寄存器中完成解包和反量

化，然后直接计算当前 query 与该块 Key 的点积  $z_i = qk_i^\top / \sqrt{d_k}$ ，其中  $k_i$  表示反量化后的第  $i$  个 Key 行向量。后续递推只保存跨块 softmax 所需的行最大值、归一化因子和输出累加器，而不需要把整段历史 K/V 先还原成完整 FP16 张量。随后，核函数用在线 softmax 维护跨块递推状态<sup>[11]</sup>。设第  $r$  个块的状态包含行最大值  $m^{(r)}$ 、归一化因子  $\ell^{(r)}$  和归一化输出累加器  $o^{(r)}$ ，并令

$$m_B = \max_{i \in B} z_i, \quad B = \{\text{第 } r+1 \text{ 个块中的 token 索引}\}, \quad (3-56)$$

跨块更新写为

$$m^{(r+1)} = \max(m^{(r)}, m_B), \quad (3-57)$$

$$\ell^{(r+1)} = e^{m^{(r)} - m^{(r+1)}} \ell^{(r)} + \sum_{i \in B} e^{z_i - m^{(r+1)}}, \quad (3-58)$$

$$o^{(r+1)} = \frac{\ell^{(r)} e^{m^{(r)} - m^{(r+1)}} o^{(r)} + \sum_{i \in B} e^{z_i - m^{(r+1)}} v_i}{\ell^{(r+1)}}, \quad (3-59)$$

这里  $v_i$  表示反量化后的第  $i$  个 Value 行向量。上述递推与 FlashAttention 的 online softmax 等价。实现中保留非归一化累加器  $\tilde{o}^{(r+1)} = \ell^{(r+1)} o^{(r+1)}$ ，待全部块处理完后再除以  $\ell^{(\text{final})}$ ，从而避免逐步重复除法。

INT4 的表示形式减少了存储字节数，但解包开销也进入运行路径。nibble packing 将两个 4-bit 整数放入一个 8-bit 字节。写入 packed 缓存时，整数码值先平移到无符号  $[0, 15]$  域再存入 nibble。非对称 INT4 使用  $[-8, 7]$  的 16 级码本，对称诊断路径仍按前文  $q_{\max} = 7$  的  $[-7, 7]$  网格产生码值。读取时，核函数用位移和掩码拆出半字节，再还原为路径对应的有符号整数，并按对应参数反量化。对称路径使用 scale，INT4-RoleAlign 使用  $(s, \zeta)$ 。执行路径上，本文保留两种 INT4 实现口径。对称 INT4 诊断路径采用 wrapper 方式，先把 nibble 缓存批量反打包为 INT8 张量，再复用 INT8 融合核完成片上反量化、点积、online softmax 和输出累加。这一路径便于把格式诊断接到已有核函数上，但仍会显式产生 INT8 中间载荷。INT4-RoleAlign 的非对称融合扩展则把解包放进核内，核函数直接读取 K 侧逐通道和 V 侧逐 token 的  $(s, \zeta)$ ，在片上存储中完成 nibble 解包与非对称反量化，从而避开显式 INT8 中间张量物化。4-bit 载荷降低了全局读取字节数，反打包和寄存器压力则会反映到每输出 token 的 TPOT 中。

为兼容 GQA<sup>[15]</sup>，融合核需要把 Query 头映射到共享的 KV 头。记 Query 头数为  $H_q$ 、KV 头数为  $H_{kv}$ 。本文涉及的 GQA 模型均满足  $H_{kv} \mid H_q$ 。重复

因子定义为

$$N_{\text{rep}} = \frac{H_q}{H_{kv}}, \quad h_{kv} = \lfloor h_q / N_{\text{rep}} \rfloor. \quad (3-60)$$

并行组织按  $(B, H_q)$  展开, 其中  $B$  表示序列块,  $H_q$  表示 Query 头维度。每个 Query 头通过上式映射到对应的  $h_{kv}$  切片, 直接读取共享 KV 头, 而不在内存中复制出  $H_q$  份 K/V。这样可以保持 GQA 的缓存布局, 但访存合并、元数据广播和寄存器占用都会受映射关系影响。这些开销会和 INT4 反打包一起体现在 TPOT 读数中。

INT8-Canonical 由 INT8 融合核支撑, 用来检验保守位宽下的行为校准闭环。INT4-RoleAlign 的质量评估主线采用参考解码实现, 重点核验非对称格式的语义一致性, 系统边界测量另设 INT4 扩展路径, 用于拆分格式对照和后端实现, 并覆盖 KIVI-style 对照与 Triton 融合后端读数。下一节在这三类路径的基础上比较访存、存储与算力开销。

### 3.7.3 复杂度、访存与存储开销分析

离线开销主要来自候选参数扫描。记候选集合规模为  $|\Theta_{\text{path}}|$ 、校准样本数为  $N$ 、模型层数为  $L$ 、Query 头数为  $H_q$ 、每个样本的校准长度为  $n$ , 头维度为  $d_k$ 。路径级离线搜索复杂度可记为

$$T_{\text{calib}}^{\text{path}} = \mathcal{O}(|\Theta_{\text{path}}| N L H_q n d_k), \quad (3-61)$$

式中采用  $H_q$  而非  $H_{kv}$ , 是因为这一阶次描述注意力分布 KL 代理的主要计算。该代理逐 Query 头比较参考分布与量化分布。INT8 基准路径、对称 INT4 与 INT4-RoleAlign 使用同一搜索流程, 但各路径的代理实例化并不完全相同。K 路径沿 KL 统计计算, V 路径按输出扰动代理统计。在主导阶次表示中, 路径差异主要体现为候选集合规模差异, 以及代理实现带来的常数项差异。

KV Cache 显存按“数据载荷 + 元数据载荷”分解。设  $S$  为当前缓存的序列长度, 每元素数据字节为  $b_{\text{data}}$  (FP16 取 2, INT8 取 1, INT4 packed 取 1/2), 每组 scale 占 4 字节 (FP32), group size 为  $g$  (INT8 路径取  $g = 128$ , 对称 INT4 路径取  $g = 32$ )。FP16 参考开销

$$M_{\text{FP16}} = \underbrace{2}_{\text{K+V}} \cdot \underbrace{2}_{2 \text{ bytes/element}} \cdot L H_{kv} S d_k = 4 L H_{kv} S d_k. \quad (3-62)$$

对称 INT8 路径

$$M_{\text{INT8}} = 2LH_{kv}Sd_k \left( \underbrace{1}_{1 \text{ byte/element}} + \underbrace{\frac{4}{g}}_{\text{scale 摊销}} \right), \quad (3-63)$$

对称 INT4 路径

$$M_{\text{INT4}} = 2LH_{kv}Sd_k \left( \frac{1}{2} + \frac{4}{g} \right). \quad (3-64)$$

INT4-RoleAlign 不采用 per-group 元数据, K 侧 scale/zero-point 形状为  $[L, H_{kv}, d_k]$ , V 侧 scale/zero-point 形状为  $[L, H_{kv}, S]$ , 因此其显存口径写为

$$M_{\text{RoleAlign}} \approx \underbrace{LH_{kv}Sd_k}_{\text{packed K+V payload}} + \underbrace{8LH_{kv}d_k}_{\text{K per-channel scale/zp}} + \underbrace{8LH_{kv}S}_{\text{V per-token scale/zp}}, \quad (3-65)$$

其中 packed payload 由 K 与 V 各一份的 nibble 化字节构成 (每元素 0.5 字节、合计  $LH_{kv}Sd_k$  字节)。K 侧 scale 与 zero-point 各占 4 字节、独立于  $S$ , V 侧 scale 与 zero-point 各占 4 字节、随  $S$  线性增长。该公式按实现口径给出方法层面的近似估计, 第四章表 4-14 给出端到端实测显存读数。

Decode 阶段的访存收益按 block 级字节量解释。设 block 大小为  $B_s$ , 每个 block 的访存量在对称 INT8 与 INT4 路径下分别近似为

$$\text{Bytes}_{\text{INT8}} \approx 2B_sd_k \left( 1 + \frac{4}{g} \right), \quad \text{Bytes}_{\text{INT4}} \approx 2B_sd_k \left( \frac{1}{2} + \frac{4}{g} \right), \quad (3-66)$$

块级浮点计算量按  $4B_sd_k$  估计 ( $qK^\top$  与权重—Value 加和各贡献  $2B_sd_k$  次乘加), 相应算术强度

$$AI_{\text{INT8}} \approx \frac{2}{1 + 4/g}, \quad AI_{\text{INT4}} \approx \frac{2}{1/2 + 4/g}. \quad (3-67)$$

代入  $g = 128$  时  $AI_{\text{INT8}} \approx 1.94$ ,  $g = 32$  时  $AI_{\text{INT4}} \approx 3.20$ , 低比特融合路径在相同浮点计算下减少全局内存传输, 从而缓解 decode 阶段的访存压力、提升计算访存比。nibble 反 pack、调度与寄存器占用成为新的条件性开销, 端到端 TPOT 边界由第四章第 4.5.1 节实测给出。

离线校准产物的存储相对运行时 KV Cache 与模型权重可忽略。对称 INT8 基准路径的产物规模为

$$\mathcal{O}(LH_{kv}d_k/g), \quad (3-68)$$

INT4-RoleAlign 产物由层级分位数参数与量化轴元数据构成。K 侧 per-channel scale/zero-point 在 prefill 阶段由数据现场计算后冻结复用，V 侧 per-token scale/zero-point 随追加 token 现场计算后入缓存，二者均不持久化到校准文件，因此离线产物规模量级与对称 INT8 同阶。第四章在上述公式基础上给出部署效率边界与跨硬件读数。

### 3.8 本章小结

本章先说明注意力误差怎样进入输出。第 3.1 节通过代数分解，把注意力近似误差写成分布侧扰动与聚合侧扰动。第 3.2 节再借助 K/V 对照诊断给出较窄的经验判断，Key 侧低比特扰动更容易触发断崖式失稳，Value 侧在本文对照中没有出现同等强度的退化。

第 3.4 节把行为对齐落到可执行的校准接口中。注意力分布 KL 负责读取量化后 attention 行为的偏移，候选参数搜索再用尾部稳健统计和回退规则固定选择口径。第 3.5 节沿这一接口展开三条位宽路径。INT8 基准路径用于建立保守位宽下的保真参照，对称 INT4 用来观察直接降位宽后低比特失稳首先出现在哪一侧，INT4-RoleAlign 则把 Key 的通道尺度和 Value 的 token 动态范围分开处理，用逐通道 Key 与逐 token Value 的非对称量化缓解低比特失稳。该路径把离线选出的百分位参数和轴元数据写入产物，运行时再按 K/V 两侧规则生成仿射参数。与 KIVI-style 的比较限定在相同 K/V 轴布局和非对称仿射格式内，两者共享格式，区别在端点统计规则。KIVI-style 运行时用 min/max 确定端点，INT4-RoleAlign 使用评测前冻结的离线百分位参数，运行时仍按当前张量计算实际仿射参数，从而把校准来源差异从格式差异中分离出来。

分配模块读取同一批校准产物。第 3.6 节由逐层 K 侧角色尺度构造敏感度画像  $S_{K,\alpha}$ ，并据此定义 BA- $k$  主线分配器。归一化覆盖度函数  $\Gamma(k)$  用来描述前  $k$  个保护层覆盖了多少敏感度质量。给定覆盖阈值  $\rho$  后，AutoK 生成满足该阈值的最小保护层数候选。第 3.7 节把这些方法产物接到系统接口，明确离线校准字段、缓存写入语义、融合解码核接口，以及三条路径的访存、存储与算术强度分解。第四章据此报告三类结果，保守位宽下的质量保真、低比特路径的缓解效果与边界证据、跨模型预算策略的适用区间，并进一步比较融合解码相对参考解码的 TPOT 读数。



## 第四章 实验评估与策略适用区间分析

### 4.1 实验设置与可信性声明

本节给出第四章共同使用的实验口径。后文的质量、长上下文和系统效率读数，均围绕这里列出的模型集合、任务协议、比较路径和数据溯源规则展开。

具体设置从模型、硬件与实现环境展开，随后交代评测指标对应的失败模式、比较对象及其控制变量，并固定正文主证据、补充审计材料与协议一致性检查之间的关系。

#### 4.1.1 模型、硬件与实现环境

本文实验覆盖 Qwen2.5<sup>[2]</sup>、LLaMA-3.1<sup>[1]</sup> 与 Mistral<sup>[43]</sup> 三个模型族，共六个开源指令模型，参数规模从 1.5B 延伸至 14B，同时覆盖  $H_{kv} = 2, 4$  与 8 三种 GQA 配置。这个矩阵给后文三类变量留下观察空间：模型族差异、规模差异和 GQA 头数差异。所有模型的头维度统一为 128。

表 4-1 本章实验所用 6 个模型与 GQA 配置

| 模型                       | 模型族       | 参数规模 | GQA<br>( $H_q, H_{kv}$ ) | Layers | 头维度 | 实验角色                  |
|--------------------------|-----------|------|--------------------------|--------|-----|-----------------------|
| Qwen2.5-1.5B-Instruct    | Qwen2.5   | 1.5B | (12, 2)                  | 28     | 128 | INT8 基准路径与官方数据对照锚点    |
| Qwen2.5-3B-Instruct      | Qwen2.5   | 3B   | (16, 2)                  | 36     | 128 | 小模型分配策略剖面             |
| Qwen2.5-7B-Instruct      | Qwen2.5   | 7B   | (28, 4)                  | 28     | 128 | 同族补充对照                |
| Qwen2.5-14B-Instruct     | Qwen2.5   | 14B  | (40, 8)                  | 48     | 128 | 大模型分配策略剖面             |
| LLaMA-3.1-8B-Instruct    | LLaMA-3.1 | 8B   | (32, 8)                  | 32     | 128 | 中等规模与 $H_{kv} = 8$ 对照 |
| Mistral-7B-Instruct-v0.3 | Mistral   | 7B   | (32, 8)                  | 32     | 128 | Mistral 家族分配策略剖面      |

Qwen2.5-1.5B-Instruct 用于基准路径和官方数据对照。Qwen2.5-3B-Instruct、Mistral-7B-Instruct-v0.3、LLaMA-3.1-8B-Instruct 与 Qwen2.5-14B-Instruct 分别承担后文典型剖面。Qwen2.5-7B-Instruct 提供同族补充对照。

所有实验均在单张 NVIDIA H20 GPU (98 GB HBM) 上完成。软件环境为 Python 3.12、PyTorch 2.8.0 (CUDA 12.8)、Transformers 与 Triton。除特别说明外，生成式质量评测与吞吐量测试采用贪婪解码<sup>1</sup>。PPL 使用固定输入序列上的 likelihood 累计，不涉及采样解码。

<sup>1</sup>除特别说明外，生成式任务采用贪婪解码：temperature=0.0、top\_p=1.0、top\_k=0。

#### 4.1.2 评测任务、数据与指标

本章的评测从两类问题展开。一类关心量化后模型行为是否仍然稳定，另一类问题关心缓存变小之后，真实推理中的显存占用、访存压力和解码时间是否同步下降。PPL 检查固定窗口内语言建模概率质量的整体漂移。Needle-in-a-Haystack<sup>[44]</sup> 用精确匹配通过率观察长距离目标片段是否还能被取回。LongBench 风格合成任务把比较推进到任务输出层面，并在同一数据生成与评分管线内读出方法差异。RULER<sup>[45]</sup> 则提供更高压力的组合式长上下文检查。官方 LongBench 真实数据对照放在第 4.2 节，用于检查评测协议与外部真实数据方向是否一致。正文主评测矩阵以 LongBench 风格合成任务为核心。

PPL 部分统一采用 32K 上下文评测协议，`chunk_size` 固定为 128。交叉熵累计时，每个位置可访问的历史窗口由这一设置限定。显存充足的模型按完整测试集报告 PPL。Qwen2.5-14B 受 H20 显存约束，使用测试集固定前缀评测。因此 14B 的 PPL 绝对值用于该模型内部对照，跨模型读数仍按同协议结果解释。

Needle-in-a-Haystack 捕捉检索型失效，实验覆盖 4K、8K、16K 与 32K 四个上下文长度，并在每个长度内使用统一的 needle 深度设置扫描。正文报告精确匹配通过率，它作为长距离目标片段取回能力的主读数。

任务级主矩阵采用 LongBench 风格合成任务。`task-core` 子集覆盖单文档问答、多文档问答和摘要三类功能，问答任务使用 F1，摘要任务使用 Rouge-L，少量扩展任务使用 Edit Similarity 等文本相似度指标。该协议服务于本文内部的方法比较，分数按同一生成和评分口径解释，并与社区官方榜单保持区分。

RULER 检查组合式长上下文任务中的稳定性，正文使用宏平均通过率汇总。Needle 是单点检索探针，暴露目标片段取回的临界点。RULER 覆盖多个子任务，观察长上下文能力是否在更复杂任务组中同步退化。两者共同构成长上下文行为侧的压力测试。

系统效率部分单独报告 TPOT 与 KV Cache 占用。TPOT 对应 Decode 阶段生成单个 token 的时间，KV Cache 占用对应缓存容量收益。峰值显存和 batch 维度容量边界作为附录扩展读数，用于补充审计整体运行压力。第 4.5 节据此讨论当前 H20 环境中的部署收益与时间边界。

## 4.1.3 比较方法与配置

表 4-2 中的每一类比较对象都承担一个控制问题。FP16 提供质量参考上界。percentile INT8/INT4 baseline 给出数值截断路径的参照。INT8-Canonical 与对称 INT4 检查同一行为引导纪律在不同位宽下的表现。INT4-RoleAlign 与 KIVI-style<sup>[8]</sup> 固定在 per-channel K + per-token V 的同一非对称格式内，用于分离格式升级与离线校准来源的影响。MixedKV 用于 K/V 角色诊断。

表 4-2 比较方法与配置总表

| 量化模式                      | 校准理念                           | 量化轴                         | Key bit | Value bit | 默认后端          |
|---------------------------|--------------------------------|-----------------------------|---------|-----------|---------------|
| FP16                      | –                              | –                           | FP16    | FP16      | FP16          |
| INT8 baseline             | percentile                     | 对称 per-group                | 8       | 8         | 参考实现 / Triton |
| INT8-Canonical            | KL-guided                      | 对称 per-group + 自适应保护        | 8       | 8         | Triton        |
| INT4 percentile baseline  | percentile                     | 对称 per-group                | 4       | 4         | 参考实现          |
| 对称 INT4 (behavior-guided) | KL-guided                      | 对称 per-group                | 4       | 4         | 参考实现          |
| INT4-RoleAlign            | role-aware offline calibration | per-channel K + per-token V | 4       | 4         | 参考实现          |
| KIVI-style                | runtime min/max                | per-channel K + per-token V | 4       | 4         | 参考实现          |
| MixedKV                   | diagnostic                     | K8V4                        | 8       | 4         | 参考实现          |

表 4-2 同时固定三个控制变量。校准理念区分 percentile、KL-guided、role-aware offline calibration 与 runtime min/max。量化轴区分对称 per-group 与非对称 per-channel K + per-token V。scale 时间语义区分离线固化与逐 token 更新。K/V 位宽混合作为单独的诊断维度，由 MixedKV 在 K/V 角色诊断中承担。

MixedKV 仅用于第 4.3.2 节的 K/V 角色敏感性诊断，不参与主线方法比较。

分配策略的比较不放入表 4-2。Uniform、BA-k、Heuristic-k 与 BA-AutoK 将在第 4.4 节按同量级预算带单独报告。其中 Heuristic-k 是位置先验基线，BA-AutoK 是画像驱动预算建议器，二者均按各自比较角色读取，不在设置节预设优劣。

#### 4.1.4 统计检验、显著性与数据溯源

第四章的证据按来源区分。正文主结果来自同一实验矩阵、同一解码设置和同一统计规则下重新执行并核验的读数，承担主要结论。官方 LongBench 小范围对照、完整 LongBench-style 聚合和上下文长度趋势作为协议一致性与补充审计材料。较早批次或回溯整理的补充读数进入正文时，在对应表注中标明来源和用途。

随机性控制采用统一的固定种子与统一生成策略。生成式质量评测统一使用 5 个固定 seeds，吞吐量测试统一使用 8 个固定 seeds。生成式任务采用贪婪解码，从而剥离采样噪声。PPL 评测采用固定输入序列上的确定性 likelihood 累计。seed 用于实现路径一致性核验，不构成独立统计重复。在此基础上，质量指标的区间估计采用基于 10,000 次重采样的 95% Bootstrap 置信区间，配对比较采用符号翻转置换检验，多重比较则使用 Benjamini-Hochberg 控制假发现率。在小样本下，Bootstrap 区间稳定性与 sign-flip 检验 power 都有限，因此正文中的“未显著”表示当前样本下不可分辨。

PPL 使用固定输入序列、固定 tokenization、固定窗口与固定 loss mask，属于确定性 likelihood 指标。其可靠性主要来自协议一致性与效应量，正文读取数值幅度，不读取统计显著性。任务级分数、吞吐量等会随种子或系统噪声波动的指标，才配合 Bootstrap、sign-flip 与 BH-FDR 一并解释。

后文主表、主图与典型剖面均沿用上述层级。各协议的绝对分数按各自口径读取。官方 LongBench 真实数据对照服务于第 4.2 节的一致性检验。完整 LongBench-style 聚合、统计检验汇总与上下文长度质量趋势见附录第 A.4 节。部署效率读数对应当前 H20 硬件、固定软件栈与当前后端组合。

## 4.2 行为引导校准的保真度验证

第 4.1 节固定了实验口径，本节验证 INT8 基准位宽下的保真度。

表 4-3 INT8 基准路径保真度 (Qwen2.5-1.5B-Instruct)

| 任务                  | FP16 | INT8-Canonical | $\Delta$ |
|---------------------|------|----------------|----------|
| NarrativeQA (F1)    | 7.07 | 7.16           | +0.09    |
| HotpotQA (F1)       | 4.90 | 4.88           | -0.02    |
| GovReport (Rouge-L) | 9.21 | 9.20           | -0.01    |
| Mean                | 7.06 | 7.08           | +0.02    |

注：本表聚焦 FP16 与 INT8-Canonical 两条基准路径，回答第 4.2 节的保真度问题。

表 4-3 汇总了 Qwen2.5-1.5B-Instruct 在三个 task-core LongBench 风格

合成基准任务上的基准路径读数。INT8-Canonical 相对 FP16 的平均差异为 +0.02, NarrativeQA 为 +0.09, HotpotQA 为 -0.02, GovReport 为 -0.01。这些差异幅度很小且方向不一致, 表现为量化噪声下的微小波动。在 Qwen2.5-1.5B-Instruct 的 task-core 协议内, INT8-Canonical 与 FP16 的任务行为保持接近。

主矩阵采用 LongBench 风格合成任务做受控比较, 但不直接对齐社区官方榜单。为检查这一方向性结论是否会被合成协议带偏, 本文从官方 LongBench<sup>[46]</sup> 数据集中选取 NarrativeQA、HotpotQA 与 GovReport 三个任务做小范围真实数据对照。实验模型固定为 Qwen2.5-1.5B-Instruct, 上下文截断至 4K, 生成长度为 64, 随机种子固定为 1234, 每个任务最多采样 50 个官方样本。量化配置仍使用 INT8-Canonical 主线配置。

表 4-4 官方 LongBench 真实数据对照 (评测协议一致性检验)

| 官方任务                | FP16 | INT8-Canonical | $\Delta$ (pp) |
|---------------------|------|----------------|---------------|
| NarrativeQA (F1)    | 7.07 | 7.13           | +0.06         |
| HotpotQA (F1)       | 4.90 | 5.27           | +0.37         |
| GovReport (Rouge-L) | 9.21 | 9.25           | +0.04         |
| 宏平均                 | 7.06 | 7.22           | +0.16         |

注: Qwen2.5-1.5B-Instruct, 4K 上下文截断, seed=1234, 生成长度为 64, 每任务最多 50 个样本。本表与表 4-3 属于不同评测数据集, 用于评测协议一致性检验, 不进入主评测矩阵。

表 4-4 给出的官方真实数据对照延续了主协议下的方向性判断。NarrativeQA 为 +0.06 pp, HotpotQA 为 +0.37 pp, GovReport 为 +0.04 pp, 宏平均相差 +0.16 pp, 单任务差异均控制在 0.4 pp 以内。INT8-Canonical 在三个官方任务上没有出现相对 FP16 的系统性退化。综合两张表, 行为引导校准在 INT8 保守位宽下形成了稳定的保真锚点, 后续低比特恢复、预算分配与部署效率将在各自实验线上继续检验。

### 4.3 低比特路径从对称失效到 RoleAlign 恢复

第 4.2 节验证了 INT8 基准位宽。本节把控制变量切换到低比特路径, 沿对称格式可用性、K/V 触发侧定位和同一非对称格式内的校准来源比较展开。

本节的证据锚点依次是表 4-5、表 4-6、表 4-7 与表 4-8。它们分别支撑对称 INT4 在部分架构上跨过功能临界点、Key 侧低比特噪声是更直接的触发源、K/V 角色差异能在任务指标上复现, 以及共享格式下 INT4-RoleAlign 与 KIVI-style 的主要差别来自校准来源这四个判断。

### 4.3.1 对称 INT4 的架构依附性失效与阶跃崩塌

INT8 基准路径说明行为引导校准可以在较保守位宽上保持任务行为。位宽继续压到 INT4 后，对称量化面对的是另一类压力。有效量化等级从 INT8 的 255 个降到对称 INT4 的 15 个，部分模型直接跨过检索功能临界点，从“可用”跳到“不可用”。不同架构越过这一临界点的难易程度并不相同，因此本节将其表述为**架构依附性失效**。

表 4-5 对称 INT4 的阶跃崩塌摘要

| 模型           | $H_{kv}$ | FP16 Needle | 对称 INT4 Needle | 诊断标签                               |
|--------------|----------|-------------|----------------|------------------------------------|
| Qwen2.5-1.5B | 2        | 100%        | 0%             | 阶跃崩塌, PPL 8.93 $\rightarrow$ 19.54 |
| Qwen2.5-7B   | 4        | 100%        | 0%             | 阶跃崩塌, PPL 6.71 $\rightarrow$ 85.49 |
| LLaMA-3.1-8B | 8        | 100%        | 98%            | 架构例外, PPL 6.92 $\rightarrow$ 6.97  |

注: Needle 为 4K-32K 上下文与统一 depth sweep 下的 exact-match 通过率。PPL 采用 WikiText-2、seq\_len=32K、chunk\_size=128 的固定 likelihood 协议。

表 4-5 中最突出的现象，是对称 INT4 并没有带来连续的小幅退化。Qwen2.5-1.5B 和 Qwen2.5-7B 的 Needle 都从 FP16 下的 100% 掉到 0%，PPL 也分别从 8.93、6.71 上升到 19.54、85.49。同一设置下，LLaMA-3.1-8B 仍保留 98% Needle，PPL 从 6.92 变为 6.97。这组对照显示，对称 INT4 在部分模型上越过了检索功能的触发边界。

这种阶跃形态与 Key 侧误差进入 attention logits 的方式有关。目标 token 的  $QK^T$  分数一旦被低比特噪声推出高排名区域，softmax 会把概率质量转移到其他位置，检索读数就可能从可用直接跌到不可用，而不一定表现为 50%、30%、10% 这类线性滑落。LLaMA-3.1-8B 的例外也说明，这个边界受架构条件调制。当前读数与  $H_{kv} = 8$  以及较小的  $H_q/H_{kv}$  重复因子相符，但模型族、规模和训练数据差异也可能共同作用。接下来需要拆开 K/V 两侧误差，定位更直接的触发源。

### 4.3.2 K/V 角色敏感性与 MixedKV 完整诊断

表 4-6 的四个干预项分别回答两个问题：高精度 Key 或 Value 是否已经足够安全，极低精度 Key 或 Value 哪一侧会单独触发 cliff。后续任务级矩阵切换为 K-only / V-only / K4V8 / MixedKV。

表 4-6 Key/Value 单侧干预的 PPL 诊断表 (Qwen2.5-1.5B-Instruct, WikiText-2, chunk\_size=128)

| 消融配置      | PPL ↓  | 相对 FP16 变化 |
|-----------|--------|------------|
| FP16 (参考) | 9.31   | —          |
| K8V16     | 9.33   | +0.2%      |
| K16V8     | 9.31   | +0.0%      |
| K4V16     | 1290.9 | +13,774%   |
| K16V4     | 9.35   | +0.4%      |

注：PPL 为固定输入序列上的确定性 likelihood 指标，固定 seed=1234 报告。追加种子的数值与 1234 逐位一致，统计解释采用效应量和协议一致性。

表 4-6 先从语言建模层面给出最直接的诊断证据。在 Qwen2.5-1.5B 上，将 Key 压到 INT4 (K4V16) 会把 PPL 从 9.31 推高到 1290.9，相对 FP16 达到 +13,774%。相比之下，将 Value 压到 INT4 (K16V4) 时，PPL 为 9.35，相对 FP16 增加 0.4%，K8V16 增加 0.2%。这说明对当前 low-bit path 而言，决定“是否越过功能临界点”的主要变量是 Key 侧位宽是否已经低到足以扰动 attention ranking 的区域。Key-first protection 的依据来自这组单侧干预证据。

表 4-7 K/V 消融多任务结果

| Panel A. RULER 通过率 (%，32K，上下文)             |       |              |              |              |              |
|--------------------------------------------|-------|--------------|--------------|--------------|--------------|
| 模型                                         | FP16  | K-only       | V-only       | K4V8         | MixedKV      |
| Qwen2.5-1.5B                               | 24.38 | 24.61 ± 0.00 | 23.83 ± 0.39 | 0.00 ± 0.00  | 24.87 ± 0.20 |
| Qwen2.5-7B                                 | 24.92 | 25.39 ± 0.68 | 25.13 ± 0.45 | 0.00 ± 0.00  | 25.16 ± 0.45 |
| LLaMA-3.1-8B                               | 31.48 | 29.82 ± 1.26 | 36.72 ± 1.56 | 31.12 ± 0.90 | 33.28 ± 0.75 |
| Panel B. LongBench 风格合成基准任务综合评分 (×100，32K) |       |              |              |              |              |
| 模型                                         | FP16  | K-only       | V-only       | K4V8         | MixedKV      |
| Qwen2.5-1.5B                               | 4.82  | 4.57 ± 0.01  | 4.54 ± 0.04  | 2.58 ± 0.08  | 4.47 ± 0.05  |
| Qwen2.5-7B                                 | 3.78  | 4.10 ± 0.11  | 3.85 ± 0.02  | 0.80 ± 0.05  | 4.27 ± 0.06  |
| LLaMA-3.1-8B                               | 7.92  | 7.31 ± 0.43  | 6.21 ± 0.66  | 8.92 ± 0.79  | 7.42 ± 0.83  |

注：Panel A 为 RULER 宏平均通过率，Panel B 为 LongBench 风格 task-core 综合评分。

表 4-7 把 K/V 诊断从 PPL 推到检索压测和任务级指标。K-only 的 RULER 基本贴近 FP16，V-only 也没有出现表 4-6 中的 PPL cliff，主要触发源集中到 K4V8。在 Qwen2.5-1.5B 和 Qwen2.5-7B 上，RULER 都被打到 0%。LLaMA-3.1-8B 仍保留 31.12 的 RULER 和 8.92 的 LongBench-style 综合分。这组结果与前面的 PPL 单侧诊断方向一致：低比特退化主要沿 Key 侧出现，但退化是否越过功能临界点，仍受模型族、规模与  $H_{kv}$  等条件调制。

图 4-1 将 Needle、RULER 与 LongBench-style 放到同一位宽布局矩阵中。Qwen2.5-1.5B 与 Qwen2.5-7B 的共同模式是：K8V8 与 K8V4 大体保持可用，而 K4V8 和 K4V4 在 Needle 与 RULER 上直接跌入 cliff，LongBench-style 也同步下降。LLaMA-3.1-8B 则不表现出同强度 cliff，K4V8 在三类指标上仍




图 4-1 K/V 角色敏感性的跨指标诊断图。子图 (a) – (c) 比较 Needle、RULER 与 LongBench-style 下的主要位宽布局，子图 (d) 汇总 K4V8 相对 K8V4 的下降幅度。Qwen 系列出现更强的 Key-side low-bit cliff，而 LLaMA-3.1-8B 未出现同强度坍塌。

接近高精度路径，K4V4 在 Needle 与 RULER 上也未出现同幅度坍塌。由此可见，4bit Key 扰动在 Qwen 系列上触发行为崩塌，其强度又受到模型族、规模与  $H_{kv}$  等架构因素调制。

图 4-2 从误差结构侧补充了这种架构依附性。配对热力图显示，在 MixedKV 配置下，Qwen2.5-1.5B 的高误差层段更早、更分散，而 LLaMA-3.1-8B 的误差峰值更集中于后部层段，整体量级也更低。这张图与表 4-7 指向同一解释。在更高  $H_{kv}$  与更平滑的架构条件下，Key 量化噪声更不容易被放大成检索崩塌。

14B 补充对比提供了大模型侧的外推参照，PPL 口径见附录第 A.7 节。在 Qwen2.5-14B 上，保持 Key 为高位宽的 K16V4 可将 PPL 从 full INT4 的 5.040 恢复到 4.709，约恢复 93% 的退化。保持 Value 为高位宽的 K4V16 恢复到 4.813，约恢复 64%。这条读数与表 4-6 和表 4-7 方向一致，共同指向 Key 侧优先保护。

在本文考察的 low-bit 场景中，Key 侧低比特噪声更早越过功能临界点。MixedKV 的恢复说明，低比特路径需要优先保护 Key，并在此基础上升级量化格式。






图 4-2 Qwen2.5-1.5B 与 LLaMA-3.1-8B 的配对 K/V 重建误差热力图 (MixedKV, K8V4, 32K 上下文)。上排为 Qwen2.5-1.5B, 下排为 LLaMA-3.1-8B。左两列分别为 Key 与 Value 的逐层逐头重建误差, 右列为逐层平均误差曲线。统一色标显示: 相较于 Qwen2.5-1.5B, LLaMA-3.1-8B 的高误差层段更集中、整体误差更低, 与其更强的噪声稀释能力一致。

### 4.3.3 INT4-RoleAlign 与 KIVI-style 的跨模型对比

本小节进入 per-channel K + per-token V 的同一非对称格式, 并比较两种实例化来源: 离线 role-aware calibration 的 INT4-RoleAlign, 以及运行时 min/max 的 KIVI-style。

表 4-8 INT4-RoleAlign 与 KIVI-style 的跨模型主对比

| 模型           | $H_{kv}$ | FP16 PPL | KIVI-style PPL | RoleAlign PPL | $\Delta$ PPL | KIVI Needle | RoleAlign Needle |
|--------------|----------|----------|----------------|---------------|--------------|-------------|------------------|
| Qwen2.5-1.5B | 2        | 9.31     | 10.43          | 10.58         | +0.15        | 100/100%    | 100/100%         |
| Qwen2.5-7B   | 4        | 7.14     | 7.53           | 7.58          | +0.05        | 100/100%    | 100/100%         |
| LLaMA-3.1-8B | 8        | 6.73     | 6.90           | 6.90          | +0.00        | 100/100%    | 100/100%         |
| Qwen2.5-14B  | 8        | 4.68     | —              | 5.04          | —            | —           | 100/100%         |

注 100/100% 表示 Needle-single-retrieval 与 MK-NIAH-2 两类检索任务均达到 100% 通过率。生成式质量协议使用 5 个固定 seeds。Qwen2.5-14B 当前提供 RoleAlign 覆盖范围, 配对差异由前三行读取。

表 4-8 中有三组完整配对。Qwen2.5-1.5B、Qwen2.5-7B 与 LLaMA-3.1-8B 上, RoleAlign 相对 KIVI-style 的 PPL 差距分别为 +0.15、+0.05 和 +0.00,

两类 Needle 任务都恢复到 100%。和前面对称 INT4 的崩塌相比，更关键的变化发生在格式层：切换到 per-channel K + per-token V 后，低比特检索已经回到可用区间。

同一格式内部，RoleAlign 与 KIVI-style 的质量读数接近。二者真正不同的是量化端点从哪里来。KIVI-style 运行时按 min/max 统计更新 scale。RoleAlign 则把 K-path 与 V-path 的分路校准结果固化为离线产物，并把这些产物继续交给第 4.4 节的行为引导分配器。表 4-8 因而给出两层判断。角色感知非对称格式先把低比特路径恢复到可用状态，RoleAlign 进一步把离线行为读数组织成后续预算分配可以复用的接口。

第 4.3 节的低比特证据由三组结果合在一起支撑。对称 INT4 在 Qwen 系列上出现阶跃崩塌，LLaMA-3.1-8B 构成架构例外。PPL、任务指标与跨指标图共同把崩塌主因定位到 Key 侧低比特噪声。共享非对称格式恢复了检索可用性，RoleAlign 进一步提供离线产物和后续分配接口。

## 4.4 跨模型预算分配与策略适用区间

本节把离线校准产出的敏感度画像推进到预算分配层，观察不同模型在同量级 INT4 预算带内落入哪些高性能区间。跨模型主表给出整体结构，四个典型剖面再展开各自的层级形状与策略落点。这里的“策略适用区间”，指在给定模型族、规模与任务组合下，某类 allocator 策略更容易进入高性能区域的条件范围。

### 4.4.1 同量级预算下的跨模型主表

表 4-9 报告同量级 INT4 预算带内的结构读数。各 allocator 策略的平均位宽大致落在 4.5–5.0 bit 带内，uniform INT4 对应  $\bar{b} = 4.0$  bit。本节关心的是同一数量级预算内，不同分配风格在不同模型上形成怎样的结构落点。严格同预算胜负判定留给后续比较协议。




图 4-3 Behavior-guided AutoK 的逐层保护决策。四个子图分别对应 Qwen2.5-3B、LLaMA-3.1-8B、Qwen2.5-14B 与 Mistral-7B，展示覆盖率准则下各模型的保护层结构（覆盖阈值 14B 为 90%，其余模型为 80%，与表 4-9 注一致）。该图将跨模型主表背后的 sensitivity shape 直接可视化。

表 4-9 同量级 INT4 预算带内的跨模型主表

| 模型                               | 任务/汇总               | Uniform INT4 | BA-k         | Heuristic-k  | BA-AutoK     |
|----------------------------------|---------------------|--------------|--------------|--------------|--------------|
| Qwen2.5-3B ( $H_{kv} = 2$ )      | NarrativeQA (F1)    | 4.33         | <b>7.17</b>  | 3.08         | 6.48         |
|                                  | HotpotQA (F1)       | 2.38         | 4.73         | 1.39         | <b>4.89</b>  |
|                                  | GovReport (Rouge-L) | 5.77         | 8.81         | 5.96         | <b>8.90</b>  |
|                                  | Mean                | 4.16         | <b>6.90</b>  | 3.48         | 6.75         |
| LLaMA-3.1-8B ( $H_{kv} = 8$ )    | NarrativeQA (F1)    | 10.24        | <b>11.14</b> | 10.47        | 10.74        |
|                                  | HotpotQA (F1)       | 6.73         | <b>7.88</b>  | 5.68         | 7.57         |
|                                  | GovReport (Rouge-L) | 9.24         | 9.54         | 9.47         | <b>9.75</b>  |
|                                  | Mean                | 8.74         | <b>9.52</b>  | 8.54         | 9.35         |
| Qwen2.5-14B ( $H_{kv} = 8$ )     | NarrativeQA (F1)    | <b>7.05</b>  | 6.67         | 6.83         | 6.80         |
|                                  | HotpotQA (F1)       | <b>5.57</b>  | 5.49         | 5.40         | 5.39         |
|                                  | GovReport (Rouge-L) | 9.09         | 8.95         | 9.03         | <b>9.27</b>  |
|                                  | Mean                | <b>7.23</b>  | 7.04         | 7.09         | 7.15         |
| Mistral-7B-v0.3 ( $H_{kv} = 8$ ) | NarrativeQA (F1)    | 15.55        | 15.71        | <b>17.11</b> | 16.26        |
|                                  | HotpotQA (F1)       | 17.81        | 17.78        | 17.84        | <b>19.08</b> |
|                                  | GovReport (Rouge-L) | 8.70         | 8.66         | 8.86         | <b>8.96</b>  |
|                                  | Mean                | 14.02        | 14.05        | 14.60        | <b>14.76</b> |

注：本表为同量级 INT4 预算带内的跨模型读数。严格同预算比较留给后续协议。best- $k$  分别为 Qwen2.5-3B 的  $k = 1$ 、LLaMA-3.1-8B 的  $k = 11$ 、Qwen2.5-14B 的  $k = 7$  与 Mistral-7B 的  $k = 3$ 。AutoK 覆盖阈值为 14B 使用 90%，其余模型使用 80%。

表 4-9 显示四个模型落在不同策略家族中。Qwen2.5-3B 的三任务均值最优落在 BA-k1，LLaMA-3.1-8B 落在 BA-k11，Qwen2.5-14B 的最高均值落在 Uniform，Mistral-7B 则落在 BA-AutoK。图 4-3 给出这些差异背后的保护层结构，图 4-5 将它们整理为后续四个模型剖面的分析入口。

图 4-3 把这种结构差异直接可视化。Qwen2.5-3B 的保护层明显前移并集中于最早层，呈现典型的 early-layer bottleneck。LLaMA-3.1-8B 与 Mistral-




图 4-4 质量-预算 Pareto 视图。三个子图分别对应 Qwen2.5-7B、LLaMA-3.1-8B 与 Mistral-7B。横轴为平均 KV bit budget，纵轴为任务核心平均质量。




图 4-5 跨模型策略适用区间速览。左图按模型行内归一化展示四类策略家族的 task-core 均值，颜色表示同一模型内部的相对适用性。实线框标出行内最高值，虚线框标出达到最高三任务均值 97% 以上的近簇。右图概括后续四个模型剖面的结构类型。

7B 形成中层簇集，关键层从单一首层扩展为一簇相邻高敏感层。Qwen2.5-14B 的保护层近乎铺满全深度，显示大模型的行为敏感度已经弥散化。策略落点的差异由 sensitivity structure 的差异支撑。

图 4-4 与图 4-5 将主表压缩为适用区间视图。Pareto 图显示同量级预算带内存在清晰的质量-预算局部几何。Mistral-7B 的 AutoK 区域最突出，LLaMA-3.1-8B 的几种高性能策略形成近 Pareto 的局部簇。适用区间图左侧给出四模型的行内高性能落点，右侧按 Mistral-7B、Qwen2.5-3B、LLaMA-3.1-8B 与 Qwen2.5-14B 的顺序概括四类结构。position-based heuristic 在多个区间与 behavior-guided 选中集合重合，其结构性含义将在第 4.6.3 节讨论。

#### 4.4.2 Mistral-7B: AutoK 的单模型支持证据

Mistral-7B 被单独列出，是因为它提供了当前最清晰的 AutoK 单模型支持证据。该剖面回答一个较窄的问题：当敏感度画像本身具有可压缩的中层簇集结构时，覆盖度预算建议能否读出层间结构。

表 4-10 典型剖面表 A: Mistral-7B 与 Qwen2.5-3B

| Panel A. Mistral-7B: AutoK 的单模型支持证据 |         |              |              |                |                  |             |
|-------------------------------------|---------|--------------|--------------|----------------|------------------|-------------|
| 任务                                  | Uniform | BA-k3        | Heuristic-k3 | BA-AutoK (80%) | 最优项              | 备注          |
| NarrativeQA (F1)                    | 15.55   | 15.71        | <b>17.11</b> | 16.26          | Heur-k3          |             |
| HotpotQA (F1)                       | 17.81   | 17.78        | 17.84        | <b>19.08</b>   | AutoK            |             |
| GovReport (Rouge-L)                 | 8.70    | 8.66         | 8.86         | <b>8.96</b>    | AutoK            |             |
| DuReader (Rouge-L)                  | 7.35    | 8.64         | 7.97         | <b>11.62</b>   | AutoK            | 增益最大        |
| LCC (EditSim)                       | 21.38   | <b>22.10</b> | 20.30        | 19.77          | BA-k3            |             |
| Mean                                | 14.16   | 14.58        | 14.42        | <b>15.14</b>   | AutoK            | 5-task mean |
| Panel B. Qwen2.5-3B: 早层保护有效区间       |         |              |              |                |                  |             |
| 任务                                  | Uniform | BA-k1        | Heuristic-k1 | BA-AutoK (80%) | Quality $\Delta$ | 备注          |
| NarrativeQA (F1)                    | 4.33    | <b>7.17</b>  | 3.08         | 6.48           | +4.09            | 提升          |
| HotpotQA (F1)                       | 2.38    | 4.73         | 1.39         | <b>4.89</b>    | +3.33            | 提升          |
| GovReport (Rouge-L)                 | 5.77    | 8.81         | 5.96         | <b>8.90</b>    | +2.85            | 提升          |
| Mean                                | 4.16    | <b>6.90</b>  | 3.48         | 6.75           | +3.42            | 差距最大        |

注：Panel A 为 Mistral-7B-v0.3 的 5-task 扩展剖面。摘要中的 core mean 为前三个 task-core 的 BA-AutoK 均值 14.76，extend mean 为 DuReader 与 LCC 的 BA-AutoK 均值 15.69。Panel B 为 Qwen2.5-3B 的 3-task task-core 剖面，behavior-guided best- $k$  为  $k = 1$ 。

表 4-10 的 Panel A 显示，BA-AutoK 在 Mistral-7B 的五个任务中有三个任务给出最高读数，并取得最高平均值。最明显的差异来自 DuReader，BA-AutoK 达到 11.62，而 Heuristic-k3 为 7.97，差距达到 3.6 分。同时，它在 HotpotQA 与 GovReport 上也给出最优读数。多个任务共同抬高均值，说明覆盖率预算建议器捕捉到了与层间结构相关的收益。

这一优势与图 4-3 中的敏感度画像一致。Mistral-7B 的重点保护层落在中前层簇集，80% 覆盖阈值选出的保护范围与该簇集结构吻合。Mistral-7B 因此给出一个清晰实例。当画像具有可压缩簇集结构时，覆盖率预算建议器能够把层间结构转化为有效的预算候选。

#### 4.4.3 Qwen2.5-3B: 早层保护有效区间

Qwen2.5-3B 承担了全文最清晰的行为引导策略与位置启发式差距剖面。它揭示了一类更窄但更重要的适用区间：当行为敏感度高度集中于最早几层时，保护正确的第一层会产生质量提升，而位置启发式若把预算投向“看起来更居中”的层，可能难以覆盖关键瓶颈位置。

表 4-10 的 Panel B 给出主要数字支撑。BA-k1 相对 Heuristic-k1 在 NarrativeQA 上高出 4.09 分，在 HotpotQA 上高出 3.33 分，在 GovReport 上高出 2.85 分，平均差距达到 3.42 分。这组差距把 Qwen2.5-3B 从低质量区间推回可用区间，直接体现早层保护带来的质量恢复。

这一恢复性收益与图 4-3 的 3B 结构读数一致。Qwen2.5-3B 的敏感度画像明显前移，top protected layers 集中在最早层。BA-k1 保护的是 layer 0，而 Heuristic-k1 的单层保护则落在中层，因而偏离瓶颈层。3B 定义了一种更精确的适用区间：当行为敏感度在最早几层高度集中时，位置启发式可能偏离关键层，而行为引导保护可以产生恢复性收益。

#### 4.4.4 LLaMA-3.1-8B：中等规模共识区间

LLaMA-3.1-8B 是当前主线中的一个重要模型案例。跨模型主表已经给出清晰结构信号，最佳平均值落在 BA-k11，同时 BA-AutoK 与其它高性能策略距离并不远。本节将这行结果展开为一个可单独讨论的结构区间。

表 4-11 典型剖面表 B：LLaMA-3.1-8B 与 Qwen2.5-14B

| Panel A. LLaMA-3.1-8B：中等规模共识区间    |             |              |               |                |             |                    |
|-----------------------------------|-------------|--------------|---------------|----------------|-------------|--------------------|
| 任务                                | Uniform     | BA-k11       | Heuristic-k11 | BA-AutoK (80%) | 最优项         | 备注                 |
| NarrativeQA (F1)                  | 10.24       | <b>11.14</b> | 10.47         | 10.74          | BA-k11      |                    |
| HotpotQA (F1)                     | 6.73        | <b>7.88</b>  | 5.68          | 7.57           | BA-k11      |                    |
| GovReport (Rouge-L)               | 9.24        | 9.54         | 9.47          | <b>9.75</b>    | AutoK       |                    |
| Mean                              | 8.74        | <b>9.52</b>  | 8.54          | 9.35           | BA-k11      | 共识高性能区间            |
| Panel B. Qwen2.5-14B：高性能簇共存而无稳定最优 |             |              |               |                |             |                    |
| 任务                                | Uniform     | BA-k7        | Heuristic-k7  | BA-AutoK (90%) | $gap_{rel}$ | 备注                 |
| NarrativeQA (F1)                  | <b>7.05</b> | 6.67         | 6.83          | 6.80           | 3.55%       | top-3 聚簇           |
| HotpotQA (F1)                     | <b>5.57</b> | 5.49         | 5.40          | 5.39           | 3.05%       | top-3 聚簇           |
| GovReport (Rouge-L)               | 9.09        | 8.95         | 9.03          | <b>9.27</b>    | 2.59%       | top-3 聚簇           |
| Mean                              | <b>7.23</b> | 7.04         | 7.09          | 7.15           | 3.06%       | max $\approx$ 3.5% |

注：Panel A 展示 LLaMA-3.1-8B 的中等规模共识区间。Panel B 的  $gap_{rel}(t) = (top1(t) - top3(t))/top1(t)$  最大约 3.5%，平均约 3.0%。Qwen2.5-14B 呈现高性能策略近簇。

表 4-11 的 Panel A 表明，LLaMA-3.1-8B 存在较明确的 BA-k11 结构落点。NarrativeQA 与 HotpotQA 上 BA-k11 都给出最优读数，GovReport 上则由 BA-AutoK 略占优势，最终平均值由 BA-k11 取得最优。它与 BA-AutoK 之间的差距非常有限。再结合图 4-4 中近 Pareto 的局部几何关系，LLaMA-3.1-8B 呈现为一个局部簇集型的 共识高性能区间。

这一命名与其敏感度画像形状一致。与 Qwen2.5-3B 的尖锐前层集中不同，LLaMA-3.1-8B 的最佳保护范围扩展到更广的中层簇集，best- $k$  =

11 对应一组中层保护。它也没有像 Qwen2.5-14B 那样弥散到几乎全深度。LLaMA-3.1-8B 因而对应 **中等规模共识区间**。它存在相对稳定的 BA-k 结构落点，其它高性能策略也保持接近。其  $H_{kv} = 8$  设置与较平滑的分配器响应共同出现，为后文讨论 GQA 架构条件提供补充剖面。

#### 4.4.5 Qwen2.5-14B：高性能簇共存而无稳定最优

Qwen2.5-14B 提供第 4.4 节的边界剖面。它在跨模型主表中的最高均值落在 Uniform，同时几类高性能策略彼此接近。这个模型的分配画像已经明显弥散，预算选择呈现近似持平的策略簇。

表 4-11 的 Panel B 直接支持这一点。三个任务上四类策略的数值都非常接近。按照  $gap_{rel}(t) = (top1(t) - top3(t))/top1(t)$  的定义，NarrativeQA、HotpotQA 与 GovReport 的 top-3 相对 top-1 gap 分别约为 3.55%、3.05% 与 2.59%，平均值约为 3.06%。14B 的 top-3 策略全部位于 top-1 的 3.5% 相对距离内。这个近簇格局与图 4-3 的广泛铺展画像一致。Qwen2.5-14B 的敏感度画像近乎铺满全深度，AutoK 在 48 层中标出 42 个受保护层，说明少数关键层已经不足以概括该模型的分配结果。14B 因此留下的结构结论为**高性能簇共存而无稳定最优**。

图 4-5 的右图将四个模型剖面收束为四类结构。Mistral-7B 提供 AutoK 的单模型支持证据，Qwen2.5-3B 是早层保护有效区间，LLaMA-3.1-8B 是中等规模共识区间，Qwen2.5-14B 表现为高性能簇共存而无单一最优。由此可见，行为敏感度画像可以在同量级预算带内组织预算选择，并把不同模型的结构落点区分出来。

### 4.5 部署效率评估

本节考察这些路径在真实推理系统中的时间与显存代价，重点观察低比特路径的缓存容量收益如何转化为解码时间收益，以及这种转化随  $H_{kv}$ 、序列长度和后端实现发生怎样的变化。

本节按“入口读数 → 长序列放大 → 经验边界 → 部署建议”的顺序组织。第 4.5.1 节给出 4K 序列下的后端路径入口读数。第 4.5.2 节展示融合路径收益如何随上下文增长而放大。第 4.5.3 节将这些读数整理为性能交叉边界。第 4.5.4 节结合 KV Cache 显存压缩率与当前硬件约束给出部署读数。

#### 4.5.1 4K 序列下的 TPOT 对比

短上下文入口层的读数是部署判断的起点。4K 序列既是常见的部署长度点，也是判断固定 kernel 开销是否已经值得付出的最低长度点。因此，本小节给出各后端路径在当前硬件与 batch 设定下的入口层读数：哪些模型上 Triton 融合路径仍受固定调度开销影响，哪些模型上它已经开始逼近甚至略微越过参考路径。

**表 4-12** 4K 序列下的 TPOT 对比（生成长度 128，batch size 为 1，NVIDIA H20，单位为 ms）

| 模型           | $H_{kv}$ | FP16  | 参考路径<br>(INT4) | KIVI(INT4) | Triton 融合路径<br>(INT4) | FlashInfer(INT4) | 最快项         |
|--------------|----------|-------|----------------|------------|-----------------------|------------------|-------------|
| Qwen2.5-1.5B | 2        | 24.36 | 36.35          | 36.39      | 38.68                 | 43.73            | 参考路径        |
| Qwen2.5-7B   | 4        | 24.82 | 37.61          | 37.41      | 38.76                 | 47.07            | KIVI        |
| LLaMA-3.1-8B | 8        | 28.55 | 44.88          | 44.70      | <b>44.49</b>          | 51.50            | Triton 融合路径 |
| Qwen2.5-14B  | 8        | 42.58 | 68.07          | 68.46      | <b>67.67</b>          | 85.07            | Triton 融合路径 |

注：粗体标注同模型 INT4 后端路径中的最快项。

表 4-12 呈现出清楚的  $H_{kv}$  分层。Qwen2.5-1.5B 对应  $H_{kv} = 2$ ，Triton 融合路径的 TPOT 为 38.68 ms，高于参考路径的 36.35 ms。Qwen2.5-7B 对应  $H_{kv} = 4$ ，融合路径为 38.76 ms，也略高于参考路径的 37.61 ms。到  $H_{kv} = 8$  的两种模型中，融合路径成为各自设置下最快的 INT4 后端路径，LLaMA-3.1-8B 与 Qwen2.5-14B 的 TPOT 分别为 44.49 ms 与 67.67 ms。入口层结果说明，较小  $H_{kv}$  下的 Grid 规模还不足以摊薄 Triton 固定调度开销。 $H_{kv}$  增大后，融合路径开始逼近并越过参考路径。

#### 4.5.2 长序列 TPOT 扩展规律

4K 入口层给出后端切换的起点，长序列读数则显示融合路径的收益是否随历史 KV 增长而放大。这里选择 Qwen2.5-14B 作为主要观察对象，因为它在  $H_{kv} = 8$  下已经显现出正向趋势，长上下文下 memory traffic 也足够重，适合观察访存节省对 TPOT 的影响。



表 4-13 部署边界综合表

| Panel A. 14B 长序列 TPOT (生成长度 64, 10 次运行, H20, ms)                           |          |                  |                  |                   |                                                       |                  |
|----------------------------------------------------------------------------|----------|------------------|------------------|-------------------|-------------------------------------------------------|------------------|
| 执行路径                                                                       | 4K       | 8K               | 16K              | 32K               | $\Delta$ vs.<br>参考路径                                  | 备注               |
| FP16                                                                       | 42.28    | 42.81            | 42.64            | 43.13             | –                                                     | baseline         |
| 参考路径<br>(INT4)                                                             | 68.17    | 86.08            | 119.83           | 190.23            | –                                                     | reference        |
| KIVI<br>(INT4)                                                             | 68.07    | 86.02            | 121.49           | 187.82            | –                                                     | runtime baseline |
| Triton 融合路径<br>(INT4)                                                      | 67.73    | 71.53            | 86.56            | 113.16            | 4K: -0.44<br>8K: -14.54<br>16K: -33.26<br>32K: -77.08 | fused path       |
| Panel B. 跨模型性能交叉边界 ( $\Delta T = T_{\text{Triton}} - T_{\text{ref}}$ , ms) |          |                  |                  |                   |                                                       |                  |
| 模型                                                                         | $H_{kv}$ | $\Delta T$<br>4K | $\Delta T$<br>8K | $\Delta T$<br>16K | $\Delta T$<br>32K                                     | 备注               |
| Qwen2.5-1.5B                                                               | 2        | +1.67<br>不显著     | +4.23            | +9.78             | +15.92                                                | 始终更慢             |
| Qwen2.5-7B                                                                 | 4        | +1.03<br>不显著     | +1.56<br>不显著     | +0.55<br>不显著      | -4.90                                                 | 32K 交叉           |
| Qwen2.5-14B                                                                | 8        | -0.44<br>不显著     | -14.54           | -33.26            | -77.08                                                | 8K 起加速           |

注: Panel A/B 使用生成长度 64、10 次运行, 与表 4-12 的生成长度 128 协议不同, 4K 处  $\Delta T$  不直接互推。性能交叉边界为经验读数。8B 与 14B 的同  $H_{kv} = 8$  对照见第 4.5.3 节正文。 $|\Delta T| < 2$  ms 统一标记为不显著。

表 4-13 的 Panel A 给出一条随序列长度展开的后端收益曲线。Qwen2.5-14B 采用 Triton 融合路径时, 4K 处相对参考路径快 0.44 ms, 仍落在不显著区间。到 8K, 差值扩大到 -14.54 ms, 16K 为 -33.26 ms, 32K 为 -77.08 ms, 对应约 -17%、-28% 与 -40% 的相对降幅。几个长度点保持单调, 说明历史 KV 增长后, 减少全局访存带来的收益开始压过融合核的固定调度开销。该读数对应 Qwen2.5-14B、H20、batch=1 与当前后端组合, 也说明融合路径的部署价值主要在长序列场景中被放大。

#### 4.5.3 性能交叉边界与 GQA 影响

第 4.5.1 节给出入口层读数, 第 4.5.2 节给出单模型扩展证据。本节将这些读数整理为性能交叉边界。这里的边界指经验量  $\Delta T = T_{\text{Triton}} - T_{\text{ref}}$  的符号变化。所有长度点上  $|\Delta T| < 2$  ms 的情况统一标记为不显著。本节关注融合路径何时进入可读出的加速区间, 以及这条边界如何随  $H_{kv}$  与序列长度共同移动。

表 4-13 的 Panel B 展示了  $H_{kv}$  不同取值下的边界移动。Qwen2.5-1.5B ( $H_{kv} = 2$ ) 的  $\Delta T$  在 4K/8K/16K/32K 上分别为 +1.67 / +4.23 / +9.78 / +15.92 ms, 融合路径在全长度下都不划算。Qwen2.5-7B ( $H_{kv} = 4$ ) 的  $\Delta T$  在 4K/8K/16K 仍为正或近似零, 直到 32K 才降为 -4.90 ms, 交叉点被推迟到更长序列。Qwen2.5-14B ( $H_{kv} = 8$ ) 从 8K 起越过不显著区间, 并在更长

上下文下继续扩大。由这组路径可读出的经验边界是：在当前硬件与后端组合下， $H_{kv}$  越高，交叉点越早。序列越长，融合路径越容易进入收益区间。

同  $H_{kv} = 8$  的 8B 与 14B 对照补充了这一边界。LLaMA-3.1-8B 与 Qwen2.5-14B 的参数规模相差约 1.75 倍，却共享相同的  $H_{kv} = 8$ 。以表 4-12 的入口层读数（生成长度 128）为统一协议，两者在 4K 处的交叉幅度高度一致，分别为  $-0.39\text{ ms}$  与  $-0.40\text{ ms}$ 。在当前模型集合中， $H_{kv}$  比参数量更接近性能交叉边界的主导相关变量。

第 4.5.3 节得到的系统读数是一条经验边界。 $H_{kv} = 2$  基本落在融合路径不划算区， $H_{kv} = 4$  到长序列才越过边界， $H_{kv} = 8$  在较早长度点进入收益区间。部署路径选择由  $H_{kv}$  与序列长度共同决定。

#### 4.5.4 KV Cache 显存压缩率与部署建议

时间边界之外，长上下文部署还关心低比特路径带来的缓存容量收益。这里继续报告 KV Cache 显存压缩率，并把容量收益与前文 TPOT 边界合并成当前平台上的部署读数。

**表 4-14** KV Cache 显存压缩率对比（4K 序列，batch size 为 1，仅统计 KV Cache，占用单位：MB）

| 模型           | $H_{kv}$ | FP16 KV Cache | INT4 KV Cache | 压缩率   | 备注 |
|--------------|----------|---------------|---------------|-------|----|
| Qwen2.5-1.5B | 2        | 115.5         | 30.7          | 73.4% |    |
| Qwen2.5-7B   | 4        | 230.9         | 61.5          | 73.4% |    |
| LLaMA-3.1-8B | 8        | 527.9         | 140.5         | 73.4% |    |
| Qwen2.5-14B  | 8        | 791.8         | 210.8         | 73.4% |    |

注：本表统计 KV Cache 本体，占用不包含模型权重与激活峰值。部署建议见第 4.5.4 节正文结尾。

表 4-14 表明，INT4 路径在四个代表性模型上都实现了近乎相同的缓存压缩率。Qwen2.5-1.5B 从 115.5 MB 压缩到 30.7 MB，Qwen2.5-7B 从 230.9 MB 压缩到 61.5 MB，LLaMA-3.1-8B 从 527.9 MB 压缩到 140.5 MB，Qwen2.5-14B 从 791.8 MB 压缩到 210.8 MB，压缩率均约为 73.4%。在当前 INT4 路径下，KV Cache 的显存收益稳定且可预估。

结合前文时间边界，可以得到当前平台上的部署读数。INT4 路径带来的显存节省是稳定容量收益，融合 decode 路径的速度收益则随  $H_{kv}$  与序列长度变化。在 NVIDIA H20 (sm\_90, 130 SM, 98 GB HBM) 平台上， $H_{kv} = 8$  且序列长度达到 8K 及以上时，Triton 融合路径进入优势区间。 $H_{kv} = 4$  的模型需要接近 32K 的长序列才越过交叉边界。 $H_{kv} = 2$  或短于 8K 的序列仍更适合参考路径。跨硬件、跨 batch 或更换 backend 后，交叉边界需要重新

测量。

附录第 A.5 节进一步给出 Qwen2.5-1.5B 设置下的 batch 维度容量边界、吞吐与显存扩展读数，用于补充审计本节部署建议的适用范围。

本节得到的系统层读数可以概括为容量收益与时间收益的分离。INT4 的 KV Cache 显存收益稳定可预期，Triton 融合路径的时间收益由  $H_{kv}$  与序列长度共同调制。下一节转入对这些结果为何呈现出当前形状的机制辨析。

## 4.6 实验结果讨论与效度威胁

第 4.2–4.5 节分别给出了基准路径保真、低比特恢复、跨模型策略适用区间与部署效率读数。本节把这些结果合并为四个机制判断，依次讨论 KL 与 MSE 校准目标、INT4 结果的分层机制、heuristic 强基线以及外推边界。

### 4.6.1 KL 与 MSE 校准目标的规模依赖性机制辨析

第 4.2 节已经说明，INT8 基准路径在主协议与官方 LongBench 对照中都能保持接近 FP16 的任务读数。attention-distribution KL 的作用需要放到低比特扰动中观察。KV Cache 误差进入注意力计算后，关键风险往往表现为 attention ranking 的改变。第三章第 3.4 节给出了 KL 作为行为代理的形式化理由，本节进一步说明它与 MSE 这类数值重建代理在实验中的分化条件。

本章结果显示，KL 的作用强弱取决于扰动是否进入注意力分布层。对称 INT4 在 Qwen 系列中触发检索崩塌时，Key 侧低比特噪声已经足以改写关键 token 的相对位置，分布侧代理能够直接读到这类风险。若扰动被位宽冗余、模型鲁棒性或架构条件吸收，attention ranking 没有明显移动，KL 与 MSE 可能收敛到相同选择。

这种趋同已经出现在 Qwen2.5-7B-Instruct 的 INT4-RoleAlign 校准中。KL 与 MSE 最终都选择  $k_{\text{pct}} = 100.0$ 、 $v_{\text{pct}} = 99.9$ ，对应 PPL 均为 7.1121，差值为 0.00。附录第 A.8.2 节保留了这组结果的溯源表。该读数说明，在这一设置中，模型条件已经压缩了两类代理的差异。

由此可见，KL 在本文中的价值来自行为代理层。attention ranking 容易被量化噪声改写时，KL 更贴近行为损伤，并能为后续敏感度画像和预算分配提供同源读数。模型规模、位宽或架构条件使扰动保持在稳定区间内时，KL 与 MSE 会逐步趋同。这个结果把 behavior-guided 主线落在可观察的分布偏移上，校准目标之间的差异也随模型条件而变化。

#### 4.6.2 INT4 结果的分层机制辨析

第 4.3 节的低比特结果呈现出清楚的分层。per-channel K + per-token V 的角色感知非对称格式把检索行为从对称 INT4 的崩塌状态恢复到可用区间。表 4-8 中三组完整配对模型的 PPL 差距都被压在  $|\Delta\text{PPL}| \leq 0.15$  范围内，Needle 检索共同恢复到 100/100%。因此，low-bit 恢复的一阶条件来自 role-aware 非对称格式本身。

在这一格式之上，RoleAlign 的价值主要体现为组织方式。K-path 以 attention-distribution KL 为主代理，并在离线搜索纪律下确定参数。V-path 由独立输出扰动代理主导。两条路径共享校准流程、结果接口与稳健选择纪律。与 KIVI-style 的同格式对比没有形成一边倒的 PPL 差距，却说明 RoleAlign 可以把低比特路径整理为可复核、可延伸，并能继续连接分配器的实例化路径。

前文 4.3.1–4.3.2 的结果还表明，low-bit cliff 的强度由模型族、规模与  $H_{kv}$  共同调制。LLaMA-3.1-8B 在对称 INT4 下表现为架构例外，Qwen 系列在 K4V8 下更容易完全坍塌。这类现象体现的是架构依附的误差传播结果。更小的 chunk\_size、更接近 streaming 的 decode 粒度、更大的官方任务覆盖，以及更强的 role-aware allocator 反馈，仍可能继续放大 behavior proxy 与 numerical proxy 的差异。

#### 4.6.3 Heuristic 强基线的结构性含义

第 4.4 节的 allocator 结果显示，position-based heuristic 在多个模型与预算带内接近 behavior-guided 策略，甚至在选中层集上出现局部重合。这是跨模型适用区间的一部分。heuristic 是**强基线**，原因来自结构本身。在某些适用区间下，关键层集中在很窄的位置区间，“保护哪几层”更接近窄选择空间，位置启发式在这些区间中能够逼近行为引导策略，说明可行层集已经被模型结构压窄。

Qwen2.5-3B 的早层保护剖面给出另一端结构。当敏感层高度集中于最早层，而位置启发式的假设偏向中层时，差距会放大到质量提升级别。启发式强基线与 3B 上的明显失配共同说明，跨模型预算分配的关键在于识别可行层集何时很窄、何时会被位置先验错过。行为引导分配器的价值就在于把这两类区间区分出来。

#### 4.6.4 威胁效度与外推边界

第四章的外推边界与评测协议直接相关。正文主矩阵使用 LongBench 风格合成基准任务，官方 LongBench 真实数据对照覆盖 Qwen2.5-1.5B 的三个任务和单一种子。主协议方向与这组真实数据对照保持一致，后续仍需要更大的官方任务覆盖来扩展外部效度。

比较口径也限定了分配实验的读法。cross-model allocator 结果建立在同量级 INT4 预算带上。第 4.4 节给出了适用区间结构和 per-model 结构落点，严格 matched-budget 条件下的形式化胜负判定留给后续比较协议。

系统读数则绑定当前 NVIDIA H20、固定软件栈、batch=1 与贪婪解码设定。性能交叉边界在其它 GPU、batch 或 runtime 上可能移动，因此第 4.5 节给出的是当前平台上的经验决策规则。

数据来源层面，正文主结论以统一协议下重新核验的主结果为准。个别补充行或外部效度参考来自较早批次或回溯整理时，表注会标明来源和用途。沿着这些边界，第四章已经给出基准保真、低比特恢复、预算适用区间和部署收益的主要读数。更完整的官方数据集验证、更严格的同预算比较、更广的硬件矩阵，以及更成熟的 role-aware allocator 与 prompt 级自适应路由，将继续扩展这些结论的适用域。

### 4.7 本章小结

本章围绕第四章的实验主线，检验了第三章提出的行为对齐量化框架能否从基准校准、低比特恢复、预算分配和系统执行四个层面形成闭环。实验结果表明，同一组注意力行为读数可以先用于校准路径选择，再进入低比特角色诊断和跨模型预算分析，最终落到真实 Decode 后端中的容量与时间读数。由此，本章不只是报告各方法的分数差异，而是把行为校准、K/V 角色差异和层级预算选择连接成一条可复核的证据链。

在基准保真方面，表 4-3 与表 4-4 给出了保守位宽下的验证结果。Qwen2.5-1.5B 的 task-core 协议中，INT8-Canonical 相对 FP16 的三任务平均差异为  $\text{mean } \Delta = +0.02$ ，三个官方 LongBench 子任务的小范围对照也延续了同一方向。这说明 attention-distribution KL 组织的行为引导校准可以在 INT8 位宽下形成稳定保真锚点，为后续更激进的低比特路径提供参照。

低比特恢复实验进一步说明，位宽降低后的主要风险并不均匀分布在 K/V 两侧。表 4-5、表 4-6、表 4-7 与图 4-1 显示，对称 INT4 在 Qwen 系列上

触发阶跃崩塌，Key 侧低比特噪声是更直接的失稳来源。切换到 per-channel K + per-token V 后，表 4-8 中三组完整配对模型的 Needle 检索都恢复到 100/100%。这一结果把第三章的 K/V 传播路径分析落到实验读数中，也说明 RoleAlign 的价值不仅在质量恢复，还在于把离线行为读数组织成可继续进入分配器的校准产物。

跨模型预算实验把这一校准产物继续推进到层级决策。表 4-9、图 4-3、图 4-5 以及两个典型剖面表显示，行为敏感度画像在不同模型中呈现出不同形状。Mistral-7B 提供 AutoK 的清晰单模型支持，Qwen2.5-3B 对应早层保护有效区间，LLaMA-3.1-8B 形成中等规模共识区间，Qwen2.5-14B 则表现为高性能簇共存而无稳定最优。heuristic 在部分区间中仍是强基线，这说明一些模型的可行层集本来就很窄。行为引导分配器的作用在于识别这些区间，并把固定  $k$  sweep 中分散的现象整理为可解释的结构读数。

系统实验给出了低比特路径进入真实后端后的边界。表 4-12、表 4-13 与表 4-14 表明，当前 INT4 路径在代表性模型上带来约 73.4% 的 KV Cache 容量压缩，但融合 decode 的时间收益随  $H_{kv}$ 、序列长度和后端组合变化。在 H20、batch=1 和当前 backend 条件下， $H_{kv} = 8$  且序列长度达到 8K 及以上时，Triton 融合路径开始进入优势区间。容量收益和时间收益因此需要分开读取，前者来自存储位宽下降，后者还取决于访存流量、调度开销和 GQA 映射方式。

综合来看，第四章完成了本文方法链的实证闭环。INT8 基准路径验证行为校准的保真基础，INT4 诊断暴露 K/V 角色差异，INT4-RoleAlign 把低比特路径恢复到可用区间，行为敏感度画像与 AutoK 则把同一组离线行为读数转化为预算候选。第五章将在这一证据基础上，进一步归纳全文贡献、适用边界和后续扩展方向。

## 结论

前四章已经将 KV Cache 量化中的行为保持问题推进到方法实例、实验读数和系统复核三个层面。本章收束全文结论，归纳注意力行为保持、K/V 角色差异恢复、敏感度画像与 AutoK 预算候选生成的贡献，并说明这些结果目前成立的适用范围。

### 5.1 研究结论

围绕第一章提出的四个研究问题，本文得到的核心结论可以归结为一条主线。KV Cache 量化同时涉及缓存元素的 bit 存储方式，以及量化后的 Key 与 Value 如何进入注意力计算，并进一步影响分布、聚合输出和任务行为。第三章给出这一问题的形式化表达，第四章则从基准保真、低比特恢复、跨模型预算和系统读数四个层面完成验证。

注意力行为可以作为 KV Cache 量化的统一观察对象。第三章的误差传播分析表明，缓存扰动经过 logits、softmax 和 Value 聚合后才真正进入模型行为。第四章的 K/V 角色诊断进一步显示，同等 bit-width 下 Key 与 Value 的扰动后果并不对称，Key 侧低比特噪声更容易触发注意力排序偏移。基准校准、低比特恢复和预算分配因此可以围绕同一组行为量展开。研究问题 1 得到肯定回答，注意力分布、聚合输出和任务行为构成本文需要保持的共同对象。

在 INT8 基准路径中，行为引导校准形成了保守位宽下的保真锚点。第四章显示，在 Qwen2.5-1.5B 的 task-core 协议内，INT8-Canonical 相对 FP16 的三任务平均差异为  $\text{mean } \Delta = +0.02$ ，三个官方 LongBench 子任务的小范围对照也延续同一方向。这一结果回答了研究问题 2。行为引导校准可以在当前基准位宽和评测协议下建立稳定参照，为后续低比特路径和系统实现提供起点。更广真实应用分布仍需要更大范围的官方数据与任务覆盖继续验证。

跨模型预算结果表明，行为敏感度画像可以作为预算分配的组织依据。第四章在同量级 INT4 预算带内读出了清晰的模型条件差异。Qwen2.5-3B 的三任务 core mean 中，BA-k1 为 6.90，中层 Heuristic-k1 为 3.48，说明 early-layer bottleneck 下位置先验可能错过关键层。LLaMA-3.1-8B 表现为中等规模共识区间。Qwen2.5-14B 上 Uniform 的 7.23 与 BA-AutoK 90% 覆盖率的 7.15 接近，呈现高性能簇共存而无稳定最优。heuristic 在多个区间仍是强基

线，说明部分模型的可行层集本来就很窄。研究问题 3 的结论是，敏感度画像能够组织和命名跨模型适用区间，并揭示策略有效性随模型族、规模和任务条件变化的结构。

固定预算选择进一步可以由敏感度画像生成模型级候选。AutoK 将离线行为敏感度排序转写为覆盖率预算建议，在 Mistral-7B 上给出最清晰的单模型支持。BA-AutoK 80% 覆盖率的 core mean 为 14.76，extend mean 为 15.69，五任务均值为 15.14。Qwen2.5-14B 这类高性能簇接近的设置则说明，AutoK 更适合作为候选区间生成器，与模型画像和预算带共同解释。研究问题 4 的结论是，画像驱动建议能够把手工 sweep 中的固定  $k$  选择转化为模型级预算候选，其有效性由模型家族、规模、任务和预算带共同塑造。

这四组结论共同指向本文的核心判断。注意力行为可以贯通校准层与分配层，先在 INT8 基准路径中建立保真参照，再在低比特场景中落实为 K/V 角色感知恢复路径，并进一步扩展为跨模型策略适用区间和 AutoK 预算候选生成机制。后文将在这一基础上归纳本文的创新点、学术价值与适用边界。

## 5.2 创新点与学术价值

从问题建模看，本文把 KV Cache 量化的对象从张量近似推进到注意力行为保持。第三章的误差传播分析说明，缓存量化误差进入下游时会经注意力分布和聚合输出表现为行为扰动。基准验证、低比特实例和预算扩展因此可以在同一组行为变量下讨论，校准目标与分配目标也被放到同一条分析主线中。

从方法链条看，本文把这一原则落实为三个相互衔接的环节。INT8 基准用于建立保守位宽下的保真参照，INT4-RoleAlign 在与 KIVI-style 共享非对称格式的条件下分析低比特失稳中的 K/V 角色差异，行为敏感度画像与 AutoK 则将离线行为读数转化为预算候选。这样，校准参数选择、低比特恢复和层级预算分配可以沿同一套产物继续传递。

系统实现提供了这条方法链的复核入口。离线校准产物、低比特缓存格式和 Triton Decode kernel 被接入同一条在线推理路径，使容量压缩、反量化开销、nibble unpack、GQA head mapping 与 TPOT 读数能够在真实 Decode 语义下被观察。系统层贡献不单独写成通用加速宣称，而是为行为校准和低比特恢复提供可执行、可复核的实验接口。

从经验结果看，跨模型实验把预算策略的有效性落到模型族、规模和



任务条件上。Mistral-7B、Qwen2.5-3B、LLaMA-3.1-8B 与 Qwen2.5-14B 分别呈现 AutoK 单模型支持、早层保护、中等规模共识区间和高性能簇共存等结构。heuristic 多次作为强基线出现，提示某些模型条件下可行层集天然较窄。行为引导框架的经验价值，在于把这些现象从单点跑分比较推进为可复核的敏感度画像图谱。

这些结果共同支持本文的核心判断。注意力行为可以把基准校准、低比特诊断、跨模型预算分析和系统复核纳入同一解释框架。本文回答的是压缩后的缓存如何被观测、诊断、恢复和分配预算，也为后续实验扩展与部署复核提供了可沿用的组织方式。

### 5.3 研究局限性

上述结论有明确的适用域。它们来自本文固定的评测协议、比较口径、模型集合和系统环境，后续扩展需要沿这些维度继续补充证据。

评测域方面，正文主矩阵使用统一生成规则下的 LongBench 风格合成基准任务。官方 LongBench 真实数据对照覆盖 Qwen2.5-1.5B、Narrative-QA/HotpotQA/GovReport 三个任务、每任务最多 50 个样本和单一随机种子。这一设置用于检查官方任务是否延续主协议方向。更开放的真实应用分布仍需要覆盖多轮问答、工具调用、代码仓库级检索、超长报告摘要和领域文档问答。PPL、Needle、RULER 与任务级指标共同降低了单一度量偏差，长上下文质量还可以继续引入更多观察维度。

比较口径方面，逐层预算分配结果来自同量级 INT4 预算带。第 4.4 节已经读出不同模型的结构落点，说明模型族、规模和任务共同塑造高性能区间，heuristic 在部分区间中是强基线。严格 matched-budget 条件下的形式化胜负判定，以及分配器相对 KIVI-style 的预算匹配比较，仍属于后续比较协议需要补齐的内容。因此，分配器方向的当前贡献落在跨模型适用区间的识别、组织和解释上。

模型与机制方面，本文模型集合以 decoder-only GQA 模型为主。MHA、MQA、滑动窗口注意力、MoE 和新的长上下文注意力变体还需要单独验证。INT4-RoleAlign 与 KIVI-style 的比较限定在 per-channel K + per-token V 同格式条件内，有助于减少格式差异干扰。格式贡献、校准贡献与架构因素还可以通过更正交的实验继续拆分。当前证据支持一条已验证设定中的低比特恢复路径，以及一组受模型族、规模和任务共同影响的结构读数。

系统环境方面，部署效率、性能交叉边界和显存读数绑定于当前

NVIDIA H20、固定软件栈、batch=1、贪婪解码以及当前 Triton/FlashInfer 后端组合。A100/H100、消费级 GPU、多 batch serving、speculative decoding、连续批处理调度或 streaming decode 都可能移动交叉点。AutoK 目前主要承担模型级静态候选生成器的角色，prompt 级自适应路由仍处于探索阶段。结果溯源链保证当前版本可追溯，未来架构或部署栈变化后还需要重新复核。

这些边界共同说明，当前关于基准路径保真、低比特恢复与跨模型策略适用区间的结论，已经被限定在清楚的评测域和系统域内。下一节沿这些边界继续整理可推进的后续方向。

## 5.4 未来工作展望

基于上述适用边界，后续工作可以继续围绕调用粒度、预算表达力和比较口径扩展行为引导框架。

调用粒度可以从模型级建议推进到 prompt 级条件化策略选择。现阶段的 AutoK 根据离线行为敏感度画像给出模型级预算候选。下一步需要检验输入提示的结构表征能否与高性能区间稳定对应，并据此把策略调用从“按模型给建议”推进到“按输入做选择”。如果 prompt 结构能够稳定预测敏感层分布，预算建议就可以从静态模型画像进一步扩展到输入条件化路由。

预算表达力可以通过角色感知分配机制继续增强。当前框架已经把 Key 与 Value 的误差传播差异纳入低比特恢复路径，但分配层仍主要使用层级敏感度画像。后续可以进一步整合 Key 与 Value 两侧的预算描述、耦合关系和画像读数，形成同时考虑层、角色和预算带的联合分配机制。这样，K/V 角色差异就能从格式设计继续进入分配器的核心决策。

比较口径也可以继续收紧。第四章已经显示，不同模型在同量级 INT4 预算带内会落入不同策略适用区间。更严格的 matched-budget 协议可以进一步比较 behavior-guided allocator、位置启发式、uniform 策略和现有 KV Cache 压缩基线之间的相对优势。比较口径收紧以后，适用区间的判读可以从经验组织推进到更可比较的结构主张。

这些方向共同指向同一目标，即在调用粒度上引入 prompt 条件，在预算机制上发展角色感知分配器，在比较口径上补齐严格同预算实验，使行为引导框架的可解释性、可比较性和适用域继续扩大。

## 5.5 结语

长上下文高效推理让 KV Cache 量化同时面对容量、行为和系统三类问题。本文以注意力行为作为校准层与分配层共用的观察对象，在 INT8 基准实例、INT4 恢复路径、跨模型预算扩展和 Triton Decode 复核之间建立了可相互校验的证据链。

跨模型实验进一步说明，预算策略需要结合模型家族、参数规模与任务条件读取。敏感度画像将这些差异整理为可命名的适用区间，AutoK 则把离线行为读数转化为模型级预算候选。在长上下文推理的部署需求下，本文提供了一条以注意力行为保持为中心，连接低比特恢复、预算候选生成与系统复核的 KV Cache 行为对齐量化路径。

## 参考文献

- [1] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The Llama 3 herd of models[A]. 2024.
- [2] YANG A, YANG B, ZHANG B, et al. Qwen2.5 technical report[A]. 2024.
- [3] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]//Advances in Neural Information Processing Systems: Vol. 30. 2017.
- [4] KWON W, LI Z, ZHUANG S, et al. Efficient memory management for large language model serving with PagedAttention[C]//Proceedings of the ACM SIGOPS 29th Symposium on Operating Systems Principles. 2023.
- [5] XIAO G, LIN J, SEZNEC M, et al. SmoothQuant: Accurate and efficient post-training quantization for large language models[C]//Proceedings of Machine Learning Research: Vol. 202 Proceedings of the 40th International Conference on Machine Learning. PMLR, 2023: 38087-38099.
- [6] FRANTAR E, ASHKBOOS S, HOEFLER T, et al. GPTQ: Accurate post-training quantization for generative pre-trained transformers[C]//International Conference on Learning Representations. 2023.
- [7] LIN J, TANG J, TANG H, et al. AWQ: Activation-aware weight quantization for on-device LLM compression and acceleration[C]//Proceedings of Machine Learning and Systems: Vol. 6. 2024.
- [8] LIU Z, YUAN J, JIN H, et al. KIVI: A tuning-free asymmetric 2bit quantization for KV cache[C]//Proceedings of Machine Learning Research: Vol. 235 Proceedings of the 41st International Conference on Machine Learning. PMLR, 2024: 32332-32344.
- [9] HOOPER C, KIM S, MOHAMMADZADEH H, et al. KVQuant: Towards 10 million context length LLM inference with KV cache quantization[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024.
- [10] HE Y, ZHANG L, WU W, et al. ZipCache: Accurate and efficient KV cache quantization with salient token identification[J]. Advances in Neural Information Processing Systems, 2024, 37.

- [11] DAO T, FU D, ERMON S, et al. FlashAttention: Fast and memory-efficient exact attention with IO-awareness[C]//Advances in Neural Information Processing Systems: Vol. 35. 2022.
- [12] DAO T. FlashAttention-2: Faster attention with better parallelism and work partitioning[C]//International Conference on Learning Representations. 2024.
- [13] TILLET P, KUNG H T, COX D. Triton: An intermediate language and compiler for tiled neural network computations[C]//Proceedings of the 3rd ACM SIGPLAN International Workshop on Machine Learning and Programming Languages. 2019.
- [14] SHAZEER N. Fast transformer decoding: One write-head is all you need [A]. 2019.
- [15] AINSLIE J, LEE-THORP J, DE JONG M, et al. GQA: Training generalized multi-query transformer models from multi-head checkpoints[C/OL]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 4895-4901. DOI: [10.18653/v1/2023.emnlp-main.298](https://doi.org/10.18653/v1/2023.emnlp-main.298).
- [16] NAGEL M, FOURNARAKIS M, AMJAD R A, et al. A white paper on neural network quantization[A]. 2021.
- [17] HUBARA I, COURBARIAUX M, SOUDRY D, et al. Quantized neural networks: Training neural networks with low precision weights and activations [J]. Journal of Machine Learning Research, 2018, 18(187): 1-30.
- [18] TAO Q, YU W, ZHOU J. AsymKV: Enabling 1-bit quantization of KV cache with layer-wise asymmetric quantization configurations[C/OL]//Proceedings of the 31st International Conference on Computational Linguistics (COLING). Association for Computational Linguistics, 2025: 2316-2328. DOI: [10.18653/v1/2025.coling-main.158](https://doi.org/10.18653/v1/2025.coling-main.158).
- [19] SHUTOVA A, MALINOVSKII V, EGIАЗARIAN V, et al. Cache me if you must: Adaptive key-value quantization for large language models[C]//International Conference on Machine Learning (ICML). 2025.

- [20] ASHKBOOS S, MOHTASHAMI A, CROCI M L, et al. QuaRot: Outlier-free 4-bit inference in rotated LLMs[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024.
- [21] KANG H, ZHANG Q, KUNDU S, et al. GEAR: An efficient KV cache compression recipe for near-lossless generative inference of LLM[J]. International Conference on Learning Representations, 2025.
- [22] LIN Y, TANG H, YANG S, et al. QServe: W4A8KV4 quantization and system co-design for efficient LLM serving[C]//Proceedings of Machine Learning and Systems (MLSys): Vol. 7. 2025.
- [23] LIU R, BAI H, LIN H, et al. IntactKV: Improving large language model quantization by keeping pivot tokens intact[C/OL]//Findings of the Association for Computational Linguistics: ACL 2024. Association for Computational Linguistics, 2024: 7716-7741. DOI: [10.18653/v1/2024.findings-acl.460](https://doi.org/10.18653/v1/2024.findings-acl.460).
- [24] DUANMU H, ZHONG Z, WEI W, et al. SKVQ: Sliding-window key and value cache quantization for large language models[A]. 2024.
- [25] SU Y, ZHOU Y, QIU Q, et al. Accurate KV cache quantization with outlier tokens tracing[C/OL]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2025: 12895-12915. DOI: [10.18653/v1/2025.acl-long.631](https://doi.org/10.18653/v1/2025.acl-long.631).
- [26] ZHAO Y, LIN C Y, ZHU K, et al. Atom: Low-bit quantization for efficient and accurate LLM serving[J]. Proceedings of Machine Learning and Systems, 2024, 6.
- [27] ZANDIEH A, DALIRI M, HAN I. QJL: 1-bit quantized JL transform for KV cache quantization with zero overhead[A]. 2024.
- [28] ZHANG Z, SHENG Y, ZHOU T, et al. H2O: Heavy-hitter oracle for efficient generative inference of large language models[J]. Advances in Neural Information Processing Systems, 2023, 36.

- [29] XIAO G, TIAN Y, CHEN B, et al. Efficient streaming language models with attention sinks[C]//International Conference on Learning Representations. 2024.
- [30] LI Y, HUANG Y, YANG B, et al. SnapKV: LLM knows what you are looking for before generation[J]. Advances in Neural Information Processing Systems, 2024, 37.
- [31] CAI Z, ZHANG Y, GAO B, et al. PyramidKV: Dynamic KV cache compression based on pyramidal information funneling[A]. 2024.
- [32] XIAO G, TANG J, ZUO J, et al. DuoAttention: Efficient long-context LLM inference with retrieval and streaming heads[C]//International Conference on Learning Representations (ICLR). 2025.
- [33] FU Y, CAI Z, ASI A, et al. Not all heads matter: A head-level KV cache compression method with integrated retrieval and reasoning[C]//International Conference on Learning Representations (ICLR). 2025.
- [34] LIU X, TANG Z, DONG P, et al. ChunkKV: Semantic-preserving KV cache compression for efficient long-context LLM inference[C]//Advances in Neural Information Processing Systems: Vol. 38. 2025.
- [35] LIU Y, LI H, CHENG Y, et al. CacheGen: KV cache compression and streaming for fast large language model serving[J/OL]. Proceedings of the ACM SIGCOMM Conference, 2024: 38-56. DOI: [10.1145/3651890.3672274](https://doi.org/10.1145/3651890.3672274).
- [36] XU Y, JIE Z, DONG H, et al. ThinK: Thinner key cache by query-driven pruning[C]//International Conference on Learning Representations. 2025.
- [37] YUAN J, LIU H, ZHONG S, et al. KV cache compression, but what must we give in return? A comprehensive benchmark of long context capable approaches[C/OL]//Findings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP Findings). Association for Computational Linguistics, 2024: 4623-4648. DOI: [10.18653/v1/2024.findings-emnlp.266](https://doi.org/10.18653/v1/2024.findings-emnlp.266).

- [38] LI X, XING Z, LI Y, et al. KVTuner: Sensitivity-aware layer-wise mixed precision KV cache quantization for efficient and nearly lossless LLM inference[C]//International Conference on Machine Learning (ICML). 2025.
- [39] BONDARENKO Y, NAGEL M, BLANKEVOORT T. Quantizable transformers: Removing outliers by helping attention heads do nothing[J]. Advances in Neural Information Processing Systems, 2023, 36.
- [40] HUANG W, GE Y, YANG S, et al. QeRL: Beyond efficiency – quantization-enhanced reinforcement learning for LLMs[C]//International Conference on Learning Representations. 2026.
- [41] VELIČKOVIĆ P, PERIVOLAROPOULOS C, BARBERO F, et al. softmax is not enough (for sharp out-of-distribution)[C]//NeurIPS Workshop on Scientific Methods for Understanding Deep Learning. 2024.
- [42] GU Y, JIANG Z, JIN J, et al. AhaKV: Adaptive holistic attention-driven kv cache eviction for efficient inference of large language models[A]. 2025.
- [43] JIANG A Q, SABLAYROLLES A, MENSCH A, et al. Mistral 7B[A]. 2023.
- [44] KAMRADT G. Needle in a haystack — pressure testing LLMs[EB/OL]. 2023. [https://github.com/gkamradt/LLMTest\\_NeedleInAHaystack](https://github.com/gkamradt/LLMTest_NeedleInAHaystack).
- [45] HSIEH C P, SUN S, KRIMAN S, et al. RULER: What’s the real context size of your long-context language models?[C]//Conference on Language Modeling (COLM). 2024.
- [46] BAI Y, LV X, ZHANG J, et al. LongBench: A bilingual, multitask benchmark for long context understanding[C/OL]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Bangkok, Thailand: Association for Computational Linguistics, 2024: 3119-3137. DOI: [10.18653/v1/2024.acl-long.172](https://doi.org/10.18653/v1/2024.acl-long.172).



## 附录 A 补充材料

### A.1 评测协议、环境与复现入口

本节汇总三类复现审计材料：PPL 评测协议与 FP16 基线、软硬件环境，以及主线实验的复现入口与覆盖范围。这些信息用于解释正文表格的协议边界与复现条件，不承担新的实验结论。

PPL 协议与基线。本文 PPL 评测在不同章节使用了三种略有差异的协议，表 A-1 统一列出各模型 FP16 PPL 基线与对应协议，供读者在交叉比较时参照。同一模型同一精度在不同协议下可能出现  $\sim 0.1\text{--}0.5$  PPL 差异，各表的绝对数字不可直接跨表比较。各退化率（相对同表内 FP16 基线）方可在表内对比。

表 A-1 FP16 PPL 基线  $\times$  评测协议汇总。

| 模型           | 协议            | max_length / stride | chunk_size | FP16 PPL            |
|--------------|---------------|---------------------|------------|---------------------|
| Qwen2.5-1.5B | 32K 上下文短窗     | 1024 / 512          | 128        | 8.93                |
| Qwen2.5-1.5B | 完整 test split | 32K / 32K           | 128        | 9.31                |
| Qwen2.5-7B   | 32K 上下文短窗     | 1024 / 512          | 128        | 6.71                |
| Qwen2.5-7B   | 完整 test split | 32K / 32K           | 128        | 7.14                |
| Qwen2.5-7B   | KL/MSE 配对诊断子集 | 32K / 32K           | 128        | 6.7097 <sup>†</sup> |
| LLaMA-3.1-8B | 32K 上下文短窗     | 1024 / 512          | 128        | 6.92                |
| LLaMA-3.1-8B | 完整 test split | 32K / 32K           | 128        | 6.73                |
| Qwen2.5-14B  | 32K prefix    | 32K / —             | 128        | 4.685 <sup>*</sup>  |

<sup>†</sup> 附录表 A-11 的 7B FP16 基线 PPL 精确到四位小数为 6.7097，来自 KL/MSE 校准目标对比使用的配对诊断子集。本表第四行的 7.14 对应完整 test split 汇总口径。两者采用相同的 PPL 定义、窗口长度与 chunk\_size，但样本覆盖与聚合人口不同，因此只允许在各自协议内部进行配对比较，不作为跨表绝对值比较对象。该表对比 INT4 KL/MSE 校准在 7B 上产生的逐位一致 PPL (7.1121, 属 INT4 侧观察，非 FP16 基线)。

<sup>\*</sup> 14B 因 H20 显存限制仅在 test split 前 32767 tokens 上评测，与其他模型的完整  $\sim 302\text{K}$  test split 不可直接比较。

注：表 4-9 与附录第 A.7 节使用 32K 上下文短窗协议。表 4-8 使用完整 test split。

实验环境。表 A-2 列出了本文所有实验所使用的软硬件环境配置。

生成式质量评测采用固定随机种子（主实验 1234–1238）与贪心解码策略（temperature=0.0, top\_p=1.0, top\_k=0），吞吐实验采用固定随机种子 1234–1241，以确保结果的可复现性。PPL 采用固定输入序列上的 likelihood 累计，seed 仅用于实现路径一致性核验，不作为统计重复，也不绑定上述生成式解码设置。

表 A-2 实验软硬件环境

| 项目           | 配置                    |
|--------------|-----------------------|
| GPU          | NVIDIA H20, 98 GB HBM |
| CPU          | Intel Xeon            |
| 操作系统         | Ubuntu 22.04 LTS      |
| Python       | 3.12                  |
| PyTorch      | 2.8.0 (CUDA 12.8)     |
| Transformers | 4.48+                 |
| Triton       | 3.2+                  |
| NumPy        | 2.x                   |
| pandas       | 2.x                   |
| Matplotlib   | 3.x                   |

复现入口与覆盖范围。本文主线实验保留了一套公开复现配置与 artifact 清单。对应条目覆盖第四章的基准路径验证、低比特恢复、跨模型预算分配与第 4.5 节的部署效率评估，并补充附录 A.8.2 的 7B KL/MSE 趋同溯源。BitDecoding 案例与官方 LongBench v2 数据作为补充参考材料保留，但不在主线复现保证范围内。

关于校准样本数量：表 A-4 中的  $N = 128$  表示正文口径下的标准规模，复现配置实际使用  $N \in \{16, 32\}$  来复现同一已选参数配置。校准样本数量敏感性检查（覆盖  $s \in \{16, 64, 256\}$ ）确认 PPL/Needle/RULER/LongBench 四类指标均已进入平坦收敛域。

## A.2 量化路径与复现配置类别

本节只承担复现审计的论文侧说明。表 A-3 给出正文量化路径名称与复现配置类别之间的对应关系。具体配置键值保留在公开 artifact manifest 中，正文论证只使用左列名称。

## A.3 校准产物与搜索空间审计

离线校准阶段产出一份小型结构化校准记录 (<10 KB)，其中包含路径特定的逐层 Key/Value scale、zero point、分位数参数、分组元数据，以及模型标识、校准样本数、seed、目标函数与量化格式等审计字段。对称路径主要消费静态 scale 与分组参数。INT4-RoleAlign 额外记录 per-channel Key 与 per-token Value 的角色感知分位数参数。逐头温度校正字段若出现在早期诊断记录中，仅用于附录第 A.8 节的诊断复现。第三章与第四章主线配置不

表 A-3 正文量化路径与复现配置类别的对应关系

| 正文名称                      | 复现配置类别                                 | K/V 位宽 | 默认执行路径        | 说明                          |
|---------------------------|----------------------------------------|--------|---------------|-----------------------------|
| FP16                      | full-precision reference               | 16/16  | FP16          | 全精度基线                       |
| INT8 baseline             | percentile symmetric baseline          | 8/8    | 参考实现 / Triton | percentile 对称基线             |
| INT8-Canonical            | behavior-guided symmetric INT8         | 8/8    | Triton        | KL-guided 对称基准路径            |
| INT4 percentile baseline  | percentile symmetric INT4              | 4/4    | 参考实现          | percentile 对称低比特基线          |
| 对称 INT4 (behavior-guided) | behavior-guided symmetric INT4         | 4/4    | 参考实现          | KL-guided 对称 INT4           |
| 融合 INT4 诊断变体              | symmetric INT4 fused-kernel diagnostic | 4/4    | Triton        | 同校准参数的融合路径诊断，非 Ch4 主表项      |
| INT4-RoleAlign            | role-aware asymmetric INT4             | 4/4    | 参考实现*         | per-channel K + per-token V |
| KIVI-style                | runtime-statistic asymmetric INT4      | 4/4    | 参考实现          | 同格式 runtime 统计基线            |
| MixedKV                   | mixed-precision diagnostic             | 8/4    | 参考实现          | K8V4 诊断路径                   |

注：第四章主表使用左列正文名称。中列仅说明公开复现材料中的配置类别，不作为正文方法命名。INT4-RoleAlign 与 KIVI-style 共享 per-channel K + per-token V 缓存格式，二者差异限定在离线行为校准与运行时统计更新的参数来源上。

\* INT4-RoleAlign 的非对称 Triton 变体只作为实现可行性验证。正文质量评测默认使用参考解码实现，系统讨论见第 4.5 节。

使用该组件。推理时一次性加载相应产物到 GPU 显存，不引入运行时校准开销。

校准超参数搜索空间。表 A-4 汇总主线校准搜索空间。对称量化数据结构只保留复现所需常量。

表 A-4 校准超参数搜索空间

| 超参数                    | 符号                           | 候选值集合 / 默认配置                                     |
|------------------------|------------------------------|--------------------------------------------------|
| 对称格式常量                 |                              |                                                  |
| 位宽 / 范围                | $n, q_{\max}$                | INT8 为 8 / 127, INT4 为 4 / 7                     |
| Scale / 量化轴            | —                            | float32 scale, 对称 per-group (沿 $d_k$ 分组)         |
| INT8 对称量化路径 (主线校准搜索)   |                              |                                                  |
| Clip percentile        | $\mathcal{P}_c$              | {99.0, 99.5, 99.9, 100.0} (默认 99.5)              |
| Group size             | $\mathcal{G}$                | {16, 32, 64, 128} (默认 16)                        |
| Outlier rescue ratio   | —                            | {0, 0.0025, 0.005, 0.01}                         |
| 补充诊断分支                 |                              |                                                  |
| 温度因子                   | $\mathcal{T}$                | {0.5, 0.7, 0.85, 1.0, 1.2, 1.5, 2.0} (不计入主线搜索规模) |
| INT4-RoleAlign 非对称量化路径 |                              |                                                  |
| K percentile           | $\mathcal{P}_K$              | {95.0, 97.0, 99.0, 99.5, 99.9, 100.0}            |
| V percentile           | $\mathcal{P}_V$              | {95.0, 97.0, 99.0, 99.5, 99.9, 100.0}            |
| 共用参数                   | $N, \text{len}, \text{data}$ | 128 (标准规模)、512 tokens、WikiText-2 (test split)    |

其中  $N = 128$  表示正文口径下的标准校准规模。复现配置使用  $N \in \{16, 32\}$  复现同一已选参数配置，见附录第 A.1 节说明。INT8 基准路径主

线搜索为  $|\mathcal{P}_c| \times |\mathcal{G}| = 16$  组。温度因子只属补充诊断，不计入搜索规模，也不改变主线默认配置。INT4-RoleAlign 可枚举  $|\mathcal{P}_K| \times |\mathcal{P}_V| = 36$  组用于审计，但 K-path 与 V-path 的代理需分别解释。

#### A.4 LongBench、统计检验与质量趋势补充材料

本节合并三类质量补充材料：LongBench-style 合成评测的完整审计表、官方 LongBench 小范围协议一致性检查、以及统计检验与上下文长度趋势图。这些材料共同服务于第四章的可信性边界，而不替代正文主表或扩大主结论适用范围。

LongBench-style 补充聚合表。表 A-5 列出了三种模型在 32K 上下文长度下、七种实验路径的 LongBench-style 聚合结果，包含 F1 宏平均、包含匹配宏平均以及综合评分。数值后的“ $\pm$ ”表示 Bootstrap 95% 置信区间半宽。本表只作为正文基准保真与低比特恢复证据的补充审计材料。其中 8B 的 INT4 读数不应被反向概括为低比特路径普遍安全。

表 A-5 LongBench-style 补充聚合结果（32K 上下文，三模型  $\times$  七实验路径）

| 模型   | 实验路径                 | F1 宏平均           | 包含匹配率 (%)       | 综合评分                |
|------|----------------------|------------------|-----------------|---------------------|
| 1.5B | FP16                 | $5.53 \pm 0.05$  | $99.9 \pm 0.2$  | $0.0482 \pm 0.0004$ |
|      | INT8-Baseline        | $5.50 \pm 0.02$  | $99.9 \pm 0.2$  | $0.0478 \pm 0.0002$ |
|      | INT8-Canonical       | $5.54 \pm 0.04$  | $99.9 \pm 0.1$  | $0.0482 \pm 0.0004$ |
|      | INT4 percentile      | $2.91 \pm 0.26$  | $45.9 \pm 2.0$  | $0.0298 \pm 0.0024$ |
|      | Fused INT4           | $0.00 \pm 0.00$  | $0.0 \pm 0.0$   | $0.0515 \pm 0.0068$ |
|      | Behavior-guided INT4 | $0.00 \pm 0.00$  | $0.0 \pm 0.0$   | $0.0241 \pm 0.0025$ |
|      | KIVI-style           | $5.58 \pm 0.07$  | $99.9 \pm 0.1$  | $0.0481 \pm 0.0005$ |
| 7B   | FP16                 | $4.29 \pm 0.15$  | $100.0 \pm 0.0$ | $0.0378 \pm 0.0008$ |
|      | INT8-Baseline        | $4.38 \pm 0.14$  | $100.0 \pm 0.0$ | $0.0383 \pm 0.0007$ |
|      | INT8-Canonical       | $4.44 \pm 0.14$  | $100.0 \pm 0.0$ | $0.0383 \pm 0.0009$ |
|      | INT4 percentile      | $0.00 \pm 0.00$  | $0.0 \pm 0.0$   | $0.0172 \pm 0.0024$ |
|      | Fused INT4           | $0.45 \pm 0.13$  | $4.2 \pm 0.9$   | $0.0183 \pm 0.0020$ |
|      | Behavior-guided INT4 | $0.00 \pm 0.01$  | $0.4 \pm 0.5$   | $0.0027 \pm 0.0011$ |
|      | KIVI-style           | $4.28 \pm 0.14$  | $99.9 \pm 0.1$  | $0.0378 \pm 0.0011$ |
| 8B   | FP16                 | $10.29 \pm 0.76$ | $99.7 \pm 0.5$  | $0.0792 \pm 0.0066$ |
|      | INT8-Baseline        | $10.71 \pm 0.85$ | $99.7 \pm 0.5$  | $0.0817 \pm 0.0092$ |
|      | INT8-Canonical       | $10.72 \pm 0.85$ | $99.6 \pm 0.7$  | $0.0817 \pm 0.0092$ |
|      | INT4 percentile      | $12.95 \pm 1.02$ | $99.7 \pm 0.5$  | $0.1037 \pm 0.0087$ |
|      | Fused INT4           | $15.89 \pm 1.37$ | $99.8 \pm 0.3$  | $0.1505 \pm 0.0138$ |
|      | Behavior-guided INT4 | $19.88 \pm 1.34$ | $99.4 \pm 0.5$  | $0.1908 \pm 0.0111$ |
|      | KIVI-style           | $8.72 \pm 0.98$  | $99.6 \pm 0.3$  | $0.0682 \pm 0.0069$ |

注：1.5B = Qwen2.5-1.5B-Instruct, 7B = Qwen2.5-7B-Instruct, 8B = LLaMA-3.1-8B-Instruct。合成 LongBench (7 类子任务), 5 seeds 均值。8B INT4 的较高 F1 可能反映合成任务、评分器或该模型/路径组合下的协议特异性，不作为 INT4 优于 FP16 或 KIVI-style 的主证据。

官方数据一致性检查。前述 LongBench-style 评测使用确定性合成数据源，绝对值不可与社区官方榜单直接对齐。为检查主评测协议是否存在方向性误判，本文在 LongBench<sup>[46]</sup> 官方数据集上使用 Qwen2.5-1.5B-Instruct、32K 截断、seed=1234 和每任务最多 50 个样本，选取 NarrativeQA、HotpotQA 与 GovReport 三个任务做小范围对照。在 INT8-Canonical 相对 FP16 的比较中，三项差异分别为  $-0.43$ 、 $+0.31$ 、 $+0.08$  pp，宏平均为 FP16=7.06、INT8-Canonical=7.05。这一小范围官方对照与合成协议对 INT8 基准路径保真方向的判断保持一致，其作用限定在协议一致性检查层面。

统计检验设置与结果。表 A-6 合并列出了 INT8 路径在固定序列 PPL、生成式质量指标 (Needle/LongBench/RULER,  $n = 5$  种子) 与推理延迟 (TPOT,  $n = 8$  种子) 上的审计结果。PPL 行对应固定输入序列上的 likelihood 累计，只报告效应量，不进入显著性检验。Needle 行对应主配置，LongBench 与 RULER 行使用主配置及补充配置的合并读数，因此只用于稳定性审计，不作为正文主路径 claim。生成式质量指标与延迟指标的检验均基于配对种子的 sign-flip 置换检验，多重比较校正采用 Benjamini-Hochberg FDR 控制 ( $\alpha = 0.05$ )。

上下文长度质量趋势表。表 A-7 汇总了 Qwen2.5-1.5B-Instruct 上 RULER 与 LongBench-style 综合评分在不同上下文长度下的关键读数。该表只保留 FP16 与 INT8-Canonical 两条主线参照，用于确认补充质量指标没有改变正文主结论。低比特长上下文边界则由图 A-3 和附录第 A.6 节补充。

## A.5 部署效率与批处理扩展补充

本节汇总 Qwen2.5-1.5B-Instruct 上的系统补充读数，包括单序列 TPOT 边界说明、吞吐/显存扩展图，以及 batch 维度的容量边界。这些材料只服务于第 4.5 节的部署边界审计。硬件、后端路径、batch size 与序列长度条件均不应外推为通用速度结论。

单序列 TPOT 边界与资源扩展图。单序列 TPOT 读数在下文以文字说明。图 A-1 和图 A-2 分别补充展示吞吐与显存扩展读数。

单序列 TPOT 的补充读数显示，在 Qwen2.5-1.5B-Instruct、NVIDIA H20、batch=1 的设置下，量化路径仍受到固定开销约束，适合作为部署边界条件

表 A-6 INT8 固定序列 PPL、质量与延迟审计统计 (32K 上下文)

| 模型                                                                 | 指标                | INT8-Baseline | 审计对象   | 变化 (%) | <i>p</i> 值 | <i>q</i> 值 | 显著  |
|--------------------------------------------------------------------|-------------------|---------------|--------|--------|------------|------------|-----|
| 固定序列 PPL (不做显著性检验)                                                 |                   |               |        |        |            |            |     |
| 1.5B                                                               | PPL↓              | 8.9316        | 8.9497 | −0.20  | N/A        | N/A        | N/A |
| 7B                                                                 | PPL↓              | 6.7145        | 6.7322 | −0.26  | N/A        | N/A        | N/A |
| 8B                                                                 | PPL↓              | 6.9193        | 6.9252 | −0.09  | N/A        | N/A        | N/A |
| 生成式质量指标 ( $n = 5$ 种子 1234–1238)                                    |                   |               |        |        |            |            |     |
| 1.5B                                                               | Needle pass rate↑ | 100.00        | 100.00 | +0.00  | 1.0000     | 1.0000     | 否   |
|                                                                    | LongBench score↑  | 0.0478        | 0.0486 | +1.77  | 0.0909     | 0.1435     | 否   |
|                                                                    | RULER pass rate↑  | 24.45         | 23.81  | −2.64  | 0.0909     | 0.7273     | 否   |
| 7B                                                                 | Needle pass rate↑ | 100.00        | 100.00 | +0.00  | 1.0000     | 1.0000     | 否   |
|                                                                    | LongBench score↑  | 0.0383        | 0.0383 | +0.17  | 0.9394     | 0.9553     | 否   |
|                                                                    | RULER pass rate↑  | 24.92         | 24.84  | −0.31  | 1.0000     | 1.0000     | 否   |
| 8B                                                                 | Needle pass rate↑ | 100.00        | 100.00 | +0.00  | 1.0000     | 1.0000     | 否   |
|                                                                    | LongBench score↑  | 0.0817        | 0.0817 | +0.09  | 0.8788     | 0.9416     | 否   |
|                                                                    | RULER pass rate↑  | 32.58         | 31.25  | −4.05  | 0.0909     | 0.7273     | 否   |
| 解码延迟 TPOT ( $n = 8$ 种子 1234–1241, batch size 为 1, 生成长度为 64 tokens) |                   |               |        |        |            |            |     |
| 1.5B                                                               | TPOT (ms)↓        | 51.42         | 47.14  | +8.32  | 0.0117     | 0.0159     | 是   |
| 7B                                                                 | TPOT (ms)↓        | 60.52         | 50.07  | +17.26 | 0.0117     | 0.0159     | 是   |
| 8B                                                                 | TPOT (ms)↓        | 91.77         | 57.23  | +37.64 | 0.0117     | 0.0159     | 是   |

注: PPL 为固定输入序列上的确定性 likelihood 指标, seed 只用于实现路径一致性核验, 因此不进入生成式指标的显著性检验流程。生成式质量指标差异均未达到 BH-FDR 校正后的统计显著性。三种模型上的 TPOT 降低均达到显著性 ( $q < 0.05$ )。1.5B Needle 行报告主配置 (5 种子均 100%)。LongBench/RULER 行为主配置与补充配置的合并审计读数, 其中 RULER 退化主要受补充配置影响。

表 A-7 补充质量指标随上下文长度的关键读数 (Qwen2.5-1.5B-Instruct)。

| 上下文长度 | RULER<br>FP16 | RULER<br>INT8-Canonical | LongBench<br>FP16 | LongBench<br>INT8-Canonical |
|-------|---------------|-------------------------|-------------------|-----------------------------|
| 4K    | 24.84         | 24.87                   | 4.37              | 4.51                        |
| 8K    | 24.92         | 24.92                   | 4.82              | 5.00                        |
| 16K   | 24.77         | 24.84                   | 4.82              | 5.00                        |
| 32K   | 24.38         | 23.88                   | 4.82              | 4.92                        |


注: RULER 为通过率 (%)。LongBench-style 综合评分按  $\times 100$  报告。

的说明。第 4.5 节的部署结论仍以正文表 4-12–4-14 以及本节的吞吐、显存补充读数为准。


批处理容量与 INT4-RoleAlign 扩展轨迹。表 A-8 合并呈现 batch 维度的容量边界与扩展轨迹: (a) 各模式在序列长度 8192 条件下的已测最大可行 batch。(b) INT4-RoleAlign 在不同 batch 下的 TPOT 与 KV Cache 显存。

## A.6 INT4 失稳机制与评估粒度边界补充

本节按四层组织 INT4 相关补充材料: 首先用 Needle 深度–位置热力图给出 long-context cliff 的可视化背景。随后用 scale 精度敏感性读数排除



**图 A-1** 吞吐扩展性三联图 (Qwen2.5-1.5B-Instruct, NVIDIA H20, 序列长度 8192, 生成长度 128)。面板 (a) 展示总吞吐量, 面板 (b) 展示单序列吞吐量, 面板 (c) 展示 prefill 吞吐量。统一图例和坐标轴用于观察当前后端组合下 batch 扩展中的并发收益与单序列代价。



**图 A-2** 显存扩展性双联图 (Qwen2.5-1.5B-Instruct, NVIDIA H20, 序列长度 8192)。面板 (a) 展示 KV Cache 显存随 batch size 的线性增长, 面板 (b) 展示总峰值显存。两者共同说明量化节省如何改变当前扫描范围内的可容纳 batch。

“scale dtype 单点失误”解释。第三部分保留噪声-长度交互的近似推导, 给出 32K 场景下 INT4 阶跃退化的机制直觉。最后用 chunk size 消融界定评估粒度和流式近似协议边界。最后一部分只限定协议适用范围, 不引入新的主机结论。

Needle 深度-位置热力图补充。图 A-3 补充展示 Needle 任务的深度位置热力图。该图服务于正文第 4.3.1 节的阶跃崩塌模式: 它说明在当前热力图覆盖设置下, 对称 INT4 的退化主要在长上下文与深层 needle 位置上被放大, 并为下文噪声-长度推导提供可视化背景。

精确匹配率 (exact match) 采用比通过率更严格的 Needle 判据, 其趋势

表 A-8 批处理扩展综合数据 (Qwen2.5-1.5B-Instruct, NVIDIA H20, 序列长度 8192, 独占 GPU)

(a) 各量化模式已测最大可行 batch (1-32 扫描)

| 量化模式           | 已测最大可行 batch | 扫描范围 | 容量结论           |
|----------------|--------------|------|----------------|
| FP16           | 16           | 1-16 | 范围内可行, 未扩展至 32 |
| INT8-Baseline  | 24           | 1-32 | batch=32 显存不足  |
| INT8-Canonical | 32           | 1-32 | 范围内可行          |
| INT4-Baseline  | 16           | 1-16 | 范围内可行, 未扩展至 32 |
| INT4-Fused     | 32           | 1-32 | 范围内可行          |
| INT4-RoleAlign | 32           | 1-32 | 范围内可行          |

(b) INT4-RoleAlign 批处理扩展轨迹 (FP16 vs INT4-RA 对照)

| Batch | TPOT FP16 / INT4-RA (ms) | KV FP16 / INT4-RA (MB) | KV 压缩比 |
|-------|--------------------------|------------------------|--------|
| 1     | 24.78 / 60.18            | 227 / 60               | 3.78×  |
| 4     | 24.65 / 73.17            | 910 / 242              | 3.76×  |
| 8     | 24.21 / 93.07            | 1820 / 484             | 3.76×  |
| 16    | 24.23 / 134.46           | 3640 / 968             | 3.76×  |

注: (a) 在序列长度 8192、NVIDIA H20 与当前后端组合下, INT8-Canonical 与 INT4 融合模式均可支持已测 batch=32。INT8-Baseline 在 batch=32 时出现中间张量显存不足, 因此容量边界从 24 移至 32 只相对于该 baseline 解释; (b) KV 压缩比约 3.76× 恒定。INT4-RoleAlign 的 TPOT 随 batch 增长, 说明该实现仍有并发反量化摊销开销。batch=16 时其 KV Cache 为 968 MB (FP16 为 3640 MB), 主要收益体现在容量边界而非速度主结论。




图 A-3 Needle-in-a-Haystack 深度-位置热力图总览。四个面板分别对应 4K、8K、16K 和 32K, 并共享同一色标。该图用于定位 INT4 退化在上下文长度和 needle 深度上的放大位置, 不替代正文的主表结论。



与图 A-3 一致：FP16 在 4K–32K 均保持 100%，INT8-Canonical 在 4K–16K 保持 100%，并在 32K 端点给出约 70.3% 的长上下文边界读数。对称 INT4 则在 4K 已显露边界，并在 8K 及以上区间构成长上下文边界对照。这些 exact-match 读数作为严格判据补充图 A-3，不再作为独立视觉证据展开。

Scale 精度敏感性诊断。表 A-9 是一组补充诊断读数，用于确认对称 INT4 失稳并非仅由 scale 存储精度不足造成。所有 scale 参数均以 float32 精度维护。本节中的 behavior-guided 对称 INT4 不等同于正文主线的 INT4-RoleAlign 非对称路径。

**表 A-9** INT4 量化 scale 精度敏感性实验（32K 序列，PPL 为固定序列 likelihood，Needle 使用三个固定种子的贪婪生成）

| 模型           | 模式                             | PPL   | Needle (%) | 校准         | Scale dtype |
|--------------|--------------------------------|-------|------------|------------|-------------|
| Qwen2.5-1.5B | Symmetric INT4 baseline        | 19.65 | 0          | percentile | float32     |
|              | Symmetric INT4 behavior-guided | 22.80 | 0          | KL proxy   | float32     |
| Qwen2.5-7B   | Symmetric INT4 baseline        | 86.56 | —          | percentile | float32     |
|              | Symmetric INT4 behavior-guided | 52.19 | —          | KL proxy   | float32     |
| LLaMA-3.1-8B | Symmetric INT4 baseline        | 6.97  | 100        | percentile | float32     |
|              | Symmetric INT4 behavior-guided | 7.64  | 100        | KL proxy   | float32     |

注：7B Needle 未包含在该诊断消融中（标记 —）。1.5B Needle 0% 反映该模型在 32K 对称 INT4 下的边界。7B 基线 PPL=86.56 与正文同量级结果一致，说明该敏感性不是 scale dtype 单点造成。

**补充读数。**在同一 float32 scale 条件下，7B 的 behavior-guided 对称 INT4 PPL 低于 percentile baseline，但 1.5B 的 Needle 仍为 0%，LLaMA-3.1-8B 则在两种对称 INT4 配置下保持 100%。因此本节只支撑第 4.6.2 节的边界判断：scale 精度是必要的数值卫生条件，但对称 INT4 cliff 还会受到模型结构与上下文长度调节。

量化噪声与序列长度交互效应。本段提供正文第 4.6.2 节中量化步长与序列长度交互效应的近似分析。

Needle-in-a-Haystack 任务的检索成功条件可形式化为：目标位置  $t$  的 attention logit 与最强干扰位置的差值  $\delta = z_t - \max_{i \neq t} z_i$ （其中  $z_i = \mathbf{q}^\top \mathbf{k}_i / \sqrt{d_k}$ ）需在量化后仍保持正值，使 softmax 将最大概率分配给目标位置。

当 Key 矩阵经 INT4 量化后，每个 logit  $z_i$  受到量化噪声扰动  $\epsilon_i$ ，其方差约为：

$$\text{Var}(\epsilon_i) \approx \|\mathbf{q}\|^2 \cdot \sigma_{q,4}^2 / d_k \quad (\text{A-1})$$

其中  $\sigma_{q,4}^2 = \Delta_4^2 / 12$  为 INT4 量化的逐元素噪声方差。

随序列长度  $n$  增大,  $\max_{i \neq t}(z_i + \epsilon_i)$  的期望值以  $O(\sqrt{2 \ln n} \cdot \sigma_\epsilon)$  的速率增长 (极值统计理论), 而目标信号  $\delta$  不随  $n$  增大。在这一近似模型下, 可以定义一个临界序列长度  $n^*$ , 满足:

$$\delta \approx \sqrt{2 \ln n^*} \cdot \sigma_\epsilon \quad (\text{A-2})$$

当  $n > n^*$  时, 量化噪声超过目标 margin 的风险快速上升, 检索失败概率随之增大。

在同一对称裁剪范围下, INT8 与 INT4 的  $q_{\max}$  分别为 127 与 7, 因此 INT4 相对 INT8 的逐元素噪声方差比约为  $\sigma_{q,4}^2 / \sigma_{q,8}^2 = (127/7)^2 \approx 3.29 \times 10^2$ 。INT4 的  $n^*$  远小于 INT8。该近似模型为 1.5B 模型上从短上下文到 32K 的 Needle 通过率下降提供了理论直觉。实际退化强度仍受模型结构、校准格式和注意力分布共同调节。

评估粒度鲁棒性。本段验证量化粒度变化对低比特路径的影响。前述各节采用 128-token chunk 协议,  $cs=1$  则更接近每步都读写量化历史 KV 的 streaming decode。表 A-10 给出 Qwen2.5-1.5B-Instruct 上三种粒度下 FP16、INT4-RoleAlign 和 KIVI-style INT4 的 PPL 对比。

表 A-10 量化评估粒度敏感性 (Qwen2.5-1.5B-Instruct, PPL, seed=1234)

| 配置                    | cs=128                | cs=8                       | cs=1                       |
|-----------------------|-----------------------|----------------------------|----------------------------|
| FP16                  | 9.31                  | 9.31                       | 9.31                       |
| INT8-Canonical        | 8.95                  | 9.34 (+0.3% <sup>†</sup> ) | 9.27 (-0.4% <sup>†</sup> ) |
| <b>INT4-RoleAlign</b> | <b>10.58</b> (+13.7%) | <b>62.10</b> (+567%)       | >10,000*                   |
| KIVI-style INT4       | 10.43 (+12.0%)        | 60.54 (+550%)              | 10,332 (+110,900%)*        |

表注与边界。括号内为相对 FP16 的 PPL 变化率,  $cs = \text{chunk\_size}$ 。<sup>†</sup> INT8-Canonical 的  $cs=128$  PPL 低于 FP16, 主要反映评测切分口径差异。 $cs=1$  相对 FP16 仍基本持平, 说明更高量化级别提供了更大的 range 容错。\*  $cs=1$  下的极端 PPL 失效来自不含 FP16 Residual Buffer 的 per-channel K + per-token V 格式: 当每步都以单 token 建立 per-channel K scale 时, 后续 token 极易超出 clamp 范围。KIVI 原论文为 streaming decode 设计了 Residual Buffer ( $R = 128$ ) 和 residual-group-scale 更新。因此表中 KIVI-style 的  $cs=1$  数字只刻画本文简化基线与 INT4-RoleAlign 在无 residual buffer 条件下的共同边界, 不代表 KIVI 原论文方法在 streaming 设置下的性能上界。该边界仅在 Qwen2.5-1.5B 单模型单种子条件下验证, 并受上述实现范围限定。

## A.7 K/V 精度消融与 MixedKV 跨模型补充数据

本节补充正文第 4.3.2 节中未展开的两类材料：Mistral-7B 的 LongBench 数据源说明，以及 MixedKV 的逐模型边界读数。

**Mistral-7B LongBench 数据说明。** Mistral-7B-Instruct-v0.3 在本组 K/V 消融与 MixedKV 补充评测中的 LongBench 结果均为 1.0，包括 K/V 消融的三种配置 (K-only, V-only, K4V8) 和 MixedKV 对比的三种方法 (FP16, KIVI-style, MixedKV)。该结果源于这组补充评测使用的 Mistral LongBench 合成数据源，评分不反映模型的实际长文本理解能力，因此在正文第 4.3.2 节的 K/V 跨模型 LongBench 对比中排除了 Mistral 的数据。需强调的是，这一数据源异常影响的仅是 LongBench 评测本身，而非量化方法。Mistral-7B 在 PPL、Needle 和 RULER 上的评测均正常有效。

**K/V 角色敏感性补充读数。** 在正文表 4-7 的 LongBench 宏平均 F1 ( $\times 100$ ) 上, K-only 与 V-only 两个诊断列分别为: Qwen2.5-1.5B 的  $4.57 \pm 0.01$  与  $4.54 \pm 0.04$ , Qwen2.5-7B 的  $4.10 \pm 0.11$  与  $3.85 \pm 0.02$ , LLaMA-3.1-8B 的  $7.31 \pm 0.43$  与  $6.21 \pm 0.66$ 。Qwen 两个模型上的 K4V8 读数分别为  $2.58 \pm 0.08$  与  $0.80 \pm 0.05$ ，支持正文关于 Key 侧低精度更容易触发退化的判断。LLaMA-3.1-8B 的 K4V8 LongBench 为  $8.92 \pm 0.79$ ，说明任务级指标还会受到模型结构和数据协议共同调节。因此本节只作为正文多指标诊断的补充，不把单一 LongBench 读数升级为独立结论。

**Qwen2.5-14B 单侧 PPL 补充。** 正文第 4.3.2 节引用的 14B 补充读数采用 32K prefix PPL 口径。FP16 为 4.685, full INT4 为 5.040, K16V4 为 4.709, K4V16 为 4.813。按  $(5.040 - x)/(5.040 - 4.685)$  计算, K16V4 恢复约 93%, K4V16 恢复约 64%。该补充读数用于校验 14B 上的方向一致性，按单模型内部对照解释。

**MixedKV 跨模型细节。** MixedKV 的逐模型表现进一步说明恢复强度具有架构依附性。LLaMA-3.1-8B ( $H_{kv} = 8$ ) 的 PPL 为 6.75 (FP16 为 6.92), Needle 为 100%, RULER 为 33.28% (FP16 为 31.48%), LongBench 为 7.42% (FP16 为 7.92%)。Qwen2.5-1.5B ( $H_{kv} = 2$ ) PPL 有轻度退化 (9.37 vs 8.93), Needle 保持 100%, RULER 为 24.87% (FP16 为 24.38%)。Qwen2.5-7B ( $H_{kv} = 4$ ) 是当前 MixedKV 诊断中唯一出现 Needle 退化的模型 (72.4% vs FP16 100%)。Mistral-7B 的 PPL 5.20 (FP16 为 5.19) 和 RULER 53.67% (FP16 为 53.98%) 均接近未量化基线，但其 LongBench 读数因上述数据源问题不参与跨模型任务比较。

## A.8 逐头温度校正诊断与 7B 校准目标溯源

本节只承担两个附录功能：记录逐头温度校正  $\tau^{-1}$  的补充诊断动机，并给出第 4.6.1 节正文读数的 7B KL/MSE 数据溯源。第三章与第四章的主线配置均不使用该组件，本节内容不构成默认组件。

### A.8.1 诊断性温度校正

量化误差会扰动 logits  $\mathbf{q}\hat{\mathbf{K}}^T/\sqrt{d_k}$  并平坦化 softmax 分布。逐头温度校正的诊断动机，是用层/头级缩放因子  $\tau_{l,h}^{-1}$  观察这种平坦化是否存在可补偿的架构依附性：

$$\mathbf{p}_{\text{corrected}} = \text{softmax}\left(\frac{\mathbf{q}\hat{\mathbf{K}}^T \cdot \tau_{l,h}^{-1}}{\sqrt{d_k}}\right) \quad (\text{A-3})$$

其中  $\tau^{-1} = 1$  退化为标准注意力。实现上，该缩放可等价写成 Query 预缩放：

$$\text{Attn}(\mathbf{Q} \cdot \tau^{-1}, \hat{\mathbf{K}}, \hat{\mathbf{V}}) = \text{softmax}\left(\frac{\mathbf{Q}\hat{\mathbf{K}}^T \cdot \tau^{-1}}{\sqrt{d_k}}\right) \hat{\mathbf{V}} \quad (\text{A-4})$$

这一等价性说明  $\tau^{-1}$  可作为诊断开关接入现有 attention kernel。但在非对称 RoleAlign 格式下，它没有形成稳定收益，因此只保留为补充诊断变体。

### A.8.2 7B KL vs MSE 校准目标趋同溯源

表 A-11 是第 4.6.1 节正文读数的溯源表。它只说明 Qwen2.5-7B-Instruct 上 KL 与 MSE 目标已经趋同，不承担新的主结果宣称。PPL 评测采用固定输入序列上的确定性 likelihood 累计，多 seed 只验证实现路径逐位一致性。规模依赖解释以正文讨论为准。

表 A-11 7B KL vs MSE 校准对比数据溯源

| 校准目标         | $k_{\text{pct}}$ | $v_{\text{pct}}$ | PPL    | Seeds |
|--------------|------------------|------------------|--------|-------|
| KL-selected  | 100.0            | 99.9             | 7.1121 | 3     |
| MSE-selected | 100.0            | 99.9             | 7.1121 | 3     |
| FP16 (基线)    | —                | —                | 6.7097 | 1     |

## A.9 Triton 融合核函数变体说明

本节仅对正文第 3.7 节提及的 Triton 融合解码路径做实现变体说明，其职责是给出不同变体的语义边界与复现角色，而不在附录中额外引入新的

速度结论。当前实现变体包括五类：INT8 融合解码主线实现、INT4 非对称融合核原型、带自动调优的 INT4 迭代变体、显式兼容 GQA 头映射的 INT4 变体，以及外部推理库适配层。这里按语义角色区分实现变体，不暴露具体文件名或实现代号。

这些变体在论文主线中的地位需要分层读取。正文默认的系统落地主线是 INT8 融合核。对 INT4-RoleAlign 而言，默认质量评测路径仍为参考解码实现，非对称 Triton 变体仅承担实现可行性验证与后端扩展接口的角色。因此，本附录补足“变体命名 / 实现角色 / 语义边界”的复核说明，不把这些实现变体提升为正文主结果的直接来源。

## A.10 Prompt-Adaptive Selector 探索性补充（future-work 起点）

本节汇总 prompt-adaptive selector 的探索性读数，作为第 5.4 节所列 per-prompt routing 方向的具体起点。所有读数均使用同一 5-task 任务集，每个任务 50 个样本。其中 8B 为正式探索矩阵，Qwen2.5-1.5B/7B 为同任务集下的补充读数。

### A.10.1 LLaMA-3.1-8B 五任务结果

8B 读数显示，prompt-adaptive selector 在 LCC 任务上取得局部正向信号：其分数为 11.36，高于 auto- $k$  的 10.96。这一任务域信号提示，代码补全类输入可能为更细粒度的 prompt 级路由提供有价值的切入点。

### A.10.2 Qwen2.5-1.5B/7B 补充结果

表 A-12 将三个模型上的 5-task mean 与局部信号并列展示。该汇总不重新定义第四章主结果，只为 future work 中的 selector 设计空间提供模型规模与任务类型上的参照。

这些读数共同指向一个正向的后续设计问题：prompt 级策略选择的收益可能集中在特定任务域与输入结构上，而三组 5-task mean 的最高项仍分别落在 fixed- $k$  或 auto- $k$  上。这说明当前 prompt-adaptive selector 更适合作为任务域线索的观察入口，后续仍有空间进一步吸收任务类型、模型规模与 prompt 表征。因此，本节将第 5.4 节的 future-work 方向落到具体可检验现象上，不新增正文主结果。

| Model        | fixed- $k$ mean | auto- $k$ mean | prompt-adaptive mean | 局部读数                                                                      |
|--------------|-----------------|----------------|----------------------|---------------------------------------------------------------------------|
| LLaMA-3.1-8B | <b>10.03</b>    | 9.85           | 9.73                 | LCC: prompt-adaptive<br>11.36 vs auto- $k$ 10.96                          |
| Qwen2.5-1.5B | 8.72            | <b>9.40</b>    | 9.04                 | auto- $k$ 与 prompt-adaptive<br>在 GovReport / DuReader<br>上读数一致            |
| Qwen2.5-7B   | 9.28            | <b>9.72</b>    | 9.41                 | auto- $k$ 与 prompt-adaptive<br>在 HotpotQA / GovReport /<br>DuReader 上读数一致 |

**表 A-12** Prompt-adaptive selector 的探索性 5-task 汇总。数值为各任务原生指标下的 mean。加粗表示该模型上的最高 mean。

## 致 谢

本论文的完成离不开诸多师长、同学和亲友的关心与帮助，在此谨致以最诚挚的谢意。

首先，衷心感谢我的指导教师在本科毕业设计全过程的悉心指导与严格要求。从选题确立、方案设计到论文撰写，老师始终给予了富有启发性的建议和耐心细致的修改意见，使我在科研方法与学术写作方面受益匪浅。

感谢实验室各位同学在日常学习与研究中的交流与协助。他们在实验方案讨论、代码调试和结果分析等方面提供的宝贵意见，对本文的完善起到了重要作用。

感谢华南理工大学提供的优良学术环境和计算资源支持，为本研究的顺利开展提供了坚实的基础保障。

最后，特别感谢我的家人多年来的无私支持与默默付出。他们的理解与鼓励是我坚持学业、完成论文的最大动力。